



Bachelorarbeit

Szenenverständnis und -manipulation in immersiven Umgebungen mittels Künstlicher Intelligenz

Sandro Jäger
Matrikelnummer: 3683886

Prüfer: Prof. Dr. Uwe Wienkop
Louis Burk

© Sandro Jäger, 2026

Diese Arbeit, einschließlich ihrer Teile, **ist urheberrechtlich geschützt**. Jede Verwertung außerhalb der engen Grenzen des Urheberrechtsgesetzes ohne Zustimmung des Urhebers ist untersagt und strafbar. Dies gilt insbesondere für Vervielfältigungen, Übersetzungen, Mikroverfilmung und die Speicherung und Verarbeitung in elektronischen Systemen.

Kurzdarstellung

Damit ein KI-Agent eine dreidimensionale Szene über natürliche Sprache verändern kann, muss ihm die Szene zuerst in einer Form vorliegen, die er verarbeiten kann. Grundsätzlich gibt es dafür zwei Wege, zum einen eine strukturelle Beschreibung als exakte Daten und zum anderen eine visuelle Beschreibung über ein gerendertes Bild. Für selbst gehostete Modelle geringer Größe fehlte bisher ein systematischer Vergleich dieser beiden Formen.

Die vorliegende Arbeit untersucht deshalb, welchen Einfluss die Repräsentationsform auf den Ausführungserfolg der Szenenmanipulation hat und ob sich eine Kombination beider Formen gezielt gestalten lässt. Dafür wurde ein prototypisches System entwickelt, das dieselbe Szene strukturell, visuell und hybrid bereitstellt und fünf daraus abgeleitete Varianten unter gleichen Bedingungen an dreizehn kontrolliert aufgebauten Szenarien vergleicht. Gemessen wurde am Desktop.

Im Vergleich zeigt sich, dass keine Form über alle Aufgaben hinweg überlegen ist und beide Formen jeweils einen Bereich abdecken, den die andere nicht erreicht. Eine naive Kombination vereint diese Stärken nicht von selbst. Während eine Priorisierung einer Schicht das Gewicht nur verschiebt, bringt eine klare Trennung der Zuständigkeiten beide Schichten auf dem untersuchten Szenarioset zusammen. Ein Demonstrator überträgt diese Variante in eine immersive Umgebung und zeigt, dass die gesamte Kette funktioniert.

Schlagwörter

Szenenrepräsentation, Immersive Umgebungen, Multimodale Agenten, Lokale Sprachmodelle, Vision-Language-Modelle

Danksagung

Mein Dank gilt Prof. Dr. Uwe Wienkop und Louis Burk für die Betreuung dieser Arbeit und für die hilfreichen Rückmeldungen im Verlauf. Dem Institut für angewandte Informatik danke ich für die Möglichkeit, diese Arbeit dort anzufertigen, sowie für die bereitgestellte Hardware, ohne die der lokale Betrieb der Modelle nicht möglich gewesen wäre. Ein besonderer Dank gilt schließlich meinem Bruder und meinen Eltern für ihre Unterstützung während des Studiums.

Inhaltsverzeichnis

Abkürzungsverzeichnis	vi
Abbildungsverzeichnis	vii
Tabellenverzeichnis	viii
Quellcodeverzeichnis	ix
1 Einleitung	1
1.1 Motivation und Problemstellung	1
1.2 Relevanz	1
1.3 Zielsetzung und Forschungsfragen	2
1.4 Methodisches Vorgehen	2
1.5 Aufbau der Arbeit	3
2 Grundlagen und Stand der Technik	4
2.1 Große Sprach- und Sprach-Bild-Modelle	4
2.2 Werkzeugnutzende Agenten	4
2.3 Szenenrepräsentation	5
2.4 Stand der Technik	5
2.4.1 Strukturelle Szenenmanipulation in immersiven Umgebungen	5
2.4.2 Hybrides Grounding	6
2.4.3 Modalitäts-Ablationen und Modalitäts-Dominanz	6
2.4.4 Ansätze mit lokalen, kleinen Modellen	6
2.5 Forschungslücke	6
3 Anforderungen	8
3.1 Herleitung der Anforderungen	8
3.2 Funktionale Anforderungen	8
3.3 Nicht-funktionale Anforderungen	9
3.4 Zielkonflikte zwischen den Anforderungen	9
3.5 Abgrenzung des Funktionsumfangs	10
4 Konzept	11
4.1 Lösungsansatz im Überblick	11
4.2 Repräsentationsformen	11
4.3 Entwurfsentscheidungen	12
4.4 Steuerung der Modalitätsfusion	12
4.5 Differenzierung nach Referenztyp	12
5 Implementierung	14
5.1 Systemüberblick	14

5.2	Szenenanbindung	14
5.3	Agent und Werkzeuge	17
5.4	Repräsentationsvarianten	18
5.5	VR-Demonstrator	20
6	Evaluation	24
6.1	Evaluationsdesign	24
6.2	Referenztyp-Taxonomie	25
6.3	Metriken	26
6.4	Ergebnisse zu RQ1	28
6.5	Ergebnisse zu RQ2	32
6.6	Validität und Grenzen	33
7	Zusammenfassung und Ausblick	36
7.1	Zusammenfassung	36
7.2	Beantwortung der Forschungsfragen	36
7.3	Beitrag	37
7.4	Ausblick	37
	Glossar	39
	Literaturverzeichnis	40
	Erklärung: Verwendung von KI-Werkzeugen	42
A	Begleitmaterial	43
A.1	Demonstrationsvideo	43

Abkürzungsverzeichnis

API Application Programming Interface, Programmierschnittstelle

ES Execution Success, Ausführungserfolg

FA funktionale Anforderung

GPU Graphics Processing Unit, Grafikprozessor

JSON JavaScript Object Notation

KI Künstliche Intelligenz

LLM Large Language Model, großes Sprachmodell

MCP Model Context Protocol

MR Mixed Reality, gemischte Realität

NFA nicht-funktionale Anforderung

RQ Research Question, Forschungsfrage

SoM Set-of-Mark

STT Speech-to-Text, Spracherkennung

VLM Vision-Language Model, Sprach-Bild-Modell

VPN Virtual Private Network, virtuelles privates Netz

VR Virtual Reality, virtuelle Realität

VRAM Video Random Access Memory, Grafikspeicher

Abbildungsverzeichnis

4.1	Konzeptionelle Kompetenzverteilung der beiden Repräsentationen. Der Überlappungsbereich steht für Referenzen, die beide Schichten auflösen können, die Außenbereiche für die exklusive Kompetenz jeweils einer Schicht. Aus diesen exklusiven Bereichen ergibt sich der Nutzen des hybriden Ansatzes.	13
5.1	Aufbau des Systems in drei Schichten und Nachrichtenfluss einer Manipulation. Durchgezogene Pfeile zeigen den Vorwärtsfluss, gestrichelte Pfeile den Rückkanal. Die Verbindung zwischen MCP-Server und Umgebung wird über WebSocket übertragen. . . .	15
5.2	Die visuelle Repräsentation am Beispiel einer einfachen Szene. Links die gerenderte Ansicht, wie sie die Kamera liefert. Rechts dieselbe Ansicht nach dem Set-of-Mark-Verfahren, bei dem jedes sichtbare Objekt eine nummerierte Marke trägt, über die das visuelle Modell es benennen kann. Die Marken sind reine Bezeichner, ihre Farbe ist bedeutungslos und wird bei der Auswertung ignoriert.	16
5.3	Ablauf einer einzelnen Manipulation. In der Agentenschleife fragt der Agent die Szene über ein Wahrnehmungswerkzeug ab, das Sprachmodell wählt die passende Operation, und das gewählte Werkzeug manipuliert das Objekt. Diese Schritte wiederholen sich, bis der Agent die Aufgabe abschließt. Danach liest die Auswertung den tatsächlichen Szenenzustand aus und bewertet daraus den Erfolg, unabhängig von der Rückmeldung des Agenten.	17
5.4	Ablauf eines gesprochenen Befehls im Demonstrator. Der lokale Rechner erkennt die Sprache und leitet den Text als Commander-Nachricht weiter, der entfernte Rechner arbeitet den Agentenlauf ab, und die Brille führt die Manipulation aus und zeigt den Verarbeitungsstatus an.	22
5.5	Frühe Ausbaustufe des Demonstrators mit Bedienmenü. Links der rote Würfel, rechts die blaue Kugel. Der gestreifte Würfel in der Mitte wird von der Menütafel größtenteils verdeckt, nur sein unterer Teil ist sichtbar. Das Standbild stammt aus der Aufzeichnung in Anhang A.1, in der unter anderem „move the striped cube up“, „put the blue sphere left of the red cube“ und „delete the striped cube“ über das Menü ausgelöst werden. .	23
6.1	Erfolg in der rein visuellen Kategorie D über die fünf Varianten. Die rein visuelle Variante bildet die Obergrenze, die rein strukturelle scheitert nahezu vollständig. Die naive Kombination erreicht etwa die Hälfte, die Priorisierung verbessert das, und die Kompetenztrennung erreicht nahezu das Niveau der reinen Bildvariante.	33

Tabellenverzeichnis

3.1	Funktionale Anforderungen.	9
3.2	Nicht-funktionale Anforderungen.	10
5.1	Die fünf Repräsentationsvarianten im Vergleich, mit den in den Ergebnistabellen verwendeten Kurzbezeichnungen.	20
6.1	Konfiguration der Messung, beschränkt auf die Angaben, die den Ausgang der Läufe beeinflussen. Zusammen mit dem verlinkten Code genügen sie, um die Messung zu wiederholen.	25
6.2	Verfügbarkeit der zur Auflösung nötigen Information je Referenztyp und Schicht, nach Konstruktion der Szenarien. Die Zeilen D und E bilden das exklusive Gegensatzpaar. .	26
6.3	Übersicht aller ausgewerteten Szenarien mit Befehl, Ausgangsszene und Soll-Ergebnis. Die Befehle geben den real gesendeten englischen Stimulus wieder.	27
6.4	Erfolg je Szenario und Variante: Mittelwert [Min–Max] über drei Durchläufe (je $N = 10$). .	28
6.5	Erfolg je Kategorie als Summe der zugehörigen Szenario-Mittelwerte über drei Durchläufe. Eine Spanne wird hier nicht ausgewiesen, da sich Minimum und Maximum einer Kategorie nicht aus den Szenario-Spannen zusammensetzen lassen. Kategorie E getrennt ausgewiesen.	29
6.6	Zentrale Zellen als Erfolge aus $n = 30$ Läufen mit Wilson-95 %-Konfidenzintervall der Erfolgsrate.	30
6.7	Exakte Tests nach Fisher für die zentralen Vergleiche, jeweils $n = 30$ je Gruppe. Das Niveau ist nicht für multiples Testen korrigiert.	31

Quellcodeverzeichnis

1	Beispiel des strukturellen Szenenzustands als JSON-Ausgabe der Umgebung.	16
2	Beispiel einer Werkzeugdefinition (gekürzt). Der Dokumentationskommentar dient dem Agenten als Beschreibung des Werkzeugs.	17
3	Prompt, mit dem das visuelle Modell die gerenderte und markierte Ansicht beschreibt. Er wird zusammen mit dem Bild übergeben und ist in allen Varianten mit visueller Schicht identisch.	18
4	Wahrnehmungswerkzeug der naiven hybriden Variante.	19
5	Wahrnehmungswerkzeug der priorisierenden Variante.	19
6	Wahrnehmungswerkzeug der kompetenzgetrennten Variante.	19

Kapitel 1

Einleitung

1.1 Motivation und Problemstellung

Ein Nutzer steht in einer virtuellen Szene und gibt einen einfachen Befehl: „Heb den gestreiften Würfel an.“ Für einen Menschen ist das ziemlich simpel. Ein KI-Agent muss dagegen zuerst wissen, wie die Szene aussieht, und diese Information muss ihm in einer Form vorliegen, die er auch verarbeiten kann.

Grundsätzlich gibt es dafür zwei Wege. Die Szene lässt sich strukturell beschreiben, also als exakte Daten über die Objekte mit ihren Typen, Positionen und Größen, oder visuell als gerendertes Bild, das ein visuelles Modell interpretiert. Beide Wege haben Stärken und blinde Flecken. Die strukturellen Daten kennen jede Koordinate, über das Aussehen eines Objekts sagen sie nichts, und beim Bild ist es andersherum.

Der gestreifte Würfel aus dem Beispiel zeigt den ersten blinden Fleck. Da das Streifenmuster in keinen strukturellen Daten steht, lässt sich der Würfel nur über das Bild bestimmen. Ebenso gibt es den umgekehrten Fall. Steht ein Objekt hinter einem anderen, taucht es im Bild überhaupt nicht auf, obwohl es in den strukturellen Daten vollständig verzeichnet ist. Ein Befehl, der sich auf ein solches Objekt bezieht, lässt sich nur über die Struktur auflösen.

Wer einen solchen Agenten entwickelt, muss deshalb früh entscheiden, in welcher Form er ihm die Szene bereitstellt und ob sich beide Wege sinnvoll kombinieren lassen. Besonders wichtig ist diese Entscheidung in immersiven Umgebungen, in denen Nutzer über natürliche Sprache mit einer Szene interagieren. Dort bieten sich lokal betreibbare Modelle an, vor allem wegen Datenschutz, Latenz und Offline-Fähigkeit, und für solche Modelle gibt es bisher keinen systematischen Vergleich der beiden Wege.

Mit *lokal* ist in dieser Arbeit durchgängig ein selbst gehosteter Betrieb auf eigener Hardware ohne Cloud-Dienst gemeint, bei dem keine Szenen- oder Sprachdaten das eigene Netz verlassen. Auf dem Endgerät selbst müssen die Modelle dafür nicht rechnen. Sowohl in der Messung als auch im Demonstrator laufen die Modelle auf einem Arbeitsplatzrechner, den die Brille im Demonstrator über eine Netzverbindung innerhalb des Institutsnetzes erreicht (Abschnitt 5.5).

1.2 Relevanz

Die Wahl der Repräsentationsform entscheidet mit darüber, welche sprachlichen Anweisungen ein Agent überhaupt zuverlässig umsetzen kann. Fehlt in einer Repräsentation eine ganze Klasse von Referenzen, scheitern die zugehörigen Befehle, egal wie gut der Agent ansonsten arbeitet.

Große, cloudbasierte Modelle können eine schwache Repräsentation teilweise durch ihre Größe ausgleichen. Bei kleinen, lokal betriebenen Modellen ist das kaum möglich, weshalb die Repräsentation

hier eine deutlich größere Rolle spielt. Die Entscheidung über die Repräsentationsform fällt früh im Entwurf, hat weitreichende Folgen und wird bislang ohne belastbare Grundlage getroffen.

Darüber hinaus betrifft die Frage auch ein allgemeineres Problem. Sobald ein Agent strukturierte und visuelle Information gemeinsam verarbeitet, stellt sich die Frage, ob sich beide Informationsarten ergänzen oder ob eine die andere verdrängt. Auch über den hier untersuchten Anwendungsfall hinaus ist diese Frage noch offen [1, 2].

1.3 Zielsetzung und Forschungsfragen

Diese Arbeit untersucht, welche Repräsentationsform einen lokal betriebenen Agenten bei der natürlichsprachlichen Szenenmanipulation am zuverlässigsten unterstützt. Dafür werden zwei Forschungsfragen gestellt.

Forschungsfrage 1 (RQ1). Welchen Einfluss hat die Form der Szenenrepräsentation, strukturell, visuell oder hybrid, auf den Ausführungserfolg der natürlichsprachlichen Szenenmanipulation durch einen lokal betriebenen Agenten, und zwar aufgeschlüsselt nach der Art der sprachlichen Referenz?

Forschungsfrage 2 (RQ2). Lässt sich das Zusammenspiel der strukturellen und der visuellen Schicht allein durch die Gestaltung der Instruktion so steuern, dass die hybride Repräsentation die Stärken beider Schichten vereint?

Die Stärken beider Schichten gelten für RQ2 dann als vereint, wenn eine gestaltete Instruktion dort deutlich besser abschneidet, wo die bloße Kombination beider Schichten scheitert, und in den übrigen Aufgaben nicht schlechter wird.

Gemessen wird in beiden Fällen ausschließlich der Ausführungserfolg. Er wird für jeden Lauf binär aus dem tatsächlichen Szenenzustand bestimmt. Ein Lauf ist nur erfolgreich, wenn das gemeinte Objekt betroffen ist und das geforderte Ergebnis eintritt, bei Positionsaufgaben innerhalb einer festen Toleranz. Ein kontinuierlicher Lagefehler gehört nicht zur Zielgröße und wird nicht berichtet. Die genaue Definition folgt in Abschnitt 6.3.

Untersucht wird ein lokales Modellpaar in kontrolliert aufgebauten Szenen, gemessen wird am Desktop. Zusätzlich entsteht ein Demonstrator, der die zuverlässigste Variante in die immersive Zielumgebung überträgt und die praktische Machbarkeit zeigen soll, ohne eine eigene Forschungsfrage zu beantworten.

1.4 Methodisches Vorgehen

Die Arbeit verfolgt einen empirischen Ansatz. Grundlage ist ein prototypisches System, das dieselbe Szene in allen drei Repräsentationsformen bereitstellt und über ein gemeinsames Interface manipulierbar macht. Mit diesem System werden die Formen unter gleichen Bedingungen an kontrolliert aufgebauten Szenarien miteinander verglichen. Ob eine Manipulation erfolgreich war, wird aus dem tatsächlichen Zustand der Szene bestimmt und nicht aus der Rückmeldung des Agenten, und jede Messung wird mehrfach wiederholt, um zufällige von belastbaren Unterschieden trennen zu können.

Daraus ergeben sich drei Beiträge, die in Abschnitt 7.3 noch einmal aufgegriffen und eingeordnet werden. Inhaltlich zeigt die Arbeit an einem kontrollierten Fall, dass sich strukturelle und visuelle Information nicht von selbst ergänzen und ihre Verbindung bewusst gestaltet werden muss. Methodisch wird eine nach Referenztypen aufgeschlüsselte Auswertung eingeführt, die Zuständigkeiten der Repräsentationen sichtbar macht, die bei einem pauschalen Vergleich verborgen blieben. Praktisch entsteht ein lauffähiger Demonstrator, der die gesamte Kette bis in die immersive Zielumgebung überträgt.

1.5 Aufbau der Arbeit

In Kapitel 2 werden die für die Arbeit notwendigen Grundlagen dargestellt, die Arbeit in den Stand der Technik eingeordnet und die Forschungslücke abgeleitet. Kapitel 3 beschreibt, welche Anforderungen ein System erfüllen muss, um die Forschungsfragen beantworten zu können. In Kapitel 4 wird daraus das Lösungskonzept entwickelt, vor allem die drei Repräsentationsformen und die Entscheidungen, die einen fairen Vergleich ermöglichen. Kapitel 5 beschreibt die technische Umsetzung, Kapitel 6 enthält den Vergleich und die Ergebnisse zu beiden Forschungsfragen. Kapitel 7 schließt mit einer Zusammenfassung und einem Ausblick.

Kapitel 2

Grundlagen und Stand der Technik

In diesem Kapitel werden zunächst die eingesetzten Modelle, das Prinzip werkzeugnutzender Agenten und die Formen der Szenenrepräsentation eingeführt. Im Anschluss wird die Arbeit in den Stand der Technik eingeordnet und die Forschungslücke abgeleitet.

2.1 Große Sprach- und Sprach-Bild-Modelle

In der Arbeit kommen zwei Arten vortrainierter Modelle mit jeweils etwa sieben Milliarden Parametern zum Einsatz, die beide unverändert genutzt und nicht weiterentwickelt werden.

Als großes Sprachmodell (Large Language Model, LLM) bezeichnet man ein neuronales Modell, das auf umfangreichen Textmengen trainiert wurde und zu einer Eingabe fortlaufend Text erzeugt. Durch ein zusätzliches Training auf Instruktionen lässt sich ein solches Modell anweisen, eine bestimmte Aufgabe zu bearbeiten, wobei die Antwort wieder als Text ausgegeben wird. In dieser Arbeit übernimmt das LLM die Rolle des Agenten, der einen Befehl interpretiert und die passende Operation auswählt.

Ein Sprach-Bild-Modell (Vision-Language Model, VLM) erweitert dieses Prinzip um eine visuelle Eingabe. Es verarbeitet ein Bild zusammen mit einem Text und erzeugt daraus eine textuelle Antwort, etwa eine Beschreibung des Bildinhalts oder die Antwort auf eine Frage zum Bild. In dieser Arbeit ist das VLM für die visuelle Wahrnehmung der Szene zuständig.

Für das Verständnis der weiteren Kapitel ist wichtig, wie die beiden Modelle im System zusammenarbeiten. Sie sind nicht zu einem multimodalen Modell verschmolzen, sondern hintereinandergeschaltet. Das Sprach-Bild-Modell erhält das gerenderte Bild und erzeugt daraus eine natürlichsprachliche Beschreibung. Erst diese Beschreibung gelangt in den Kontext des Sprachmodells, das anschließend den Befehl deutet und die Operation wählt. Das Modell, das die eigentliche Entscheidung trifft, bekommt also zu keinem Zeitpunkt ein Bild zu sehen.

Was in dieser Arbeit als „visuelle Repräsentation“ bezeichnet wird, ist deshalb streng genommen keine Bildeingabe, sondern die sprachliche Beschreibung eines Bildes. Wenn später von der Gewichtung der strukturellen gegenüber der visuellen Schicht die Rede ist, konkurrieren somit zwei Textquellen im Kontext eines reinen Sprachmodells. Die Datenstruktur ist exakt und unvollständig, die Beschreibung reichhaltig und unscharf. Das gilt für alle folgenden Kapitel, auch wenn es dort nicht jedes Mal wiederholt wird.

2.2 Werkzeugnutzende Agenten

Die Interaktion mit der Szene folgt dem Muster eines werkzeugnutzenden Agenten. Darunter versteht man ein Sprachmodell, das nicht nur Text erzeugt, sondern in einer Schleife aus Wahrnehmung und

Handlung Werkzeuge aufruft, um eine Aufgabe zu lösen.

Ein Werkzeug ist hierbei eine benannte Funktion mit einer kurzen Beschreibung ihrer Wirkung und ihrer Parameter. Anhand dieser Beschreibung entscheidet das Sprachmodell, welches Werkzeug es mit welchen Argumenten aufruft. Das Ergebnis des Aufrufs fließt danach in den Kontext zurück, und das Modell wählt den nächsten Schritt, bis es die Aufgabe als abgeschlossen meldet. Auf diese Weise verbindet der Agent die sprachliche Interpretation eines Befehls mit konkreten Aktionen in der Umgebung.

Umgesetzt wird der Agent mit dem Framework *smolagents*, das einen werkzeugaufrufenden Agenten bereitstellt [3]. Angebunden sind die Werkzeuge über das Model Context Protocol (MCP), einen offenen Standard, über den Sprachmodelle mit einer einheitlichen Schnittstelle auf externe Werkzeuge und Datenquellen zugreifen können [4]. Positiv ist, dass das Protokoll die Bereitstellung der Werkzeuge von ihrer Nutzung trennt. So können dieselben Werkzeuge unabhängig vom konkreten Modell aufgerufen werden. Wie das System dieses Muster umsetzt, beschreibt Kapitel 5.

2.3 Szenenrepräsentation für Sprachmodelle

Damit ein Sprachmodell eine Szene verändern kann, muss es sie zuerst erfassen. Da ein Sprachmodell auf Text arbeitet, muss die dreidimensionale Szene dafür in eine passende Form gebracht werden. Hierfür gibt es zwei grundlegende Ansätze.

Beim strukturellen Ansatz wird die Szene als Daten beschrieben. Die Objekte werden mit ihren Eigenschaften wie Typ, Position, Größe und Farbe in Textform aufgeführt, z. B. als JSON oder als Szenengraph. Diese Darstellung ist exakt, für ein Sprachmodell direkt lesbar und auf das beschränkt, was in den Daten kodiert ist.

Beim visuellen Ansatz wird die Szene als gerendertes Bild bereitgestellt, das ein Sprach-Bild-Modell interpretiert. Erfasst wird damit das Aussehen der Szene, so wie es sich einem Betrachter zeigt, ohne exakte Koordinaten. Damit das Modell ein im Bild erkanntes Objekt später gezielt ansprechen kann, muss es dieses benennen können. Verbreitet ist dafür das Set-of-Mark-Prompting, bei dem sichtbare Objekte im Bild mit nummerierten Marken versehen werden [5]. Das Modell kann sich dann auf eine Marke beziehen, deren Nummer sich eindeutig einem Objekt zuordnen lässt.

Unabhängig von der Repräsentationsform hängt die Schwierigkeit einer Aufgabe auch davon ab, wie der Befehl auf ein Objekt verweist. Bestehende Arbeiten unterscheiden Referenzen bereits nach verschiedenen Eigenschaften, z. B. danach, ob eine Referenz vom Blickwinkel des Betrachters abhängt oder ob das Zielobjekt in der Szene eindeutig ist [6, 7]. Auf diesen Einteilungen baut die feinere Aufschlüsselung nach Referenztypen auf, die in Abschnitt 6.2 eingeführt wird.

2.4 Stand der Technik

Die einzelnen Bausteine dieser Arbeit sind für sich bereits gut erforscht. Im Folgenden wird die Arbeit in vier angrenzende Forschungsfelder eingeordnet, wobei jeweils gezeigt wird, an welcher Stelle sich deren Fragestellung von der hier untersuchten unterscheidet.

2.4.1 Strukturelle Szenenmanipulation in immersiven Umgebungen

Mehrere Arbeiten beschäftigen sich mit der sprachgesteuerten Manipulation von Szenen in virtuellen und gemischten Realitäten. LLMR erzeugt und verändert interaktive Mixed-Reality-Szenen zur Laufzeit, indem es mehrere Sprachmodelle orchestriert und die Szene als strukturierten Graphen führt [8]. VR Mover manipuliert Objekte in der virtuellen Realität über natürliche Sprache und kodiert die Szene dafür als strukturierte Objektdaten [9]. Beide Arbeiten zeigen, dass sich Szenen in immersiven Umgebungen sprachlich verändern lassen, und setzen dafür auf die strukturelle Repräsentation und große, cloudbasierte Modelle, ohne verschiedene Repräsentationsformen zu vergleichen.

2.4.2 Hybrides Grounding

Strukturelle und visuelle Information gemeinsam zu nutzen, um ein Objekt in einer Szene zu bestimmen, ist kein neuer Gedanke. SeeGround stellt eine Szene als Kombination aus einer gerenderten Ansicht und einer räumlich angereicherten Textbeschreibung dar und verknüpft beide über visuelle Marken [10]. Konzeptionell kommt dieser Ansatz der vorliegenden Arbeit am nächsten. Ziel ist dort das Auffinden eines Objekts und nicht seine Manipulation, es wird ein großes Modell eingesetzt, und die Repräsentationsformen werden nicht als gleichwertige Bedingungen gegenübergestellt.

Einen ähnlichen Weg geht SceneGraphGrounder, das das Auffinden eines Objekts als strukturiertes Graph-Matching formuliert [11]. Hierbei leitet ein visuelles Modell über eine Marker-Strategie die Beziehungen zwischen Objekten aus zweidimensionalen Ansichten ab, die anschließend in einen persistenten Szenengraphen überführt werden. Laut den Autoren verbessert eine explizite strukturelle Repräsentation die Grounding-Genauigkeit. Auch hier geht es um das Auffinden von Objekten, und strukturelle und visuelle Information werden von Anfang an gemeinsam eingesetzt, statt sie als getrennte Repräsentationsformen zu prüfen.

2.4.3 Modalitäts-Ablationen und Modalitäts-Dominanz

Wie sich verschiedene Eingabemodalitäten auf die Leistung auswirken, wurde bereits in mehreren Ablationsstudien untersucht. Die Arbeit zum Embodied Agent Interface vergleicht unter anderem eine rein strukturelle, eine rein visuelle und eine kombinierte Eingabe und zeigt, dass strukturierter Input reine Bildeingabe deutlich übertrifft [12]. Untersucht wird dort die Handlungsplanung, nicht die Szenenmanipulation, und eine Unterscheidung nach Referenztypen gibt es nicht. Erwähnenswert ist außerdem SIRI-Bench, ein Benchmark für räumliches Schließen [13]. Dort werden in einer kontrollierten Ablation baugleiche Modelle einmal mit textueller und einmal mit visueller Eingabe derselben Aufgabe verglichen. Die textbasierten Varianten schneiden dabei deutlich besser ab als ihre videobasierten Gegenstücke, und die Untersuchung stellt fest, dass sich die Modelle übermäßig auf textuelle Hinweise stützen und räumliche Information nur schwer aus dem visuellen Eingang gewinnen. Dieser Befund aus dem Bereich abstrakter Reasoning-Aufgaben passt zu der auch in dieser Arbeit beobachteten Tendenz, dass strukturierte Information bei räumlichen Aufgaben gegenüber rein visueller im Vorteil ist.

Eng verwandt sind zwei Arbeiten zur Modalitäts-Dominanz. Sie zeigen, dass Sprach-Bild-Modelle textuelle Information gegenüber visueller übergewichten und bei widersprüchlichen Eingaben eher dem Text vertrauen [1, 2]. Eine der beiden Arbeiten bezieht dabei auch ein Modell derselben Familie ein, aus der das hier eingesetzte visuelle Modell stammt [2].

Beide Arbeiten betrachten Bild gegen Text *innerhalb* eines multimodalen Modells, während hier zwei Textquellen konkurrieren (Abschnitt 2.1). Als Analogie legen sie nahe, dass eine naive Kombination beider Quellen die präzisere überbewerten könnte.

2.4.4 Ansätze mit lokalen, kleinen Modellen

Kleine, lokal betreibbare Modelle werden vor allem dort eingesetzt, wo Datenschutz, Latenz oder Offline-Fähigkeit eine Rolle spielen. Ein Ansatz zur Handlungsplanung nutzt z. B. ein lokales Modell mit sieben Milliarden Parametern und zeigt, dass sich solche Aufgaben grundsätzlich auch mit kleinen Modellen bearbeiten lassen [14]. Ein weiterer Ansatz löst das Auffinden von Objekten in 3D-Szenen mit einem kleinen visuellen Modell [15]. Beide Arbeiten belegen die Machbarkeit unter begrenzten Ressourcen, mehrere Repräsentationsformen für die Szenenmanipulation vergleichen sie nicht.

2.5 Forschungslücke

Es gibt also Arbeiten zur sprachgesteuerten Manipulation von Szenen, zum hybriden Auffinden von Objekten, zur Wirkung einzelner Modalitäten und zum Einsatz kleiner, lokal betreibbarer Modelle.

Dem Autor dieser Arbeit ist jedoch keine Arbeit bekannt, die die natürlichsprachliche Manipulation einer Szene untersucht (und nicht nur ihr Verständnis, das Auffinden von Objekten oder ihre Erzeugung), dabei strukturelle, visuelle und hybride Repräsentation als gleichwertige Bedingungen vergleicht, die Aufgaben nach der Art der sprachlichen Referenz aufschlüsselt und dafür kleine, lokal betreibbare Modelle einsetzt.

Offen ist damit, wie eine Szene einem lokal betriebenen Agenten für die natürlichsprachliche Manipulation bereitgestellt werden sollte und welchen Einfluss die Repräsentationsform auf den Ausführungserfolg hat. Vor allem ist unklar, ob eine hybride Kombination die Stärken beider Repräsentationen vereint oder ob bei einem kleinen, lokalen Modell eine Quelle die andere verdrängt. An dieser Stelle setzen die beiden Forschungsfragen aus Abschnitt 1.3 an.

Kapitel 3

Anforderungen

Die Anforderungen an das System stammen nicht aus einem vorgegebenen Lastenheft, sondern ergeben sich aus dem wissenschaftlichen Ziel der Arbeit und den Bedingungen, unter denen sie entstanden ist. In diesem Kapitel werden zunächst die Quellen der Anforderungen benannt. Danach folgen die funktionalen und nicht-funktionalen Anforderungen sowie die Zielkonflikte zwischen ihnen, und zuletzt wird abgegrenzt, was bewusst nicht gefordert ist.

3.1 Herleitung der Anforderungen

Da die Arbeit kein Auftragsprojekt mit externem Auftraggeber ist, gibt es keinen klassischen Anforderungskatalog. Auch mit der Betreuung wurden keine formalen Anforderungen im Einzelnen festgelegt. Die Anforderungen werden deshalb aus vier Quellen abgeleitet.

Das System soll in erster Linie den Einfluss der Repräsentationsform auf die natürlichsprachliche Szenenmanipulation messbar machen. Aus den Forschungsfragen folgt deshalb, dass es mehrere Repräsentationsformen bereitstellen muss, die sich unter fairen Bedingungen vergleichen lassen. Die immersive Zielumgebung, in der Datenschutz, geringe Latenz und die Unabhängigkeit von einer Netzverbindung zählen, spricht für lokale Modelle und verlangt, dass sich die Verarbeitungskette bis in die Brille übertragen lässt.

Damit die Ergebnisse belastbar sind, müssen die Messungen reproduzierbar und die Erfolgsbewertung objektiv sein. Das betrifft vor allem die Kontrolle der Szenen und die Art, wie Erfolg gemessen wird. Als feste Randbedingung kam die Hardware hinzu. Für die Arbeit stand ein vom Institut bereitgestellter Arbeitsplatzrechner mit einer einzelnen Grafikkarte zur Verfügung, der die Größe der einsetzbaren Modelle begrenzt und damit mehrere der folgenden Anforderungen prägt.

3.2 Funktionale Anforderungen

Zunächst muss das System einen natürlichsprachlichen Befehl entgegennehmen und in eine Veränderung der Szene umsetzen. Die Operationen beschränken sich dabei auf das Erzeugen, Verschieben und Entfernen von Objekten. Diese Beschränkung ist bewusst gewählt, da sich bereits mit diesen wenigen Operationen alle für die Untersuchung nötigen Arten von Referenzen abdecken lassen.

Die zentrale Anforderung ist, dass das System die Szene in den drei zu vergleichenden Repräsentationsformen bereitstellt, also strukturell, visuell und hybrid. Damit der Vergleich dabei fair bleibt, müssen alle Varianten Objekte über dasselbe Interface ansprechen, d. h. über ein gemeinsames Kennungssystem. Warum das für die Fairness so wichtig ist, wird in Abschnitt 4.3 zusammen mit den übrigen Entwurfsentscheidungen begründet.

Der Erfolg einer Manipulation muss sich objektiv bestimmen lassen. Hierfür muss das System den tatsächlichen Zustand der Szene nach einer Manipulation auslesen können, sodass der Erfolg unabhängig von der Rückmeldung des Agenten ermittelt werden kann. Das ist notwendig, da ein kleines Modell durchaus einen Erfolg melden kann, den es gar nicht erreicht hat. Eine Messung anhand seiner eigenen Antwort wäre dann unzuverlässig. Damit Messungen unter identischen Bedingungen wiederholt werden können, muss sich jedes Testszenario reproduzierbar aufbauen und zurücksetzen lassen.

Tabelle 3.1 fasst die funktionalen Anforderungen zusammen. Die Spalte Herkunft gibt an, ob eine Anforderung aus den Forschungsfragen oder aus methodischen Gründen folgt.

Tabelle 3.1: Funktionale Anforderungen.

Nr.	Anforderung	Herkunft
FA1	Natürlichsprachliche Befehle in Szenenmanipulationen umsetzen, beschränkt auf Erzeugen, Verschieben und Entfernen von Objekten	RQ1, RQ2
FA2	Die Szene in struktureller, visueller und hybrider Repräsentation bereitstellen	RQ1
FA3	Objekte über ein gemeinsames Kennungssystem ansprechen, unabhängig von der Repräsentationsform	Validität
FA4	Den Erfolg einer Manipulation aus dem tatsächlichen Szenenzustand bestimmen	Validität
FA5	Testszenarien reproduzierbar aufbauen und zurücksetzen	Methodik

3.3 Nicht-funktionale Anforderungen

Die nicht-funktionalen Anforderungen betreffen keine einzelnen Funktionen, sondern Eigenschaften und Randbedingungen des Systems als Ganzes.

Aus der Zielumgebung folgt der lokale Betrieb der Modelle. Da dafür nur die vorgegebene Hardware zur Verfügung steht, muss das System mit dem Grafikspeicher einer einzelnen Karte auskommen, und zwar so, dass Sprachmodell und visuelles Modell gleichzeitig im Speicher liegen. Infrage kommen damit nur kleine Modelle.

Für die Aussagekraft der Untersuchung müssen sich unter identischer Konfiguration vergleichbare Ergebnisse einstellen, was kontrollierte und wiederholbar aufgebaute Szenen voraussetzt. Da die eigentliche Zielumgebung die immersive Anwendung ist, muss dieselbe Verarbeitungskette außerdem sowohl am Desktop für die Messung als auch in der Brille laufen, ohne dass ihr Kern verändert wird. Unterschiede lassen sich nur dann eindeutig auf die Repräsentation zurückführen, wenn sie die einzige Größe ist, die sich zwischen den Varianten ändert. Tabelle 3.2 fasst die nicht-funktionalen Anforderungen zusammen.

NFA5 ließ sich in der Umsetzung nur teilweise einhalten, was Abschnitt 6.6 erläutert.

3.4 Zielkonflikte zwischen den Anforderungen

Die genannten Anforderungen lassen sich nicht alle gleichzeitig maximieren. Am deutlichsten wird das bei Leistungsfähigkeit und Ressourcen. Große Modelle würden natürlichsprachliche Befehle natürlich zuverlässiger umsetzen als die hier vorgegebenen kleinen lokalen Modelle. Dieser Konflikt wird bewusst in Kauf genommen, da gerade das Verhalten unter dieser Beschränkung untersucht werden soll.

Ähnlich sieht es bei Fairness und Reproduzierbarkeit auf der einen und Praxisnähe auf der anderen Seite aus. Das gemeinsame Kennungssystem und die einfachen, kontrolliert aufgebauten Szenen sind für einen sauberen und wiederholbaren Vergleich notwendig. Gleichzeitig entfernen sie die Aufgabe

Tabelle 3.2: Nicht-funktionale Anforderungen.

Nr.	Anforderung	Herkunft
NFA1	Modelle lokal betreiben	Zielumgebung
NFA2	Mit der vorgegebenen Hardware, einer einzelnen Grafikkarte, und Modellen geringer Größe auskommen	Hardware
NFA3	Messungen unter identischer Konfiguration reproduzierbar halten und die Konfiguration vollständig dokumentieren	Methodik
NFA4	Dieselbe Verarbeitungskette am Desktop und in der immersiven Umgebung betreiben	Zielumgebung
NFA5	Die Repräsentationsform als einzige zwischen den Varianten variierende Größe sicherstellen	Validität

ein Stück weit von einer realistischen Anwendung mit komplexen, realen Szenen. In diesen Fällen hat die wissenschaftliche Kontrolle Vorrang, da das Ziel der Arbeit eine belastbare Erkenntnis und kein fertiges Produkt ist. Die Übertragung in die reale Umgebung bleibt dem Demonstrator vorbehalten.

3.5 Abgrenzung des Funktionsumfangs

Passend zur Abgrenzung in Abschnitt 1.3 sind folgende Punkte bewusst nicht gefordert:

- **Produktreife:** Es reicht, die untersuchten Repräsentationen und die Kette bis in die immersive Umgebung funktionsfähig umzusetzen, ohne Robustheit unter Dauerlast oder eine ausgereifte Bedienung.
- **Weitere Operationen:** Drehen oder Skalieren zur Laufzeit gehören nicht zur Untersuchung.
- **Beliebige oder mehrdeutige Formulierungen:** Die Befehle sind klar formuliert, Robustheit gegenüber umgangssprachlicher Vielfalt ist kein Ziel.
- **Eine Nutzerstudie,** da die Bewertung rein systembasiert aus dem Szenenzustand erfolgt.
- **Übertragbarkeit auf andere Modelle oder reale, komplexe Szenen,** da sich die Untersuchung auf ein Modellpaar und kontrolliert aufgebaute Szenen beschränkt.

Kapitel 4

Konzept

Auf Basis der Anforderungen wird in diesem Kapitel das Lösungskonzept entwickelt, von den drei Repräsentationsformen über die Entwurfsentscheidungen für einen fairen Vergleich bis zur Steuerung der hybriden Form und der Begründung, warum der Erfolg nach Referenztypen getrennt betrachtet wird. Die technische Umsetzung folgt in Kapitel 5.

4.1 Lösungsansatz im Überblick

Der Lösungsansatz basiert auf einem sprachgesteuerten Agenten. Dieser nimmt einen natürlichsprachlichen Befehl entgegen, verschafft sich über eine Repräsentation ein Bild der Szene und verändert die Szene anschließend über eine feste Menge von Operationen. Der entscheidende Freiheitsgrad im Entwurf ist dabei die Form, in der dem Agenten die Szene bereitgestellt wird, und diese Form ist gleichzeitig der Untersuchungsgegenstand der Arbeit.

Zunächst werden verschiedene Repräsentationsformen unter gleichen Bedingungen verglichen, um ihren Einfluss zu bestimmen (RQ1). Aufbauend auf diesen Ergebnissen wird untersucht, ob sich die Kombination der Repräsentationen gezielt verbessern lässt (RQ2). Die beste Variante wird anschließend als Demonstrator in die immersive Zielumgebung übertragen.

4.2 Repräsentationsformen

Der Entwurfsraum umfasst drei Formen, in denen die Szene dem Agenten bereitgestellt werden kann.

Die strukturelle Form beschreibt die Szene als exakte Daten. Sie kennt die Objekte mit ihren Kennungen, Typen, Positionen und Größen und ist damit stark bei allem, was sich aus diesen Daten ableiten lässt, z. B. bei geometrischen Beziehungen. Was nicht in den Daten kodiert ist, bleibt für sie unsichtbar.

Bei der visuellen Form wird die Szene über eine gerenderte Ansicht beschrieben, die ein visuelles Modell interpretiert. Sie erfasst das Aussehen der Szene und ist deshalb stark bei Eigenschaften, die nur im Bild erkennbar sind, exakte Koordinaten liefert sie nicht.

Die hybride Form stellt beide Schichten gleichzeitig bereit, wodurch sich exakte Geometrie und Aussehen gemeinsam berücksichtigen lassen. Ob das in der Praxis auch gelingt, zeigt erst der Vergleich mit den beiden Einzelformen, an denen sich wiederum ablesen lässt, wofür jede Schicht zuständig ist.

Eine bewusste Entscheidung betrifft den Inhalt der strukturellen Schicht. Sie enthält für jedes Objekt die Kennung, den Typ, die Position, die Farbe und die Größe sowie zusätzlich die Pose der Kamera. Vorberechnete räumliche Beziehungen fehlen, d. h. eine Relation wie „links von“ muss der Agent

selbst aus den Koordinaten ableiten. Würde man diese Beziehungen vorab berechnen, dann würde die Auswertung eher die Qualität dieser Vorverarbeitung messen als die Eignung der Repräsentation.

4.3 Entwurfsentscheidungen für einen fairen Vergleich

Damit der Vergleich tatsächlich die Repräsentation misst und nicht einen Nebeneffekt des Aufbaus, darf keine Variante aus Gründen bevorzugt oder benachteiligt werden, die nichts mit ihrer Repräsentation zu tun haben.

Alle Varianten sprechen Objekte deshalb über dieselben Kennungen an. Eine Kennung dient dabei nur der Adressierung und ist kein Teil des Szenenverständnisses. Die visuelle Variante wird über Marken, die in das gerenderte Bild eingezeichnet werden, an dieselben Kennungen gebunden, angelehnt an das Set-of-Mark-Prinzip [5]. Auf diese Weise kann auch die visuelle Variante ein erkanntes Objekt benennen, ohne dadurch einen strukturellen Vorteil zu erhalten.

Neben einer absoluten gibt es auch eine relative Bewegungsoperation, mit der sich Objekte ohne exakten Weltbezug verschieben lassen. Ohne sie wäre die visuelle Variante im Nachteil, weil sie keine exakten Koordinaten kennt, und dieser Nachteil käme vom Zuschnitt der Werkzeuge, nicht von der Repräsentation.

Die unterscheidende Eigenschaft der rein perzeptuellen Aufgaben, z. B. ein Oberflächenmuster, fehlt absichtlich in der strukturellen Schicht. Nur so entsteht ein Fall, in dem die strukturelle Schicht grundsätzlich blind ist und sich die exklusive Kompetenz der visuellen Schicht überhaupt zeigen kann.

4.4 Steuerung der Modalitätsfusion

Wie der Agent die beiden Schichten der hybriden Form gegeneinander gewichtet, legt die Form selbst nicht fest. Das Konzept geht davon aus, dass es nicht ausreicht, beide Schichten einfach verfügbar zu machen, damit ihre Stärken auch tatsächlich zusammenwirken. Diese Annahme stützt sich auf eine Analogie zu Beobachtungen aus der Literatur, wonach multimodale Modelle bei widersprüchlichen Eingaben eher der textuellen Information folgen [1, 2]. Übertragen auf diese Arbeit (Abschnitt 2.4) wäre zu erwarten, dass die exaktere Quelle die unschärfere überschreibt, auch wenn nur die unschärfere die Antwort enthält. Wie die beiden Schichten dem Agenten präsentiert werden, ist deshalb selbst Teil des Entwurfs.

Dafür sind im Konzept zwei Strategien vorgesehen. Bei der Priorisierung wird eine der beiden Schichten für einen bestimmten Zweck als maßgeblich erklärt und in den Vordergrund gestellt. Bei der Kompetenztrennung bekommen die beiden Schichten getrennte Zuständigkeiten, sodass jede Schicht nur für den Teil der Aufgabe genutzt wird, für den sie auch geeignet ist.

Beide Strategien wirken ausschließlich über die Gestaltung der Instruktion. Die Modelle werden nicht nachtrainiert, und ihre Gewichte bleiben unverändert. Das ist bewusst so gewählt, da sich nur der Kontext ändert und nicht das Modell, was auch zur Fragestellung passt, bei der es um die Repräsentation und nicht um eine Anpassung des Modells geht. Wie die beiden Strategien konkret formuliert sind, wird in Kapitel 5 beschrieben.

4.5 Differenzierung nach Referenztyp

Ob eine Repräsentation eine Aufgabe lösen kann, hängt stark davon ab, wie im Befehl auf ein Objekt verwiesen wird. Ein Verweis über die exakte Lage stellt andere Anforderungen als ein Verweis über eine sichtbare Eigenschaft. Daraus ergibt sich der zentrale Gedanke des Konzepts, nämlich dass die beiden Repräsentationen nicht nur unterschiedlich stark sind, sondern teilweise für Bereiche zuständig sind, die sich gegenseitig ausschließen.

Manche Referenzen lassen sich nur über die strukturelle Schicht auflösen. Ein Objekt, das im Bild verdeckt ist, bleibt z. B. in den strukturellen Daten trotzdem verzeichnet. Andere Referenzen lassen sich wiederum nur über die visuelle Schicht auflösen, etwa ein Oberflächenmuster, das in den strukturellen Daten nicht vorkommt und nur im Bild erkennbar ist. Zwischen diesen beiden Extremen liegt ein Bereich, in dem beide Schichten dieselbe Referenz auflösen können.

Abbildung 4.1 stellt diese Verteilung dar. Wegen der sich ausschließenden Bereiche ist eine Kombination beider Schichten überhaupt sinnvoll, und aus demselben Grund wird der Erfolg getrennt nach Referenztypen betrachtet und nicht als einzelner Gesamtwert. Die konkrete Einteilung folgt in Kapitel 6.




Abbildung 4.1: Konzeptionelle Kompetenzverteilung der beiden Repräsentationen. Der Überlappungsbereich steht für Referenzen, die beide Schichten auflösen können, die Außenbereiche für die exklusive Kompetenz jeweils einer Schicht. Aus diesen exklusiven Bereichen ergibt sich der Nutzen des hybriden Ansatzes.

Kapitel 5

Implementierung

In diesem Kapitel wird beschrieben, wie das Konzept in ein lauffähiges System umgesetzt wurde. Nach einem Überblick über den Aufbau geht es um die Anbindung der Szene, den Agenten mit seinen Werkzeugen, die fünf Repräsentationsvarianten und den VR-Demonstrator.

5.1 Systemüberblick

Das System verbindet einen natürlichsprachlichen Befehl mit einer sichtbaren Veränderung der 3D-Szene. Aufgebaut ist es aus drei lose gekoppelten Schichten, die über festgelegte Schnittstellen miteinander kommunizieren (Abbildung 5.1).

In der obersten Schicht deutet ein Agent den Befehl und wählt die passende Manipulation aus. Angetrieben wird der Agent von einem lokal betriebenen Sprachmodell, für die visuelle Wahrnehmung greift er zusätzlich auf ein lokales visuelles Modell zurück. Die mittlere Schicht bildet ein Server nach dem Model Context Protocol (MCP) [4]. Er stellt die Manipulationsoperationen als aufrufbare Werkzeuge bereit und übersetzt jeden Aufruf in eine Nachricht an die Umgebung. Übertragen werden diese Nachrichten über eine WebSocket-Verbindung, über die auch der Szenenzustand und gerenderte Bilder zurückkommen. Die unterste Schicht ist die Umgebung selbst, die die Szene hält, darstellt und die Manipulationen ausführt. In der Evaluation läuft sie am Desktop, im Demonstrator auf der Meta Quest. Weil die Schichten nur über diese Schnittstellen verbunden sind, lässt sich die Umgebung austauschen, ohne die anderen Schichten anzupassen. Für den Demonstrator war das äußerst hilfreich, da dieselbe Kette so für die Messung wie für die Brille funktioniert.

Ein Durchlauf beginnt mit dem Befehl an den Agenten. Dieser fordert über die Werkzeuge zunächst den strukturellen Zustand oder eine gerenderte Ansicht an, entscheidet dann, welche Operation nötig ist, und ruft das entsprechende Werkzeug auf. Der MCP-Server leitet den Aufruf über die WebSocket-Verbindung an die Umgebung weiter, wo die Manipulation ausgeführt wird. Anschließend liest die Auswertung den neuen Szenenzustand aus und bestimmt daraus den Erfolg.

5.2 Szenenanbindung

Die Umgebung stellt die Szene in zwei Sichten bereit, einer strukturellen und einer visuellen.

Für die strukturelle Sicht führt die Umgebung intern ein Verzeichnis aller manipulierbaren Objekte, das sie auf Anfrage als JSON ausgibt. Enthalten sind für jedes Objekt eine eindeutige Kennung, der Objekttyp, die Farbe, die Größe und die Position sowie zusätzlich die Pose der Kamera (Listing 1). Die Kamerapose wird mitgeliefert, damit sich auch Aufgaben lösen lassen, die sich auf den Betrachter beziehen. Nicht enthalten sind Eigenschaften des Aussehens, die über die Grundfarbe hinausgehen,




Abbildung 5.1: Aufbau des Systems in drei Schichten und Nachrichtenfluss einer Manipulation. Durchgezogene Pfeile zeigen den Vorwärtsfluss, gestrichelte Pfeile den Rückkanal. Die Verbindung zwischen MCP-Server und Umgebung wird über WebSocket übertragen.

z.B. eine Oberflächentextur. Aus diesem Grund lassen sich rein perzeptuelle Referenzen über den strukturellen Zustand nicht auflösen.

```

1  {
2    "type": "state",
3    "objects": [
4      {"id": "obj_1", "type": "cube", "color": "red", "x": 0.0, "y": 0.0, "z": 0.0,
5       ↪ "scale": 1.0},
6      {"id": "obj_2", "type": "sphere", "color": "blue", "x": 2.0, "y": 0.0, "z": 0.0,
7       ↪ "scale": 1.0}
8    ],
9    "camera": {
10     "position": [0.0, 1.6, -6.0],
11     "forward": [0.0, 0.0, 1.0],
12     "up": [0.0, 1.0, 0.0]
13   }
14 }
```

Listing 1: Beispiel des strukturellen Szenenzustands als JSON-Ausgabe der Umgebung.

Für die visuelle Sicht rendert die Umgebung die Szene aus der Kamera und übergibt das Bild. Damit das visuelle Modell ein erkanntes Objekt auch für einen Werkzeugaufruf benennen kann, bekommt jedes sichtbare Objekt nach dem Set-of-Mark-Prinzip [5] eine gelbe, nummerierte Marke oberhalb seiner Bildposition. Über eine Zuordnungstabelle werden die vom visuellen Modell genannten Nummern anschließend wieder in die Objektkennungen übersetzt. Beide Sichten verweisen dadurch auf dieselben Kennungen, sodass der Agent Objekte unabhängig von der Repräsentationsform einheitlich ansprechen kann, wie in Abschnitt 4.3 gefordert. In Abbildung 5.2 ist dieselbe Szene einmal ohne und einmal mit Marken zu sehen.




Abbildung 5.2: Die visuelle Repräsentation am Beispiel einer einfachen Szene. Links die gerenderte Ansicht, wie sie die Kamera liefert. Rechts dieselbe Ansicht nach dem Set-of-Mark-Verfahren, bei dem jedes sichtbare Objekt eine nummerierte Marke trägt, über die das visuelle Modell es benennen kann. Die Marken sind reine Bezeichner, ihre Farbe ist bedeutungslos und wird bei der Auswertung ignoriert.

Eine Marke bekommt ein Objekt nur, wenn es tatsächlich sichtbar ist. Dafür prüft ein einzelner Sichtstrahl von der Kamera zum Objektmittelpunkt, ob ein anderes Objekt die Sichtlinie unterbricht. Ist das der Fall, gilt das Objekt als verdeckt und bekommt keine Marke. Ein verdecktes Objekt fehlt dadurch komplett in der visuellen Sicht, während es im strukturellen Zustand weiterhin verzeichnet ist. Auf dieser Asymmetrie beruhen die Testfälle, in denen ein Befehl auf ein im Bild unsichtbares

Objekt verweist und die in Abschnitt 6.2 als eigener Referenztyp eingeführt werden. Der Test ist ziemlich geradlinig und kennt nur sichtbar oder verdeckt, eine Teilverdeckung erfasst er nicht. Für die hier verwendeten Szenen, in denen ein Objekt entweder frei steht oder vollständig hinter einer großen Wand liegt, reicht das aus.

5.3 Agent und Werkzeuge

Als Agent kommt ein werkzeugaufzufordernder Agent aus dem Framework smolagents zum Einsatz [3]. Angetrieben wird er von einem lokal betriebenen Sprachmodell, das über eine OpenAI-kompatible Schnittstelle angesprochen wird, die LM Studio auf dem Rechner bereitstellt. Der Agent arbeitet in einer Schleife, in der das Sprachmodell in jedem Schritt anhand des aktuellen Kontexts entscheidet, welches Werkzeug mit welchen Argumenten aufgerufen wird, bis es die Aufgabe als abgeschlossen meldet. Abbildung 5.3 zeigt diesen Ablauf von der Wahrnehmung bis zur Erfolgsbestimmung. Da die Modelle nicht nachtrainiert werden, lässt sich ihr Verhalten nur über die Gestaltung des Kontexts steuern, und an diesem Punkt setzt die zweite Forschungsfrage an.




Abbildung 5.3: Ablauf einer einzelnen Manipulation. In der Agentenschleife fragt der Agent die Szene über ein Wahrnehmungswerkzeug ab, das Sprachmodell wählt die passende Operation, und das gewählte Werkzeug manipuliert das Objekt. Diese Schritte wiederholen sich, bis der Agent die Aufgabe abschließt. Danach liest die Auswertung den tatsächlichen Szenenzustand aus und bewertet daraus den Erfolg, unabhängig von der Rückmeldung des Agenten.

Die eigentlichen Operationen stellt der MCP-Server als Werkzeuge bereit. Manipulierende Werkzeuge erzeugen, verschieben und entfernen Objekte oder setzen die Szene zurück, wahrnehmende liefern den strukturellen Zustand oder eine gerenderte Ansicht. Jedes Werkzeug hat eine kurze Beschreibung in Form eines Dokumentationskommentars, und diese Beschreibung ist das, was der Agent bei der Wahl des nächsten Aufrufs zu sehen bekommt. Listing 2 zeigt den Aufbau eines solchen Werkzeugs am Beispiel des Verschiebens.

```

1 @mcp.tool()
2 def move_object(object_id: str, x: float, y: float, z: float) -> str:
3     """Move an existing object (id from get_scene_state) to a new position."""
4     global _last_op
5     key = ("move", object_id, x, y, z)
6     if key == _last_op:
7         return f"Skipped: identical move already applied to {object_id}."
8     _last_op = key
9     send_to_unity({"action": "move", "id": object_id, "x": x, "y": y, "z": z})
10    return f"Done: {object_id} moved to ({x}, {y}, {z})."
  
```

Listing 2: Beispiel einer Werkzeugdefinition (gekürzt). Der Dokumentationskommentar dient dem Agenten als Beschreibung des Werkzeugs.

Schutz gegen doppelte Ausführung

Da der Erfolg einer Manipulation aus dem tatsächlichen Folgezustand der Szene bestimmt wird (Abschnitt 6.3), spielt ein Detail der Werkzeuge eine wichtige Rolle. Während der Entwicklung fiel auf, dass das lokale Modell gelegentlich einen Manipulations- und einen Abschlussaufruf so bündelte, dass dieselbe Manipulation zweimal ausgeführt wurde. In den ersten Messungen sah das zunächst wie ein deutlicher Nachteil der hybriden Varianten aus. Um dieses Verhalten des Frameworks abzufangen, vergleicht seitdem jedes manipulierende Werkzeug den aktuellen Aufruf mit dem direkt vorangegangenen und überspringt eine identische Wiederholung. Umgesetzt ist das über die Abfrage von `_last_op` in Listing 2.

Der Schutz ist recht grob, weil er nicht unterscheiden kann, ob eine identische Wiederholung ein Fehler des Frameworks ist oder vom Befehl tatsächlich verlangt wird. Ein Befehl, der dieselbe Operation absichtlich zweimal fordert, würde dadurch ebenfalls blockiert. In den ausgewerteten Szenarien kommt dieser Fall nicht vor, da kein Soll-Ergebnis zwei identische Aufrufe erfordert.

5.4 Repräsentationsvarianten

Alle fünf Varianten nutzen denselben Agenten und dieselbe Grundinstruktion. Diese verlangt, vor jeder Manipulation zuerst die Szene wahrzunehmen, keine Kennung zu erfinden, die Aufgabe mit einem einzigen Manipulationsaufruf zu lösen und danach abzuschließen. Dass die letzte Vorgabe nicht zu allen Szenarien passt, zeigte sich erst in der Auswertung (Abschnitt 6.4, Kategorie E).

Unterschiede zwischen den Varianten gibt es nur beim Wahrnehmungswerkzeug, das dem Agenten zur Verfügung steht. Gesteuert wird die Gewichtung der beiden Schichten über den Dokumentationskommentar des Werkzeugs, den der Agent bei der Wahl des nächsten Aufrufs liest, und über den zurückgegebenen Text, der die beiden Schichten benennt und ordnet.

Strukturelle und visuelle Variante

Die strukturelle Variante hat ausschließlich Zugriff auf den strukturellen Zustand. Sie sieht die Szene also als JSON mit Kennungen, Typen, Farben, Größen und Positionen und bekommt kein Bild. Die visuelle Variante erhält nur eine Beschreibung der gerenderten und markierten Ansicht. Sie kennt die Objekte deshalb nur über ihre Marken und sichtbaren Eigenschaften und hat keine exakten Koordinaten.

Welche Eigenschaften in der Beschreibung stehen, hängt vollständig vom Prompt ab, mit dem das visuelle Modell das Bild beschreibt (Listing 3). Dieser Prompt ist in allen Varianten mit visueller Schicht gleich und wird im Vergleich nicht verändert. Dass er das Modell ausdrücklich anweist, die Farbe der Marke zu ignorieren, geht auf einen Störfaktor zurück, der in Abschnitt 6.6 beschrieben ist.

```

1 "Each object has a yellow numbered badge floating above it. Badges are
2 labels ONLY - ignore badge color; report the actual object color. For
3 each numbered object give number, shape (cube/sphere/cylinder), color,
4 qualitative position, and a surface texture descriptor (e.g. 'striped'
5 or 'solid'). Answer ONLY as a JSON list with keys: number, shape,
6 color, position, texture."
```

Listing 3: Prompt, mit dem das visuelle Modell die gerenderte und markierte Ansicht beschreibt. Er wird zusammen mit dem Bild übergeben und ist in allen Varianten mit visueller Schicht identisch.

Der Prompt verlangt für jedes Objekt fünf Angaben (Nummer, Form, Farbe, qualitative Lage und einen Texturdeskriptor), nach der Größe fragt er nicht. Was die visuelle Schicht über die Größe eines Objekts berichtet, steht damit höchstens zufällig in der Lagebeschreibung. Als Beispiel für einen

Texturdeskriptor nennt er „striped“, ein Wort, das auch in den Befehlen der perzeptuellen Szenarien vorkommt. Beides wirkt sich auf die Ergebnisse aus und wird in Abschnitt 6.6 diskutiert.

Hybride Varianten

Die naive hybride Variante stellt beide Schichten einfach nebeneinander. Ausgegeben wird zuerst der strukturelle Zustand und danach die visuelle Beschreibung, wobei nur grob angedeutet wird, wofür welche Schicht gedacht ist. Eine verbindliche Regel zur Zuständigkeit gibt es nicht (Listing 4).

```

1 @tool
2 def get_scene_hybrid() -> str:
3     """Perceive the scene using BOTH exact structural data (ids, positions,
4     colors, sizes, camera) and a visual description. Use exact data for
5     geometry, visual data for semantics."""

```

Listing 4: Wahrnehmungswerkzeug der naiven hybriden Variante.

Die priorisierende Variante, im Code als **guided** bezeichnet, setzt die erste Strategie aus Abschnitt 4.4 um. Hier wird die visuelle Beschreibung vorangestellt und für das Aussehen als maßgeblich erklärt. Die strukturelle Schicht wird ausdrücklich als rein geometrisch und ohne Information über das Aussehen gekennzeichnet (Listing 5). Das Gewicht verschiebt sich dadurch zugunsten der visuellen Beschreibung.

```

1 @tool
2 def get_scene_hybrid_guided() -> str:
3     """Perceive the scene using a visual description AND exact structural
4     data. The visual description is authoritative for how objects LOOK
5     (texture, pattern, whether something stands out). The structural data
6     contains ONLY geometry (positions, sizes, base colors) and does NOT
7     encode any visual surface property."""

```

Listing 5: Wahrnehmungswerkzeug der priorisierenden Variante.

Die kompetenzgetrennte Variante, im Code **surgical**, setzt die zweite Strategie um. Wie bei der naiven Variante wird zuerst der strukturelle Zustand ausgegeben, und die beiden Schichten bekommen klar getrennte Aufgaben (Listing 6). Die visuelle Beschreibung wird nur dafür genutzt, das gemeinte Objekt zu bestimmen, wenn die Referenz vom Aussehen abhängt. Alles Numerische, also Koordinaten, Größen, Abstände und die Kamerageometrie, kommt aus der strukturellen Schicht. Der Unterschied zur priorisierenden Variante liegt damit vor allem in dieser klaren, sich gegenseitig ausschließenden Aufteilung und erst in zweiter Linie in der Reihenfolge.

```

1 @tool
2 def get_scene_hybrid_surgical() -> str:
3     """Perceive the scene using a visual description AND exact structural
4     data, with a clear division of labor. Use the VISUAL description ONLY
5     to identify WHICH object is meant when the reference depends on
6     appearance (texture, pattern, 'striped', 'stands out', 'most salient').
7     Use the STRUCTURAL data for EVERYTHING numerical: all coordinates,
8     positions, sizes, distances, camera geometry, and to compute where to
9     move things. Every object id appears in both - match them by id.
10    Never take coordinates from the visual description; never resolve an
11    appearance-based reference from the structural data alone."""

```

Listing 6: Wahrnehmungswerkzeug der kompetenzgetrennten Variante.

Die kompetenzgetrennte Variante wurde nicht vorab entworfen, sondern Schritt für Schritt entwickelt. Zunächst gab es als hybride Varianten nur die naive und die priorisierende. Bei der naiven Kombination

ging in einem Teil der perzeptuellen Szenarien der visuelle Zugriff verloren, mit der Priorisierung ließ sich das beheben, dafür litten metrische Aufgaben. Deshalb wurde ein dritter Ansatz verfolgt, der den beiden Schichten getrennte Rollen gibt, anstatt eine von ihnen zu bevorzugen. Die Formulierung der Instruktion wurde dabei in mehreren Schritten angepasst, wobei die Ergebnisse der vorherigen Läufe jeweils bekannt waren und auf demselben Szenarioset gemessen wurde, auf dem die Variante später auch berichtet wird. Das ist in Listing 6 auch erkennbar, da „striped“ und „most salient“ wörtlich in den Befehlen der Szenarien D1 und D2 vorkommen.

Tabelle 5.1 fasst die fünf Varianten zusammen. Neben den deutschen Bezeichnungen, die im Fließtext verwendet werden, enthält sie auch die Kurzbezeichnungen aus dem Code, die in den Ergebnistabellen als Spaltenköpfe stehen. Wie die Spalte „Im Kontext“ zeigt, unterscheidet sich die priorisierende Variante von den beiden anderen hybriden Varianten auch in der Reihenfolge der Schichten.

Tabelle 5.1: Die fünf Repräsentationsvarianten im Vergleich, mit den in den Ergebnistabellen verwendeten Kurzbezeichnungen.

Variante	Kurzform	Im Kontext	Regel zur Gewichtung
strukturell	<code>json</code>	nur struktureller Zustand	entfällt, keine visuelle Schicht
visuell	<code>vlm</code>	nur visuelle Beschreibung	entfällt, keine strukturelle Schicht
naiv hybrid	<code>hybrid</code>	Struktur, dann Beschreibung	grobe Zuordnung ohne verbindliche Regel
priorisierend	<code>guided</code>	Beschreibung, dann Struktur	Beschreibung maßgeblich fürs Aussehen, Struktur nur Geometrie
kompetenzgetrennt	<code>surgical</code>	Struktur, dann Beschreibung	Beschreibung nur zur Objektwahl, Struktur für alles Numerische

5.5 VR-Demonstrator

Die Evaluation wurde am Desktop unter kontrollierten Bedingungen durchgeführt. Um zu zeigen, dass der Ansatz auch in der eigentlichen Zielumgebung funktioniert, überträgt ein Demonstrator die gesamte Kette in die immersive Umgebung. Eingesetzt wird dabei die kompetenzgetrennte Variante, die sich in Kapitel 6 auf dem untersuchten Szenarioset als die zuverlässigste herausstellt. Die Modelle laufen dabei wie in der Messung auf dem Arbeitsplatzrechner, den die Brille über die weiter unten beschriebene Netzwerkkette erreicht.

Sprachsteuerung

Der Nutzer spricht einen Befehl, der anschließend von einem selbst gehosteten Whisper-Modell in der Größe `small` in Text umgewandelt wird. Das Modell läuft auf dem lokalen Rechner auf der CPU, nimmt mit 16 kHz auf und ist auf englische Eingaben festgelegt, passend zur Sprache der Befehle. Der erkannte Text wird in dieselbe Kommando-Warteschlange gegeben, die auch in der Evaluation den Agenten antreibt. Ein gesprochener Befehl durchläuft somit dieselbe Kette wie ein Befehl im Experiment, nur mit vorgeschalteter Spracherkennung (Abbildung 5.4).

Über dieselbe Verbindung kommunizieren dabei zwei Arten von Clients. Die Brille übernimmt die Rolle des Renderers, der die Manipulationen ausführt und die Szene darstellt. Die Sprachsteuerung ist der Commander, der ausschließlich Befehle einspeist. Unterschieden werden beide Rollen über eine Anmeldenachricht, damit die Befehlsquelle die Verbindung der Brille nicht verdrängt. Sobald ein

Befehl in der Warteschlange liegt, arbeitet ein Worker den Agentenlauf ab und meldet der Brille den Beginn und das Ende der Verarbeitung. Die Brille zeigt diesen Status an, sodass der Nutzer erkennen kann, dass sein Befehl gerade bearbeitet wird.

Wahrnehmung und Netzwerk

Für die visuelle Wahrnehmung benötigt das visuelle Modell ein flaches, gerendertes Bild der Szene. Am Desktop ist das kein Problem, in der Brille rendert die Hauptkamera jedoch stereoskopisch für beide Augen und liefert kein brauchbares Einzelbild. Gelöst wurde das über eine eigene Aufnahmekamera, die der Kopfpose folgt und nur einfach statt stereoskopisch rendert.

Aus Ressourcengründen laufen die Modelle auf dem Arbeitsplatzrechner im Institutsnetz, den die Brille nicht direkt erreichen kann. Die Brille verbindet sich deshalb mit einem Vermittler auf einem Rechner im selben Funknetz, der die Nachrichten über ein virtuelles privates Netz an den Arbeitsplatzrechner weiterleitet. Ein mobiler Zugangspunkt umgeht hierbei die Isolation gemeinsam genutzter Netze, die eine direkte Verbindung sonst verhindert. Diese Kette dient nur der Demonstration und ist nicht Gegenstand der Untersuchung.

Ausbaustufen und Aufzeichnung

Zu Beginn entstand eine Fassung mit einem Bedienmenü in der Szene, über das sich vordefinierte Befehle auslösen lassen und das bereits dieselbe Kommando-Warteschlange nutzt. Die Sprachsteuerung kam erst später hinzu. Von dieser frühen Menüfassung gibt es eine Videoaufzeichnung aus Sicht der Brille, die als Begleitmaterial beiliegt (Anhang A.1) und aus der auch das Standbild in Abbildung 5.5 stammt. Zu sehen sind ein roter Würfel links, ein gestreifter Würfel in der Mitte und eine blaue Kugel rechts, wobei der gestreifte Würfel im Standbild größtenteils von der Menütafel verdeckt wird. Im Video werden die vordefinierten Befehle nacheinander ausgelöst, und die Manipulationen sind jeweils sofort in der Szene zu sehen. Zuerst hebt sich der gestreifte Würfel an, danach wandert die blaue Kugel nach links neben den roten Würfel, und zuletzt wird der gestreifte Würfel entfernt.

Von der lauffähigen Spracheingabe gibt es keine Aufzeichnung.




Abbildung 5.4: Ablauf eines gesprochenen Befehls im Demonstrator. Der lokale Rechner erkennt die Sprache und leitet den Text als Commander-Nachricht weiter, der entfernte Rechner arbeitet den Agentenlauf ab, und die Brille führt die Manipulation aus und zeigt den Verarbeitungsstatus an.




Abbildung 5.5: Frühe Ausbaustufe des Demonstrators mit Bedienmenü. Links der rote Würfel, rechts die blaue Kugel. Der gestreifte Würfel in der Mitte wird von der Menütabelle größtenteils verdeckt, nur sein unterer Teil ist sichtbar. Das Standbild stammt aus der Aufzeichnung in Anhang A.1, in der unter anderem „move the striped cube up“, „put the blue sphere left of the red cube“ und „delete the striped cube“ über das Menü ausgelöst werden.

Kapitel 6

Evaluation

In diesem Kapitel werden die Repräsentationsformen anhand einer nach Referenztypen aufgeschlüsselten Taxonomie verglichen, um zu bestimmen, welche Form welche Art von Referenz unterstützt (RQ1). Im Anschluss wird geprüft, ob sich die hybride Repräsentation allein über ihre Instruktion so gestalten lässt, dass sie die Stärken beider Schichten vereint (RQ2), bevor es um Validität und Grenzen der Ergebnisse geht.

6.1 Evaluationsdesign

Verglichen werden die fünf Varianten aus Abschnitt 5.4. Alle Varianten nutzen dieselben Szenen, Befehle und Manipulationswerkzeuge und unterscheiden sich nur darin, in welcher Form dem Agenten die Szene bereitgestellt wird. Ein ungleicher Werkzeugzugriff scheidet als Ursache für Unterschiede aus, da alle Varianten Objekte über dasselbe Kennungssystem ansprechen (Abschnitt 4.3). Ob eine Manipulation erfolgreich war, entscheidet der Folgezustand der Szene, also ihr tatsächlicher Zustand nach der Ausführung, den die Auswertung mit der Soll-Vorgabe des Szenarios vergleicht (Abschnitt 6.3).

Jede Kombination aus Szenario und Variante wird zehnmal ausgeführt, und der gesamte Durchlauf wird dreimal wiederholt, sodass jede Zelle auf 30 Läufen beruht. Berichtet wird der Mittelwert über die drei Durchläufe mit der Spanne aus Minimum und Maximum, an der sich ablesen lässt, wie stark eine Zelle zwischen den Durchläufen schwankt. Für die zentralen Vergleiche werden die 30 Läufe einer Zelle zusätzlich statistisch ausgewertet.

Ausgewertet werden dreizehn Szenarien in fünf Kategorien. Die Kategorien A, B und C enthalten jeweils drei Szenarien, D und E je zwei. Die Szenen bestehen aus einfachen geometrischen Grundkörpern und sind so aufgebaut, dass jedes Szenario eine bestimmte Kompetenz der Repräsentation isoliert prüft. Gemessen wird am Desktop, da sich die Szenen dort exakt kontrollieren und beliebig oft identisch wiederholen lassen. Als Sprachmodell kommt Qwen2.5-7B zum Einsatz, als visuelles Modell Qwen2.5-VL-7B, die gemeinsam auf einer NVIDIA RTX A5000 mit 24 Gigabyte Grafikspeicher laufen. Tabelle 6.1 enthält die vollständige Konfiguration, die nach NFA3 für eine Wiederholung der Messung nötig ist.

Beide Modelle liegen in derselben Quantisierungsstufe vor. Das ist für den Vergleich wichtig, da eine unterschiedlich starke Quantisierung die beiden Schichten ungleich beeinträchtigt und damit eine weitere Störgröße eingeführt hätte. Mit 4,68 GB und 6,04 GB belegen die Gewichte zusammen rund 10,7 GB. Auf der Karte bleibt dadurch genug Platz für den Schlüssel-Wert-Zwischenspeicher beider Modelle, was den gleichzeitigen Betrieb nach NFA2 erst möglich macht.

Die Kontextlänge von 4096 Token ist eher knapp und trifft die Varianten unterschiedlich stark. Neben Grundinstruktion, Werkzeugbeschreibungen und dem bisherigen Verlauf der Agentenschleife enthält der Kontext der strukturellen Variante nur den JSON-Zustand, der der visuellen Variante nur die

Tabelle 6.1: Konfiguration der Messung, beschränkt auf die Angaben, die den Ausgang der Läufe beeinflussen. Zusammen mit dem verlinkten Code genügen sie, um die Messung zu wiederholen.

Größe	Wert
Sprachmodell	<code>qwen2.5-7b-instruct</code> , GGUF Q4_K_M, 4096 Token Kontext
Visuelles Modell	<code>qwen/qwen2.5-vl-7b</code> , GGUF Q4_K_M, 4096 Token Kontext
Hardware, Laufzeit	NVIDIA RTX A5000 mit 24 GB, LM Studio (CLI-Commit <code>efce996</code>), beide Modelle gleichzeitig geladen
Agent	<code>smolagents 1.26.0 (ToolCallingAgent)</code> unter Python 3.13, <code>max_steps = 6</code>
Dekodierung	Sprachmodell: Temperatur 0,8 (Voreinstellung der Laufzeitumgebung, im Client nicht überschrieben). Visuelles Modell: Temperatur 0,1 (im Client ausdrücklich gesetzt). Kein fester Seed
Messumfang	13 Szenarien $\times$ 5 Varianten, je 10 Läufe in 3 Durchläufen, also 30 Läufe pro Zelle
Code und Rohdaten	https://git.informatik.fh-nuernberg.de/jobboerse/forschung/bachelorarbeiten/bachelorarbeit-sandro-jaeger

Beschreibung und der der hybriden Varianten beides, wodurch ihnen für mehrere aufeinanderfolgende Schritte weniger Platz bleibt. Ob sich das in den Messungen tatsächlich ausgewirkt hat, z. B. durch abgeschnittenen Kontext in längeren Läufen, wurde nicht überwacht und lässt sich im Nachhinein nicht mehr feststellen.

Auch bei der Dekodierung unterscheiden sich die beiden Modelle. Das Sprachmodell, das die Entscheidung trifft, lief mit einer Temperatur von 0,8. Diese Einstellung lässt dem Modell spürbar Spielraum bei der Antwort, sodass die zehn Läufe einer Zelle weitgehend unabhängige Ziehungen sind und nicht einfache Wiederholungen derselben Antwort. Liegt eine Zelle trotzdem bei 0 von 30 oder bei 30 von 30, dann nicht, weil das Modell ohnehin immer gleich antwortet, sondern weil der Effekt stärker wirkt als das Rauschen der Dekodierung.

Beim visuellen Modell lag die Temperatur bei 0,1, sodass die Beschreibung einer Szene über die Läufe hinweg weitgehend gleich ausfällt. Das war so gewollt, weil die Wahrnehmung hier nur als Eingabe dient und eine stark schwankende Beschreibung eine zusätzliche Störgröße zwischen Repräsentationsform und Ergebnis gebracht hätte. Die Streuung innerhalb einer Zelle geht so fast vollständig auf das Sprachmodell zurück. Dass alle Läufe einer Zelle dieselbe, kaum veränderte Szenenbeschreibung nutzen, betrifft die Eingabe und nicht die gemessene Entscheidung.

6.2 Referenztyp-Taxonomie

Welche Repräsentation für eine Aufgabe geeignet ist, hängt davon ab, worauf sich der Befehl bezieht. Ein Verweis auf die Farbe eines Objekts stellt andere Anforderungen als ein Verweis auf seine Lage oder auf ein Objekt, das im Bild gar nicht zu sehen ist. Deshalb wird die sprachliche Referenz in fünf Typen unterteilt, und für jeden Typ wird einzeln geprüft, welche Repräsentation ihn auflösen kann. Tabelle 6.2 zeigt, in welcher Schicht die dafür nötige Information jeweils vorhanden ist.

Kategorie A bildet die Kontrollbedingung. Hier nennt der Befehl das Zielobjekt direkt über seine Kennung, sodass die Aufgabe unabhängig von der Repräsentationsform lösbar ist. Die Kategorie dient damit zur Prüfung des Messaufbaus und nicht zum inhaltlichen Vergleich. In Kategorie B wird ein Objekt über ein Attribut wie die Farbe oder die Größe angesprochen, in Kategorie C über eine räumliche Relation zu einem anderen Objekt, z. B. „links von“. In beiden Fällen lässt sich das gemeinte Objekt aus Eigenschaften oder Koordinaten bestimmen, die in den strukturellen Daten stehen.

Die Kategorien D und E bilden das eigentliche Gegensatzpaar. In Kategorie D bezieht sich der Befehl auf eine rein perzeptuelle Eigenschaft, z. B. auf ein Oberflächenmuster, das in den strukturellen Daten nicht vorkommt. Ein solches Objekt lässt sich nur über das Bild bestimmen. In Kategorie E ist das Objekt im Bild verdeckt und nur in den strukturellen Daten verzeichnet, weshalb es sich nur über die Struktur bestimmen lässt. In beiden Kategorien hat also nur eine der beiden Schichten Zugang zur Antwort.

Die Unterscheidung nach Referenztypen baut auf bestehenden Arbeiten auf, die Referenzen z. B. nach ihrer Abhängigkeit vom Blickwinkel oder nach der Eindeutigkeit des Zielobjekts einteilen [6, 7]. Neu sind in dieser Taxonomie die rein perzeptuelle und die verdeckte Referenz als eigene Typen, mit denen sich die exklusiven Zuständigkeiten der beiden Repräsentationen prüfen lassen. Die konkreten Szenarien für jeden Referenztyp sind in Tabelle 6.3 aufgeführt.

Tabelle 6.2: Verfügbarkeit der zur Auflösung nötigen Information je Referenztyp und Schicht, nach Konstruktion der Szenarien. Die Zeilen D und E bilden das exklusive Gegensatzpaar.

Referenztyp	In der strukturellen Schicht	In der visuellen Schicht
A — direkt	Kennung und Zielkoordinaten vorhanden	markiertes Objekt sichtbar
B — Attribut	Attribute wie Farbe und Größe vorhanden	Aussehen sichtbar
C — relational	exakte Koordinaten vorhanden	Anordnung sichtbar
D — perzeptuell	nicht enthalten	Muster sichtbar
E — verdeckt	vollständig verzeichnet	verdeckt, nicht sichtbar

6.3 Metriken

Die verwendeten Erfolgsmaße orientieren sich an etablierten Metriken aus der Literatur zum sprachlichen Auffinden von Objekten in 3D-Szenen [7, 6]. Die wichtigste Kennzahl ist der Ausführungserfolg. Er ist für jeden Lauf binär und ergibt sich allein aus dem Folgezustand der Szene, den die Auswertung nach der Manipulation mit der Soll-Vorgabe des Szenarios vergleicht. Berichtet wird die Zahl der Erfolge aus zehn Läufen, gemittelt über die drei Durchläufe mit der zugehörigen Spanne.

Wann eine Vorgabe als erfüllt gilt, hängt vom Aufgabentyp ab. Grundsätzlich muss bei jeder Aufgabe zuerst das richtige Objekt betroffen sein. Wird ein anderes als das gemeinte Objekt verändert, zählt der Lauf als Misserfolg, auch wenn die Zielkoordinate ansonsten getroffen wäre. Über dieses Kriterium wird erfasst, ob die Referenz korrekt aufgelöst wurde. Bei Aufgaben mit einer Zielposition muss außerdem die erreichte Position innerhalb einer festen Toleranz τ um den Sollwert liegen. Bei relationalen Aufgaben muss die geforderte Lagebeziehung im Folgezustand gelten, z. B. dass ein Objekt einen kleineren x-Wert hat als ein anderes. Bei Aufgaben, die ein Objekt entfernen oder erzeugen, muss das Objekt im Folgezustand entsprechend fehlen oder vorhanden sein. Als Erfolg zählt ein Lauf nur dann, wenn das jeweils maßgebliche Kriterium vollständig erfüllt ist.

Die Toleranz liegt bei $\tau = 0,1$ Einheiten, also einem Zehntel der kleinsten geforderten Verschiebung. Festgelegt wurde der Wert für diesen Aufbau, damit eine grob danebenliegende Bewegung nicht als Treffer gilt und numerisches Rauschen der Engine trotzdem keinen korrekten Lauf verwirft.

Ein kontinuierlicher Lagefehler, also der Abstand zwischen erreichter und geforderter Position, wird in dieser Arbeit nicht berichtet. Die Toleranz τ geht nur als Schwelle in das binäre Kriterium ein. Nachträglich lässt er sich auch nicht mehr berechnen, da für die metrischen Szenarien C2 und C4 die erreichten Endpositionen nicht mehr vorliegen. Das ist bedauerlich, weil gerade dort alle Varianten scheitern und erst der Lagefehler zeigen würde, ob sie knapp danebenliegen oder die Aufgabe grundsätzlich verfehlen.

Tabelle 6.3: Übersicht aller ausgewerteten Szenarien mit Befehl, Ausgangsszene und Soll-Ergebnis. Die Befehle geben den real gesendeten englischen Stimulus wieder.

ID	Befehl	Ausgangsszene	Soll-Ergebnis
<i>Kategorie A — direkt / id-basiert</i>			
A1	„Spawn a red cube at x=2, y=0, z=1.“	leere Szene	roter Würfel bei (2,0,1) vorhanden
A2	„Move obj_2 to position (0, 1, 0).“	rot (0,0,0), grün (2,0,0), blau (4,0,0)	grüner Würfel (obj_2) bei (0,1,0)
A3	„Delete obj_1.“	wie A2	roter Würfel (obj_1) entfernt
<i>Kategorie B — Attribut-Referenz</i>			
B1	„Raise the red cube by 1 unit.“	rot (1,0,0), blau (3,0,0)	roter Würfel in der Höhe +1
B2	„Delete all red cubes.“	rot (0,0,0), rot (2,0,0), grüne Kugel (4,0,0)	beide roten Würfel entfernt, Kugel bleibt
B3	„Move the largest object to (0, 0, 0).“	roter Würfel Größe 0,5 (-2,0,0); grüner Größe 1,5 (0,0,3); blauer Größe 1,0 (3,0,0)	größtes Objekt (grün) bei (0,0,0)
<i>Kategorie C — räumlich-relational</i>			
C1	„Move the sphere to the left of the cube.“	blaue Kugel (1,0,0), grüner Würfel (-1,0,0)	Kugel links vom Würfel
C2 ^a	„Raise the cube nearest to the camera by 1.“	rot (-2,0,2), grün (0,0,5), blau (2,0,8)	kamera-nächster Würfel in der Höhe +1
C4	„Place the sphere exactly 2 units left of the cube.“	grüner Würfel (1,0,0), blaue Kugel (4,0,0)	Kugel bei x=-1 (genau 2 links)
<i>Kategorie D — rein perzeptuell</i>			
D1	„Raise the striped cube by 1 unit.“	zwei graue Würfel (-1,0,3) und (1,0,3); zweiter gestreift	gestreifter Würfel +1, anderer unverändert
D2	„Move the most salient object to (0, 0, 0).“	vier graue Würfel (-3/-1/3/5, 0, 4); ein gestreifter (1,0,4)	gestreifter (auffälliger) Würfel bei (0,0,0)
<i>Kategorie E — verdeckt</i>			
E1	„Raise the green cube by 1 unit.“	rot (-3,0,5); graue Wand Größe 4,0 (2,0,2); grün (2,0,6) dahinter verdeckt	verdeckter grüner Würfel +1
E2	„Raise every cube by 1 unit.“	wie E1	alle drei Würfel in der Höhe +1

Positionen als (x, y, z), wobei y die Höhe angibt. „Größe“ ist die relative Kantenlänge (Standard 1,0).

^a C2 mit seitlich versetztem Aufbau. Der ursprünglich achsenkollineare Aufbau wurde ersetzt (Abschnitt 6.6). Szenario C3 wurde aus methodischen Gründen ausgeschlossen (ebenda).

Statistische Auswertung

Mittelwert und Spanne über drei Durchläufe beschreiben, wie stabil eine Zelle ist. Da drei Durchläufe für eine Entscheidung zu wenig sind, werden für die zentralen Vergleiche zusätzlich die jeweils 30 Einzelläufe einer Zelle zusammengefasst und statistisch ausgewertet.

Da jeder Lauf binär ausgeht, lässt sich eine Zelle vollständig über die Zahl k der Erfolge aus $n = 30$ Läufen beschreiben. Für jede Zelle wird die Erfolgsrate k/n mit einem Wilson-Konfidenzintervall zum Niveau 95 % angegeben. Das Wilson-Intervall ist hier besser geeignet als das übliche Intervall nach der Normalapproximation, da viele Zellen bei null oder bei allen Erfolgen liegen. In diesen Fällen würde die Normalapproximation ein Intervall der Breite null liefern. Verglichen werden zwei Zellen mit dem exakten Test nach Fisher auf der zugehörigen Vierfeldertafel, der keine Annahmen über erwartete Zellhäufigkeiten braucht und auch bei extremen Anteilen gültig bleibt.

Die dafür nötige Annahme unabhängiger Läufe ist durch die in Abschnitt 6.1 beschriebene Dekodierung weitgehend erfüllt. Eine Korrektur für multiples Testen wurde nicht vorgenommen, die schwächsten Vergleiche (die beiden in D2 mit $p = 0,0046$) würden auch eine konservative Korrektur überstehen.

6.4 Ergebnisse zum Einfluss der Repräsentationsform (RQ1)

Tabelle 6.4 zeigt die Ergebnisse je Szenario als Mittelwert über drei Durchläufe mit der Spanne [Minimum–Maximum], wobei jede Zelle für zehn mögliche Erfolge steht. In Tabelle 6.5 sind diese Werte je Kategorie zusammengefasst. Die Tabellen 6.6 und 6.7 enthalten keine zusätzlichen Messungen. Sie fassen die wichtigsten Zellen als Erfolge aus je 30 Läufen mit Wilson-Konfidenzintervall zusammen und geben die exakten Tests für die Vergleiche an, auf denen die Argumentation in diesem und im folgenden Abschnitt beruht.

Tabelle 6.4: Erfolg je Szenario und Variante: Mittelwert [Min–Max] über drei Durchläufe (je $N = 10$).

Kat.	Szen.	json	vlm	hybrid	guided	surgical
A	A1	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
A	A2	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
A	A3	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
B	B1	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
B	B2	10,0 [10–10]	9,7 [9–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
B	B3	10,0 [10–10]	0,0 [0–0]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
C	C1	10,0 [10–10]	1,7 [0–3]	8,3 [7–10]	10,0 [10–10]	10,0 [10–10]
C	C2 ⁽¹⁾	0,0 [0–0]	0,0 [0–0]	0,3 [0–1]	2,7 [1–4]	2,0 [1–3]
C	C4	1,7 [0–4]	0,7 [0–2]	3,3 [3–4]	1,3 [1–2]	2,0 [1–3]
D	D1	0,0 [0–0]	10,0 [10–10]	0,7 [0–1]	8,3 [6–10]	9,7 [9–10]
D	D2	0,3 [0–1]	10,0 [10–10]	10,0 [10–10]	7,3 [6–9]	10,0 [10–10]
E	E1	10,0 [10–10]	0,0 [0–0]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
E	E2 ⁽²⁾	10,0 [10–10]	0,0 [0–0]	0,3 [0–1]	0,0 [0–0]	0,0 [0–0]

Spaltenköpfe sind die Kurzformen der Varianten nach Tabelle 5.1: **json** strukturell, **vlm** visuell, **hybrid** naiv hybrid, **guided** priorisierend, **surgical** kompetenzgetrennt.

⁽¹⁾ C2 wurde nach Entdeckung eines Störfaktors mit seitlich versetztem Aufbau neu gemessen. Die Werte stammen aus dieser zweiten Messung und sind nicht mit den übrigen Zeilen im selben Durchlauf erhoben (Abschnitt 6.6).

⁽²⁾ E2 ist kein reiner Verdeckungstest. Das Soll-Ergebnis verlangt die Manipulation mehrerer Objekte und damit mehr als einen Manipulationsaufruf, was der Grundinstruktion widerspricht (Abschnitt 6.6). Die Zeile wird deshalb nicht als Repräsentationsbefund gewertet.

Kategorie A: Kontrollbedingung

Mit Kategorie A wird geprüft, ob der Aufbau selbst Unterschiede zwischen den Varianten erzeugt. Der Befehl nennt Zielobjekt und Zielkoordinaten direkt über die *id*, eine Deutung der Szene ist nicht

Tabelle 6.5: Erfolg je Kategorie als Summe der zugehörigen Szenario-Mittelwerte über drei Durchläufe. Eine Spanne wird hier nicht ausgewiesen, da sich Minimum und Maximum einer Kategorie nicht aus den Szenario-Spannen zusammensetzen lassen. Kategorie E getrennt ausgewiesen.

Kat.	max	json	vlm	hybrid	guided	surgical
A	30	30,0	30,0	30,0	30,0	30,0
B	30	30,0	19,7	30,0	30,0	30,0
C	30	11,7	2,4	11,9	14,0	14,0
D	20	0,3	20,0	10,7	15,6	19,7
E1	10	10,0	0,0	10,0	10,0	10,0
E2	10	10,0	0,0	0,3	0,0	0,0

nötig. Alle fünf Varianten lösen jedes der drei Szenarien in allen 30 Läufen, Kennungssystem und Werkzeugzugriff erzeugen also für sich genommen keine Unterschiede.

Kategorie B: Attribut-Referenzen

In Kategorie B wird ein Objekt über eine Eigenschaft wie die Farbe oder die Größe angesprochen. Bis auf die visuelle Variante lösen hier alle Varianten jedes Szenario vollständig, während die visuelle Variante nur 19,7 von 30 erreicht. Die kleine Abweichung in B2 (9,7 von 10) liegt dabei innerhalb der beobachteten Streuung, sodass fast der gesamte Rückstand aus B3 stammt. In diesem Szenario soll das größte Objekt bewegt werden, und die visuelle Variante scheitert in allen 30 Läufen, während alle anderen Varianten alle 30 lösen ($p = 1,7 \cdot 10^{-17}$, Tabelle 6.7).

Eine Erklärung über die Perspektive (ein weiter entferntes Objekt wirkt im Bild kleiner) braucht es dafür nicht. Sieht man sich den Wahrnehmungs-Prompt an, ist das Ergebnis nicht weiter verwunderlich. Er fragt Nummer, Form, Farbe, qualitative Lage und Textur ab, nach der Größe fragt er nicht (Listing 3), sodass der visuellen Variante in B3 schlicht die Information fehlt, nach der gefragt wird. Ein vollständiges Scheitern ist unter dieser Bedingung zu erwarten und sagt mehr über den Zuschnitt des Prompts aus als über visuelle Repräsentationen im Allgemeinen.

Kategorie C: Räumlich-relationale Referenzen

In Kategorie C wird ein Objekt in Bezug auf ein anderes ausgewählt oder platziert. Über die gesamte Kategorie hinweg bricht die visuelle Variante mit 2,4 von 30 fast vollständig ein. Die strukturelle und die hybriden Varianten liegen mit rund 12 bis 14 von 30 deutlich davor, da relationale Aufgaben exakte Koordinaten benötigen, die nur in der strukturellen Schicht stehen.

Gut sichtbar ist das in C1, wo die Kugel links vom Würfel platziert werden soll. Gefordert ist hier nur die Richtung der Relation, also ein negativer x-Abstand zum Würfel, und kein exakter Zielwert. Die strukturelle und die hybriden Varianten lösen diese Aufgabe zuverlässig oder größtenteils, die visuelle Variante fast nie.

In C4 wird dieselbe Aufgabe zu einer metrischen Vorgabe verschärft, die Kugel soll exakt zwei Einheiten links vom Würfel liegen. Hier kommt keine Variante über rund drei von zehn hinaus, egal in welcher Form die Szene vorliegt. Solange nur die Richtung einer Relation zählt, entscheidet also die Repräsentation über den Erfolg, bei einem exakten Wert die Präzision des Modells. Entsprechend graduell fällt das Scheitern in C4 aus, alle Varianten liegen zwischen 2 und 10 Erfolgen aus 30 und keine bei exakt null.

Interessant ist der Fall C2, in dem der Würfel, der der Kamera am nächsten ist, um eine Einheit angehoben werden soll. Alle Varianten schneiden schwach ab, die strukturelle sogar mit 0 von 30, obwohl die Aufgabe aus den strukturellen Daten heraus nicht schwer ist. Die drei Würfel liegen bei $(-2, 0, 2)$, $(0, 0, 5)$ und $(2, 0, 8)$, also gestaffelt entlang der z-Achse. Steht die Kamera wie in Listing 1 bei negativem z und blickt entlang der positiven z-Achse, ist der Würfel mit dem kleinsten z-Wert der

Tabelle 6.6: Zentrale Zellen als Erfolge aus $n = 30$ Läufen mit Wilson-95 %-Konfidenzintervall der Erfolgsrate.

Szen.	Variante	Erfolge	Wilson-95 %-KI
D1	strukturell	0/30	[0,0 %; 11,4 %]
D1	visuell	30/30	[88,6 %; 100,0 %]
D1	naiv hybrid	2/30	[1,8 %; 21,3 %]
D1	priorisierend	25/30	[66,4 %; 92,7 %]
D1	kompetenzgetrennt	29/30	[83,3 %; 99,4 %]
D2	strukturell	1/30	[0,6 %; 16,7 %]
D2	visuell	30/30	[88,6 %; 100,0 %]
D2	naiv hybrid	30/30	[88,6 %; 100,0 %]
D2	priorisierend	22/30	[55,6 %; 85,8 %]
D2	kompetenzgetrennt	30/30	[88,6 %; 100,0 %]
E1	strukturell	30/30	[88,6 %; 100,0 %]
E1	visuell	0/30	[0,0 %; 11,4 %]
B3	visuell	0/30	[0,0 %; 11,4 %]
C1	visuell	5/30	[7,3 %; 33,6 %]
C2	strukturell	0/30	[0,0 %; 11,4 %]
C2	priorisierend	8/30	[14,2 %; 44,4 %]
C4	strukturell	5/30	[7,3 %; 33,6 %]
C4	naiv hybrid	10/30	[19,2 %; 51,2 %]

Kamera am nächsten, und diese Reihenfolge stimmt mit der euklidischen Distanz überein. Das Zielobjekt ließe sich also schon durch den Vergleich von drei Zahlen bestimmen, ganz ohne Wurzelrechnung. Dieselbe Variante löst B1, eine ähnlich einfache Aufgabe zum Anheben, in 30 von 30 Läufen, was eher für eine systematische Ursache spricht als für ein Problem mit der Präzision.

Möglich ist, dass das Modell die Referenz tatsächlich falsch auflöst, z. B. weil es die Nähe zur Kamera mit einer anderen Reihenfolge verwechselt oder die Blickrichtung ignoriert. Ebenso könnte die Soll-Vorgabe der Auswertung ein anderes Objekt als korrekt führen, als die Geometrie der Szene nahelegt, was jeden Lauf verwerfen und das beobachtete Muster erzeugen würde. Und schließlich kommt ein Fehler im Werkzeug oder im Aufbau infrage, etwa eine Anhebung, die nicht übernommen wird. Nur im ersten Fall läge ein Befund über das Modell vor. Entscheiden lässt sich das im Nachhinein nicht, weil für C2 keine verwertbaren Aufzeichnungen der einzelnen Läufe mehr vorliegen, aus denen hervorginge, welches Objekt der Agent mit welchen Argumenten manipuliert hat. C2 bleibt deshalb ein ungeklärter Fall und wird nicht als Beleg für eine Grenze des Modells gewertet.

Kategorie D: Rein perzeptuelle Referenzen

In Kategorie D dreht sich das Verhältnis um. Hier spricht der Befehl ein Objekt über ein Oberflächenmuster an, das in den strukturellen Daten nicht vorkommt. Wer nur Koordinaten und Objekttypen kennt, kann ein gestreiftes Objekt nicht von einem einfarbigen unterscheiden. Entsprechend löst die visuelle Variante alle Läufe (20 von 20), während die strukturelle Variante mit 0,3 von 20 fast vollständig scheitert. War in Kategorie C noch die visuelle Schicht blind, ist es hier die strukturelle.

Auffallend ist, dass die naive hybride Variante, der beide Schichten vorliegen, nur 10,7 von 20 erreicht und in D1 sogar nur 2 von 30, während die visuelle Variante dort alle 30 Läufe löst ($p = 8,4 \cdot 10^{-15}$, Tabelle 6.7). Sie schneidet damit schlechter ab als die bessere der beiden Einzelvarianten.

Tabelle 6.7: Exakte Tests nach Fisher für die zentralen Vergleiche, jeweils $n = 30$ je Gruppe. Das Niveau ist nicht für multiples Testen korrigiert.

Vergleich	Erfolge	p
D1: naiv hybrid vs. visuell	2/30 vs. 30/30	$8,4 \cdot 10^{-15}$
D1: naiv hybrid vs. kompetenzgetrennt	2/30 vs. 29/30	$2,3 \cdot 10^{-13}$
D1: naiv hybrid vs. priorisierend	2/30 vs. 25/30	$1,4 \cdot 10^{-9}$
D2: priorisierend vs. naiv hybrid	22/30 vs. 30/30	0,0046
D2: priorisierend vs. kompetenzgetrennt	22/30 vs. 30/30	0,0046
D1: strukturell vs. visuell	0/30 vs. 30/30	$1,7 \cdot 10^{-17}$
E1: visuell vs. strukturell	0/30 vs. 30/30	$1,7 \cdot 10^{-17}$
B3: visuell vs. strukturell	0/30 vs. 30/30	$1,7 \cdot 10^{-17}$
C1: visuell vs. strukturell	5/30 vs. 30/30	$5,5 \cdot 10^{-12}$

Für diesen Verlust kommen zwei Erklärungen infrage. Entweder verdrängt die strukturelle Information die visuelle, oder es handelt sich um einen einfachen Reihenfolgeeffekt. In D1 stehen zwei graue Würfel bei $(-1, 0, 3)$ und $(1, 0, 3)$, wobei der gestreifte Würfel der *zweite* ist. Wählt der Agent immer das erste aufgeführte Objekt, ohne die Referenz überhaupt aufzulösen, entsteht dasselbe Muster. Dafür spricht, dass auch die strukturelle Variante 0 von 30 erreicht, obwohl blindes Raten zwischen zwei Objekten etwa 15 von 30 ergeben würde. Bei einer Temperatur von 0,8 hätte ein auch nur teilweise zufälliges Wahlverhalten über 30 Läufe mit hoher Wahrscheinlichkeit mindestens einen Treffer erzeugt. Ein Wert von exakt null deutet deshalb auf ein systematisches Verhalten hin, und eine Vorliebe für eine bestimmte Position ist die einfachste Erklärung, die zu null führt. Auch die 2 von 30 der naiven hybriden Variante passen in dieses Bild. Unterscheiden ließen sich beide Erklärungen mit einer Messung, in der der gestreifte Würfel an erster Stelle steht, die in dieser Arbeit nicht durchgeführt wurde.

In D2 löst dieselbe naive Variante alle 30 Läufe. Dort steht der gestreifte Würfel bei $(1, 0, 4)$ zwischen vier grauen Würfeln, also weder am Rand noch an erster Stelle einer nach der x-Koordinate sortierten Aufzählung. Eine reine Vorliebe für das erste Objekt erklärt diesen Erfolg nicht, was die Erklärung über die Reihenfolge schwächt, ohne sie für D1 auszuschließen. Ob die Reihenfolge im übergebenen JSON dieser räumlichen Ordnung entspricht, geht aus der Szenariodefinition nicht hervor und müsste den Protokollen entnommen werden.

Dass sich der verlorene Zugriff auf die visuelle Beschreibung über die Instruktion zurückgewinnen lässt, deuten die Werte der beiden anderen hybriden Varianten bereits an (Abschnitt 6.5).

Kategorie E: Verdeckte Referenzen

Kategorie E prüft den umgekehrten Fall, nämlich ein Objekt, das im gerenderten Bild verdeckt, in den strukturellen Daten aber vollständig verzeichnet ist. In E1 verdeckt eine große Wand einen grünen Würfel, der angehoben werden soll. Alle Varianten mit struktureller Schicht lösen diese Aufgabe in allen 30 Läufen, die visuelle Variante in keinem, da sie ein Objekt, das im Bild nicht erscheint, auch nicht ansprechen kann. E1 ist damit das Gegenstück zu Kategorie D.

In E2 sollen alle Würfel der Szene angehoben werden, also auch der verdeckte. Die strukturelle Variante löst das in 30 von 30 Läufen, die hybriden Varianten scheitern fast vollständig, und die visuelle Variante löst keinen Lauf. Als Befund über die Repräsentation taugt diese Zelle nicht, weil sich der Aufbau hier selbst widerspricht. Die gemeinsame Grundinstruktion verlangt, die Aufgabe mit einem einzigen Manipulationsaufruf zu lösen und danach abzuschließen (Abschnitt 5.4). Um drei Würfel anzuheben, braucht es drei Aufrufe. Erfolgreich ist der Agent also nur, wenn er die Instruktion missachtet, sodass hier vor allem gemessen wird, wie bereitwillig eine Variante das tut. Dass die strukturelle Variante

das zuverlässig macht, sagt etwas über ihr Verhalten gegenüber der Instruktion aus und nichts über ihre Repräsentationskompetenz.

Auch B2 betrifft mit „delete all red cubes“ zwei Objekte und wird von den hybriden Varianten trotzdem in 30 von 30 Läufen gelöst. Die zunächst naheliegende Erklärung, dass der größere Kontext der hybriden Varianten mehrere aufeinanderfolgende Schritte erschwert, passt deshalb nicht. Wäre sie richtig, müsste B2 ähnliche Probleme verursachen wie E2. Die Ursache des Einbruchs in E2 bleibt ungeklärt, die Zelle wird nicht gewertet, und für Kategorie E bleibt nur E1.

Zwischenfazit

Aus den Ergebnissen lässt sich schließen, dass es keine Repräsentation gibt, die über alle Aufgaben hinweg am besten abschneidet. Die strukturelle Schicht eignet sich für Referenzen über Attribute, qualitative Relationen und verdeckte Objekte, die visuelle für perzeptuelle Referenzen. Eine hybride Repräsentation vereint die Stärken beider nicht automatisch, wie D1 zeigt.

6.5 Ergebnisse zur Gestaltung der hybriden Repräsentation (RQ2)

In D1 löst die naive hybride Variante nur 2 von 30 Läufen, in D2 alle 30. Ob sich dieses Verhalten allein über die Instruktion steuern lässt, ohne die Modelle zu verändern, ist Gegenstand der zweiten Forschungsfrage.

Ausgangslage

Warum die naive Variante in D1 scheitert und in D2 nicht, lässt sich aus den Erfolgsraten allein nicht ablesen. Eine mögliche Ursache ist die Formulierung des Befehls. In D1 beschreibt „striped“ eine Objekteigenschaft, wie sie sonst in der strukturellen Schicht steht, sodass das Modell dort nach einem Merkmal suchen könnte, wo es keines gibt, denn im strukturellen Zustand unterscheiden sich die beiden grauen Würfel nicht. „Most salient“ in D2 verweist auf etwas, das nur in der visuellen Beschreibung vorkommt. Denkbar ist auch, dass die visuelle Eindeutigkeit des Zielobjekts eine Rolle spielt, da ein gestreiftes Objekt unter vier grauen in der Beschreibung stärker auffällt als eines neben nur einem einfarbigen. Als dritte Möglichkeit bleibt der Reihenfolgeeffekt aus Abschnitt 6.4.

Priorisierende Variante

Bei der priorisierenden Variante wird die visuelle Beschreibung vorangestellt und für das Aussehen als maßgeblich erklärt. Dort, wo die naive Kombination scheitert, verbessert sich das Ergebnis dadurch deutlich. In D1 steigt der Erfolg von 2 auf 25 von 30 Läufen ($p = 1,4 \cdot 10^{-9}$), über die gesamte Kategorie D von 10,7 auf 15,6 von 20.

In D2 fällt die priorisierende Variante dafür auf 22 von 30 zurück, während die naive Variante dort alle 30 Läufe löst ($p = 0,0046$). D2 verlangt neben der Zuordnung über die visuelle Beschreibung auch eine Verschiebung an eine feste Zielkoordinate. Verschiebt man das Gewicht in Richtung der visuellen Beschreibung, leiden vermutlich gerade solche Aufgaben, bei denen gleichzeitig die strukturellen Koordinaten präzise genutzt werden müssen. Die Priorisierung tauscht so eine Kompetenz gegen eine andere ein.

Kompetenzgetrennte Variante

Die kompetenzgetrennte Variante teilt die Zuständigkeiten stattdessen klar auf. Die visuelle Beschreibung bestimmt, welches Objekt gemeint ist, und die strukturelle Schicht liefert die zugehörigen Koordinaten.

In Kategorie D erreicht die Variante 19,7 von 20 und kommt damit nah an die visuelle Variante heran. In D1 löst sie 29 von 30 Läufen, wo die naive Variante nur 2 von 30 schaffte ($p = 2,3 \cdot 10^{-13}$). In D2

bleibt sie bei 30 von 30, während die priorisierende Variante dort auf 22 von 30 abfiel ($p = 0,0046$). Sie verbindet den Zugriff auf die visuelle Beschreibung aus D1 mit der strukturellen Präzision aus D2, woran die Priorisierung gescheitert war (Abbildung 6.1). In den übrigen Kategorien bleibt sie auf dem besten erreichten Niveau, mit 30 von 30 in A und B, gemeinsam an der Spitze in C und 30 von 30 in E1. Schlechter als die strukturelle Variante ist sie nur in der nicht gewerteten Zelle E2.




Abbildung 6.1: Erfolg in der rein visuellen Kategorie D über die fünf Varianten. Die rein visuelle Variante bildet die Obergrenze, die rein strukturelle scheitert nahezu vollständig. Die naive Kombination erreicht etwa die Hälfte, die Priorisierung verbessert das, und die Kompetenztrennung erreicht nahezu das Niveau der reinen Bildvariante.

Bewertung

Nach dem Maßstab aus Abschnitt 1.3 muss eine gestaltete Instruktion dort deutlich besser abschneiden, wo die naive Kombination scheitert, ohne in den übrigen Kategorien schlechter zu werden. Die kompetenzgetrennte Variante verbessert D1 von 2 auf 29 von 30 Läufen und hält gleichzeitig das Niveau in allen anderen gewerteten Kategorien. Für das untersuchte Szenarioset lässt sich die zweite Forschungsfrage damit mit Ja beantworten.

Für einen lokalen Agenten mit gemischter Repräsentation folgt daraus die Empfehlung, die Quellen nicht einfach nebeneinanderzustellen, sondern jede Schicht für den Bereich einzusetzen, den sie nach RQ1 exklusiv abdeckt. Die visuelle Beschreibung beantwortet dann, welches Objekt gemeint ist, und die Struktur, wo es sich befindet.

6.6 Validität und Grenzen

Dieser Abschnitt beschreibt die Störfaktoren, die während der Arbeit beseitigt wurden, und die Einschränkungen, die bestehen bleiben.

Beseitigte Störfaktoren und nachträgliche Entscheidungen

Mehrere Befunde, die zunächst plausibel wirkten, stellten sich bei genauerer Prüfung als Fehler im Aufbau heraus und wurden vor der Auswertung beseitigt. Anfangs nannte das visuelle Modell teilweise die Farbe des Markers statt der des Objekts. Deshalb wurden die Marker versetzt und die Anweisung im Prompt angepasst. In Szenarien, in denen ein Referenzobjekt im Koordinatenursprung stand, fielen relative und absolute Zielangabe zusammen, sodass eine relationale Aufgabe auch ohne Verständnis der Relation lösbar war. Diese Aufbauten wurden geändert. Bei C2 lagen die Objekte ursprünglich auf einer Achse. Verdeckte Objekte bekamen durch den Sichtbarkeitstest keine Marke, sodass das

kameranächste Objekt als einziges markiert und die Aufgabe damit trivial war. Dieser Aufbau wurde verworfen und C2 mit seitlich versetzten Objekten neu gemessen. Dazu kam die doppelte Ausführung von Manipulationen, die zunächst wie ein Nachteil der hybriden Varianten aussah (Abschnitt 5.3).

Dass alle Varianten in der Kontrollkategorie A das Maximum erreichen, zeigt, dass der Messaufbau selbst keine Unterschiede zwischen den Varianten erzeugt.

Einige dieser Anpassungen wurden erst vorgenommen, nachdem die zugehörigen Ergebnisse bereits vorlagen. Szenario C3 wurde aus der Auswertung genommen, da die achsenparallele Ausrichtung der Kamera die aus Sicht der Kamera formulierte Referenz mehrdeutig machte. C2 wurde wegen des beschriebenen Problems mit den Markern nicht ausgeschlossen, sondern mit verändertem Aufbau neu gemessen. E2 wurde als nicht wertbar eingestuft, da sein Soll-Ergebnis der Grundinstruktion widerspricht, was beim Entwurf nicht bedacht worden war. In allen drei Fällen gab es einen konkreten Störfaktor, vorab festgelegt waren die Entscheidungen trotzdem nicht.

Abhängigkeit vom Szenarioset

Die Testfälle sind an zwei Stellen in den Aufbau selbst eingeflossen. Das betrifft zum einen den Wahrnehmungs-Prompt (Listing 3), der festlegt, was die visuelle Schicht überhaupt berichten kann. Wenn die visuelle Variante in B3 scheitert, weil der Prompt keine Größe abfragt, zeigt Kategorie B eben nicht, dass Referenzen über Attribute grundsätzlich strukturelle Daten brauchen, sondern nur, dass das unter diesem Prompt so ist. In die andere Richtung wirkt das Beispielwort „striped“ im Prompt, denn über dieses Merkmal sprechen D1 und D2 ihr Zielobjekt an. Den Vergleich *zwischen* den Varianten mit visueller Schicht verzerrt das nicht, da alle denselben Prompt nutzen. Für Kategorie D ist damit gezeigt, dass die visuelle Schicht eine Eigenschaft erkennt, auf die ihr Prompt ausdrücklich hinweist, und nicht, ob sie ein unerwartetes Oberflächenmerkmal genauso zuverlässig erkannt hätte.

Schwerer wiegt die Entstehung der kompetenzgetrennten Variante, die aus der Analyse der naiven und der priorisierenden Variante auf demselben Szenarioset hervorging, auf dem sie danach gemessen wurde, und deren Instruktion zwei Formulierungen aus den Befehlen von D1 und D2 enthält (Abschnitt 5.4). Belegt ist damit, dass sich die Kombination beider Schichten auf diesem Szenarioset durch die Instruktion deutlich verbessern lässt. Ob das auch für neue Formulierungen gilt, ist offen. Ein Teil des Vorteils könnte daher kommen, dass die Instruktion die Wörter aus dem Testbefehl schon enthält und dem Modell so die Zuordnung abnimmt. Welche Prüfungen das klären könnten, steht in Abschnitt 7.4.

Nicht getrennte Einflussgrößen

Die hybriden Varianten unterscheiden sich nicht nur in ihrer Regel zur Zuständigkeit. Bei der priorisierenden Variante steht zusätzlich die visuelle Beschreibung am Anfang, während die naive und die kompetenzgetrennte Variante mit dem strukturellen Zustand beginnen (Tabelle 5.1). Instruktion und Reihenfolge ändern sich also gemeinsam, und welchen Anteil jeder der beiden Faktoren hat, lässt sich nicht trennen. Für den Vergleich der hybriden Varianten untereinander ist NFA5 in diesem Punkt nicht erfüllt. Für den Vergleich zwischen strukturell, visuell und hybrid gilt die Anforderung weiterhin, da sich diese Bedingungen in der Repräsentation selbst unterscheiden.

Ebenfalls ungeklärt bleibt, warum die naive Kombination in D1 den Zugriff auf die visuelle Beschreibung verliert. Die drei Erklärungen aus Abschnitt 6.5 lassen sich in diesem Aufbau nicht trennen, und der Reihenfolgeeffekt betrifft dabei nicht nur die Erklärung, sondern den Befund selbst. Dass die exakte Struktur die unschärfere Beschreibung verdrängt, ist deshalb eine mögliche Deutung und kein nachgewiesener Mechanismus. Die Arbeiten zur Modalitäts-Dominanz [1, 2] stützen sie nicht, da sie einen anderen Aufbau untersuchen (Abschnitt 2.4).

Messung und Auswertung

Dass der Erfolg nur aus dem Folgezustand bestimmt wird, hat einen praktischen Grund. Das lokale Modell meldete immer wieder Erfolge, die der Folgezustand nicht bestätigte, nannte teilweise Objektkennungen, die es gar nicht gab, und führte einzelne Manipulationen doppelt aus. Wie oft das passierte, wurde nicht systematisch erfasst, die Beobachtung stützt sich auf wiederholte Einzelfälle in den Protokollen. Für die Ergebnisse spielt das keine Rolle, da ein falsch gemeldeter Erfolg die gemessene Erfolgszahl nicht verändert.

Bei fester Konfiguration war die Messung stabil. Die meisten Zellen zeigen über die drei Durchläufe eine Spanne von null oder eins, nennenswerte Streuung gibt es vor allem in C1 und C4 sowie in D1 und D2 der priorisierenden Variante. Für Vergleiche zwischen Varianten gilt die statistische Auswertung aus Abschnitt 6.3, die Spannen dienen nur der Beschreibung.

Die Konfidenzintervalle in Tabelle 6.6 beschreiben die Unsicherheit innerhalb einer Zelle und nicht, ob eine Zelle für ihren Referenztyp repräsentativ ist. Bei zwei Szenarien für den Bereich der visuellen Schicht und nach dem Ausschluss von E2 nur einem für den der strukturellen dürfte diese zweite Unsicherheit die größere sein.

Werkzeugaufrufe mit Argumenten und erreichte Endpositionen mitzuschreiben, hätte keinen zusätzlichen Messaufwand bedeutet und die offenen Fragen zu C2 und C4 beantwortet (Abschnitt 6.4). Wie empfindlich diese beiden Szenarien auf die Toleranz von $\tau = 0,1$ reagieren, wurde ebenfalls nicht geprüft.

Technische Einschränkungen

Die Prüfung der Sichtbarkeit arbeitet mit einem einzelnen Sichtstrahl zum Objektmittelpunkt und kennt deshalb nur die Zustände sichtbar und verdeckt (Abschnitt 5.2). Für die verwendeten Szenen reicht das aus, für dichtere Szenen mit teilweise verdeckten Objekten nicht. Der Schutz gegen identische Wiederholungen würde auch eine vom Befehl gewollte Wiederholung blockieren (Abschnitt 5.3), was in den ausgewerteten Szenarien nicht vorkommt.

Reichweite

Alle Ergebnisse beruhen auf einem einzelnen lokalen Modellpaar und auf synthetischen Szenen aus einfachen Grundkörpern, eine Übertragung auf größere oder anders aufgebaute Modelle sowie auf reale, komplexe Szenen wurde nicht geprüft.

Manche Ergebnisse sagen eher etwas über das Modell als über die Repräsentation. In C4 liegen die Koordinaten vor, und trotzdem wird die geforderte Genauigkeit nur manchmal erreicht, was zu einer Grenze der Präzision passt, an der keine Repräsentation etwas ändert. Für C2 ist eine solche Grenze nicht belegt (Abschnitt 6.4). C2 bezieht sich mit „nearest to the camera“ übrigens auf den Blickpunkt, blickpunktabhängige Referenzen fehlen in der Auswertung also nicht ganz, auch wenn das dafür vorgesehene Szenario C3 ausgeschlossen wurde.

Kapitel 7

Zusammenfassung und Ausblick

7.1 Zusammenfassung

Ausgangspunkt der Arbeit war die Frage, in welcher Form einem lokal betriebenen KI-Agenten eine 3D-Szene bereitgestellt werden sollte, damit er sie über natürliche Sprache manipulieren kann. Zur Auswahl standen ein struktureller und ein visueller Weg, die beide eigene Stärken haben und jeweils einen Bereich abdecken, den der andere nicht erreicht.

Um diese Frage zu beantworten, wurde ein prototypisches System entwickelt, das dieselbe Szene strukturell, visuell und hybrid bereitstellt und über ein gemeinsames Interface manipulierbar macht. Die Repräsentationsformen wurden unter gleichen Bedingungen an dreizehn kontrolliert aufgebauten Szenarien verglichen, wobei jede Kombination aus Szenario und Variante in 30 Läufen gemessen und der Erfolg aus dem tatsächlichen Zustand der Szene bestimmt wurde.

Welche Repräsentation am besten abschneidet, hing vom Referenztyp ab, und eine naive Kombination beider Schichten vereinte deren Stärken nicht automatisch. Erst eine Instruktion, die den Schichten getrennte Zuständigkeiten zuweist, brachte beide auf dem untersuchten Szenarioset zusammen.

Für den Demonstrator wurde diese kompetenzgetrennte Variante in die immersive Zielumgebung übertragen. Er zeigt, dass die Kette vom Befehl bis zur sichtbaren Manipulation in der Brille funktioniert. Per Video dokumentiert ist die Fassung mit Bedienmenü, die später ergänzte Spracheingabe nicht.

7.2 Beantwortung der Forschungsfragen

Erste Forschungsfrage

Welchen Einfluss hat die Form der Szenenrepräsentation, strukturell, visuell oder hybrid, auf den Ausführungserfolg der natürlichsprachlichen Szenenmanipulation durch einen lokal betriebenen Agenten, und zwar aufgeschlüsselt nach der Art der sprachlichen Referenz?

Für die erste Forschungsfrage lautet das Fazit, dass die Repräsentationsform einen großen Einfluss auf den Ausführungserfolg hat und dieser Einfluss vom Referenztyp abhängt. Referenzen, deren Merkmal in den Daten kodiert ist, sowie Referenzen auf verdeckte Objekte werden von der strukturellen Form getragen, die als einzige ein im Bild verdecktes Objekt ansprechen kann. Referenzen auf rein visuelle Eigenschaften wie ein Oberflächenmuster lassen sich nur über die visuelle Form auflösen.

Die naive hybride Form übernimmt den Vorteil der strukturellen Form, den der visuellen nicht zuverlässig. In der perzeptuellen Kategorie erreicht sie nur 10,7 von 20 möglichen Erfolgen, die visuelle Form alle 20. Eine Kombination ist also nicht automatisch so gut wie die bessere der beiden Einzelformen.

Zweite Forschungsfrage

Lässt sich das Zusammenspiel der strukturellen und der visuellen Schicht allein durch die Gestaltung der Instruktion so steuern, dass die hybride Repräsentation die Stärken beider Schichten vereint?

Für das untersuchte Szenarioset lässt sich diese Frage mit Ja beantworten, ohne dass die Modelle verändert werden müssen. Eine Priorisierung einer Schicht reicht dafür nicht, sie verschiebt nur das Gewicht und tauscht eine Kompetenz gegen eine andere. Eine klare Trennung der Zuständigkeiten, bei der die visuelle Beschreibung das gemeinte Objekt bestimmt und die strukturelle Schicht alle geometrischen Werte liefert, bringt beide Schichten dagegen zusammen. Die kompetenzgetrennte Variante erreicht so in der perzeptuellen Kategorie 19,7 von 20 und behält gleichzeitig die Stärke der strukturellen Form.

7.3 Wissenschaftlicher Beitrag

Inhaltlich zeigt die Arbeit an einem kontrollierten Fall, dass sich strukturelle und visuelle Information nicht automatisch ergänzen. Ob eine Kombination beide Informationsarten sinnvoll zusammenführt oder ob eine die andere verdrängt, hängt davon ab, wie die Kombination gestaltet ist. Gewonnen wurde dieser Befund mit einem Modellpaar an dreizehn Szenarien. Er legt nahe, die Kombination mehrerer Informationsquellen auch bei anderen Agenten als Gestaltungsaufgabe zu sehen und nicht einfach als zusätzliche Information.

Methodisch führt die Arbeit eine nach Referenztypen aufgeschlüsselte Auswertung ein, bei der der Erfolg für jeden Referenztyp einzeln gemessen wird und nicht als ein Gesamtwert. Erst dadurch werden die exklusiven Zuständigkeiten der Repräsentationen sichtbar, die bei einem pauschalen Vergleich verborgen geblieben wären. Da dieses Schema nicht an das konkrete System gebunden ist, sollte es sich auch auf ähnliche Vergleiche übertragen lassen.

Praktisch zeigt die Arbeit, dass sich die gesamte Kette aus 3D-Umgebung, Vermittlungsschicht, Agent und zwei gleichzeitig betriebenen lokalen Modellen umsetzen und bis in die immersive Zielumgebung betreiben lässt.

7.4 Ausblick

Die meisten Ansatzpunkte für weitere Arbeiten ergeben sich direkt aus den Einschränkungen in Abschnitt 6.6. Als Erstes sollte geprüft werden, ob die kompetenzgetrennte Variante ihren Vorteil auch außerhalb des Szenariosets behält, auf dem sie entwickelt wurde. Dafür bräuchte es neue Szenarien, vor allem mit anderen perzeptuellen Eigenschaften als einem Streifenmuster und mit anderen Formulierungen für dieselbe Referenz, sowie eine Fassung der Instruktion ohne „striped“ und „most salient“, in der die Trennung der Zuständigkeiten rein allgemein formuliert ist. Erst wenn eine solche Instruktion auch auf neuen Szenarien denselben Vorteil zeigt, ließe sich von einem übertragbaren Gestaltungsprinzip sprechen.

Ähnlich wichtig ist eine Messung, die den Reihenfolgeeffekt in Kategorie D ausschließt. Dafür würde es reichen, die entscheidenden Szenarien mit vertauschter Objektreihenfolge zu wiederholen und die Reihenfolge der beiden Schichten im Kontext unabhängig von der Instruktion zu verändern. Beides ist ohne neuen Aufbau möglich. Bei jeder Wiederholung sollten zudem Werkzeugaufrufe und Endpositionen protokolliert werden, womit sich die offenen Fragen zu C2 und C4 beantworten ließen.

Weitere Ansatzpunkte betreffen die Effizienz und den Umfang des Systems. Die visuelle Schicht abzurufen dauert spürbar länger als der Abruf des strukturellen Zustands, da ein zusätzlicher Inferenzschritt des Sprach-Bild-Modells nötig ist. Gemessen wurde dieser Unterschied nicht. Eine systematische Erhebung von Latenz, Schrittzahl und Rechenaufwand würde diesen bisher nur qualitativ bekannten Trade-off greifbar machen, was vor allem für eine interaktive immersive Anwendung wichtig ist. Mit

steigender Objektzahl dürfte vor allem die visuelle Schicht an ihre Grenzen kommen, weil die Markierung vieler Objekte schnell unübersichtlich wird. Die Menge der Operationen ließe sich um Drehungen und Skalierungen erweitern sowie um Befehle mit mehreren Manipulationen, deren eigene Schwierigkeiten sich hier bereits angedeutet haben. Offen sind auch blickpunktabhängige Referenzen, die sich auf die Sicht des Betrachters beziehen und gerade für immersive Umgebungen typisch sind. Jüngere Arbeiten zur blickpunktabhängigen Segmentierung zeigen, dass solche Bezüge ohne einen expliziten Blickpunkt mehrdeutig sind und von einer ausdrücklichen Darstellung des Blickwinkels profitieren [16]. Eine saubere Behandlung dieses Referenztyps wäre deshalb eine sinnvolle Erweiterung der Taxonomie.

Auf wissenschaftlicher Ebene ließe sich prüfen, ob die gefundenen Kompetenzprofile und die Grenzen der naiven Kombination auch für größere oder anders aufgebaute Modelle gelten oder ob ein größeres Modell das beobachtete Problem von selbst löst. Ein gezieltes Experiment könnte außerdem die drei offenen Erklärungen voneinander trennen, indem Formulierung, visuelle Eindeutigkeit und Reihenfolge der Objekte unabhängig voneinander verändert werden. Interessant wäre auch ein Vergleich der zweistufigen Pipeline mit einem einzelnen multimodalen Modell, dem Bild und strukturelle Daten direkt vorliegen. Damit ließe sich zeigen, ob der beobachtete Effekt von der Pipeline abhängt oder auch unabhängig davon auftritt. Ob sich das Prinzip der Kompetenztrennung auch auf andere multimodale Aufgaben übertragen lässt, kann Gegenstand zukünftiger Arbeiten werden.

Aus Sicht der Anwendung fehlt noch eine Erprobung mit echten Nutzern. Die Bewertung in dieser Arbeit ist rein systembasiert, und eine qualitative Nutzerstudie im Demonstrator könnte zeigen, wie Menschen die sprachgesteuerte Manipulation in der immersiven Umgebung tatsächlich erleben.

Glossar

Folgezustand Tatsächlicher Zustand der Szene nach einer Manipulation, aus dem der Ausführungserfolg unabhängig von der Selbstauskunft des Agenten bestimmt wird

gemeinsames Kennungssystem Einheitliche Objektkennungen, über die alle Repräsentationsvarianten Objekte ansprechen; die visuelle Variante ist über ihre Bildmarken an dieselben Kennungen gebunden

Grounding Auflösung einer sprachlichen Referenz auf ein konkretes Szenenobjekt

kompetenzgetrennte hybride Repräsentation Hybride Repräsentation mit expliziter Aufgabenteilung: die visuelle Beschreibung bestimmt, welches Objekt gemeint ist, die strukturelle Schicht liefert alle numerischen Werte

lokaler Betrieb Selbst gehosteter Betrieb der Modelle ohne Cloud-Dienst, siehe Abschnitt 1.1

naive hybride Repräsentation Kombination aus struktureller und visueller Schicht ohne verbindliche Instruktion zur Zuständigkeit der beiden Quellen

priorisierende hybride Repräsentation Hybride Repräsentation mit vorangestellter visueller Beschreibung, die als maßgeblich für das Aussehen deklariert wird

Referenztyp Art, in der ein natürlichsprachlicher Befehl auf ein Objekt verweist, etwa über eine Kennung, ein Attribut, eine räumliche Relation, eine rein sichtbare Eigenschaft oder ein verdecktes Objekt

strukturelle Repräsentation Bereitstellung der Szene als exakte Laufzeitdaten der Engine (Objekt-ids, Typen, Positionen, Größen, Farben, Kamerapose) in textueller Form, hier als JSON

visuelle Repräsentation Bereitstellung der Szene über eine von einem Sprach-Bild-Modell erzeugte natürlichsprachliche Beschreibung der gerenderten, mit Set-of-Mark-Markern versehenen Ansicht, siehe Abschnitt 2.1

Literaturverzeichnis

- [1] A. Deng, T. Cao, Z. Chen, und B. Hooi, „Words or Vision: Do Vision-Language Models Have Blind Faith in Text?” in *2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2025, S. 3867–3876, Abgerufen am 03.09.2026. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/11092720> (Zitiert auf Seiten 2, 6, 12 und 34.)
- [2] H. Wu, M. Tang, X. Zheng, und H. Jiang. (2025) When Language Overrides: Revealing Text Dominance in Multimodal Large Language Models. Abgerufen am 27.08.2026. [Online]. Available: <http://arxiv.org/abs/2508.10552> (Zitiert auf Seiten 2, 6, 12 und 34.)
- [3] Hugging Face. (2024) Smolagents. [Online]. Available: <https://github.com/huggingface/smolagents> (Zitiert auf Seiten 5 und 17.)
- [4] Anthropic. Model Context Protocol. [Online]. Available: <https://modelcontextprotocol.io> (Zitiert auf Seiten 5 und 14.)
- [5] J. Yang, H. Zhang, F. Li, X. Zou, C. Li, und J. Gao. (2023) Set-of-Mark Prompting Unleashes Extraordinary Visual Grounding in GPT-4V. Abgerufen am 10.09.2026. [Online]. Available: <http://arxiv.org/abs/2310.11441> (Zitiert auf Seiten 5, 12 und 16.)
- [6] P. Achlioptas, A. Abdelreheem, F. Xia, M. Elhoseiny, und L. Guibas, „ReferIt3D: Neural Listeners for Fine-Grained 3D Object Identification in Real-World Scenes,” in *Computer Vision – ECCV 2020*, A. Vedaldi, H. Bischof, T. Brox, und J.-M. Frahm, Hrsgg. Springer International Publishing, 2020, S. 422–440. (Zitiert auf Seiten 5 und 26.)
- [7] D. Z. Chen, A. X. Chang, und M. Nießner, „ScanRefer: 3D Object Localization in RGB-D Scans Using Natural Language,” in *Computer Vision – ECCV 2020*, A. Vedaldi, H. Bischof, T. Brox, und J.-M. Frahm, Hrsgg. Springer International Publishing, 2020, S. 202–221. (Zitiert auf Seiten 5 und 26.)
- [8] F. De La Torre, C. M. Fang, H. Huang, A. Banburski-Fahey, J. Amores Fernandez, und J. Lanier, „LLMR: Real-time Prompting of Interactive Worlds Using Large Language Models,” in *Proceedings of the 2024 CHI Conference on Human Factors in Computing Systems*, Serie CHI ’24. Association for Computing Machinery, 2024, S. 1–22, Abgerufen am 10.09.2026. [Online]. Available: <https://dl.acm.org/doi/10.1145/3613904.3642579> (Zitiert auf Seite 5.)
- [9] X. E. Wang, Z. P. T. Sin, Y. Jia, D. Archer, W. H. Y. Fong, Q. Li, und C. Li, „Can You Move These Over There? Exploring an LLM-based VR Mover to Support Natural Multi-object Manipulation,” in *Proceedings of the 38th Annual ACM Symposium on User Interface Software and Technology*, Serie UIST ’25. Association for Computing Machinery, 2025, S. 1–18, Abgerufen am 10.09.2026. [Online]. Available: <https://dl.acm.org/doi/10.1145/3746059.3747673> (Zitiert auf Seite 5.)
- [10] R. Li, S. Li, L. Kong, X. Yang, und J. Liang. (2025) SeeGround: See and Ground for Zero-Shot Open-Vocabulary 3D Visual Grounding. Abgerufen am 10.09.2026. [Online]. Available: <http://arxiv.org/abs/2412.04383> (Zitiert auf Seite 6.)
- [11] X. Sun, X. Zhang, B. Crowe, D. Albin, und C. Heckman. (2026) SceneGraphGrounder: Zero-Shot 3D Visual Grounding via Structured Scene Graph Matching. Abgerufen am 27.08.2026. [Online]. Available: <http://arxiv.org/abs/2605.21788> (Zitiert auf Seite 6.)
- [12] M. Li, S. Zhao, Q. Wang, K. Wang, Y. Zhou, S. Srivastava, C. Gokmen, T. Lee, L. E. Li, R. Zhang, W. Liu, P. Liang, L. Fei-Fei, J. Mao, und J. Wu. (2025) Embodied Agent Interface: Benchmarking LLMs for Embodied Decision Making. Abgerufen am 10.09.2026. [Online]. Available: <http://arxiv.org/abs/2410.07166> (Zitiert auf Seite 6.)

- [13] Z. Song, X. Lin, Q. Huang, S. Qin, G. Wang, und L. Lin. (2026) SIRE-Bench: Challenging VLMs' Spatial Intelligence through Complex Reasoning Tasks. Abgerufen am 27.08.2026. [Online]. Available: <http://arxiv.org/abs/2506.14512> (Zitiert auf Seite 6.)
- [14] Z. Wu, Z. Wang, X. Xu, J. Lu, und H. Yan. (2023) Embodied Task Planning with Large Language Models. Abgerufen am 11.09.2026. [Online]. Available: <http://arxiv.org/abs/2307.01848> (Zitiert auf Seite 6.)
- [15] D. C. Dinh, K. Le-Duc, F. Draye, C. Ngo, T. J. Zhang, B. Schölkopf, und Z. Jin. (2026) PruneGround: Plug-and-play Spatial Pruning for 3D Visual Grounding. Abgerufen am 27.08.2026. [Online]. Available: <http://arxiv.org/abs/2606.31148> (Zitiert auf Seite 6.)
- [16] A. Nanri, K. Reichard, M. Kiray, F. Tombari, B. Busam, und A. Kanezaki. (2026) 3D Segmentation Using Viewpoint-Dependent Spatial Relationships. Abgerufen am 27.08.2026. [Online]. Available: <http://arxiv.org/abs/2605.15708> (Zitiert auf Seite 38.)

Erklärung: Verwendung von KI-Werkzeugen

Im Rahmen der Erstellung dieser Arbeit wurde das KI-Werkzeug Claude (Anthropic) eingesetzt. Die Nutzung wird im Folgenden gemäß der KI-Leitlinie der Technischen Hochschule Nürnberg Georg Simon Ohm offengelegt.

- Grobe Literaturrecherche mit anschließender manueller Überarbeitung und Verifikation der Quellen.
- Umformulierung von selbst verfasstem Text.
- Unterstützung bei der Codeerstellung im Implementierungsteil.

Sämtliche von dem Werkzeug erzeugten Inhalte wurden eigenständig geprüft, überarbeitet und inhaltlich verantwortet. Die Verantwortung für alle Aussagen, Ergebnisse und Schlussfolgerungen dieser Arbeit liegt vollständig beim Verfasser. Die reine Rechtschreib- und Grammatikprüfung ist gemäß Leitlinie nicht dokumentationspflichtig und daher nicht aufgeführt.

Anhang A

Begleitmaterial

A.1 Demonstrationsvideo

Als Begleitmaterial zu dieser Arbeit steht eine Videoaufzeichnung des Demonstrators zur Verfügung. Sie zeigt eine frühe Ausbaustufe, in der die Szene über ein Menü in der virtuellen Umgebung manipuliert wird, das vordefinierte Befehle bereitstellt. Das Video ist unter der folgenden Adresse abrufbar.

`https://git.informatik.fh-nuernberg.de/jobboerse/forschung/bachelorarbeiten/
bachelorarbeit-sandro-jaeger/-/blob/fe68f112f06df9da38eff687fd8df8460061186c/BA_VR_
Demo_with_menu.mp4`



Abbildung: QR-Code zur Videoaufzeichnung.