



Bachelorarbeit

Szenenverständnis und -manipulation in immersiven Umgebungen mittels Künstlicher Intelligenz

Sandro Jäger
Matrikelnummer: 3683886

Prüfer: Prof. Dr. Uwe Wienkop
Louis Burk

© Sandro Jäger, 2026

Diese Arbeit, einschließlich ihrer Teile, **ist urheberrechtlich geschützt**. Jede Verwertung außerhalb der engen Grenzen des Urheberrechtsgesetzes ohne Zustimmung des Urhebers ist untersagt und strafbar. Dies gilt insbesondere für Vervielfältigungen, Übersetzungen, Mikroverfilmung und die Speicherung und Verarbeitung in elektronischen Systemen.

Kurzdarstellung

Damit ein KI-Agent eine dreidimensionale Szene natürlichsprachlich verändern kann, muss ihm die Szene zunächst in einer verarbeitbaren Form vorliegen. Dafür stehen zwei grundlegende Wege zur Verfügung, eine strukturelle Beschreibung als exakte Daten und eine visuelle Beschreibung über ein gerendertes Bild. Für selbst gehostete Modelle geringer Größe fehlte bislang ein systematischer Vergleich dieser Formen.

Die vorliegende Arbeit untersucht daher, welchen Einfluss die Repräsentationsform auf den Ausführungserfolg der Szenenmanipulation hat und ob sich eine Kombination beider Formen gezielt gestalten lässt. Dazu wurde ein prototypisches System entwickelt, das dieselbe Szene strukturell, visuell und hybrid bereitstellt und fünf daraus abgeleitete Varianten unter gleichen Bedingungen an dreizehn kontrolliert aufgebauten Szenarien vergleicht. Die Messung selbst fand am Desktop statt; die immersive Umgebung wird ausschließlich in einem Demonstrator gezeigt und nicht eigenständig evaluiert.

Der Vergleich zeigt eine referenztypabhängige Kompetenz ohne Gesamtsieger, wobei beide Formen jeweils einen Bereich abdecken, den die andere nicht erreicht. Eine naive Kombination vereint diese Stärken nicht von selbst. Erst eine ausdrückliche Trennung der Zuständigkeiten führt die beiden Schichten auf diesem Szenarioset zusammen, während eine bloße Priorisierung das Gewicht nur verschiebt. Ob sich dieser Vorteil auf ungesehene Formulierungen überträgt, bleibt offen, da die Variante iterativ am vorliegenden Szenarioset entwickelt wurde. Ein Demonstrator überträgt diese Variante in eine immersive Umgebung und zeigt die Machbarkeit der gesamten Kette.

Schlagwörter

Szenenrepräsentation, Immersive Umgebungen, Multimodale Agenten, Lokale Sprachmodelle, Vision-Language-Modelle

Danksagung

Mein Dank gilt Prof. Dr. Uwe Wienkop und Louis Burk für die Betreuung dieser Arbeit und für die hilfreichen Rückmeldungen im Verlauf. Dem Institut für angewandte Informatik danke ich für die Möglichkeit, diese Arbeit dort anzufertigen, sowie für die bereitgestellte Hardware, ohne die der lokale Betrieb der Modelle nicht möglich gewesen wäre. Ein besonderer Dank gilt schließlich meinem Bruder und meinen Eltern für ihre Unterstützung während des Studiums.

Inhaltsverzeichnis

Abkürzungsverzeichnis	vi
Abbildungsverzeichnis	vii
Tabellenverzeichnis	viii
Quellcodeverzeichnis	ix
1 Einleitung	1
1.1 Motivation und Problemstellung	1
1.2 Relevanz	1
1.3 Zielsetzung und Forschungsfragen	2
1.4 Methodisches Vorgehen	2
1.5 Aufbau der Arbeit	3
2 Grundlagen und Stand der Technik	4
2.1 Große Sprach- und Sprach-Bild-Modelle	4
2.2 Werkzeugnutzende Agenten	5
2.3 Szenenrepräsentation	5
2.4 Stand der Technik	5
2.4.1 Strukturelle Szenenmanipulation in immersiven Umgebungen	5
2.4.2 Hybrides Grounding	6
2.4.3 Modalitäts-Ablationen und Modalitäts-Dominanz	6
2.4.4 Ansätze mit lokalen, kleinen Modellen	7
2.5 Forschungslücke	7
3 Anforderungen	8
3.1 Herleitung der Anforderungen	8
3.2 Funktionale Anforderungen	8
3.3 Nicht-funktionale Anforderungen	9
3.4 Zielkonflikte zwischen den Anforderungen	10
3.5 Abgrenzung des Funktionsumfangs	10
4 Konzept	11
4.1 Lösungsansatz im Überblick	11
4.2 Repräsentationsformen	11
4.3 Entwurfsentscheidungen	12
4.4 Steuerung der Modalitätsfusion	12
4.5 Differenzierung nach Referenztyp	12
5 Implementierung	14
5.1 Systemüberblick	14

5.2	Szenenanbindung	14
5.3	Agent und Werkzeuge	16
5.4	Repräsentationsvarianten	18
5.5	VR-Demonstrator	20
6	Evaluation	24
6.1	Evaluationsdesign	24
6.2	Referenztyp-Taxonomie	26
6.3	Metriken	26
6.4	Ergebnisse zu RQ1	28
6.5	Ergebnisse zu RQ2	33
6.6	Validität und Grenzen	34
7	Zusammenfassung und Ausblick	38
7.1	Zusammenfassung	38
7.2	Beantwortung der Forschungsfragen	38
7.3	Beitrag	39
7.4	Grenzen der Arbeit	39
7.5	Ausblick	40
	Glossar	42
	Literaturverzeichnis	43
	Erklärung: Verwendung von KI-Werkzeugen	45
A	Begleitmaterial	46
A.1	Demonstrationsvideo	46

Abkürzungsverzeichnis

API Application Programming Interface, Programmierschnittstelle

ES Execution Success, Ausführungserfolg

FA funktionale Anforderung

GPU Graphics Processing Unit, Grafikprozessor

JSON JavaScript Object Notation

KI Künstliche Intelligenz

LLM Large Language Model, großes Sprachmodell

MCP Model Context Protocol

MR Mixed Reality, gemischte Realität

NFA nicht-funktionale Anforderung

RQ Research Question, Forschungsfrage

SoM Set-of-Mark

STT Speech-to-Text, Spracherkennung

VLM Vision-Language Model, Sprach-Bild-Modell

VPN Virtual Private Network, virtuelles privates Netz

VR Virtual Reality, virtuelle Realität

VRAM Video Random Access Memory, Grafikspeicher

Abbildungsverzeichnis

4.1	Konzeptionelle Kompetenzverteilung der beiden Repräsentationen. Der Überlappungsbereich steht für Referenzen, die beide Schichten auflösen können, die Außenbereiche für die exklusive Kompetenz jeweils einer Schicht. Aus diesen exklusiven Bereichen ergibt sich der Nutzen des hybriden Ansatzes.	13
5.1	Aufbau des Systems in drei Schichten und Nachrichtenfluss einer Manipulation. Durchgezogene Pfeile zeigen den Vorwärtsfluss, gestrichelte Pfeile den Rückkanal. Die Verbindung zwischen MCP-Server und Umgebung wird über WebSocket übertragen. . . .	15
5.2	Die visuelle Repräsentation am Beispiel einer einfachen Szene. Links die gerenderte Ansicht, wie sie die Kamera liefert. Rechts dieselbe Ansicht nach dem Set-of-Mark-Verfahren, bei dem jedes sichtbare Objekt eine nummerierte Marke trägt, über die das visuelle Modell es benennen kann. Die Marken sind reine Bezeichner; ihre Farbe ist bedeutungslos und wird bei der Auswertung ignoriert.	16
5.3	Ablauf einer einzelnen Manipulation. In der Agentenschleife fragt der Agent die Szene über ein Wahrnehmungswerkzeug ab, das Sprachmodell wählt die passende Operation, und das gewählte Werkzeug manipuliert das Objekt. Diese Schritte wiederholen sich, bis der Agent die Aufgabe abschließt. Danach liest die Auswertung den tatsächlichen Szenenzustand aus und bewertet daraus den Erfolg, unabhängig von der Selbstauskunft des Agenten.	17
5.4	Ablauf eines gesprochenen Befehls im Demonstrator. Der lokale Rechner erkennt die Sprache und leitet den Text als Commander-Nachricht weiter, der entfernte Rechner arbeitet den Agentenlauf ab, und die Brille führt die Manipulation aus und zeigt den Verarbeitungsstatus an.	22
5.5	Frühe Ausbaustufe des Demonstrators mit Bedienmenü. Links der rote Würfel, rechts die blaue Kugel; der gestreifte Würfel in der Mitte wird von der Menütafel weitgehend verdeckt, nur sein unterer Teil ist sichtbar. Das Standbild stammt aus der Aufzeichnung in Anhang A.1, in der unter anderem „move the striped cube up“, „put the blue sphere left of the red cube“ und „delete the striped cube“ über das Menü ausgelöst werden. .	23
6.1	Erfolg in der rein visuellen Kategorie D über die fünf Varianten. Die rein visuelle Variante bildet die Obergrenze, die rein strukturelle scheitert nahezu vollständig. Die naive Kombination erreicht etwa die Hälfte, die Priorisierung verbessert das, und die Kompetenztrennung erreicht nahezu das Niveau der reinen Bildvariante.	34

Tabellenverzeichnis

3.1	Funktionale Anforderungen.	9
3.2	Nicht-funktionale Anforderungen.	10
5.1	Die fünf Repräsentationsvarianten im Vergleich, mit den in den Ergebnistabellen verwendeten Kurzbezeichnungen.	20
6.1	Konfiguration der Messung, beschränkt auf die Angaben, die den Ausgang der Läufe beeinflussen. Zusammen mit dem verlinkten Code genügen sie, um die Messung zu wiederholen.	25
6.2	Verfügbarkeit der zur Auflösung nötigen Information je Referenztyp und Schicht, nach Konstruktion der Szenarien. Die Zeilen D und E bilden das exklusive Gegensatzpaar. .	26
6.3	Übersicht aller ausgewerteten Szenarien mit Befehl, Ausgangsszene und Soll-Ergebnis. Die Befehle geben den real gesendeten englischen Stimulus wieder.	27
6.4	Erfolg je Szenario und Variante: Mittelwert [Min–Max] über drei Durchläufe (je $N = 10$). .	29
6.5	Erfolg je Kategorie als Summe der zugehörigen Szenario-Mittelwerte über drei Durchläufe. Eine Spanne wird hier nicht ausgewiesen, da sich Minimum und Maximum einer Kategorie nicht aus den Szenario-Spannen zusammensetzen lassen. Kategorie E getrennt ausgewiesen.	29
6.6	Zentrale Zellen als Erfolge aus $n = 30$ Läufen mit Wilson-95 %-Konfidenzintervall der Erfolgsrate.	30
6.7	Exakte Tests nach Fisher für die zentralen Vergleiche, jeweils $n = 30$ je Gruppe. Das Niveau ist nicht für multiples Testen korrigiert.	31

Quellcodeverzeichnis

1	Beispiel des strukturellen Szenenzustands als JSON-Ausgabe der Umgebung.	15
2	Beispiel einer Werkzeugdefinition (gekürzt). Der Dokumentationskommentar dient dem Agenten als Beschreibung des Werkzeugs.	17
3	Prompt, mit dem das visuelle Modell die gerenderte und markierte Ansicht beschreibt. Er wird zusammen mit dem Bild übergeben und ist in allen Varianten mit visueller Schicht identisch.	18
4	Wahrnehmungswerkzeug der naiven hybriden Variante.	19
5	Wahrnehmungswerkzeug der priorisierenden Variante.	19
6	Wahrnehmungswerkzeug der kompetenzgetrennten Variante.	20

Kapitel 1

Einleitung

1.1 Motivation und Problemstellung

Ein Nutzer steht in einer virtuellen Szene und sagt einen einfachen Satz: Heb den gestreiften Würfel an. Für einen Menschen ist das trivial. Ein KI-Agent muss dafür zuerst wissen, wie die Szene aussieht, und diese Information muss ihm in einer Form vorliegen, die er verarbeiten kann.

Grundsätzlich gibt es dafür zwei Wege. Die Szene lässt sich strukturell beschreiben, als exakte Daten über Objekte, ihre Typen, Positionen und Größen, oder visuell, als gerendertes Bild, das ein visuelles Modell interpretiert. Die strukturellen Daten kennen jede Koordinate, sagen über das Aussehen eines Objekts aber nichts. Das Bild zeigt das Aussehen, enthält aber keine exakten Zahlen.

Am gestreiften Würfel aus dem Beispiel wird die erste Lücke sichtbar: Das Streifenmuster steht in keinen strukturellen Daten, der Würfel lässt sich also nur über das Bild bestimmen. Umgekehrt taucht ein Objekt, das hinter einem anderen steht, im Bild gar nicht auf, ist in den strukturellen Daten aber vollständig verzeichnet. Ein Befehl, der sich auf ein solches Objekt bezieht, lässt sich nur über die Struktur auflösen. Jeder der beiden Wege deckt damit einen Bereich ab, zu dem der andere grundsätzlich keinen Zugang hat.

Wer einen solchen Agenten baut, muss deshalb früh entscheiden, in welcher Form er ihm die Szene bereitstellt und ob sich beide Wege so kombinieren lassen, dass ihre Stärken zusammenkommen. Bisher gibt es für diese Entscheidung keine empirische Grundlage. Praktisch wichtig ist die Frage vor allem in immersiven Umgebungen, in denen Nutzer per Sprache mit einer Szene interagieren. Dort liegen lokal betreibbare Modelle aus Gründen des Datenschutzes, der Latenz und der Offline-Fähigkeit nahe, und gerade für solche Modelle fehlt ein systematischer Vergleich der beiden Wege.

Der Begriff *lokal* wird in dieser Arbeit durchgängig in einem festen Sinn verwendet: selbst gehostet auf eigener Hardware, ohne Cloud-Dienst, sodass keine Szenen- oder Sprachdaten das eigene Netz verlassen. Er bedeutet nicht, dass die Modelle auf dem Endgerät selbst rechnen. In der Messung wie im Demonstrator laufen sie auf einem Arbeitsplatzrechner; die Brille erreicht diesen im Demonstrator über eine Netzverbindung innerhalb des Institutsnetzes (Abschnitt 5.5).

1.2 Relevanz

Von der Repräsentationsform hängt ab, welche sprachlichen Anweisungen ein Agent überhaupt zuverlässig umsetzen kann. Bildet eine Repräsentation eine ganze Klasse von Referenzen nicht ab, scheitern die zugehörigen Befehle, ganz gleich, wie gut der Agent im Übrigen arbeitet.

Große, cloudbasierte Modelle können eine schwache Repräsentation zum Teil durch ihre schiere Größe ausgleichen. Bei kleinen, lokal betriebenen Modellen fällt dieser Ausgleich weg, und die Repräsentation

wird zum entscheidenden Hebel. Die Entscheidung über sie fällt früh im Entwurf, hat weitreichende Folgen und wird bislang ohne belastbare Grundlage getroffen. Diese Grundlage zu schaffen, ist das praktische Anliegen der Arbeit.

Daneben berührt die Frage ein allgemeineres Problem. Jede Anwendung, die strukturierte und visuelle Information in einem Agenten zusammenführt, muss damit umgehen, dass sich beide Informationsarten ergänzen, aber auch gegenseitig verdrängen können. Welcher Fall eintritt, ist auch über den hier untersuchten Anwendungsfall hinaus offen [1, 2].

1.3 Zielsetzung und Forschungsfragen

Ziel der Arbeit ist es, empirisch zu bestimmen, welche Repräsentationsform einen lokal betriebenen Agenten bei der natürlichsprachlichen Szenenmanipulation am zuverlässigsten unterstützt. Dazu dienen zwei Forschungsfragen.

Forschungsfrage 1 (RQ1). Welchen Einfluss hat die Form der Szenenrepräsentation, strukturell, visuell oder hybrid, auf den Ausführungserfolg der natürlichsprachlichen Szenenmanipulation durch einen lokal betriebenen Agenten, und zwar aufgeschlüsselt nach der Art der sprachlichen Referenz?

Forschungsfrage 2 (RQ2). Lässt sich das Zusammenspiel der strukturellen und der visuellen Schicht allein durch die Gestaltung der Instruktion so steuern, dass die hybride Repräsentation die Stärken beider Schichten vereint?

Einzigste Zielgröße ist der Ausführungserfolg. Er wird je Lauf binär aus dem tatsächlichen Szenenzustand bestimmt und setzt zweierlei voraus: Das gemeinte Objekt muss betroffen sein, und das geforderte Ergebnis muss eintreten, bei Positionsaufgaben innerhalb einer festen Toleranz. Ein kontinuierlicher Lagefehler gehört nicht zur Zielgröße und wird nicht berichtet; Abschnitt 6.3 legt das Maß im Einzelnen fest.

Zusätzlich entsteht ein Demonstrator, der die auf dem untersuchten Szenarioset zuverlässigste Variante in die immersive Zielumgebung überträgt. Er beantwortet keine eigene Forschungsfrage, wird nicht eigenständig evaluiert und soll lediglich die praktische Machbarkeit zeigen.

Der Anspruch der Arbeit ist bewusst begrenzt. Sie beansprucht weder eine Generalisierung auf andere Modelle oder auf reale, komplexe Szenen noch eine global optimale Lösung oder einen produktreifen Demonstrator. Die Ergebnisse gelten für ein lokales Modellpaar in kontrolliert aufgebauten Szenen. Gemessen wurde ausschließlich am Desktop; die immersive Umgebung ist Zielumgebung des Demonstrators, nicht Gegenstand der Messung.

1.4 Methodisches Vorgehen

Die Arbeit geht empirisch vor. Grundlage ist ein prototypisches System, das dieselbe Szene in den drei zu vergleichenden Repräsentationsformen bereitstellt und über ein gemeinsames Interface manipulierbar macht. Mit diesem System werden die Formen unter gleichen Bedingungen an kontrolliert aufgebauten Szenarien gegeneinander gemessen. Ob eine Manipulation gelungen ist, wird aus dem tatsächlichen Zustand der Szene bestimmt und nicht aus der Selbstauskunft des Agenten, und jede Messung wird wiederholt, um zufällige von belastbaren Unterschieden zu trennen.

Daraus ergeben sich drei Beiträge, die Abschnitt 7.3 wieder aufgreift und in ihrer Reichweite einordnet. Inhaltlich zeigt die Arbeit an einem kontrollierten Fall, dass sich strukturelle und visuelle Information nicht von selbst ergänzen und ihre Verbindung gestaltet werden muss. Methodisch führt sie eine nach Referenztypen aufgeschlüsselte Auswertung ein, die exklusive Zuständigkeiten der Repräsentationen sichtbar macht, die ein pauschaler Vergleich verdecken würde. Praktisch liefert sie einen lauffähigen Demonstrator, der die gesamte Kette bis in die immersive Zielumgebung überträgt.

1.5 Aufbau der Arbeit

Kapitel 2 führt die begrifflichen Grundlagen ein, ordnet die Arbeit in den Stand der Technik ein und bestimmt die Forschungslücke. Kapitel 3 leitet daraus ab, was ein System leisten muss, um die Forschungsfragen beantworten zu können. Kapitel 4 entwickelt das Lösungskonzept, insbesondere den Entwurfsraum der drei Repräsentationsformen und die Entscheidungen, die einen fairen Vergleich ermöglichen. Kapitel 5 beschreibt die technische Umsetzung, Kapitel 6 den Vergleich und seine Ergebnisse zu beiden Forschungsfragen. Kapitel 7 fasst die Erkenntnisse zusammen, ordnet ihre Grenzen ein und nennt offene Fragen.

Kapitel 2

Grundlagen und Stand der Technik

Dieses Kapitel führt zunächst die eingesetzten Modelle, das Agenten-Paradigma und die Formen der Szenenrepräsentation ein und ordnet die Arbeit anschließend in den Stand der Technik ein.

2.1 Große Sprach- und Sprach-Bild-Modelle

Die Arbeit setzt zwei Arten vortrainierter Modelle als Bausteine ein, die unverändert genutzt und nicht weiterentwickelt werden.

Ein großes Sprachmodell, im Folgenden als LLM (Large Language Model) bezeichnet, ist ein auf umfangreichen Textmengen trainiertes neuronales Modell, das zu einer Eingabe fortlaufend Text erzeugt. Durch zusätzliches Training auf Instruktionen lässt es sich anweisen, eine Aufgabe zu bearbeiten, und gibt seine Antwort wiederum als Text aus. In dieser Arbeit übernimmt ein LLM die Rolle des Agenten, der einen Befehl interpretiert und die passende Operation auswählt.

Ein Sprach-Bild-Modell, im Folgenden als VLM (Vision-Language Model) bezeichnet, erweitert dieses Prinzip um eine visuelle Eingabe. Es verarbeitet ein Bild zusammen mit einem Text und erzeugt daraus eine textuelle Antwort, etwa eine Beschreibung des Bildinhalts oder die Antwort auf eine Frage zum Bild. In dieser Arbeit übernimmt ein VLM die visuelle Wahrnehmung der Szene.

Die beiden Modelle sind im hier untersuchten System nicht zu einem multimodalen Modell verschmolzen, sondern hintereinandergeschaltet. Das Sprach-Bild-Modell erhält das gerenderte Bild und erzeugt daraus eine natürlichsprachliche Beschreibung. Erst diese Beschreibung gelangt in den Kontext des Sprachmodells, das den Befehl deutet und die Operation wählt. Das Modell, das die eigentliche Entscheidung trifft, sieht also zu keinem Zeitpunkt ein Bild.

Diese Eigenschaft des Aufbaus ist für die Deutung aller späteren Ergebnisse wichtig. Was in dieser Arbeit „visuelle Repräsentation“ heißt, ist streng genommen keine Bildeingabe, sondern die sprachliche Beschreibung eines Bildes. Ist später von der Gewichtung der strukturellen gegenüber der visuellen Schicht die Rede, konkurrieren daher nicht Bild und Text im Inneren eines multimodalen Modells, sondern zwei Textquellen im Kontext eines reinen Sprachmodells: eine exakte, aber unvollständige Datenstruktur und eine reichhaltige, aber unscharfe Beschreibung. Die konkrete Umsetzung zeigt Abschnitt 5.4, die Folgen für die Befunde diskutiert Abschnitt 6.6.

Beide Modelle werden lokal im Sinne der Definition aus Abschnitt 1.1 betrieben und haben eine Größe von jeweils etwa sieben Milliarden Parametern. Die Gründe für den lokalen Betrieb nennt Abschnitt 1.2.

2.2 Werkzeugnutzende Agenten

Die Interaktion mit der Szene folgt dem Muster eines werkzeugnutzenden Agenten. Darunter versteht man ein Sprachmodell, das nicht nur Text erzeugt, sondern in einer Schleife aus Wahrnehmung und Handlung Werkzeuge aufruft, um eine Aufgabe zu lösen.

Ein Werkzeug ist eine benannte Funktion mit einer kurzen Beschreibung ihrer Wirkung und ihrer Parameter. Anhand dieser Beschreibung entscheidet das Sprachmodell, welches Werkzeug es mit welchen Argumenten aufruft. Das Ergebnis des Aufrufs fließt in den Kontext zurück, und das Modell wählt den nächsten Schritt, bis es die Aufgabe als abgeschlossen meldet. So verbindet der Agent die sprachliche Interpretation eines Befehls mit konkreten Aktionen in der Umgebung.

Umgesetzt wird der Agent mit dem Framework *smolagents*, das einen werkzeugaufrufenden Agenten bereitstellt [3]. Die Werkzeuge sind über das Model Context Protocol (MCP) angebunden, einen offenen Standard, über den Sprachmodelle auf externe Werkzeuge und Datenquellen über eine einheitliche Schnittstelle zugreifen [4]. Das Protokoll trennt die Bereitstellung der Werkzeuge von ihrer Nutzung, sodass dieselben Werkzeuge unabhängig vom konkreten Modell aufgerufen werden können. Wie das System dieses Muster umsetzt, beschreibt Kapitel 5.

2.3 Szenenrepräsentation für Sprachmodelle

Damit ein Sprachmodell eine Szene verändern kann, muss es sie zunächst erfassen, und da es auf Text arbeitet, muss die dreidimensionale Szene in eine dafür zugängliche Form gebracht werden. Dafür gibt es zwei grundlegende Ansätze.

Der strukturelle Ansatz beschreibt die Szene als Daten. Die Objekte werden mit Eigenschaften wie Typ, Position, Größe und Farbe in textueller Form aufgeführt, etwa als JSON oder als Szenengraph. Diese Darstellung ist exakt und für ein Sprachmodell unmittelbar lesbar, gibt aber nur wieder, was in den Daten kodiert ist.

Der visuelle Ansatz stellt die Szene als gerendertes Bild bereit, das ein Sprach-Bild-Modell interpretiert. Er erfasst das Aussehen der Szene, wie es sich einem Betrachter zeigt, liefert aber keine exakten Koordinaten. Hinzu kommt, dass ein Modell ein im Bild erkanntes Objekt benennen können muss, um es danach gezielt anzusprechen. Verbreitet ist dafür das Set-of-Mark-Prompting, bei dem sichtbare Objekte im Bild mit nummerierten Marken versehen werden [5]. Das Modell kann sich dann auf eine Marke beziehen, deren Nummer sich eindeutig einem Objekt zuordnen lässt.

Wie schwierig eine Aufgabe ist, hängt unabhängig von der Repräsentationsform auch davon ab, wie der Befehl auf ein Objekt verweist. Bestehende Arbeiten unterscheiden Referenzen etwa danach, ob sie vom Blickwinkel des Betrachters abhängen oder ob das Zielobjekt in der Szene eindeutig ist [6, 7]. Von solchen Einteilungen geht die feinere Aufschlüsselung nach Referenztypen aus, die Abschnitt 6.2 einführt.

2.4 Stand der Technik

Die einzelnen Bausteine der Arbeit sind gut erforscht. Dieser Abschnitt ordnet die Arbeit in vier angrenzende Forschungsfelder ein und zeigt jeweils, wo sich deren Fragestellung von der hier untersuchten unterscheidet.

2.4.1 Strukturelle Szenenmanipulation in immersiven Umgebungen

Ein erstes Feld befasst sich mit der sprachgesteuerten Manipulation von Szenen in virtuellen und gemischten Realitäten. LLMR erzeugt und verändert interaktive Mixed-Reality-Szenen zur Laufzeit, indem es mehrere Sprachmodelle orchestriert und die Szene als strukturierten Graphen führt [8]. VR Mover manipuliert Objekte in der virtuellen Realität über natürliche Sprache und kodiert die Szene

dazu als strukturierte Objektdaten [9]. Beide Arbeiten zeigen, dass sich Szenen in immersiven Umgebungen sprachlich verändern lassen, nutzen dafür aber ausschließlich die strukturelle Repräsentation und große, cloudbasierte Modelle. Verschiedene Repräsentationsformen vergleichen sie nicht.

2.4.2 Hybrides Grounding

Ein zweites Feld verbindet strukturelle und visuelle Information, um ein Objekt in einer Szene zu bestimmen. SeeGround stellt eine Szene als Kombination aus einer gerenderten Ansicht und einer räumlich angereicherten textuellen Beschreibung dar und verknüpft beide über visuelle Marken [10]. Konzeptionell steht dieser Ansatz der vorliegenden Arbeit am nächsten, verfolgt aber ein anderes Ziel: Er dient dem Auffinden eines Objekts, nicht seiner Manipulation, setzt ein großes Modell ein und stellt die Repräsentationsformen nicht als gleichwertige Bedingungen einander gegenüber.

Ähnlich geht SceneGraphGrounder vor, das das Auffinden eines Objekts als strukturiertes Graph-Matching formuliert [11]. Ein visuelles Modell leitet dabei über eine Marker-Strategie die Beziehungen zwischen Objekten aus zweidimensionalen Ansichten ab, die anschließend in einen persistenten Szenengraphen überführt werden. Die Autoren berichten, dass eine explizite strukturelle Repräsentation die Grounding-Genauigkeit verbessert, was zeigt, dass die Verbindung beider Informationsarten aktiv verfolgt wird. Wie SeeGround bleibt die Arbeit aber beim Auffinden von Objekten und setzt strukturelle und visuelle Information von vornherein gemeinsam ein, statt sie als getrennte Repräsentationsformen gegeneinander zu prüfen.

2.4.3 Modalitäts-Ablationen und Modalitäts-Dominanz

Ein drittes Feld untersucht, wie sich verschiedene Eingabemodalitäten auf die Leistung auswirken. Die Arbeit zum Embodied Agent Interface vergleicht unter anderem eine rein strukturelle, eine rein visuelle und eine kombinierte Eingabe und zeigt, dass strukturierter Input reine Bildeingabe deutlich übertrifft [12]. Der Vergleich betrifft allerdings die Handlungsplanung, nicht die Szenenmanipulation, und schlüsselt die Aufgaben nicht nach Referenztypen auf. In eine ähnliche Richtung weist SIRI-Bench, ein Benchmark für räumliches Schließen [13]. In einer kontrollierten Ablation werden dort baugleiche Modelle einmal mit textueller und einmal mit visueller Eingabe derselben Aufgabe verglichen. Die textbasierten Varianten übertreffen ihre videobasierten Gegenstücke deutlich; die Modelle stützen sich übermäßig auf textuelle Hinweise und gewinnen räumliche Information nur schwer aus dem visuellen Eingang. Das stützt aus einer anderen Domäne die auch in dieser Arbeit beobachtete Tendenz, dass strukturierte Information bei räumlichen Aufgaben gegenüber rein visueller im Vorteil ist, betrifft aber abstrakte Reasoning-Aufgaben statt der Manipulation einer 3D-Szene und unterscheidet keine Referenztypen.

Eng verwandt sind zwei Arbeiten zur Modalitäts-Dominanz. Sie zeigen, dass Sprach-Bild-Modelle textuelle gegenüber visueller Information übergewichten und bei widersprüchlichen Eingaben eher dem Text vertrauen [1, 2]. Eine der beiden Arbeiten untersucht dabei auch ein Modell derselben Familie, aus der das hier eingesetzte visuelle Modell stammt [2].

Auf die vorliegende Untersuchung lassen sich diese Befunde allerdings nur als Analogie übertragen. Beide Arbeiten betrachten die Gewichtung von Bild gegen Text *innerhalb* eines multimodalen Modells, dem beide Modalitäten zugleich vorliegen. In der hier verwendeten zweistufigen Pipeline sieht das entscheidende Sprachmodell dagegen gar kein Bild, sondern zwei Textquellen (Abschnitt 2.1). Der Konflikt besteht also zwischen einer präzisen, maschinell erzeugten Datenstruktur und einer sprachlich vagen Schilderung derselben Szene. Eine direkte Erwartung für diesen Aufbau begründen die Arbeiten daher nicht; sie legen aber als strukturell ähnliches Muster nahe, dass eine naive Kombination beider Quellen die präzisere von beiden überbewerten könnte. Wo sich spätere Kapitel auf diese Literatur beziehen, gilt diese Einschränkung.

2.4.4 Ansätze mit lokalen, kleinen Modellen

Ein viertes Feld setzt lokal betreibbare Modelle geringer Größe ein, meist aus Gründen des Datenschutzes, der Latenz oder der Offline-Fähigkeit. Ein Ansatz zur Handlungsplanung nutzt ein lokales Modell mit sieben Milliarden Parametern und zeigt, dass sich solche Aufgaben grundsätzlich auch mit kleinen Modellen bearbeiten lassen [14]. Ein weiterer löst das Auffinden von Objekten in 3D-Szenen mit einem kleinen visuellen Modell [15]. Beide belegen die Machbarkeit unter Ressourcenbeschränkung, vergleichen aber nicht mehrere Repräsentationsformen für die Szenenmanipulation. Welche Repräsentation eine natürlichsprachliche Manipulation unter diesen Bedingungen am zuverlässigsten trägt, ist damit offen.

2.5 Forschungslücke

Strukturelle und visuelle Repräsentation sind jeweils für sich etabliert. Es gibt Arbeiten zur sprachgesteuerten Manipulation von Szenen, zum hybriden Auffinden von Objekten, zur Wirkung einzelner Modalitäten und zum Einsatz kleiner, lokal betreibbarer Modelle. Keine bekannte Arbeit verbindet jedoch die folgenden vier Eigenschaften: Sie befasst sich mit der natürlichsprachlichen Manipulation einer Szene und nicht nur mit deren Verständnis, dem Auffinden von Objekten oder der Erzeugung von Szenen; sie vergleicht strukturelle, visuelle und hybride Repräsentation als gleichwertige Bedingungen; sie schlüsselt die Aufgaben nach der Art der sprachlichen Referenz auf; und sie setzt kleine, lokal betreibbare Modelle statt großer Cloud-Modelle ein.

Offen ist damit, wie eine Szene einem lokal betriebenen Agenten für die natürlichsprachliche Manipulation bereitgestellt werden sollte und welchen Einfluss die Repräsentationsform auf den Ausführungserfolg hat. Insbesondere ist unklar, ob eine hybride Kombination die Stärken beider Repräsentationen vereint oder ob bei einem kleinen, lokalen Modell eine Quelle die andere verdrängt. Hier setzen die beiden Forschungsfragen aus Abschnitt 1.3 an.

Kapitel 3

Anforderungen

Die Anforderungen an das System stammen nicht aus einem vorgegebenen Lastenheft, sondern aus dem wissenschaftlichen Ziel der Arbeit und den Bedingungen, unter denen sie entstanden ist. Das Kapitel legt zunächst diese Quellen offen, beschreibt dann die funktionalen und nicht-funktionalen Anforderungen und die Zielkonflikte zwischen ihnen und grenzt zuletzt ab, was bewusst nicht gefordert ist.

3.1 Herleitung der Anforderungen

Da die Arbeit kein Auftragsprojekt mit externem Auftraggeber ist, gibt es keinen klassischen Anforderungskatalog, und auch mit der Betreuung wurden keine formalen Anforderungen im Einzelnen festgelegt. Die Anforderungen werden deshalb aus vier Quellen abgeleitet.

Den Ausgangspunkt bilden die Forschungsfragen. Das System soll den Einfluss der Repräsentationsform auf die natürlichsprachliche Szenenmanipulation messbar machen und muss dazu mehrere Repräsentationsformen bereitstellen und unter fairen Bedingungen vergleichbar machen. Hinzu kommt die Zielumgebung. Die Arbeit ist auf eine immersive Anwendung ausgerichtet, in der Datenschutz, geringe Latenz und Unabhängigkeit von einer Netzverbindung zählen. Das legt lokal betriebene Modelle nahe und verlangt, dass sich die Verarbeitungskette bis in die Brille übertragen lässt.

Aus der wissenschaftlichen Methodik folgt, dass die Messungen reproduzierbar und die Erfolgsbewertung objektiv sein müssen, was sich auf die Kontrolle der Szenen und die Art der Erfolgsmessung auswirkt. Schließlich ist die Hardware vorgegeben. Zur Verfügung stand ein vom Institut bereitgestellter Arbeitsplatzrechner mit einer einzelnen Grafikkarte. Diese Ausstattung war eine feste Randbedingung und keine Entwurfsentscheidung; sie begrenzt die Größe der einsetzbaren Modelle und prägt damit mehrere der folgenden Anforderungen.

3.2 Funktionale Anforderungen

Zunächst muss das System einen natürlichsprachlichen Befehl entgegennehmen und in eine Veränderung der Szene umsetzen. Die Operationen beschränken sich dabei auf das Erzeugen, Verschieben und Entfernen von Objekten. Mit diesen wenigen Operationen lassen sich bereits alle für die Untersuchung nötigen Arten von Referenzen abdecken, ohne den Funktionsumfang unnötig auszuweiten.

Kern der Untersuchung ist, dass das System die Szene in den drei zu vergleichenden Repräsentationsformen bereitstellt, also strukturell, visuell und hybrid. Damit der Vergleich fair bleibt, müssen alle Varianten Objekte über dasselbe Interface ansprechen, also über ein gemeinsames Kennungssystem. Warum das für die Fairness wesentlich ist, begründet Abschnitt 4.3 zusammen mit den übrigen Entwurfsentscheidungen.

Der Erfolg einer Manipulation muss objektiv bestimmbar sein. Dazu muss das System den tatsächlichen Zustand der Szene nach einer Manipulation auslesen können, sodass sich der Erfolg unabhängig von der Selbstauskunft des Agenten ermitteln lässt. Hintergrund ist die Beobachtung, dass ein kleines Modell einen Erfolg melden kann, den es nicht erreicht hat; eine Messung anhand seiner eigenen Antwort wäre damit unzuverlässig. Außerdem muss sich jedes Testszenario reproduzierbar aufbauen und zurücksetzen lassen, damit Messungen unter identischen Bedingungen wiederholbar sind.

Tabelle 3.1 fasst die funktionalen Anforderungen zusammen; die Spalte Herkunft gibt an, ob eine Anforderung aus den Forschungsfragen oder aus methodischen Gründen folgt.

Tabelle 3.1: Funktionale Anforderungen.

Nr.	Anforderung	Herkunft
FA1	Natürlichsprachliche Befehle in Szenenmanipulationen umsetzen, beschränkt auf Erzeugen, Verschieben und Entfernen von Objekten	RQ1, RQ2
FA2	Die Szene in struktureller, visueller und hybrider Repräsentation bereitstellen	RQ1
FA3	Objekte über ein gemeinsames Kennungssystem ansprechen, unabhängig von der Repräsentationsform	Validität
FA4	Den Erfolg einer Manipulation aus dem tatsächlichen Szenenzustand bestimmen	Validität
FA5	Testszenarien reproduzierbar aufbauen und zurücksetzen	Methodik

3.3 Nicht-funktionale Anforderungen

Die nicht-funktionalen Anforderungen betreffen Eigenschaften und Randbedingungen des Systems als Ganzes.

Aus der Zielumgebung folgt, dass die Modelle lokal betrieben werden, im Sinne der Definition aus Abschnitt 1.1: selbst gehostet auf eigener Hardware und ohne Cloud-Dienst, aber nicht notwendigerweise auf dem Endgerät. Damit verbunden ist die Beschränkung auf die vorgegebene Hardware. Das System muss mit dem Grafikspeicher einer einzelnen Karte auskommen, und zwar so, dass Sprachmodell und visuelles Modell gleichzeitig im Speicher gehalten werden können. Das legt die Wahl auf Modelle geringer Größe fest.

Damit die Untersuchung aussagekräftig ist, müssen sich unter identischer Konfiguration vergleichbare Ergebnisse einstellen, was kontrollierte und wiederholbar aufgebaute Szenen voraussetzt. Da die eigentliche Zielumgebung die immersive Anwendung ist, muss dieselbe Verarbeitungskette sowohl am Desktop für die Messung als auch in der Brille laufen, ohne dass ihr Kern verändert wird. Schließlich muss die Repräsentationsform die einzige Größe sein, die zwischen den Varianten variiert, weil sich Unterschiede nur dann eindeutig auf die Repräsentation zurückführen lassen. Tabelle 3.2 fasst die nicht-funktionalen Anforderungen zusammen.

NFA5 ließ sich in der Umsetzung nicht vollständig einhalten. Die priorisierende hybride Variante unterscheidet sich von den beiden anderen hybriden Varianten nicht nur in der Instruktion, sondern auch in der Reihenfolge, in der die beiden Schichten im Kontext erscheinen. Für den Vergleich der hybriden Varianten untereinander ist NFA5 daher nur eingeschränkt erfüllt, für den Vergleich von strukturell, visuell und hybrid dagegen vollständig (Abschnitt 6.6).

Tabelle 3.2: Nicht-funktionale Anforderungen.

Nr.	Anforderung	Herkunft
NFA1	Modelle lokal, das heißt selbst gehostet und ohne Cloud, betreiben	Zielumgebung
NFA2	Mit der vorgegebenen Hardware, einer einzelnen Grafikkarte, und Modellen geringer Größe auskommen	Hardware
NFA3	Messungen unter identischer Konfiguration reproduzierbar halten und die Konfiguration vollständig dokumentieren	Methodik
NFA4	Dieselbe Verarbeitungskette am Desktop und in der immersiven Umgebung betreiben	Zielumgebung
NFA5	Die Repräsentationsform als einzige zwischen den Varianten variiierende Größe sicherstellen	Validität

3.4 Zielkonflikte zwischen den Anforderungen

Die Anforderungen lassen sich nicht alle zugleich maximieren. Am deutlichsten ist der Konflikt zwischen Leistungsfähigkeit und Ressourcen: Mit großen Modellen wären natürlichsprachliche Befehle leichter zuverlässig umzusetzen, die Vorgabe kleiner lokaler Modelle begrenzt dagegen, was das System leisten kann. Dieser Konflikt wird bewusst in Kauf genommen, denn untersucht werden soll ja das Verhalten unter dieser Beschränkung.

Ähnlich verhält es sich mit Fairness und Reproduzierbarkeit auf der einen und Praxisnähe auf der anderen Seite. Das gemeinsame Kennungssystem und die einfachen, kontrolliert aufgebauten Szenen sind für einen sauberen und wiederholbaren Vergleich nötig, entfernen die Aufgabe aber ein Stück von einer realistischen Anwendung mit komplexen, realen Szenen. In diesen Fällen hat die wissenschaftliche Kontrolle Vorrang, weil das Ziel der Arbeit eine belastbare Erkenntnis und kein fertiges Produkt ist. Die Übertragung in die reale Umgebung bleibt dem Demonstrator vorbehalten.

3.5 Abgrenzung des Funktionsumfangs

Entsprechend der Abgrenzung in Abschnitt 1.3 ist einiges bewusst nicht gefordert. Das System muss keine Produktreife erreichen; es genügt, die untersuchten Repräsentationen und die Kette bis in die immersive Umgebung funktionsfähig zu machen, ohne Robustheit unter Dauerlast oder eine ausgereifte Bedienung. Die Manipulationen bleiben auf Erzeugen, Verschieben und Entfernen beschränkt, Drehen oder Skalieren zur Laufzeit gehören nicht zur Untersuchung. Ebenso wenig muss das System beliebige oder mehrdeutige Formulierungen zuverlässig auflösen: Die Befehle sind für die Untersuchung klar formuliert, Robustheit gegenüber umgangssprachlicher Vielfalt ist kein Ziel. Eine Nutzerstudie ist nicht vorgesehen, da die Bewertung rein systembasiert aus dem Szenenzustand erfolgt. Gefordert ist schließlich auch keine Übertragbarkeit auf andere Modelle oder auf reale, komplexe Szenen, da die Untersuchung auf ein Modellpaar und kontrolliert aufgebaute Szenen begrenzt ist.

Kapitel 4

Konzept

Dieses Kapitel entwickelt aus den Anforderungen das Lösungskonzept. Nach einem Überblick beschreibt es den Entwurfsraum der drei Repräsentationsformen, die Entwurfsentscheidungen für einen fairen Vergleich, die Idee zur Steuerung der hybriden Form und die Begründung dafür, den Erfolg nach Referenztypen getrennt zu betrachten. Die technische Umsetzung folgt in Kapitel 5.

4.1 Lösungsansatz im Überblick

Der Lösungsansatz beruht auf einem sprachgesteuerten Agenten. Er nimmt einen natürlichsprachlichen Befehl entgegen, verschafft sich über eine Repräsentation ein Bild der Szene und verändert sie über eine feste Menge von Operationen. Der entscheidende Freiheitsgrad des Entwurfs ist die Form, in der dem Agenten die Szene bereitgestellt wird, und diese Form ist zugleich der Untersuchungsgegenstand.

Die Arbeit geht in drei Schritten vor. Zuerst werden verschiedene Repräsentationsformen unter gleichen Bedingungen verglichen, um ihren Einfluss zu bestimmen (RQ1). Danach wird untersucht, ob sich die Kombination der Repräsentationen gezielt verbessern lässt (RQ2). Zuletzt wird die beste Variante in die immersive Zielumgebung übertragen und dort als Demonstrator erprobt, um die Übertragbarkeit zu zeigen.

4.2 Repräsentationsformen

Der Entwurfsraum umfasst drei Formen, in denen die Szene dem Agenten bereitgestellt werden kann.

Die strukturelle Form beschreibt die Szene als exakte Daten. Sie kennt die Objekte mit Kennungen, Typen, Positionen und Größen und ist damit stark bei allem, was sich aus diesen Daten ableiten lässt, etwa bei geometrischen Beziehungen. Was in den Daten nicht kodiert ist, bleibt ihr verborgen.

Die visuelle Form beschreibt die Szene über eine gerenderte Ansicht, die ein visuelles Modell interpretiert. Sie erfasst das Aussehen der Szene und ist damit stark bei Eigenschaften, die nur im Bild erkennbar sind, liefert aber keine exakten Koordinaten. Wie in Abschnitt 2.1 beschrieben, erreicht sie das entscheidende Sprachmodell nur als sprachliche Beschreibung, die das Sprach-Bild-Modell aus dem Bild erzeugt.

Die hybride Form stellt beide Schichten zugleich bereit und erlaubt damit, exakte Geometrie und Aussehen gemeinsam zu berücksichtigen. Im Kontext des Sprachmodells treffen in ihr eine exakte, aber unvollständige Datenstruktur und eine reichhaltige, aber unscharfe Beschreibung aufeinander.

Mit diesen drei Formen sind die beiden Einzelquellen und ihre Kombination abgedeckt. Der Vergleich der Einzelformen zeigt, wofür jede Schicht zuständig ist, der Vergleich mit der hybriden Form, ob eine

Kombination die Stärken beider vereint.

Bewusst festgelegt ist der Inhalt der strukturellen Schicht. Sie enthält je Objekt Kennung, Typ, Position, Farbe und Größe sowie die Pose der Kamera, aber keine vorberechneten räumlichen Beziehungen. Eine Relation wie „links von“ muss der Agent selbst aus den Koordinaten ableiten. Andernfalls würde die Auswertung die Güte einer Vorverarbeitung messen und nicht die Eignung der Repräsentation.

4.3 Entwurfsentscheidungen für einen fairen Vergleich

Damit der Vergleich die Repräsentation misst und nicht einen Nebeneffekt des Aufbaus, darf keine Variante aus Gründen bevorzugt oder benachteiligt werden, die mit ihrer Repräsentation nichts zu tun haben. Drei Entwurfsentscheidungen dienen diesem Zweck.

Alle Varianten sprechen Objekte über dieselben Kennungen an. Eine Kennung ist dabei nur ein Adressierungsmittel und kein Bestandteil des Szenenverständnisses. Die visuelle Variante wird über Marken, die in das gerenderte Bild eingezeichnet werden, an dieselben Kennungen gebunden, nach dem Set-of-Mark-Prinzip [5]. So kann auch sie ein erkanntes Objekt benennen, ohne dadurch einen strukturellen Vorteil zu erhalten.

Für Bewegungen stellt das System neben einer absoluten auch eine relative Operation bereit, mit der sich Objekte ohne exakten Weltbezug verschieben lassen. Fehlte sie, wäre die visuelle Variante benachteiligt, weil sie keine exakten Koordinaten kennt, und dieser Nachteil ginge auf den Zuschnitt der Werkzeuge zurück, nicht auf die Repräsentation.

Schließlich wird Information gezielt weggelassen. Die unterscheidende Eigenschaft der rein perzeptuellen Aufgaben, etwa ein Oberflächenmuster, wird absichtlich nicht in die strukturelle Schicht aufgenommen. Nur so entsteht ein Fall, in dem die strukturelle Schicht prinzipiell blind ist und die exklusive Kompetenz der visuellen Schicht sichtbar werden kann.

4.4 Steuerung der Modalitätsfusion

Die hybride Form stellt beide Schichten bereit, legt aber nicht fest, wie der Agent sie gegeneinander gewichtet. Das Konzept geht davon aus, dass die bloße Verfügbarkeit beider Schichten nicht ausreicht, damit ihre Stärken auch zusammenwirken. Gestützt wird diese Annahme durch eine Analogie zu Beobachtungen, nach denen multimodale Modelle bei widersprüchlichen Eingaben der textuellen Information den Vorrang geben [1, 2]. Da hier keine Bild- und Textquelle, sondern zwei Textquellen konkurrieren (Abschnitt 2.4), lautet die Erwartung genauer, dass die exaktere Quelle die unschärfere überschreibt, auch wo nur die unschärfere die Antwort enthält. Wie die beiden Schichten dem Agenten präsentiert werden, wird damit selbst zum Entwurfsgegenstand.

Das Konzept sieht dafür zwei Strategien vor. Bei der Priorisierung wird eine der beiden Schichten für einen bestimmten Zweck für maßgeblich erklärt und in den Vordergrund gestellt. Bei der Kompetenztrennung erhalten die beiden Schichten getrennte Zuständigkeiten, sodass jede nur für den Teil der Aufgabe herangezogen wird, für den sie geeignet ist.

Beide Strategien wirken ausschließlich über die Instruktion; die Modelle werden nicht nachtrainiert, ihre Gewichte bleiben unverändert. Diese Beschränkung ist gewollt. Sie hält den Vergleich sauber, weil sich nur der Kontext ändert, und sie passt zur Fragestellung, die nach der Repräsentation und nicht nach einer Modellanpassung fragt. Wie die beiden Strategien konkret formuliert sind, beschreibt Kapitel 5.

4.5 Differenzierung nach Referenztyp

Ob eine Repräsentation eine Aufgabe lösen kann, hängt davon ab, wie der Befehl auf ein Objekt verweist. Ein Verweis über eine exakte Lage stellt andere Anforderungen als einer über eine sichtbare

Eigenschaft. Die beiden Repräsentationen sind daher nicht nur unterschiedlich stark, sondern teilweise für einander ausschließende Bereiche zuständig, und dieser Gedanke trägt das gesamte Konzept.

Manche Referenzen lassen sich nur über die strukturelle Schicht auflösen: Ein Objekt, das im Bild verdeckt ist, bleibt in den strukturellen Daten verzeichnet. Andere lassen sich nur über die visuelle Schicht auflösen: Ein Oberflächenmuster, das in den strukturellen Daten nicht vorkommt, ist nur im Bild erkennbar. Dazwischen liegt ein Bereich, in dem beide Schichten dieselbe Referenz auflösen können.

Abbildung 4.1 stellt diese Verteilung dar. Die einander ausschließenden Bereiche sind der Grund, warum eine Kombination beider Schichten überhaupt sinnvoll ist, und zugleich der Grund, den Erfolg nach Referenztypen aufzuschlüsseln statt als einen einzelnen Gesamtwert zu berichten. Die konkrete Einteilung der Referenztypen und die zugehörigen Szenarien führt Kapitel 6 ein.




Abbildung 4.1: Konzeptionelle Kompetenzverteilung der beiden Repräsentationen. Der Überlappungsbereich steht für Referenzen, die beide Schichten auflösen können, die Außenbereiche für die exklusive Kompetenz jeweils einer Schicht. Aus diesen exklusiven Bereichen ergibt sich der Nutzen des hybriden Ansatzes.

Kapitel 5

Implementierung

Dieses Kapitel beschreibt, wie das Konzept in ein lauffähiges System umgesetzt ist: den Aufbau im Überblick, die Anbindung der Szene, den Agenten mit seinen Werkzeugen, die fünf Repräsentationsvarianten und den VR-Demonstrator.

5.1 Systemüberblick

Das System verbindet einen natürlichsprachlichen Befehl mit einer sichtbaren Veränderung der 3D-Szene. Es besteht aus drei lose gekoppelten Schichten, die über festgelegte Schnittstellen kommunizieren (Abbildung 5.1).

In der obersten Schicht deutet ein Agent den Befehl und wählt die nötige Manipulation. Angetrieben wird er von einem lokal betriebenen Sprachmodell, für die visuelle Wahrnehmung greift er auf ein lokales visuelles Modell zurück. Die mittlere Schicht ist ein Server nach dem Model Context Protocol (MCP) [4]. Er stellt die Manipulationsoperationen als aufrufbare Werkzeuge bereit und übersetzt jeden Aufruf in eine Nachricht an die Umgebung; eine WebSocket-Verbindung transportiert diese Nachrichten und liefert Szenenzustand und gerenderte Bilder zurück. Die unterste Schicht ist die Umgebung selbst, die die Szene hält, darstellt und die Manipulationen ausführt. In der Evaluation läuft sie am Desktop, im Demonstrator auf der Meta Quest. Weil die Schichten nur über diese Schnittstellen verbunden sind, lässt sich die Umgebung austauschen, ohne die übrigen Schichten zu verändern, und dieselbe Kette kann für die Messung und für den Demonstrator genutzt werden.

Ein Durchlauf beginnt mit dem Befehl an den Agenten. Dieser fordert über die Werkzeuge zunächst den strukturellen Zustand oder eine gerenderte Ansicht an, entscheidet dann, welche Operation auszuführen ist, und ruft das passende Werkzeug auf. Der MCP-Server leitet den Aufruf über die WebSocket-Verbindung an die Umgebung weiter, die die Manipulation ausführt. Anschließend liest die Auswertung den neuen Szenenzustand aus und bestimmt daraus den Erfolg.

5.2 Szenenanbindung

Die Umgebung stellt die Szene in zwei Sichten bereit, einer strukturellen und einer visuellen.

Für die strukturelle Sicht führt die Umgebung intern ein Verzeichnis aller manipulierbaren Objekte und serialisiert es auf Anfrage als JSON. Die Ausgabe enthält für jedes Objekt eine eindeutige Kennung, den Objekttyp, die Farbe, die Größe und die Position sowie zusätzlich die Pose der Kamera (Listing 1). Die Kamerapose ist enthalten, damit sich auch Aufgaben lösen lassen, die sich auf den Betrachter beziehen. Eigenschaften des Aussehens, die über die Grundfarbe hinausgehen, etwa eine Oberflächentextur, fehlen dagegen; deshalb sind rein perzeptuelle Referenzen über den strukturellen Zustand nicht auflösbar.




Abbildung 5.1: Aufbau des Systems in drei Schichten und Nachrichtenfluss einer Manipulation. Durchgezogene Pfeile zeigen den Vorwärtsfluss, gestrichelte Pfeile den Rückkanal. Die Verbindung zwischen MCP-Server und Umgebung wird über WebSocket übertragen.

```

1  {
2    "type": "state",
3    "objects": [
4      {"id": "obj_1", "type": "cube", "color": "red", "x": 0.0, "y": 0.0, "z": 0.0,
5       ↪ "scale": 1.0},
6      {"id": "obj_2", "type": "sphere", "color": "blue", "x": 2.0, "y": 0.0, "z": 0.0,
7       ↪ "scale": 1.0}
8    ],
9    "camera": {
10     "position": [0.0, 1.6, -6.0],
11     "forward": [0.0, 0.0, 1.0],
12     "up": [0.0, 1.0, 0.0]
13   }
14 }

```

Listing 1: Beispiel des strukturellen Szenenzustands als JSON-Ausgabe der Umgebung.

Für die visuelle Sicht rendert die Umgebung die Szene aus der Kamera und übergibt das Bild. Damit das visuelle Modell ein erkanntes Objekt auch für einen Werkzeugaufruf benennen kann, erhält jedes sichtbare Objekt nach dem Set-of-Mark-Prinzip [5] eine gelbe, nummerierte Marke oberhalb seiner Bildposition. Eine Zuordnungstabelle übersetzt die vom visuellen Modell genannten Nummern zurück in die Objektkennungen. Beide Sichten verweisen damit auf dieselben Kennungen, sodass der Agent Objekte unabhängig von der Repräsentationsform einheitlich anspricht, wie es Abschnitt 4.3 verlangt. Abbildung 5.2 zeigt dieselbe Szene ohne und mit Marken.




Abbildung 5.2: Die visuelle Repräsentation am Beispiel einer einfachen Szene. Links die gerenderte Ansicht, wie sie die Kamera liefert. Rechts dieselbe Ansicht nach dem Set-of-Mark-Verfahren, bei dem jedes sichtbare Objekt eine nummerierte Marke trägt, über die das visuelle Modell es benennen kann. Die Marken sind reine Bezeichner; ihre Farbe ist bedeutungslos und wird bei der Auswertung ignoriert.

Eine Marke wird nur gesetzt, wenn das Objekt tatsächlich sichtbar ist. Dazu prüft ein einzelner Sichtstrahl von der Kamera zum Objektmittelpunkt, ob ein anderes Objekt die Sichtlinie unterbricht; ist das der Fall, gilt das Objekt als verdeckt und bleibt unmarkiert. Ein verdecktes Objekt fehlt dann in der visuellen Sicht vollständig, im strukturellen Zustand ist es aber weiterhin verzeichnet. Auf dieser Asymmetrie beruhen die Testfälle, in denen ein Befehl auf ein im Bild unsichtbares Objekt verweist und die Abschnitt 6.2 als eigenen Referenztyp einführt. Der Test ist binär und kennt keine Teilverdeckung. Für die verwendeten Szenen, in denen ein Objekt entweder frei steht oder vollständig hinter einer großen Wand liegt, reicht das aus, für dichtere Szenen nicht.

5.3 Agent und Werkzeuge

Als Agent dient ein werkzeugaufzufordernder Agent aus dem Framework *smolagents* [3]. Angetrieben wird er von einem lokal betriebenen Sprachmodell, das über eine OpenAI-kompatible Schnittstelle angesprochen wird, die LM Studio auf dem Rechner bereitstellt. In jedem Schritt der Agentenschleife entscheidet das Sprachmodell anhand des aktuellen Kontexts, welches Werkzeug mit welchen Argumenten aufgerufen wird, bis es die Aufgabe als abgeschlossen meldet. Abbildung 5.3 zeigt diesen Ablauf von der Wahrnehmung bis zur Erfolgsbestimmung. Da die Modelle nicht nachtrainiert werden, lässt sich ihr Verhalten nur über die Gestaltung des Kontexts steuern, und hier setzt die zweite Forschungsfrage an.

Die Operationen selbst stellt der MCP-Server als Werkzeuge bereit. Die manipulierenden Werkzeuge erzeugen, verschieben und entfernen Objekte oder setzen die Szene zurück, die wahrnehmenden liefern den strukturellen Zustand oder eine gerenderte Ansicht. Jedes Werkzeug trägt eine kurze Beschreibung als Dokumentationskommentar, und diese Beschreibung ist es, die der Agent bei der Wahl des nächsten Aufrufs sieht. Listing 2 zeigt den Aufbau am Beispiel des Verschiebens.




Abbildung 5.3: Ablauf einer einzelnen Manipulation. In der Agentenschleife fragt der Agent die Szene über ein Wahrnehmungswerkzeug ab, das Sprachmodell wählt die passende Operation, und das gewählte Werkzeug manipuliert das Objekt. Diese Schritte wiederholen sich, bis der Agent die Aufgabe abschließt. Danach liest die Auswertung den tatsächlichen Szenenzustand aus und bewertet daraus den Erfolg, unabhängig von der Selbstauskunft des Agenten.

```

1  @mcp.tool()
2  def move_object(object_id: str, x: float, y: float, z: float) -> str:
3      """Move an existing object (id from get_scene_state) to a new position."""
4      global _last_op
5      key = ("move", object_id, x, y, z)
6      if key == _last_op:                               # Schutz gegen doppelte Ausführung
7          return f"Skipped: identical move already applied to {object_id}."
8      _last_op = key
9      send_to_unity({"action": "move", "id": object_id, "x": x, "y": y, "z": z})
10     return f"Done: {object_id} moved to ({x}, {y}, {z})."

```

Listing 2: Beispiel einer Werkzeugdefinition (gekürzt). Der Dokumentationskommentar dient dem Agenten als Beschreibung des Werkzeugs.

Schutz gegen doppelte Ausführung

Der Erfolg einer Manipulation wird aus dem tatsächlichen Folgezustand der Szene bestimmt (Abschnitt 6.3), und damit hängt ein Detail der Werkzeuge zusammen. Das lokale Modell bündelte gelegentlich einen Manipulations- und einen Abschlussaufruf so, dass dieselbe Manipulation zweimal ausgeführt wurde. Um dieses Verhalten des Frameworks zu neutralisieren, vergleicht jedes manipulierende Werkzeug den aktuellen Aufruf mit dem unmittelbar vorangegangenen und überspringt eine identische Wiederholung (Abfrage von `_last_op` in Listing 2).

Der Schutz ist grob, denn er kann nicht unterscheiden, ob eine identische Wiederholung ein Artefakt des Frameworks ist oder vom Befehl verlangt wird. Ein Befehl, der dieselbe Operation absichtlich zweimal fordert, würde ebenfalls blockiert. In den ausgewerteten Szenarien kommt das nicht vor, da kein Soll-Ergebnis zwei identische Aufrufe erfordert; bei Mehrschritt-Befehlen ließe es sich aber nicht ausschließen.

5.4 Repräsentationsvarianten

Alle fünf Varianten teilen denselben Agenten und dieselbe Grundinstruktion. Diese verlangt, vor jeder Manipulation zuerst die Szene wahrzunehmen, keine Kennung zu erfinden, die Aufgabe mit einem einzigen Manipulationsaufruf zu lösen und danach abzuschließen. Die letzte Vorgabe ist eine Vereinfachung, die nicht zu allen Szenarien passt: Zwei Szenarien betreffen ihrem Soll-Ergebnis nach mehrere Objekte, was Abschnitt 6.6 diskutiert.

Die Varianten unterscheiden sich allein im Wahrnehmungswerkzeug, das dem Agenten zur Verfügung steht. Gesteuert wird die Gewichtung der beiden Schichten über zwei Stellen: den Dokumentationskommentar des Werkzeugs, den der Agent bei der Wahl des nächsten Aufrufs liest, und den zurückgegebenen Text, der die beiden Schichten benennt und ordnet.

Strukturelle und visuelle Variante

Die strukturelle Variante hat nur Zugriff auf den strukturellen Zustand, also auf das JSON mit Kennungen, Typen, Farben, Größen und Positionen, aber auf kein Bild. Die visuelle Variante erhält nur eine Beschreibung der gerenderten und markierten Ansicht und kennt die Objekte damit nur über ihre Marken und sichtbaren Eigenschaften, ohne exakte Koordinaten. Diese Beschreibung erzeugt das visuelle Modell aus dem Bild; das Bild selbst gelangt nie in den Kontext des Agenten (Abschnitt 2.1). Auch die hybriden Varianten kombinieren daher zwei Textquellen, den JSON-Zustand und die erzeugte Beschreibung.

Was die Beschreibung enthält, legt der Prompt fest, mit dem das visuelle Modell das Bild beschreibt (Listing 3). Er wird in allen Varianten mit visueller Schicht unverändert verwendet und ist damit ein fester, nicht variierter Teil des Aufbaus. Der Prompt weist das Modell ausdrücklich an, die Farbe der Marke zu ignorieren und die tatsächliche Objektfarbe zu berichten; diese Anweisung geht auf einen in Abschnitt 6.6 beschriebenen Störfaktor zurück.

```

1 "Each object has a yellow numbered badge floating above it. Badges are
2 labels ONLY - ignore badge color; report the actual object color. For
3 each numbered object give number, shape (cube/sphere/cylinder), color,
4 qualitative position, and a surface texture descriptor (e.g. 'striped'
5 or 'solid'). Answer ONLY as a JSON list with keys: number, shape,
6 color, position, texture."
```

Listing 3: Prompt, mit dem das visuelle Modell die gerenderte und markierte Ansicht beschreibt. Er wird zusammen mit dem Bild übergeben und ist in allen Varianten mit visueller Schicht identisch.

Zwei Eigenschaften des Prompts wirken sich auf die Ergebnisse aus. Er verlangt je Objekt fünf Angaben, nämlich Nummer, Form, Farbe, qualitative Lage und einen Texturdeskriptor, aber keine Größe; was die visuelle Schicht über Größen berichtet, steht allenfalls zufällig in der Lagebeschreibung. Außerdem nennt er als Beispiel für einen Texturdeskriptor „striped“, ein Wort, das auch in den Befehlen der perzeptuellen Szenarien vorkommt. Da alle Varianten mit visueller Schicht denselben Prompt nutzen, verschafft das keiner einzelnen Variante einen Vorteil, schränkt aber die Aussagekraft der Kategorie D ein. Auf beide Punkte kommen die Abschnitte 6.4 und 6.6 zurück.

Hybride Varianten

Die naive hybride Variante stellt beide Schichten nebeneinander. Sie gibt zuerst den strukturellen Zustand und danach die visuelle Beschreibung aus und deutet nur grob an, wofür welche Schicht gedacht ist; eine verbindliche Zuständigkeitsregel fehlt (Listing 4).

```

1 @tool
2 def get_scene_hybrid() -> str:
3     """Perceive the scene using BOTH exact structural data (ids, positions,
4     colors, sizes, camera) and a visual description. Use exact data for
5     geometry, visual data for semantics."""

```

Listing 4: Wahrnehmungswerkzeug der naiven hybriden Variante.

Die priorisierende Variante, im Code `guided`, setzt die erste Strategie aus Abschnitt 4.4 um. Sie stellt die visuelle Beschreibung voran und erklärt sie für das Aussehen als maßgeblich, während die strukturelle Schicht ausdrücklich als rein geometrisch und frei von Aussehens-Information gekennzeichnet wird (Listing 5). Das Gewicht verschiebt sich damit zugunsten der visuellen Beschreibung.

```

1 @tool
2 def get_scene_hybrid_guided() -> str:
3     """Perceive the scene using a visual description AND exact structural
4     data. The visual description is authoritative for how objects LOOK
5     (texture, pattern, whether something stands out). The structural data
6     contains ONLY geometry (positions, sizes, base colors) and does NOT
7     encode any visual surface property."""

```

Listing 5: Wahrnehmungswerkzeug der priorisierenden Variante.

Die kompetenzgetrennte Variante, im Code `surgical`, setzt die zweite Strategie um. Wie die naive Variante gibt sie den strukturellen Zustand zuerst aus, weist den Schichten aber ausdrücklich getrennte Aufgaben zu (Listing 6). Die visuelle Beschreibung dient nur dazu, das gemeinte Objekt zu bestimmen, wenn die Referenz vom Aussehen abhängt; alles Numerische, also Koordinaten, Größen, Abstände und Kamerageometrie, kommt aus der strukturellen Schicht. Von der priorisierenden Variante unterscheidet sie sich also vor allem durch diese enge, gegenseitig ausschließende Zuweisung und erst in zweiter Linie durch die Reihenfolge.

Die kompetenzgetrennte Variante wurde nicht vorab entworfen, sondern iterativ entwickelt. Ausgangspunkt war die Beobachtung, dass die naive Kombination in einem Teil der perzeptuellen Szenarien den visuellen Zugriff verliert und die Priorisierung das zwar behebt, dafür aber metrische Aufgaben schwächt. Daraus entstand die Idee, den Schichten getrennte Rollen zu geben, statt eine von ihnen zu bevorzugen. Die Formulierung wurde in mehreren Schritten geschärft, jeweils in Kenntnis der Ergebnisse der vorigen Läufe und auf demselben Szenarioset, auf dem die Variante anschließend berichtet wird. Die Spuren davon sind in Listing 6 zu sehen: „striped“ und „most salient“ kommen wörtlich in den Befehlen der Szenarien D1 und D2 vor. Was das für die Reichweite des Befundes bedeutet, diskutiert Abschnitt 6.6.

```

1  @tool
2  def get_scene_hybrid_surgical() -> str:
3      """Perceive the scene using a visual description AND exact structural
4      data, with a clear division of labor. Use the VISUAL description ONLY
5      to identify WHICH object is meant when the reference depends on
6      appearance (texture, pattern, 'striped', 'stands out', 'most salient').
7      Use the STRUCTURAL data for EVERYTHING numerical: all coordinates,
8      positions, sizes, distances, camera geometry, and to compute where to
9      move things. Every object id appears in both - match them by id.
10     Never take coordinates from the visual description; never resolve an
11     appearance-based reference from the structural data alone."""

```

Listing 6: Wahrnehmungswerkzeug der kompetenzgetrennten Variante.

Tabelle 5.1 fasst die Varianten zusammen. Sie nennt auch die Kurzbezeichnungen aus dem Code, die in den Ergebnistabellen als Spaltenköpfe erscheinen; im Fließtext werden die deutschen Bezeichnungen verwendet. An der Spalte „Im Kontext“ ist abzulesen, dass sich die priorisierende Variante von den beiden anderen hybriden Varianten auch in der Reihenfolge der Schichten unterscheidet, Instruktion und Reihenfolge also nicht getrennt variiert sind.

Tabelle 5.1: Die fünf Repräsentationsvarianten im Vergleich, mit den in den Ergebnistabellen verwendeten Kurzbezeichnungen.

Variante	Kurzform	Im Kontext	Regel zur Gewichtung
strukturell	json	nur struktureller Zustand	entfällt, keine visuelle Schicht
visuell	vlm	nur visuelle Beschreibung	entfällt, keine strukturelle Schicht
naiv hybrid	hybrid	Struktur, dann Beschreibung	grobe Zuordnung ohne verbindliche Regel
priorisierend	guided	Beschreibung, dann Struktur	Beschreibung maßgeblich fürs Aussehen, Struktur nur Geometrie
kompetenzgetrennt	surgical	Struktur, dann Beschreibung	Beschreibung nur zur Objektwahl, Struktur für alles Numerische

5.5 VR-Demonstrator

Die Evaluation lief am Desktop unter kontrollierten Bedingungen. Um zu zeigen, dass der Ansatz auch in der eigentlichen Zielumgebung funktioniert, überführt ein Demonstrator die gesamte Kette in die immersive Umgebung. Er nutzt die kompetenzgetrennte Variante, die sich in Kapitel 6 auf dem untersuchten Szenarioset als die zuverlässigste erweist. Der Demonstrator ist lokal im Sinne von Abschnitt 1.1: Alle Modelle sind selbst gehostet, kein Cloud-Dienst ist beteiligt, und keine Szenen- oder Sprachdaten verlassen das Institutsnetz. Gerechnet wird aber nicht auf der Brille, sondern auf dem Arbeitsplatzrechner, den die Brille über die unten beschriebene Netzwerkkette erreicht.

Sprachsteuerung

Der Nutzer spricht einen Befehl, und ein selbst gehostetes Whisper-Modell in der Größe `small` wandelt die Aufnahme in Text um. Es läuft auf dem lokalen Rechner auf der CPU, nimmt mit 16 kHz auf

und ist passend zur Sprache der Befehle auf englische Eingaben festgelegt. Der erkannte Text landet in derselben Kommando-Warteschlange, die auch in der Evaluation den Agenten antreibt; ein gesprochener Befehl durchläuft also dieselbe Kette wie ein Befehl im Experiment, nur mit vorgeschalteter Spracherkennung (Abbildung 5.4).

Über dieselbe Verbindung treten dabei zwei Arten von Clients auf. Die Brille ist der Renderer, der die Manipulationen ausführt und die Szene darstellt, die Sprachsteuerung der Commander, der nur Befehle einspeist. Eine Anmeldenachricht unterscheidet die beiden Rollen, damit die Befehlsquelle die Verbindung der Brille nicht verdrängt. Sobald ein Befehl in der Warteschlange liegt, arbeitet ein Worker den Agentenlauf ab und meldet der Brille Beginn und Abschluss der Verarbeitung, sodass der Nutzer sieht, dass sein Befehl gerade bearbeitet wird.

Wahrnehmung und Netzwerk

Für die visuelle Wahrnehmung braucht das visuelle Modell ein flaches, gerendertes Bild. Die Hauptkamera der Brille rendert jedoch stereoskopisch für beide Augen und liefert kein brauchbares Einzelbild. Deshalb gibt es eine eigene Aufnahmekamera, die der Kopfpose folgt, aber einfach statt stereoskopisch rendert.

Die Modelle laufen aus Ressourcengründen auf dem Arbeitsplatzrechner im Institutsnetz, den die Brille nicht direkt erreicht. Sie verbindet sich deshalb mit einem Vermittler auf einem Rechner im selben Funknetz, der die Nachrichten über ein virtuelles privates Netz an den Arbeitsplatzrechner weiterleitet. Ein mobiler Zugangspunkt umgeht dabei die Isolation gemeinsam genutzter Netze, die eine direkte Verbindung sonst unterbindet. Diese Kette ist reine Demonstrationsinfrastruktur und nicht Gegenstand der Untersuchung.

Ausbaustufen und Aufzeichnung

Zuerst entstand eine Fassung mit einem Bedienmenü in der Szene, das vordefinierte Befehle bereitstellt und bereits dieselbe Kommando-Warteschlange nutzt; die Sprachsteuerung kam später hinzu. Von dieser frühen Menüfassung gibt es eine Videoaufzeichnung aus der Sicht der Brille, die als Begleitmaterial beiliegt (Anhang A.1) und aus der das Standbild in Abbildung 5.5 stammt. Die Szene enthält einen roten Würfel links, einen gestreiften Würfel in der Mitte und eine blaue Kugel rechts; der gestreifte Würfel wird im Standbild von der Menütafel weitgehend verdeckt. Im Video werden die vordefinierten Befehle nacheinander ausgelöst, und die Manipulationen sind jeweils unmittelbar zu sehen: Der gestreifte Würfel hebt sich an, die blaue Kugel wandert nach links neben den roten Würfel, und zuletzt wird der gestreifte Würfel entfernt.

Die Aufzeichnung belegt damit die Kette von der Befehlsauswahl über Agent und MCP-Server bis zur sichtbaren Manipulation in der Brille. Die Spracheingabe ist umgesetzt und lauffähig, aber nicht aufgezeichnet und damit nicht per Video belegt.




Abbildung 5.4: Ablauf eines gesprochenen Befehls im Demonstrator. Der lokale Rechner erkennt die Sprache und leitet den Text als Commander-Nachricht weiter, der entfernte Rechner arbeitet den Agentenlauf ab, und die Brille führt die Manipulation aus und zeigt den Verarbeitungsstatus an.




Abbildung 5.5: Frühe Ausbaustufe des Demonstrators mit Bedienmenü. Links der rote Würfel, rechts die blaue Kugel; der gestreifte Würfel in der Mitte wird von der Menütabelle weitgehend verdeckt, nur sein unterer Teil ist sichtbar. Das Standbild stammt aus der Aufzeichnung in Anhang A.1, in der unter anderem „move the striped cube up“, „put the blue sphere left of the red cube“ und „delete the striped cube“ über das Menü ausgelöst werden.

Kapitel 6

Evaluation

Dieses Kapitel vergleicht die Repräsentationsformen entlang einer nach Referenztypen aufgeschlüsselten Taxonomie und bestimmt, welche Form welche Art von Referenz trägt (RQ1). Anschließend prüft es, ob sich die hybride Repräsentation allein über ihre Instruktion so gestalten lässt, dass sie die Stärken beider Schichten vereint (RQ2). Zum Schluss werden Validität und Grenzen der Ergebnisse diskutiert.

6.1 Evaluationsdesign

Verglichen werden die fünf Varianten aus Abschnitt 5.4. Sie nutzen dieselben Szenen, Befehle und Manipulationswerkzeuge und unterscheiden sich allein darin, in welcher Form die Szene dem Agenten bereitgestellt wird. Da alle Varianten Objekte über dasselbe Kennungssystem ansprechen (Abschnitt 4.3), gehen gemessene Unterschiede nicht auf einen ungleichen Werkzeugzugriff zurück. Für die Deutung ist dabei im Blick zu behalten, dass das entscheidende Sprachmodell in keiner Variante ein Bild erhält, sondern im visuellen Fall eine Beschreibung des Bildes (Abschnitt 2.1). Streng genommen werden also eine exakte Datenstruktur und eine unscharfe sprachliche Beschreibung derselben Szene verglichen.

Ob eine Manipulation gelungen ist, wird aus dem tatsächlichen Zustand der Szene nach der Ausführung bestimmt, den die Auswertung mit der Soll-Vorgabe des Szenarios vergleicht (Abschnitt 6.3). Die Selbstauskunft des Agenten bleibt unberücksichtigt, weil das lokale Modell wiederholt Erfolge meldete, die der Folgezustand nicht bestätigte (Abschnitt 6.6).

Jede Kombination aus Szenario und Variante wird zehnmal ausgeführt und der gesamte Durchlauf dreimal wiederholt, sodass jede Zelle auf 30 Läufen beruht. Berichtet wird der Mittelwert über die drei Durchläufe mit der Spanne von Minimum und Maximum, an der sich ablesen lässt, wie stark eine Zelle zwischen den Durchläufen schwankt. Für die zentralen Vergleiche werden die 30 Läufe einer Zelle zusätzlich zusammengefasst und inferenzstatistisch ausgewertet.

Ausgewertet werden dreizehn Szenarien in fünf Kategorien. Die Kategorien A, B und C umfassen je drei Szenarien, D und E nur je zwei, obwohl gerade diese beiden die inhaltlich zentralen Befunde tragen. Die Szenen bestehen aus einfachen geometrischen Grundkörpern und sind so aufgebaut, dass jedes Szenario eine bestimmte Repräsentationskompetenz isoliert. Gemessen wird am Desktop, weil sich die Szenen dort exakt kontrollieren und beliebig oft identisch wiederholen lassen; die immersive Umgebung ist nur Zielumgebung des Demonstrators. Als Sprachmodell dient Qwen2.5-7B, als visuelles Modell Qwen2.5-VL-7B, beide selbst gehostet und gemeinsam auf einer NVIDIA RTX A5000 mit 24 Gigabyte Grafikspeicher. Tabelle 6.1 führt die vollständige Konfiguration auf, die nach NFA3 für eine Wiederholung der Messung nötig ist.

Tabelle 6.1: Konfiguration der Messung, beschränkt auf die Angaben, die den Ausgang der Läufe beeinflussen. Zusammen mit dem verlinkten Code genügen sie, um die Messung zu wiederholen.

Größe	Wert
Sprachmodell	<code>qwen2.5-7b-instruct</code> , GGUF Q4_K_M, 4096 Token Kontext
Visuelles Modell	<code>qwen/qwen2.5-vl-7b</code> , GGUF Q4_K_M, 4096 Token Kontext
Hardware, Laufzeit	NVIDIA RTX A5000 mit 24 GB, LM Studio (CLI-Commit <code>efce996</code>), beide Modelle gleichzeitig geladen
Agent	<code>smolagents 1.26.0 (ToolCallingAgent)</code> unter Python 3.13, <code>max_steps = 6</code>
Dekodierung	Sprachmodell: Temperatur 0,8 (Voreinstellung der Laufzeitumgebung, im Client nicht überschrieben). Visuelles Modell: Temperatur 0,1 (im Client ausdrücklich gesetzt). Kein fester Seed
Messumfang	13 Szenarien $\times$ 5 Varianten, je 10 Läufe in 3 Durchläufen, also 30 Läufe pro Zelle
Code und Rohdaten	https://git.informatik.fh-nuernberg.de/jobboerse/forschung/bachelorarbeiten/bachelorarbeit-sandro-jaeger

Beide Modelle liegen in derselben Quantisierungsstufe vor. Eine unterschiedlich starke Quantisierung hätte die beiden Schichten ungleich beeinträchtigt und damit neben der Repräsentationsform eine weitere Störgröße eingeführt. Mit 4,68 GB und 6,04 GB belegen die Gewichte zusammen rund 10,7 GB, sodass auf der Karte Platz für den Schlüssel-Wert-Zwischenspeicher beider Modelle bleibt; erst dadurch ist der gleichzeitige Betrieb nach NFA2 möglich.

Knapp bemessen ist dagegen die Kontextlänge von 4096 Token, und sie trifft die Varianten ungleich. Zusätzlich zu Grundinstruktion, Werkzeugbeschreibungen und bisherigem Verlauf der Agentenschleife trägt die strukturelle Variante nur den JSON-Zustand im Kontext, die visuelle nur die Beschreibung, die hybriden Varianten aber beides. Für mehrere aufeinanderfolgende Schritte bleibt ihnen deshalb systematisch weniger Platz. Ob sich das in den Messungen auswirkte, etwa durch abgeschnittenen Kontext in längeren Läufen, wurde nicht überwacht und lässt sich nachträglich nicht mehr feststellen.

Unterschiedlich ist auch die Dekodierung der beiden Modelle. Das Sprachmodell, das die Entscheidung trifft, lief mit einer Temperatur von 0,8, einer Einstellung, die den Antwortraum spürbar öffnet. Die zehn Läufe einer Zelle sind damit weitgehend unabhängige Ziehungen aus einer breiten Verteilung und keine Wiederholungen derselben Antwort. Eine Zelle, die bei 0 von 30 oder bei 30 von 30 liegt, kommt also nicht dadurch zustande, dass das Modell ohnehin immer dasselbe antwortet, sondern trotz des Spielraums in der Dekodierung. Die vielen Zellen ohne Streuung sind unter dieser Bedingung ein Befund und kein Artefakt einer zu niedrigen Temperatur: Der jeweilige Effekt wirkt stärker als das Rauschen.

Das visuelle Modell lief dagegen mit einer Temperatur von 0,1 und damit nahezu deterministisch, sodass die Beschreibung einer gegebenen Szene über die Läufe hinweg weitgehend gleich ausfällt. Das ist gewollt, denn die Wahrnehmungsstufe ist Eingabe und nicht Untersuchungsgegenstand, und eine stark schwankende Beschreibung hätte eine zusätzliche Störgröße zwischen Repräsentationsform und Ergebnis geschoben. Die Streuung einer Zelle geht damit fast vollständig auf das Sprachmodell zurück, also auf die Stufe, die verglichen wird. Eine Restabhängigkeit zwischen den Läufen bleibt, weil alle Läufe einer Zelle dieselbe, nahezu unveränderliche Szenenbeschreibung nutzen; sie betrifft aber die Eingabe und nicht die gemessene Entscheidung.

6.2 Referenztyp-Taxonomie

Welche Repräsentation eine Aufgabe trägt, hängt davon ab, worauf sich der Befehl bezieht. Ein Verweis auf die Farbe eines Objekts stellt andere Anforderungen als ein Verweis auf seine Lage oder auf ein Objekt, das im Bild gar nicht zu sehen ist. Eine pauschale Antwort auf die Frage nach der besten Repräsentation gibt es deshalb nicht. Die Evaluation zerlegt die natürlichsprachliche Referenz stattdessen in fünf Typen und prüft für jeden einzeln, welche Repräsentation ihn auflösen kann. Tabelle 6.2 zeigt, in welcher Schicht die dafür nötige Information jeweils verfügbar ist.

Kategorie A ist die Kontrollbedingung. Der Befehl benennt das Zielobjekt direkt über seine Kennung, sodass die Aufgabe unabhängig von der Repräsentationsform lösbar ist; sie prüft also den Messaufbau und vergleicht nicht inhaltlich. In Kategorie B wird ein Objekt über ein Attribut wie Farbe oder Größe angesprochen, in Kategorie C über eine räumliche Relation zu einem anderen Objekt, etwa „links von“. Bei beiden lässt sich das gemeinte Objekt aus Eigenschaften oder Koordinaten bestimmen, die in den strukturellen Daten stehen.

Die Kategorien D und E bilden das eigentliche Gegensatzpaar. In D bezieht sich der Befehl auf eine rein perzeptuelle Eigenschaft, etwa ein Oberflächenmuster, das in den strukturellen Daten nicht vorkommt; das Objekt lässt sich nur über das Bild bestimmen. In E ist das Objekt im Bild verdeckt, in den strukturellen Daten aber vollständig verzeichnet, sodass es sich nur über die Struktur bestimmen lässt. An diesen beiden Polen hat jeweils nur eine Schicht Zugang zur Antwort, und an ihnen zeigt sich, ob eine Repräsentation eine Kompetenz besitzt, die der anderen grundsätzlich fehlt.

Die Unterscheidung nach Referenztypen knüpft an bestehende Arbeiten an, die Referenzen etwa nach ihrer Abhängigkeit vom Blickwinkel oder nach der Eindeutigkeit des Zielobjekts einteilen [6, 7]. Neu sind in der vorliegenden Taxonomie die rein perzeptuelle und die verdeckte Referenz als eigene Typen, ohne die sich die exklusiven Zuständigkeiten der beiden Repräsentationen nicht prüfen ließen. Tabelle 6.3 führt die konkreten Szenarien je Referenztyp auf.

Tabelle 6.2: Verfügbarkeit der zur Auflösung nötigen Information je Referenztyp und Schicht, nach Konstruktion der Szenarien. Die Zeilen D und E bilden das exklusive Gegensatzpaar.

Referenztyp	In der strukturellen Schicht	In der visuellen Schicht
A — direkt	Kennung und Zielkoordinaten vorhanden	markiertes Objekt sichtbar
B — Attribut	Attribute wie Farbe und Größe vorhanden	Aussehen sichtbar
C — relational	exakte Koordinaten vorhanden	Anordnung sichtbar
D — perzeptuell	nicht enthalten	Muster sichtbar
E — verdeckt	vollständig verzeichnet	verdeckt, nicht sichtbar

6.3 Metriken

Die Erfolgs- und Genauigkeitsmaße orientieren sich an etablierten Metriken aus der Literatur zum sprachlichen Auffinden von Objekten in 3D-Szenen [7, 6]. Primäre Kennzahl ist der Ausführungserfolg. Er ist je Lauf binär und ergibt sich allein aus dem Folgezustand der Szene, den die Auswertung nach der Manipulation mit der Soll-Vorgabe des Szenarios vergleicht. Berichtet wird die Zahl der Erfolge aus zehn Läufen, gemittelt über die drei Durchläufe mit der zugehörigen Spanne.

Was als erfüllte Vorgabe gilt, hängt vom Aufgabentyp ab. In jedem Fall muss das richtige Objekt betroffen sein: Wird ein anderes als das gemeinte Objekt verändert, ist der Lauf ein Misserfolg, auch wenn die Zielkoordinate sonst getroffen wäre. Dieses Kriterium erfasst, ob die Referenz korrekt aufgelöst wurde. Bei Aufgaben mit Zielposition muss außerdem die erreichte Position innerhalb einer festen

Tabelle 6.3: Übersicht aller ausgewerteten Szenarien mit Befehl, Ausgangsszene und Soll-Ergebnis. Die Befehle geben den real gesendeten englischen Stimulus wieder.

ID	Befehl	Ausgangsszene	Soll-Ergebnis
<i>Kategorie A — direkt / id-basiert</i>			
A1	„Spawn a red cube at x=2, y=0, z=1.“	leere Szene	roter Würfel bei (2,0,1) vorhanden
A2	„Move obj_2 to position (0, 1, 0).“	rot (0,0,0), grün (2,0,0), blau (4,0,0)	grüner Würfel (obj_2) bei (0,1,0)
A3	„Delete obj_1.“	wie A2	roter Würfel (obj_1) entfernt
<i>Kategorie B — Attribut-Referenz</i>			
B1	„Raise the red cube by 1 unit.“	rot (1,0,0), blau (3,0,0)	roter Würfel in der Höhe +1
B2	„Delete all red cubes.“	rot (0,0,0), rot (2,0,0), grüne Kugel (4,0,0)	beide roten Würfel entfernt, Kugel bleibt
B3	„Move the largest object to (0, 0, 0).“	roter Würfel Größe 0,5 (-2,0,0); grüner Größe 1,5 (0,0,3); blauer Größe 1,0 (3,0,0)	größtes Objekt (grün) bei (0,0,0)
<i>Kategorie C — räumlich-relational</i>			
C1	„Move the sphere to the left of the cube.“	blaue Kugel (1,0,0), grüner Würfel (-1,0,0)	Kugel links vom Würfel
C2 ^a	„Raise the cube nearest to the camera by 1.“	rot (-2,0,2), grün (0,0,5), blau (2,0,8)	kamera-nächster Würfel in der Höhe +1
C4	„Place the sphere exactly 2 units left of the cube.“	grüner Würfel (1,0,0), blaue Kugel (4,0,0)	Kugel bei x=-1 (genau 2 links)
<i>Kategorie D — rein perzeptuell</i>			
D1	„Raise the striped cube by 1 unit.“	zwei graue Würfel (-1,0,3) und (1,0,3); zweiter gestreift	gestreifter Würfel +1, anderer unverändert
D2	„Move the most salient object to (0, 0, 0).“	vier graue Würfel (-3/-1/3/5, 0, 4); ein gestreifter (1,0,4)	gestreifter (auffälliger) Würfel bei (0,0,0)
<i>Kategorie E — verdeckt</i>			
E1	„Raise the green cube by 1 unit.“	rot (-3,0,5); graue Wand Größe 4,0 (2,0,2); grün (2,0,6) dahinter verdeckt	verdeckter grüner Würfel +1
E2	„Raise every cube by 1 unit.“	wie E1	alle drei Würfel in der Höhe +1

Positionen als (x, y, z), wobei y die Höhe angibt. „Größe“ ist die relative Kantenlänge (Standard 1,0).

^a C2 mit seitlich versetztem Aufbau. Der ursprünglich achsenkollineare Aufbau wurde ersetzt (Abschnitt 6.6). Szenario C3 wurde aus methodischen Gründen ausgeschlossen (ebenda).

Toleranz τ um den Sollwert liegen. Bei relationalen Aufgaben muss die geforderte Lagebeziehung im Folgezustand gelten, etwa dass ein Objekt einen kleineren x-Wert besitzt als ein anderes, und beim Entfernen oder Erzeugen muss das Objekt im Folgezustand fehlen beziehungsweise vorhanden sein. Ein Lauf zählt nur als Erfolg, wenn das jeweils maßgebliche Kriterium vollständig erfüllt ist.

Die Toleranz ist auf $\tau = 0,1$ Einheiten gesetzt. Sie ist nicht aus einer externen Vorgabe übernommen, sondern für diesen Aufbau festgelegt und an zwei Größen ausgerichtet. Sie liegt deutlich unter der kleinsten in den Szenarien geforderten Verschiebung von einer Einheit, sodass eine grob danebenliegende Bewegung nicht als Treffer zählt, und über der Genauigkeit, mit der die Engine Positionen zurückmeldet, sodass numerisches Rauschen keinen korrekten Lauf verwirft. Ein Zehntel der kleinsten geforderten Distanz erfüllt beides. Wie empfindlich die Ergebnisse auf diese Wahl reagieren, wurde nicht untersucht.

Einen kontinuierlichen Lagefehler, also den Abstand zwischen erreichter und geforderter Position, berichtet die Arbeit nicht; τ geht nur als Schwelle in das binäre Kriterium ein. Nachträglich lässt er sich auch nicht mehr berechnen, weil für die metrischen Szenarien C2 und C4 die erreichten Endpositionen nicht mehr vorliegen. Das ist bedauerlich, denn gerade dort scheitern alle Varianten am binären Kriterium, und erst der Lagefehler würde zeigen, ob sie knapp danebenliegen oder die Aufgabe grundsätzlich verfehlen.

Statistische Auswertung

Mittelwert und Spanne über drei Durchläufe beschreiben, wie stabil eine Zelle ist, taugen als Entscheidungsgrundlage aber nur begrenzt. Drei Durchläufe sind eine schmale Basis, und nicht überlappende Spannen als belastbar zu werten, wäre eine Heuristik ohne Fehlerkontrolle. Für die inhaltlich zentralen Vergleiche werden deshalb die je 30 Einzelläufe einer Zelle zusammengefasst und inferenzstatistisch ausgewertet.

Da jeder Lauf binär ausgeht, ist eine Zelle durch die Zahl k der Erfolge aus $n = 30$ Läufen vollständig beschrieben. Für jede Zelle wird die Erfolgsrate k/n mit einem Wilson-Konfidenzintervall zum Niveau 95 % angegeben. Das Wilson-Intervall ist hier dem Normalapproximationsintervall vorzuziehen, weil viele Zellen bei null oder bei allen Erfolgen liegen, wo die Normalapproximation ein Intervall der Breite null liefern würde. Zwei Zellen werden mit dem exakten Test nach Fisher auf der zugehörigen Vierfeldertafel verglichen, der keine Annahmen über erwartete Zellhäufigkeiten voraussetzt und auch bei extremen Anteilen gültig bleibt.

Die dafür nötige Annahme unabhängiger Läufe ist wegen der in Abschnitt 6.1 beschriebenen Dekodierung im Wesentlichen erfüllt. Das Niveau wird nicht für multiples Testen korrigiert. Die zentralen Unterschiede sind allerdings so groß, dass keiner an einer Entscheidungsgrenze liegt; die schwächsten Vergleiche, die beiden in D2 mit $p = 0,0046$, blieben auch bei einer konservativen Korrektur bestehen.

6.4 Ergebnisse zum Einfluss der Repräsentationsform (RQ1)

Tabelle 6.4 zeigt die Ergebnisse je Szenario als Mittelwert über drei Durchläufe mit der Spanne [Minimum–Maximum], wobei jede Zelle für zehn mögliche Erfolge steht. Tabelle 6.5 fasst diese Werte je Kategorie zusammen. Die Tabellen 6.6 und 6.7 enthalten keine zusätzlichen Messungen, sondern fassen die inhaltlich tragenden Zellen als Erfolge aus je 30 Läufen mit Wilson-Konfidenzintervall zusammen und geben die exakten Tests für die Vergleiche an, auf denen die Argumentation dieses und des folgenden Abschnitts beruht.

Kategorie A: Kontrollbedingung

Bevor sich Unterschiede zwischen den Repräsentationen deuten lassen, muss feststehen, dass der Aufbau misst, was er messen soll. In Kategorie A nennt der Befehl Zielobjekt und Zielkoordinaten direkt

Tabelle 6.4: Erfolg je Szenario und Variante: Mittelwert [Min–Max] über drei Durchläufe (je $N = 10$).

Kat.	Szen.	json	vlm	hybrid	guided	surgical
A	A1	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
A	A2	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
A	A3	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
B	B1	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
B	B2	10,0 [10–10]	9,7 [9–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
B	B3	10,0 [10–10]	0,0 [0–0]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
C	C1	10,0 [10–10]	1,7 [0–3]	8,3 [7–10]	10,0 [10–10]	10,0 [10–10]
C	C2 ⁽¹⁾	0,0 [0–0]	0,0 [0–0]	0,3 [0–1]	2,7 [1–4]	2,0 [1–3]
C	C4	1,7 [0–4]	0,7 [0–2]	3,3 [3–4]	1,3 [1–2]	2,0 [1–3]
D	D1	0,0 [0–0]	10,0 [10–10]	0,7 [0–1]	8,3 [6–10]	9,7 [9–10]
D	D2	0,3 [0–1]	10,0 [10–10]	10,0 [10–10]	7,3 [6–9]	10,0 [10–10]
E	E1	10,0 [10–10]	0,0 [0–0]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
E	E2 ⁽²⁾	10,0 [10–10]	0,0 [0–0]	0,3 [0–1]	0,0 [0–0]	0,0 [0–0]

Spaltenköpfe sind die Kurzformen der Varianten nach Tabelle 5.1: **json** strukturell, **vlm** visuell, **hybrid** naiv hybrid, **guided** priorisierend, **surgical** kompetenzgetrennt.

⁽¹⁾ C2 wurde nach Entdeckung eines Störfaktors mit seitlich versetztem Aufbau neu gemessen; die Werte stammen aus dieser zweiten Messung und sind nicht mit den übrigen Zeilen im selben Durchlauf erhoben (Abschnitt 6.6).

⁽²⁾ E2 ist kein reiner Verdeckungstest. Das Soll-Ergebnis verlangt die Manipulation mehrerer Objekte und damit mehr als einen Manipulationsaufruf, was der Grundinstruktion widerspricht (Abschnitt 6.6). Die Zeile wird deshalb nicht als Repräsentationsbefund gewertet.

Tabelle 6.5: Erfolg je Kategorie als Summe der zugehörigen Szenario-Mittelwerte über drei Durchläufe. Eine Spanne wird hier nicht ausgewiesen, da sich Minimum und Maximum einer Kategorie nicht aus den Szenario-Spannen zusammensetzen lassen. Kategorie E getrennt ausgewiesen.

Kat.	max	json	vlm	hybrid	guided	surgical
A	30	30,0	30,0	30,0	30,0	30,0
B	30	30,0	19,7	30,0	30,0	30,0
C	30	11,7	2,4	11,9	14,0	14,0
D	20	0,3	20,0	10,7	15,6	19,7
E1	10	10,0	0,0	10,0	10,0	10,0
E2	10	10,0	0,0	0,3	0,0	0,0

über die *id*, eine Deutung der Szene ist nicht nötig, und bei sauberem Aufbau darf die Repräsentationsform keinen Unterschied machen. So ist es auch: Alle fünf Varianten lösen jedes der drei Szenarien in allen 30 Läufen. Kennungssystem und Werkzeugzugriff erzeugen also für sich keine variantenspezifischen Unterschiede. Abweichungen in den übrigen Kategorien lassen sich damit auf die Repräsentationsform zurückführen, soweit nicht die in Abschnitt 6.6 genannten Restkonfundierungen greifen.

Kategorie B: Attribut-Referenzen

In Kategorie B wird ein Objekt über eine Eigenschaft wie Farbe oder Größe angesprochen. Bis auf die visuelle lösen alle Varianten jedes Szenario vollständig, die visuelle erreicht 19,7 von 30. Die kleine Abweichung in B2 (9,7 von 10) liegt innerhalb der beobachteten Streuung; fast der gesamte Rückstand entsteht in B3. Dort soll das größte Objekt bewegt werden, und die visuelle Variante scheitert in allen 30 Läufen, während alle übrigen alle 30 lösen ($p = 1,7 \cdot 10^{-17}$, Tabelle 6.7).

Eine perspektivische Erklärung läge nahe, da ein weiter entferntes Objekt im Bild kleiner wirkt, als es ist. Sie wird hier aber nicht gebraucht, denn die Ursache liegt im Aufbau der Pipeline. Das Sprachmodell erhält nur die Beschreibung des visuellen Modells, und der Wahrnehmungs-Prompt fordert darin Nummer, Form, Farbe, qualitative Lage und Textur an, aber keine Größe (Listing 3). Der visuellen Variante fehlt in B3 also nicht die Wahrnehmungsfähigkeit, sondern die Information,

Tabelle 6.6: Zentrale Zellen als Erfolge aus $n = 30$ Läufen mit Wilson-95 %-Konfidenzintervall der Erfolgsrate.

Szen.	Variante	Erfolge	Wilson-95 %-KI
D1	strukturell	0/30	[0,0 %; 11,4 %]
D1	visuell	30/30	[88,6 %; 100,0 %]
D1	naiv hybrid	2/30	[1,8 %; 21,3 %]
D1	priorisierend	25/30	[66,4 %; 92,7 %]
D1	kompetenzgetrennt	29/30	[83,3 %; 99,4 %]
D2	strukturell	1/30	[0,6 %; 16,7 %]
D2	visuell	30/30	[88,6 %; 100,0 %]
D2	naiv hybrid	30/30	[88,6 %; 100,0 %]
D2	priorisierend	22/30	[55,6 %; 85,8 %]
D2	kompetenzgetrennt	30/30	[88,6 %; 100,0 %]
E1	strukturell	30/30	[88,6 %; 100,0 %]
E1	visuell	0/30	[0,0 %; 11,4 %]
B3	visuell	0/30	[0,0 %; 11,4 %]
C1	visuell	5/30	[7,3 %; 33,6 %]
C2	strukturell	0/30	[0,0 %; 11,4 %]
C2	priorisierend	8/30	[14,2 %; 44,4 %]
C4	strukturell	5/30	[7,3 %; 33,6 %]
C4	naiv hybrid	10/30	[19,2 %; 51,2 %]

nach der gefragt wird, und unter dieser Bedingung ist ein vollständiges Scheitern zu erwarten. Das Ergebnis sagt damit etwas über den Zuschnitt des Prompts aus und nichts über eine grundsätzliche Grenze visueller Repräsentationen. Ein Prompt, der auch die Größe abfragt, hätte vermutlich anders abgeschnitten; geprüft wurde das nicht. Für diesen Aufbau bleibt festzuhalten, dass eine Referenz auf die absolute Größe über die strukturelle Schicht zuverlässig und über die visuelle gar nicht aufgelöst wird.

Kategorie C: Räumlich-relationale Referenzen

In Kategorie C wird ein Objekt in Bezug auf ein anderes ausgewählt oder platziert. Über die Kategorie hinweg bricht die visuelle Variante mit 2,4 von 30 fast vollständig ein, während die strukturelle und die hybriden Varianten mit rund 12 bis 14 von 30 deutlich davor liegen. Relationale Aufgaben brauchen exakte Koordinaten, und die stehen nur in der strukturellen Schicht.

Am klarsten zeigt das C1, wo die Kugel links vom Würfel platziert werden soll. Gefordert ist nur die Richtung der Relation, also ein negativer x-Abstand zum Würfel, kein exakter Zielwert. Die strukturelle und die hybriden Varianten lösen das zuverlässig oder weitgehend, die visuelle scheitert fast durchgehend.

C4 verschärft dieselbe Aufgabe zu einer metrischen Vorgabe: Die Kugel soll exakt zwei Einheiten links vom Würfel liegen. Jetzt scheitern alle Varianten, und keine kommt über rund drei von zehn hinaus, gleich in welcher Form die Szene vorliegt. Solange nur die Richtung einer Relation zählt, entscheidet also die Repräsentation über den Erfolg; wird ein exakter metrischer Wert verlangt, wird die Präzision des Modells zur Grenze. Dazu passt, dass das Scheitern in C4 graduell ist: Alle Varianten liegen zwischen 2 und 10 Erfolgen aus 30, keine bei exakt null.

Für C2 trägt diese Lesart nicht ohne Weiteres. Der Befehl verlangt, den zur Kamera nächstgelegenen

Tabelle 6.7: Exakte Tests nach Fisher für die zentralen Vergleiche, jeweils $n = 30$ je Gruppe. Das Niveau ist nicht für multiples Testen korrigiert.

Vergleich	Erfolge	p
D1: naiv hybrid vs. visuell	2/30 vs. 30/30	$8,4 \cdot 10^{-15}$
D1: naiv hybrid vs. kompetenzgetrennt	2/30 vs. 29/30	$2,3 \cdot 10^{-13}$
D1: naiv hybrid vs. priorisierend	2/30 vs. 25/30	$1,4 \cdot 10^{-9}$
D2: priorisierend vs. naiv hybrid	22/30 vs. 30/30	0,0046
D2: priorisierend vs. kompetenzgetrennt	22/30 vs. 30/30	0,0046
D1: strukturell vs. visuell	0/30 vs. 30/30	$1,7 \cdot 10^{-17}$
E1: visuell vs. strukturell	0/30 vs. 30/30	$1,7 \cdot 10^{-17}$
B3: visuell vs. strukturell	0/30 vs. 30/30	$1,7 \cdot 10^{-17}$
C1: visuell vs. strukturell	5/30 vs. 30/30	$5,5 \cdot 10^{-12}$

Würfel um eine Einheit anzuheben, und alle Varianten bleiben schwach; die strukturelle erreicht 0 von 30. Aus den strukturellen Daten heraus ist die Aufgabe aber nicht schwer. Die drei Würfel liegen bei $(-2, 0, 2)$, $(0, 0, 5)$ und $(2, 0, 8)$, also gestaffelt entlang der z-Achse. Steht die Kamera wie in Listing 1 bei negativem z und blickt entlang der positiven z-Achse, ist der kameranächste Würfel derjenige mit dem kleinsten z-Wert, und diese Ordnung stimmt mit der euklidischen Distanzordnung überein. Das Zielobjekt ließe sich also durch den Vergleich dreier Zahlen bestimmen, ohne jede Wurzelrechnung. Zudem löst dieselbe Variante B1, eine ähnlich einfache Anhebe-Aufgabe, in 30 von 30 Läufen. Ein deterministisches Null neben deterministischer Perfektion in einer verwandten Aufgabe spricht eher für eine systematische Ursache als für ein Präzisionsproblem.

Drei Ursachen kommen in Betracht. Das Modell könnte die Referenz tatsächlich falsch auflösen, etwa indem es Kameranähe mit einer anderen Ordnung verwechselt oder die Blickrichtung ignoriert. Die Soll-Vorgabe der Auswertung könnte ein anderes Objekt als korrekt führen, als die Szenengeometrie nahelegt; ein solcher Fehler würde jeden Lauf verwerfen und das beobachtete Muster erzeugen. Schließlich könnte ein Werkzeug- oder Aufbaufehler vorliegen, etwa eine nicht übernommene Anhebung. Nur die erste Erklärung wäre ein Befund über das Modell, die beiden anderen wären Fehler des Aufbaus. Entscheiden lässt sich das nachträglich nicht, weil für C2 keine verwertbaren Aufzeichnungen der einzelnen Läufe mehr vorliegen, aus denen hervorginge, welches Objekt der Agent mit welchen Argumenten manipuliert hat. C2 wird deshalb als ungeklärter Fall geführt und nicht als Beleg für eine Modellgrenze.

Kategorie D: Rein perzeptuelle Referenzen

In Kategorie D kehrt sich das Verhältnis um. Der Befehl spricht ein Objekt über ein Oberflächenmuster an, das in den strukturellen Daten nicht vorkommt, und wer nur Koordinaten und Objekttypen kennt, kann ein gestreiftes Objekt nicht von einem einfarbigen unterscheiden. Entsprechend löst die visuelle Variante alle Läufe, 20 von 20, während die strukturelle mit 0,3 von 20 fast vollständig scheitert. War in Kategorie C die visuelle Schicht blind, so ist es hier die strukturelle.

Da der hybriden Repräsentation beide Schichten vorliegen, wäre zu erwarten, dass sie mindestens so gut abschneidet wie die bessere Einzelvariante. Das ist nicht der Fall. Die naive hybride Variante erreicht nur 10,7 von 20, und in D1 steht sie mit 2 von 30 der visuellen Variante mit 30 von 30 gegenüber ($p = 8,4 \cdot 10^{-15}$, Tabelle 6.7). Den Vorteil der visuellen Beschreibung übernimmt die Kombination dort also nicht, sie verliert ihn.

Wie dieser Verlust zu deuten ist, lässt der Aufbau offen. Naheliegend ist, dass die strukturelle Information die visuelle verdrängt, statt sie zu ergänzen. Mit den Daten ebenso vereinbar ist aber ein schlichter Reihenfolgeeffekt. In D1 stehen zwei graue Würfel bei $(-1, 0, 3)$ und $(1, 0, 3)$, und der ge-

gestreifte ist der *zweite*. Wählt der Agent systematisch das erste aufgeführte Objekt, ohne die Referenz überhaupt aufzulösen, entsteht dasselbe Muster. Dafür spricht, dass auch die strukturelle Variante 0 von 30 erreicht, obwohl blindes Raten zwischen zwei Kandidaten etwa 15 von 30 ergäbe. Bei einer Temperatur von 0,8 hätte ein auch nur teilweise zufälliges Wahlverhalten über 30 Läufe mit hoher Wahrscheinlichkeit wenigstens einen Treffer erzeugt; ein Wert von exakt null deutet daher auf eine Systematik hin, und eine Positionspräferenz ist die einfachste Systematik, die zu null führt. Auch die 2 von 30 der naiven hybriden Variante passen dazu. Zwischen Verdrängung und Reihenfolgeeffekt ließe sich nur mit einer Messung entscheiden, in der der gestreifte Würfel an erster Stelle steht, und eine solche Messung wurde nicht durchgeführt.

In D2 löst dieselbe naive Variante dagegen alle 30 Läufe. Dort steht der gestreifte Würfel bei (1, 0, 4) zwischen vier grauen Würfeln, also weder am Rand noch an erster Stelle einer nach der x-Koordinate geordneten Aufzählung. Eine reine Präferenz für das erste Objekt erklärt diesen Erfolg nicht, was die Reihenfolgehypothese schwächt, ohne sie für D1 auszuräumen. Ob die Reihenfolge im übergebenen JSON dieser räumlichen Ordnung entspricht, geht allerdings aus der Szenariodefinition nicht hervor und wäre den Protokollen zu entnehmen.

Unabhängig von der Deutung zeigt die Kategorie, dass die bloße Verfügbarkeit beider Schichten nicht über den Erfolg entscheidet, sondern die Art, wie sie kombiniert werden. Dass sich der verlorene Zugriff auf die visuelle Beschreibung über die Instruktion zurückgewinnen lässt, deuten die instruierten Varianten bereits an; Abschnitt 6.5 geht dem nach.

Kategorie E: Verdeckte Referenzen

Kategorie E prüft den umgekehrten Fall: ein Objekt, das im gerenderten Bild verdeckt, in den strukturellen Daten aber vollständig verzeichnet ist. In E1 verbirgt eine große Wand einen grünen Würfel, der angehoben werden soll. Alle Varianten mit struktureller Schicht lösen die Aufgabe in allen 30 Läufen, die visuelle in keinem, weil sie ein Objekt, das im Bild nicht erscheint, nicht ansprechen kann. E1 ist damit das Gegenstück zu Kategorie D: Dort trägt allein die visuelle Schicht, hier allein die strukturelle, und erst diese Symmetrie macht eine Kombination beider Schichten überhaupt sinnvoll.

E2 verlangt, alle Würfel der Szene anzuheben, auch den verdeckten. Die strukturelle Variante löst das in 30 von 30 Läufen, die hybriden Varianten scheitern nahezu vollständig, die visuelle ganz. Als Repräsentationsbefund lässt sich diese Zelle aber nicht werten, weil der Aufbau sich hier selbst widerspricht. Die gemeinsame Grundinstruktion verlangt, die Aufgabe mit einem einzigen Manipulationsaufruf zu lösen und danach abzuschließen (Abschnitt 5.4), drei Würfel anzuheben erfordert aber drei Aufrufe. Erfolgreich ist der Agent also nur, wenn er die Instruktion übergeht, und gemessen wird in erster Linie, wie bereitwillig eine Variante das tut. Dass die strukturelle Variante es zuverlässig tut, sagt etwas über ihr Instruktionsverhalten und nichts über ihre Repräsentationskompetenz.

Auch B2 betrifft mit „delete all red cubes“ zwei Objekte, gelingt den hybriden Varianten aber in 30 von 30 Läufen. Die zunächst plausible Erklärung, der größere Kontext der hybriden Varianten erschwere mehrere aufeinanderfolgende Schritte, passt deshalb nicht; träfe sie zu, müsste B2 ähnliche Schwierigkeiten bereiten wie E2. Die Ursache des Einbruchs in E2 bleibt ungeklärt, und die Zelle wird weder als Verdeckungstest noch als Mehrschritt-Befund gewertet. Die Aussagen der Kategorie E stützen sich damit allein auf E1.

Zwischenfazit

Einen Gesamtsieger gibt es nicht. Die strukturelle Schicht trägt attributive, qualitativ-relationale und verdeckte Referenzen, die visuelle Schicht perzeptuelle. Welche Repräsentation erfolgreich ist, hängt vom Referenztyp ab. Die Annahme, eine hybride Repräsentation vereine ohne Weiteres die Stärken beider, bestätigt sich nicht: In D1 bleibt die naive Kombination mit 2 von 30 weit hinter der visuellen Einzelvariante mit 30 von 30 zurück ($p = 8,4 \cdot 10^{-15}$). Ob dahinter eine Verdrängung der visuellen durch die strukturelle Information steht oder ein Reihenfolgeeffekt, ist offen. In jedem Fall reicht es nicht, beide Schichten bereitzustellen, und an dieser Stelle setzt die zweite Forschungsfrage an.

6.5 Ergebnisse zur Gestaltung der hybriden Repräsentation (RQ2)

Die naive hybride Variante stellt beide Schichten bereit, nutzt den visuellen Vorteil aber nicht zuverlässig: In D1 löst sie 2 von 30 Läufen, in D2 alle 30. Die zweite Forschungsfrage prüft, ob sich dieses Verhalten allein über die Gestaltung der Instruktion steuern lässt, ohne die Modelle zu verändern.

Ausgangslage

Warum die naive Variante in D1 scheitert und in D2 nicht, lässt sich aus den Erfolgsraten allein nicht bestimmen. Drei Erklärungen kommen in Betracht, und auf diese drei beziehen sich auch die folgenden Abschnitte und Kapitel 7. Die erste betrifft die Formulierung des Befehls. In D1 benennt „striped“ eine Objekteigenschaft, wie sie sonst in der strukturellen Schicht steht, sodass das Modell dort nach einem unterscheidenden Merkmal suchen könnte, wo keines ist; die beiden grauen Würfel unterscheiden sich im strukturellen Zustand nicht. „Most salient“ in D2 verweist dagegen auf etwas, das nur in der visuellen Beschreibung vorkommt. Die zweite Erklärung betrifft die visuelle Eindeutigkeit des Zielobjekts: Ein gestreiftes Objekt unter vier grauen hebt sich in der Beschreibung stärker ab als eines neben nur einem einfarbigen. Die dritte ist der in Abschnitt 6.4 beschriebene Reihenfolgeeffekt in D1.

Die Beobachtung ähnelt dem aus der Literatur bekannten Muster der Modalitäts-Dominanz, allerdings nur mit den in Abschnitt 2.4 genannten Einschränkungen.

Priorisierende Variante

Die priorisierende Variante stellt die visuelle Beschreibung voran und erklärt sie für das Aussehen als maßgeblich. Dort, wo die naive Kombination scheitert, gewinnt sie deutlich: In D1 steigt der Erfolg von 2 auf 25 von 30 Läufen ($p = 1,4 \cdot 10^{-9}$), über die Kategorie D von 10,7 auf 15,6 von 20. Da sich die Variante von der naiven aber auch in der Reihenfolge der Schichten unterscheidet (Tabelle 5.1), bleibt offen, ob der Gewinn auf die Instruktion oder auf die Voranstellung der Beschreibung zurückgeht; das gilt für alle Vergleiche zwischen den hybriden Varianten.

In D2 fällt die priorisierende Variante zudem auf 22 von 30 zurück, wo die naive alle 30 Läufe löst ($p = 0,0046$). D2 verlangt neben der visuellen Zuordnung eine Verschiebung an eine feste Zielkoordinate. Wird das Gewicht zur visuellen Beschreibung verschoben, dürften gerade Aufgaben leiden, die zugleich die strukturellen Koordinaten präzise nutzen müssen. Die Priorisierung tauscht damit eine Kompetenz gegen eine andere, statt beide zu vereinen.

Kompetenzgetrennte Variante

Die kompetenzgetrennte Variante trennt stattdessen die Zuständigkeiten: Die visuelle Beschreibung bestimmt, welches Objekt gemeint ist, die strukturelle Schicht liefert die Koordinaten. Wie in Abschnitt 5.4 beschrieben, wurde sie iterativ am selben Szenarioset entwickelt, und ihre Instruktion enthält die Testwörter „striped“ und „most salient“. Die folgenden Ergebnisse gelten deshalb zunächst nur für dieses Set (Abschnitt 6.6).

Auf diesem Set erreicht sie in Kategorie D 19,7 von 20 und kommt damit nahe an die visuelle Variante heran. In D1 löst sie 29 von 30 Läufen, wo die naive Variante 2 von 30 erreichte ($p = 2,3 \cdot 10^{-13}$), und in D2 hält sie 30 von 30, wo die priorisierende auf 22 von 30 zurückfiel ($p = 0,0046$). Sie verbindet also den Zugriff auf die visuelle Beschreibung aus D1 mit der strukturellen Präzision aus D2, woran die Priorisierung gescheitert war. Abbildung 6.1 zeigt diese Entwicklung über die fünf Varianten. In den übrigen Kategorien bleibt sie auf dem besten erreichten Niveau: 30 von 30 in A und B, gleichauf an der Spitze in C und 30 von 30 in E1. Nur in der nicht gewerteten Zelle E2 liegt die strukturelle Variante vor allen hybriden. In jeder gewerteten Zelle ist die kompetenzgetrennte Variante die beste oder eine der besten.




Abbildung 6.1: Erfolg in der rein visuellen Kategorie D über die fünf Varianten. Die rein visuelle Variante bildet die Obergrenze, die rein strukturelle scheitert nahezu vollständig. Die naive Kombination erreicht etwa die Hälfte, die Priorisierung verbessert das, und die Kompetenztrennung erreicht nahezu das Niveau der reinen Bildvariante.

Bewertung

Gefordert war, dass eine Gestaltung dort belastbar verbessert, wo die naive Kombination scheitert, ohne in den übrigen Kategorien zu verlieren. Die kompetenzgetrennte Variante erfüllt beides: Sie hebt D1 von 2 auf 29 von 30 Läufen und hält das Niveau in allen anderen gewerteten Kategorien. Für dieses Szenarioset ist die zweite Forschungsfrage damit positiv beantwortet. Die beiden Quellen ergänzen sich nicht von selbst, ihr Zusammenspiel lässt sich aber allein über die Instruktion steuern. Einschränkend kommt hinzu, dass die Variante am Messset entwickelt wurde und Instruktion und Reihenfolge der Schichten nicht getrennt variiert sind; Abschnitt 6.6 führt beides aus.

Als Leitlinie für einen lokalen Agenten mit gemischter Repräsentation lässt sich daraus ableiten, die Quellen nicht nur nebeneinanderzustellen, sondern jeder Schicht den Referenzbereich zuzuweisen, für den sie nach RQ1 exklusiv zuständig ist. Die visuelle Beschreibung beantwortet dann, welches Objekt gemeint ist, die Struktur, wo es sich befindet. Da diese Leitlinie auf zwei Szenarien einer Kategorie und einer an diesen Szenarien entwickelten Instruktion beruht, ist sie eine Empfehlung und kein nachgewiesenes Prinzip. Die kompetenzgetrennte Variante bildet auch die Grundlage des Demonstrators aus Abschnitt 5.5.

6.6 Validität und Grenzen

Die Ergebnisse sind nur so belastbar wie die Kontrolle der Bedingungen, unter denen sie entstanden. Dieser Abschnitt beschreibt, welche Störfaktoren erkannt und beseitigt wurden, welche Einflüsse bestehen bleiben und wo die Aussagekraft endet.

Beseitigte Störfaktoren und nachträgliche Entscheidungen

Mehrere zunächst plausible Befunde erwiesen sich bei genauerer Prüfung als Artefakte des Aufbaus und wurden vor der Wertung beseitigt. Die Farbe der Marker beeinflusste die Farbwahrnehmung des visuellen Modells, das teils die Farbe des Markers statt die des Objekts nannte; die Marker wurden daraufhin versetzt und die Anweisung angepasst. In Szenarien, in denen ein Referenzobjekt im Koordinatenursprung stand, fielen relative und absolute Zielangabe zusammen, sodass eine relationale Aufgabe auch ohne Verständnis der Relation lösbar war; diese Aufbauten wurden entkonfundiert. Im

ursprünglichen, achsenkollinearen Aufbau von C2 erhielten verdeckte Objekte durch den Sichtbarkeits-test keinen Marker, wodurch das kameranächste Objekt als einziges markiert erschien und die Aufgabe trivial wurde; C2 wurde mit seitlich versetztem Aufbau neu gemessen. Ein scheinbar deutlicher Nachteil der hybriden Varianten schließlich entpuppte sich als Terminierungsartefakt des Frameworks und verschwand mit dem serverseitigen Schutz gegen identische Wiederholungen (Abschnitt 5.3).

Dass alle Varianten in der Kontrollkategorie A das Maximum erreichen, zeigt, dass der Messaufbau selbst keine variantenspezifischen Unterschiede erzeugt. Vollständigkeit lässt sich daraus nicht ableiten: Die genannten Störfaktoren sind die markantesten, nicht notwendigerweise die einzigen.

Einige dieser Eingriffe erfolgten erst, nachdem die zugehörigen Ergebnisse vorlagen. C3 wurde aus der Auswertung genommen, weil die achsenparallele Kameraausrichtung die aus Sicht der Kamera formulierte Referenz mehrdeutig machte; C2 wurde wegen des oben beschriebenen Markerproblems nicht ausgeschlossen, sondern mit verändertem Aufbau neu gemessen; und E2 wurde als nicht wertbar eingestuft, weil sein Soll-Ergebnis der Grundinstruktion widerspricht, was beim Entwurf nicht bedacht worden war. In allen drei Fällen lag ein benennbarer Störfaktor vor, nicht bloß ein unerwünschtes Ergebnis. Vorab festgelegt waren die Entscheidungen aber nicht, und ein solches Vorgehen erhöht grundsätzlich das Risiko, dass die berichtete Auswahl zugunsten der erzählten Deutung ausfällt.

Abhängigkeit vom Szenarioset

An zwei Stellen sind die Testfälle in den Aufbau selbst eingeflossen. Die erste ist der Wahrnehmungs-Prompt (Listing 3). Er bestimmt, was die visuelle Schicht überhaupt berichten kann, und begrenzt damit, was sich über ihre Schwächen sagen lässt. Das Scheitern in B3 geht darauf zurück, dass der Prompt keine Größe abfragt; Kategorie B zeigt deshalb nicht, dass Attributreferenzen grundsätzlich strukturelle Daten erfordern, sondern nur, dass sie es unter diesem Prompt tun. Umgekehrt nennt der Prompt als Beispiel für einen Texturdeskriptor „striped“, also das Merkmal, über das D1 und D2 ihr Zielobjekt ansprechen. Weil alle Varianten mit visueller Schicht denselben Prompt nutzen, verzerrt das den Vergleich *zwischen* ihnen nicht. Gezeigt ist in Kategorie D aber nur, dass die visuelle Schicht eine Eigenschaft erkennt, auf die ihr Prompt sie ausdrücklich hinweist; ob sie ein unerwartetes Oberflächenmerkmal ebenso zuverlässig berichtet hätte, ist offen.

Die zweite und gewichtigere Stelle betrifft die kompetenzgetrennte Variante. Sie entstand nicht aus einer vorab formulierten Theorie, sondern aus der Analyse der naiven und der priorisierenden Variante auf demselben Szenarioset, auf dem sie danach gemessen wird, und ihre Instruktion enthält mit „striped“ und „most salient“ zwei Formulierungen aus den Befehlen von D1 und D2 (Listing 6). Gezeigt ist damit, dass sich die Kombination beider Schichten auf diesem Set durch die Instruktion erheblich verbessern lässt. Nicht gezeigt ist, dass die Variante bei ungesesehenen Formulierungen ebenso überlegen wäre. Ein Teil ihres Vorteils könnte darauf beruhen, dass die Instruktion die Wörter des Testbefehls schon enthält und dem Modell die Zuordnung abnimmt, statt eine allgemeine Kompetenz zu vermitteln. Zwischen beiden Möglichkeiten kann die Arbeit nicht entscheiden; Abschnitt 7.5 nennt die Prüfungen, die dafür nötig wären.

Nicht getrennte Einflussgrößen

Die hybriden Varianten unterscheiden sich nicht nur in ihrer Zuständigkeitsregel. Die priorisierende stellt zusätzlich die visuelle Beschreibung voran, während die naive und die kompetenzgetrennte mit dem strukturellen Zustand beginnen (Tabelle 5.1). Instruktion und Reihenfolge variieren damit gemeinsam, und ihr jeweiliger Beitrag lässt sich nicht trennen. Für den Vergleich der hybriden Varianten untereinander ist NFA5 insoweit nicht erfüllt; für den Vergleich von strukturell, visuell und hybrid gilt sie, da sich diese Bedingungen in der Repräsentation selbst unterscheiden.

Ungeklärt bleibt auch, warum die naive Kombination den Zugriff auf die visuelle Beschreibung in D1 verliert. Formulierung des Befehls, visuelle Eindeutigkeit des Zielobjekts und Reihenfolge der Objekte (Abschnitt 6.5) sind mit den Daten verträglich und lassen sich in diesem Aufbau nicht voneinander trennen. Besonders schwer wiegt der Reihenfolgeeffekt, weil er nicht nur den Mechanismus, sondern

den Befund selbst betrifft: Das Scheitern der strukturellen Variante mit 0 von 30 passt zu einer Positionspräferenz ebenso gut wie zu einer Verdrängung. Die Deutung, die exakte strukturelle Information verdränge die unschärfere Beschreibung, ist deshalb eine mögliche Erklärung und kein nachgewiesener Mechanismus. Die Ähnlichkeit zu Befunden über die Übergewichtung von Text in multimodalen Modellen [1, 2] stützt sie nicht, denn dort konkurrieren Bild und Text innerhalb eines Modells, hier zwei Textquellen (Abschnitt 2.4).

Ein weiterer Konflikt besteht zwischen der Grundinstruktion und den Mehrobjekt-Szenarien. Die Grundinstruktion verlangt einen einzigen Manipulationsaufruf, die Soll-Ergebnisse von B2 und E2 betreffen aber mehrere Objekte. Für E2 macht das die Zelle unwertbar, weil ein Erfolg nur durch Missachtung der Instruktion möglich ist. Warum B2 den hybriden Varianten trotzdem durchgängig gelingt, ist ungeklärt und hängt davon ab, ob das Löschwerkzeug mehrere Objekte in einem Aufruf annimmt. Damit bleibt auch offen, ob das knappe Kontextfenster von 4096 Token, das die hybriden Varianten stärker belastet (Abschnitt 6.1), irgendwo wirksam wurde. Für E2 läge diese Erklärung nahe, B2 spricht aber dagegen, und eine Protokollierung der Kontextauslastung je Lauf, die das klären könnte, wurde nicht vorgenommen.

Messung und Auswertung

Der Erfolg wird ausschließlich aus dem Folgezustand bestimmt, weil das lokale Modell ein instabiles Abschlussverhalten zeigte. Es meldete wiederholt Erfolge, die der Folgezustand nicht bestätigte, nannte teils nicht vorhandene Objektkennungen und führte einzelne Manipulationen doppelt aus. Wie häufig Selbstauskunft und Folgezustand auseinanderfielen, wurde nicht quantifiziert; die Beobachtung beruht auf wiederholten Einzelfällen in den Protokollen. Für die Gültigkeit der Ergebnisse genügt das, weil ein falsch gemeldeter Erfolg die Erfolgszahl nicht beeinflusst.

Innerhalb einer festen Konfiguration erwies sich die Messung als stabil. Die meisten Zellen zeigen über die drei Durchläufe eine Spanne von null oder eins, nennenswerte Streuung tritt nur in wenigen Szenarien auf, vor allem in C1 und C4 sowie in D1 und D2 der priorisierenden Variante. Wie in Abschnitt 6.1 ausgeführt, kommt diese Stabilität trotz einer Temperatur von 0,8 zustande. Die Spannen dienen nur noch der Beschreibung der Durchlaufstabilität; die in einer früheren Fassung verwendete Heuristik, nicht überlappende Spannen als belastbaren Unterschied zu werten, wurde durch die Auswertung aus Abschnitt 6.3 ersetzt.

Die Konfidenzintervalle in Tabelle 6.6 quantifizieren allerdings nur die Unsicherheit innerhalb einer Zelle, nicht die Frage, ob diese Zelle für ihren Referenztyp repräsentativ ist. Diese zweite Unsicherheit ist die größere und lässt sich hier nicht quantifizieren. Den bild-exklusiven Bereich belegen zwei Szenarien, den strukturell-exklusiven nach dem Ausschluss von E2 nur eines, und das erlaubt keine Aussage darüber, wie sich der Effekt über die Breite möglicher Referenzen verhält.

Auch die Aufzeichnung der Läufe begrenzt die Analyse. Für C2 und C4 liegen keine verwertbaren Protokolle mehr vor, sodass sich weder der Lagefehler bestimmen noch nachvollziehen lässt, welches Objekt der Agent in C2 tatsächlich manipuliert hat (Abschnitt 6.4). Werkzeugaufrufe mit Argumenten und erreichte Endpositionen mitzuschreiben, hätte keinen zusätzlichen Messaufwand bedeutet und mehrere der offenen Fragen dieser Arbeit beantwortet; bei einer Wiederholung ist das vorzusehen. Schließlich wurde nicht geprüft, wie empfindlich insbesondere C2 und C4 auf die Toleranz $\tau = 0,1$ reagieren. Eine großzügigere Toleranz könnte die dortigen Erfolgsraten anheben, ohne dass sich die Rangfolge der Varianten ändern muss.

Technische Einschränkungen

Die Sichtbarkeitsprüfung arbeitet mit einem einzelnen Sichtstrahl auf den Objektmittelpunkt und kennt nur sichtbar und verdeckt (Abschnitt 5.2). Für die verwendeten Szenen genügt das, in dichten Szenen mit Teilverdeckung nicht. Der Schutz gegen identische Wiederholungen würde auch eine vom Befehl geforderte Wiederholung blockieren (Abschnitt 5.3); in den ausgewerteten Szenarien kommt das nicht vor, bei Mehrschritt-Befehlen wäre es aber möglich.

Reichweite

Alle Befunde beruhen auf einem einzelnen lokalen Modellpaar und auf synthetischen Szenen aus einfachen Grundkörpern. Innerhalb dieses Rahmens sind sie repliziert und intern konsistent, eine Übertragung auf größere oder anders gebaute Modelle und auf reale, komplexe Szenen wurde aber nicht geprüft. Für RQ2 kommt hinzu, dass die beste Variante am Szenarioset selbst entwickelt wurde.

Ein Teil der Befunde betrifft eher das Modell als die Repräsentation. Für C4 ist die Deutung als Präzisionsgrenze tragfähig, denn die Koordinaten liegen vor, die geforderte Rechengenauigkeit wird aber nur manchmal erreicht, und daran ändert keine Repräsentation etwas. Für C2 ist eine Modellgrenze dagegen nicht belegt (Abschnitt 6.4). C2 enthält zudem mit „nearest to the camera“ eine blickpunktbezogene Referenz; dass blickpunktabhängige Referenzen nicht ausgewertet wurden, gilt also nur für das dafür vorgesehene und ausgeschlossene Szenario C3.

Die Aussagekraft der Arbeit liegt damit in der kontrollierten Isolation der Repräsentationskompetenzen und nicht in einer allgemeinen Gültigkeit über Modelle und Szenen hinweg.

Kapitel 7

Zusammenfassung und Ausblick

7.1 Zusammenfassung

Ausgangspunkt der Arbeit war die Frage, in welcher Form einem lokal betriebenen KI-Agenten eine 3D-Szene bereitgestellt werden sollte, damit er sie natürlichsprachlich manipulieren kann. Zur Wahl standen ein struktureller und ein visueller Weg, die jeweils eigene Stärken haben und jeweils einen Bereich abdecken, zu dem der andere keinen Zugang hat.

Um die Frage zu beantworten, wurde ein prototypisches System entwickelt, das dieselbe Szene strukturell, visuell und hybrid bereitstellt und über ein gemeinsames Interface manipulierbar macht. Die Formen wurden unter gleichen Bedingungen an dreizehn kontrolliert aufgebauten Szenarien verglichen, jede Kombination aus Szenario und Variante in 30 Läufen, wobei der Erfolg aus dem tatsächlichen Zustand der Szene bestimmt wurde.

Der Vergleich ergab eine referenztypabhängige Kompetenz ohne Gesamtsieger, und eine naive Kombination beider Schichten vereinte deren Stärken nicht von selbst. Erst eine Instruktion, die den Schichten getrennte Zuständigkeiten zuweist, führte sie auf dem untersuchten Szenarioset zusammen; Abschnitt 7.2 beantwortet die beiden Forschungsfragen im Einzelnen.

Diese kompetenzgetrennte Variante wurde schließlich in die immersive Zielumgebung übertragen. Der Demonstrator zeigt, dass die Kette von einem Befehl bis zur sichtbaren Manipulation in der Brille funktioniert, wobei die Modelle selbst gehostet auf einem Arbeitsplatzrechner laufen und nicht auf dem Endgerät. Per Aufzeichnung dokumentiert ist die Menüfassung; die ergänzte Spracheingabe ist umgesetzt, aber nicht per Video belegt.

7.2 Beantwortung der Forschungsfragen

Erste Forschungsfrage

Welchen Einfluss hat die Form der Szenenrepräsentation, strukturell, visuell oder hybrid, auf den Ausführungserfolg der natürlichsprachlichen Szenenmanipulation durch einen lokal betriebenen Agenten, und zwar aufgeschlüsselt nach der Art der sprachlichen Referenz?

Die Repräsentationsform hat einen erheblichen Einfluss, und dieser hängt vom Referenztyp ab. Keine Form ist über alle Aufgaben hinweg überlegen. Referenzen, deren Merkmal in den Daten kodiert ist, und Referenzen auf verdeckte Objekte trägt die strukturelle Form; nur sie kann ein im Bild verdecktes Objekt ansprechen. Referenzen auf rein visuelle Eigenschaften wie ein Oberflächenmuster trägt ausschließlich die visuelle Form. Beide haben damit einen exklusiven Zuständigkeitsbereich.

Die naive hybride Form übernimmt den strukturellen Vorteil, den visuellen aber nicht zuverlässig. In der perzeptuellen Kategorie erreicht sie nur 10,7 von 20 möglichen Erfolgen, die visuelle Form dagegen 20 von 20. Das stellt die Erwartung in Frage, eine Kombination sei stets mindestens so gut wie die bessere Einzelform. Widerlegt ist sie damit nicht, weil für das tragende Szenario D1 ein Reihenfolgeeffekt bei der Objektwahl als gleichwertige Erklärung offen bleibt.

Zweite Forschungsfrage

Lässt sich das Zusammenspiel der strukturellen und der visuellen Schicht allein durch die Gestaltung der Instruktion so steuern, dass die hybride Repräsentation die Stärken beider Schichten vereint?

Auf dem untersuchten Szenarioset ja: Das Zusammenspiel lässt sich allein über die Instruktion steuern, ohne die Modelle zu verändern. Es kommt dabei auf die Art der Steuerung an. Eine Priorisierung einer Schicht verschiebt das Gewicht nur und tauscht eine Kompetenz gegen eine andere. Erst die ausdrückliche Trennung der Zuständigkeiten, bei der die visuelle Beschreibung das gemeinte Objekt bestimmt und die strukturelle Schicht alle geometrischen Werte liefert, führt beide Schichten zusammen. Die kompetenzgetrennte Variante erreicht in der perzeptuellen Kategorie 19,7 von 20, behält die Stärke der strukturellen Form und ist in jedem gewerteten Bereich die beste oder eine der besten.

Die Reichweite dieser Antwort ist allerdings deutlich begrenzt. Die Variante wurde iterativ und in Kenntnis der Ergebnisse auf demselben Szenarioset entwickelt, an dem sie gemessen wurde, und ihre Instruktion enthält zwei Wörter aus den Testbefehlen. Außerdem unterscheiden sich die hybriden Varianten neben der Instruktion auch in der Reihenfolge der Schichten. Für diesen Aufbau ist die Antwort belastbar, ob sie auf ungesehene Formulierungen übertragbar ist, bleibt offen.

7.3 Wissenschaftlicher Beitrag

Die Arbeit leistet drei Beiträge, deren Reichweite jeweils vorsichtig einzuordnen ist.

Inhaltlich zeigt sie an einem kontrollierten Fall, dass sich strukturelle und visuelle Information nicht automatisch ergänzen. Ob eine Kombination ihre Bestandteile zusammenführt oder ob eine Informationsart die andere verdrängt, hängt davon ab, wie die Zusammenführung gestaltet ist. Gewonnen ist dieser Befund an einem Modellpaar, an dreizehn Szenarien und in einer zweistufigen Pipeline, und er wird nicht als allgemein gültig behauptet. Er legt aber nahe, die Fusion mehrerer Informationsquellen auch in anderen Agenten als Gestaltungsaufgabe zu behandeln und nicht als selbstverständlichen Gewinn an Information.

Methodisch führt die Arbeit eine nach Referenztypen aufgeschlüsselte Auswertung ein, die den Erfolg nicht als einen Gesamtwert, sondern je Referenztyp misst. Erst dadurch werden die exklusiven Zuständigkeiten der Repräsentationen sichtbar, die ein pauschaler Vergleich verdeckt hätte. Das Schema ist nicht an das konkrete System gebunden und dürfte sich auf ähnliche Vergleiche übertragen lassen.

Praktisch zeigt die Arbeit, dass sich die gesamte Kette aus 3D-Umgebung, Vermittlungsschicht, Agent und zwei gleichzeitig betriebenen, selbst gehosteten Modellen umsetzen und bis in die immersive Zielumgebung betreiben lässt, wobei die Modelle auf einem Arbeitsplatzrechner und nicht auf dem Endgerät rechnen. Ein Anspruch auf Produktreife ist damit nicht verbunden, und der Demonstrator wurde nicht eigenständig evaluiert.

7.4 Grenzen der Arbeit

Die methodischen Grenzen sind in Abschnitt 6.6 im Einzelnen behandelt; hier werden die wichtigsten für die Arbeit als Ganzes zusammengefasst.

Der Untersuchungsgegenstand ist bewusst eng gefasst. Die Operationen beschränken sich auf Erzeugen, Verschieben und Entfernen, die Befehle sind durchgehend klar formuliert, und Befehle mit mehreren

Manipulationen wurden nicht systematisch untersucht. Dass die Grundinstruktion nur einen Manipulationsaufruf zulässt, machte E2 unwertbar, sodass sich der strukturell-exklusive Befund am Ende auf ein einziges Szenario stützt. Blickpunktabhängige Referenzen wurden ebenfalls nicht systematisch untersucht, weil das dafür vorgesehene Szenario C3 ausgeschlossen werden musste; das blickpunkt-bezogene Szenario C2 gehört zu den ungeklärten Fällen. Der Demonstrator belegt die Machbarkeit, liefert aber keine eigenen Erfolgsraten.

Die Übertragbarkeit ist auf ein lokales Modellpaar und auf synthetische, einfache Szenen begrenzt. Auch an die zweistufige Pipeline sind die Ergebnisse gebunden: Was hier als Konkurrenz von Struktur und Bild erscheint, ist die Konkurrenz einer exakten Datenstruktur mit einer sprachlichen Beschreibung, und für ein multimodales Modell, dem Bild und Daten unmittelbar vorliegen, gelten die Befunde nicht ohne Weiteres. Am stärksten begrenzt ist die Übertragbarkeit der besten Variante, die am Messset selbst entwickelt wurde.

Auf der Ebene der Erklärung bleibt offen, warum die naive Kombination den visuellen Zugriff in D1 verliert. Formulierung des Befehls, visuelle Eindeutigkeit und ein Reihenfolgeeffekt sind gleichermaßen mit den Daten verträglich, und der Reihenfolgeeffekt betrifft nicht nur den Mechanismus, sondern den Befund selbst. Ebenso wenig getrennt sind Instruktion und Reihenfolge der Schichten. Mehrere Entscheidungen über den Zuschnitt der Auswertung fielen nach Sichtung der Ergebnisse, waren inhaltlich begründet, aber nicht vorab festgelegt. Die statistischen Tests sichern die Unterschiede innerhalb einer Zelle ab, nicht jedoch, ob eine Zelle für ihren Referenztyp repräsentativ ist, und gerade die zentralen Kategorien sind schmal besetzt. Hinzu kommen kleinere Einschränkungen des Aufbaus wie die fehlende Teilverdeckung im Sichtbarkeitstest, der grobe Schutz gegen identische Wiederholungen und die nicht auf Empfindlichkeit geprüfte Toleranz.

7.5 Ausblick

Am dringlichsten ist zu prüfen, ob die kompetenzgetrennte Variante ihren Vorteil auch außerhalb des Szenariosets behält, an dem sie entwickelt wurde. Dafür bieten sich zwei einander ergänzende Prüfungen an. Die erste ist eine Messung an neuen Szenarien, insbesondere mit anderen perzeptuellen Eigenschaften als einem Streifenmuster und mit anderer sprachlicher Formulierung derselben Referenz. Die zweite ist eine Fassung der Instruktion ohne szenariospezifische Wörter, also ohne „striped“ und „most salient“, die die Trennung der Zuständigkeiten rein abstrakt formuliert. Erst wenn eine so formulierte Instruktion auf ungesesehenen Szenarien denselben Vorteil zeigt, ließe sich von einem übertragbaren Gestaltungsprinzip sprechen statt von einer Formulierung, die für diesen Testsatz funktioniert.

Ebenso vorrangig ist eine Messung, die den Reihenfolgeeffekt in Kategorie D ausschließt. Dazu genügt es, die tragenden Szenarien mit vertauschter Objektreihenfolge zu wiederholen und die Reihenfolge der beiden Schichten im Kontext unabhängig von der Instruktion zu variieren. Beides ist ohne neuen Aufbau möglich und würde die zentrale Deutung der Arbeit entweder absichern oder korrigieren. Bei jeder Wiederholung sollten außerdem die Werkzeugaufrufe mit ihren Argumenten und die erreichten Endpositionen protokolliert werden. Das kostet keinen zusätzlichen Messaufwand und hätte hier mehrere offene Fragen beantwortet, etwa ob die metrischen Szenarien knapp oder grundsätzlich scheitern und welches Objekt der Agent in den ungeklärten Fällen gewählt hat.

Weitere Fortführungen betreffen Effizienz und Umfang. Der Abruf der visuellen Schicht ist erkennbar langsamer als der des strukturellen Zustands, weil er einen zusätzlichen Inferenzschritt des Sprach-Bild-Modells erfordert. Wie groß der Unterschied ist, wurde nicht gemessen; eine systematische Erhebung von Latenz, Schrittzahl und Rechenaufwand würde diesen bislang nur qualitativ bekannten Trade-off greifbar machen und wäre gerade für eine interaktive immersive Anwendung wichtig. Mit wachsender Objektzahl dürfte vor allem die visuelle Schicht an Grenzen stoßen, weil die Markierung vieler Objekte unübersichtlich wird. Die Menge der Operationen ließe sich um Drehungen und Skalierungen erweitern sowie um Befehle mit mehreren Manipulationen, deren eigene Schwierigkeit sich hier bereits angedeutet hat. Schließlich sind blickpunktabhängige Referenzen zu nennen, die sich auf die Sicht des

Betrachters beziehen und für immersive Umgebungen typisch sind. Jüngere Arbeiten zur blickpunkt-abhängigen Segmentierung zeigen, dass solche Bezüge ohne expliziten Blickpunkt mehrdeutig sind und von einer ausdrücklichen Repräsentation des Blickwinkels profitieren [16]; eine saubere Behandlung dieses Referenztyps wäre eine lohnende Erweiterung der Taxonomie.

Wissenschaftlich ließe sich prüfen, ob die Kompetenzprofile und die Grenzen der naiven Kombination auch für größere oder anders gebaute Modelle gelten oder ob größere Modellkapazität den beobachteten Bruch von selbst auflöst. Ein gezieltes Experiment könnte die drei offenen Erklärungen trennen, indem es Formulierung, visuelle Eindeutigkeit und Objektreihenfolge unabhängig voneinander variiert und so aus der offenen Deutung einen belegten Mechanismus macht. Aufschlussreich wäre auch ein Vergleich der zweistufigen Pipeline mit einem einzelnen multimodalen Modell, dem Bild und strukturelle Daten unmittelbar vorliegen; er würde zeigen, ob der beobachtete Effekt an der Pipeline hängt. Offen ist zudem, ob sich das Prinzip der Kompetenztrennung auf andere multimodale Aufgaben übertragen lässt.

Aus Anwendungssicht fehlt eine Erprobung mit echten Nutzern. Die vorliegende Bewertung ist rein systembasiert, und eine qualitative Nutzerstudie im Demonstrator könnte zeigen, wie Menschen die sprachgesteuerte Manipulation in der immersiven Umgebung tatsächlich erleben.

Glossar

Folgezustand Tatsächlicher Zustand der Szene nach einer Manipulation, aus dem der Ausführungserfolg unabhängig von der Selbstauskunft des Agenten bestimmt wird

gemeinsames Kennungssystem Einheitliche Objektkennungen, über die alle Repräsentationsvarianten Objekte ansprechen; die visuelle Variante ist über ihre Bildmarken an dieselben Kennungen gebunden

Grounding Auflösung einer sprachlichen Referenz auf ein konkretes Szenenobjekt

kompetenzgetrennte hybride Repräsentation Hybride Repräsentation mit expliziter Aufgabenteilung: die visuelle Beschreibung bestimmt, welches Objekt gemeint ist, die strukturelle Schicht liefert alle numerischen Werte

lokaler Betrieb In dieser Arbeit: selbst gehosteter Betrieb der Modelle auf eigener Hardware ohne Nutzung eines Cloud-Dienstes. Der Begriff besagt nicht, dass die Modelle auf dem Endgerät selbst rechnen; im Demonstrator laufen sie auf einem Arbeitsplatzrechner im Institutsnetz, den die Brille über ein virtuelles privates Netz erreicht

naive hybride Repräsentation Kombination aus struktureller und visueller Schicht ohne verbindliche Instruktion zur Zuständigkeit der beiden Quellen

priorisierende hybride Repräsentation Hybride Repräsentation mit vorangestellter visueller Beschreibung, die als maßgeblich für das Aussehen deklariert wird

Referenztyp Art, in der ein natürlichsprachlicher Befehl auf ein Objekt verweist, etwa über eine Kennung, ein Attribut, eine räumliche Relation, eine rein sichtbare Eigenschaft oder ein verdecktes Objekt

strukturelle Repräsentation Bereitstellung der Szene als exakte Laufzeitdaten der Engine (Objekt-ids, Typen, Positionen, Größen, Farben, Kamerapose) in textueller Form, hier als JSON

visuelle Repräsentation Bereitstellung der Szene über eine von einem Sprach-Bild-Modell erzeugte natürlichsprachliche Beschreibung der gerenderten, mit Set-of-Mark-Markern versehenen Ansicht. Das Sprachmodell erhält die Beschreibung, nicht das Bild

Literaturverzeichnis

- [1] A. Deng, T. Cao, Z. Chen, und B. Hooi, „Words or Vision: Do Vision-Language Models Have Blind Faith in Text?” in *2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2025, S. 3867–3876, Abgerufen am 03.09.2026. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/11092720> (Zitiert auf Seiten 2, 6, 12 und 36.)
- [2] H. Wu, M. Tang, X. Zheng, und H. Jiang. (2025) When Language Overrides: Revealing Text Dominance in Multimodal Large Language Models. Abgerufen am 27.08.2026. [Online]. Available: <http://arxiv.org/abs/2508.10552> (Zitiert auf Seiten 2, 6, 12 und 36.)
- [3] Hugging Face. (2024) Smolagents. [Online]. Available: <https://github.com/huggingface/smolagents> (Zitiert auf Seiten 5 und 16.)
- [4] Anthropic. Model Context Protocol. [Online]. Available: <https://modelcontextprotocol.io> (Zitiert auf Seiten 5 und 14.)
- [5] J. Yang, H. Zhang, F. Li, X. Zou, C. Li, und J. Gao. (2023) Set-of-Mark Prompting Unleashes Extraordinary Visual Grounding in GPT-4V. Abgerufen am 10.09.2026. [Online]. Available: <http://arxiv.org/abs/2310.11441> (Zitiert auf Seiten 5, 12 und 16.)
- [6] P. Achlioptas, A. Abdelreheem, F. Xia, M. Elhoseiny, und L. Guibas, „ReferIt3D: Neural Listeners for Fine-Grained 3D Object Identification in Real-World Scenes,” in *Computer Vision – ECCV 2020*, A. Vedaldi, H. Bischof, T. Brox, und J.-M. Frahm, Hrsgg. Springer International Publishing, 2020, S. 422–440. (Zitiert auf Seiten 5 und 26.)
- [7] D. Z. Chen, A. X. Chang, und M. Nießner, „ScanRefer: 3D Object Localization in RGB-D Scans Using Natural Language,” in *Computer Vision – ECCV 2020*, A. Vedaldi, H. Bischof, T. Brox, und J.-M. Frahm, Hrsgg. Springer International Publishing, 2020, S. 202–221. (Zitiert auf Seiten 5 und 26.)
- [8] F. De La Torre, C. M. Fang, H. Huang, A. Banburski-Fahey, J. Amores Fernandez, und J. Lanier, „LLMR: Real-time Prompting of Interactive Worlds Using Large Language Models,” in *Proceedings of the 2024 CHI Conference on Human Factors in Computing Systems*, Serie CHI ’24. Association for Computing Machinery, 2024, S. 1–22, Abgerufen am 10.09.2026. [Online]. Available: <https://dl.acm.org/doi/10.1145/3613904.3642579> (Zitiert auf Seite 5.)
- [9] X. E. Wang, Z. P. T. Sin, Y. Jia, D. Archer, W. H. Y. Fong, Q. Li, und C. Li, „Can You Move These Over There? Exploring an LLM-based VR Mover to Support Natural Multi-object Manipulation,” in *Proceedings of the 38th Annual ACM Symposium on User Interface Software and Technology*, Serie UIST ’25. Association for Computing Machinery, 2025, S. 1–18, Abgerufen am 10.09.2026. [Online]. Available: <https://dl.acm.org/doi/10.1145/3746059.3747673> (Zitiert auf Seite 6.)
- [10] R. Li, S. Li, L. Kong, X. Yang, und J. Liang. (2025) SeeGround: See and Ground for Zero-Shot Open-Vocabulary 3D Visual Grounding. Abgerufen am 10.09.2026. [Online]. Available: <http://arxiv.org/abs/2412.04383> (Zitiert auf Seite 6.)
- [11] X. Sun, X. Zhang, B. Crowe, D. Albin, und C. Heckman. (2026) SceneGraphGrounder: Zero-Shot 3D Visual Grounding via Structured Scene Graph Matching. Abgerufen am 27.08.2026. [Online]. Available: <http://arxiv.org/abs/2605.21788> (Zitiert auf Seite 6.)
- [12] M. Li, S. Zhao, Q. Wang, K. Wang, Y. Zhou, S. Srivastava, C. Gokmen, T. Lee, L. E. Li, R. Zhang, W. Liu, P. Liang, L. Fei-Fei, J. Mao, und J. Wu. (2025) Embodied Agent Interface: Benchmarking LLMs for Embodied Decision Making. Abgerufen am 10.09.2026. [Online]. Available: <http://arxiv.org/abs/2410.07166> (Zitiert auf Seite 6.)

- [13] Z. Song, X. Lin, Q. Huang, S. Qin, G. Wang, und L. Lin. (2026) SIRE-Bench: Challenging VLMs' Spatial Intelligence through Complex Reasoning Tasks. Abgerufen am 27.08.2026. [Online]. Available: <http://arxiv.org/abs/2506.14512> (Zitiert auf Seite 6.)
- [14] Z. Wu, Z. Wang, X. Xu, J. Lu, und H. Yan. (2023) Embodied Task Planning with Large Language Models. Abgerufen am 11.09.2026. [Online]. Available: <http://arxiv.org/abs/2307.01848> (Zitiert auf Seite 7.)
- [15] D. C. Dinh, K. Le-Duc, F. Draye, C. Ngo, T. J. Zhang, B. Schölkopf, und Z. Jin. (2026) PruneGround: Plug-and-play Spatial Pruning for 3D Visual Grounding. Abgerufen am 27.08.2026. [Online]. Available: <http://arxiv.org/abs/2606.31148> (Zitiert auf Seite 7.)
- [16] A. Nanri, K. Reichard, M. Kiray, F. Tombari, B. Busam, und A. Kanezaki. (2026) 3D Segmentation Using Viewpoint-Dependent Spatial Relationships. Abgerufen am 27.08.2026. [Online]. Available: <http://arxiv.org/abs/2605.15708> (Zitiert auf Seite 41.)

Erklärung: Verwendung von KI-Werkzeugen

Im Rahmen der Erstellung dieser Arbeit wurde das KI-Werkzeug Claude (Anthropic) eingesetzt. Die Nutzung wird im Folgenden gemäß der KI-Leitlinie der Technischen Hochschule Nürnberg Georg Simon Ohm offengelegt.

- Grobe Literaturrecherche mit anschließender manueller Überarbeitung und Verifikation der Quellen.
- Umformulierung von selbst verfasstem Text.
- Unterstützung bei der Codeerstellung im Implementierungsteil.

Sämtliche von dem Werkzeug erzeugten Inhalte wurden eigenständig geprüft, überarbeitet und inhaltlich verantwortet. Die Verantwortung für alle Aussagen, Ergebnisse und Schlussfolgerungen dieser Arbeit liegt vollständig beim Verfasser. Die reine Rechtschreib- und Grammatikprüfung ist gemäß Leitlinie nicht dokumentationspflichtig und daher nicht aufgeführt.

Anhang A

Begleitmaterial

A.1 Demonstrationsvideo

Als Begleitmaterial zu dieser Arbeit steht eine Videoaufzeichnung des Demonstrators zur Verfügung. Sie zeigt eine frühe Ausbaustufe, in der die Szene über ein Menü in der virtuellen Umgebung manipuliert wird, das vordefinierte Befehle bereitstellt. Das Video ist unter der folgenden Adresse abrufbar.

`https://git.informatik.fh-nuernberg.de/jobboerse/forschung/bachelorarbeiten/
bachelorarbeit-sandro-jaeger/-/blob/fe68f112f06df9da38eff687fd8df8460061186c/BA_VR_
Demo_with_menu.mp4`



Abbildung: QR-Code zur Videoaufzeichnung.