



Bachelorarbeit

Szenenverständnis und -manipulation in immersiven Umgebungen mittels Künstlicher Intelligenz

Sandro Jäger

Matrikelnummer: 3683886

Prüfer: Prof. Dr. Uwe Wienkop
Louis Burk

© Sandro Jäger, 2026

Diese Arbeit, einschließlich ihrer Teile, **ist urheberrechtlich geschützt**. Jede Verwertung außerhalb der engen Grenzen des Urheberrechtsgesetzes ohne Zustimmung von dem Urheber ist untersagt und strafbar. Dies gilt insbesondere für Vervielfältigungen, Übersetzungen, Mikroverfilmung und die Speicherung und Verarbeitung in elektronischen Systemen.

Danksagung

Only if you want to thank someone.

Kurzdarstellung

Kurze Zusammenfassung der Arbeit, höchstens halbe Seite. Deutsche Fassung auch nötig, wenn die Arbeit auf Englisch angefertigt wird.

Schlagwörter

Inhaltsverzeichnis

1	Einleitung	1
1.1	Motivation und Problemstellung	1
1.2	Relevanz	1
1.3	Zielsetzung und Forschungsfragen	2
1.4	Methodisches Vorgehen	2
1.5	Aufbau der Arbeit	2
2	Grundlagen und Stand der Technik	4
2.1	Große Sprach- und Sprach-Bild-Modelle	4
2.2	Werkzeugnutzende Agenten	4
2.3	Szenenrepräsentation	5
2.4	Stand der Technik	5
2.4.1	Strukturelle Szenenmanipulation in immersiven Umgebungen	5
2.4.2	Hybrides Grounding	6
2.4.3	Modalitäts-Ablationen und Modalitäts-Dominanz	6
2.4.4	Ansätze mit lokalen, kleinen Modellen	6
2.5	Forschungslücke	7
3	Anforderungen	8
3.1	Herleitung der Anforderungen	8
3.2	Funktionale Anforderungen	8
3.3	Nicht-funktionale Anforderungen	9
3.4	Spannungen zwischen den Anforderungen	10
3.5	Abgrenzung des Funktionsumfangs	10
4	Konzept	12
4.1	Lösungsansatz im Überblick	12
4.2	Die drei Repräsentationsformen	12
4.3	Entwurfsentscheidungen	13
4.4	Steuerung der Modalitätsfusion	13
4.5	Differenzierung nach Referenztyp	14
5	Implementierung	15
5.1	Systemüberblick	15
5.2	Szenenanbindung	17
5.3	Agent und Werkzeuge	18
5.4	Die fünf Repräsentationsvarianten	20
5.5	Der VR-Demonstrator	22
6	Evaluation	25
6.1	Evaluationsdesign	25

6.2	Referenztyp-Taxonomie	26
6.3	Metriken	27
6.4	Ergebnisse zu RQ1	29
6.5	Ergebnisse zu RQ2	32
6.6	Validität und Grenzen	34
7	Zusammenfassung und Ausblick	36
7.1	Zusammenfassung	36
7.2	Beantwortung der Forschungsfragen	36
7.3	Beitrag	37
7.4	Grenzen der Arbeit	38
7.5	Ausblick	38
	Erklärung: Verwendung von KI-Werkzeugen	40
A	Begleitmaterial	46
A.1	Demonstrationsvideo	46

Kapitel 1

Einleitung

1.1 Motivation und Problemstellung

Ein Nutzer steht in einer virtuellen Szene und sagt einen einfachen Satz: Heb den gestreiften Würfel an. Für einen Menschen ist die Aufgabe trivial. Für einen KI-Agenten beginnt hier das eigentliche Problem. Bevor er den Würfel anheben kann, muss er die Szene verstehen, und dazu muss ihm die Szene in einer Form vorliegen, die er verarbeiten kann.

Für diese Form gibt es zwei grundverschiedene Wege. Der eine Weg beschreibt die Szene strukturell, als exakte Daten über Objekte, ihre Typen, Positionen und Größen. Der andere Weg beschreibt die Szene visuell, als gerendertes Bild, das ein visuelles Modell interpretiert. Beide Wege haben offensichtliche Stärken und ebenso offensichtliche blinde Flecken. Die strukturellen Daten kennen jede Koordinate, aber nicht das Aussehen eines Objekts. Das Bild zeigt das Aussehen, aber keine exakten Zahlen.

Der gestreifte Würfel aus dem Beispiel macht den ersten blinden Fleck sichtbar. Er lässt sich nur über das Bild bestimmen, denn das Streifenmuster steht in keinen strukturellen Daten. Der umgekehrte Fall ist ebenso denkbar. Ein Objekt, das hinter einem anderen verborgen ist, erscheint im Bild überhaupt nicht, bleibt in den strukturellen Daten aber vollständig verzeichnet. Ein Befehl, der sich auf ein solches verdecktes Objekt bezieht, lässt sich nur über die strukturelle Schicht auflösen. Beide Wege haben also nicht nur unterschiedliche Stärken, sondern jeweils einen Bereich, den der andere Weg grundsätzlich nicht abdeckt.

Damit stellt sich eine Frage, die am Anfang jedes solchen Systems steht und bisher ohne empirische Grundlage beantwortet werden musste. In welcher Form sollte einem lokal betriebenen Agenten eine Szene bereitgestellt werden, und lässt sich eine Kombination beider Wege so gestalten, dass sie die Stärken beider vereint? Gerade in immersiven Umgebungen, in denen ein Nutzer über natürliche Sprache mit einer Szene interagiert, ist diese Frage praktisch bedeutsam. Und gerade für lokal betreibbare Modelle, die aus Gründen des Datenschutzes, der Latenz und der Offline-Fähigkeit in solchen Umgebungen naheliegen, fehlt ein systematischer Vergleich dieser Wege.

1.2 Relevanz

Die Wahl der Repräsentationsform ist keine technische Nebensache. Sie entscheidet mit darüber, welche sprachlichen Anweisungen ein Agent überhaupt zuverlässig umsetzen kann. Eine Repräsentation, die eine ganze Klasse von Referenzen nicht abbildet, lässt die zugehörigen Befehle scheitern, unabhängig davon, wie gut der Agent im Übrigen arbeitet.

Bei großen, cloudbasierten Modellen lässt sich eine schwache Repräsentation teilweise durch schiere Modellgröße ausgleichen. Bei lokal betreibbaren Modellen geringer Größe entfällt dieser Ausgleich.

Hier wird die Repräsentation zum eigentlichen Hebel für den Erfolg. Wer ein solches System entwirft, trifft die Entscheidung über die Repräsentationsform früh und mit weitreichenden Folgen, bislang jedoch ohne belastbare Grundlage. Genau diese Grundlage zu schaffen, ist das praktische Anliegen der Arbeit.

Über den praktischen Nutzen hinaus berührt die Frage ein allgemeineres Problem. Wie sich strukturierte und visuelle Information in einem Agenten verbinden lassen, betrifft jede Anwendung, die beide Arten von Information kombiniert. Ob eine solche Kombination ihre Bestandteile ergänzt oder ob eine Informationsart die andere verdrängt, ist eine offene Frage mit Bedeutung über den hier untersuchten Fall hinaus [1, 2].

1.3 Zielsetzung und Forschungsfragen

Das zentrale Ziel der Arbeit ist eine empirisch fundierte Erkenntnis darüber, welche Repräsentationsform einen lokal betriebenen Agenten bei der natürlichsprachlichen Szenenmanipulation am zuverlässigsten unterstützt. Die Arbeit verfolgt dieses Ziel anhand zweier Forschungsfragen.

Forschungsfrage 1 (RQ1). Welchen Einfluss hat die Form der Szenenrepräsentation, strukturell, visuell oder hybrid, auf die räumliche Korrektheit und den Ausführungserfolg der natürlichsprachlichen Szenenmanipulation durch einen lokal betriebenen Agenten?

Forschungsfrage 2 (RQ2). Lässt sich das Zusammenspiel der strukturellen und der visuellen Schicht allein durch die Gestaltung der Instruktion so steuern, dass die hybride Repräsentation die Stärken beider Schichten vereint?

Über diese beiden Fragen hinaus entsteht ein Demonstrator, der die als am zuverlässigsten ermittelte Variante in die immersive Zielumgebung überträgt und ihre Übertragbarkeit nachweist. Er beantwortet keine eigene Forschungsfrage, sondern dient dem Nachweis der praktischen Machbarkeit.

Die Arbeit grenzt ihren Anspruch bewusst ab. Sie beansprucht keine Generalisierung auf andere Modelle oder auf reale, komplexe Szenen, keine global optimale Lösung und keine Produktreife des Demonstrators. Die Ergebnisse gelten für ein lokales Modellpaar in kontrolliert aufgebauten Szenen.

1.4 Methodisches Vorgehen

Zur Beantwortung der Forschungsfragen verfolgt die Arbeit einen empirischen Ansatz. Grundlage ist ein prototypisches System, das dieselbe Szene in den drei zu vergleichenden Repräsentationsformen bereitstellt und über ein gemeinsames Interface manipulierbar macht. Auf dieser Grundlage werden die Formen unter gleichen Bedingungen an einer Reihe kontrolliert aufgebauter Szenarien gegeneinander gemessen. Der Erfolg jeder Manipulation wird dabei aus dem tatsächlichen Zustand der Szene bestimmt und nicht aus der Selbstauskunft des Agenten, und jede Messung wird wiederholt, um belastbare von zufälligen Unterschieden trennen zu können.

Aus diesem Vorgehen ergeben sich drei Beiträge. Der erste Beitrag ist ein kontrollierter, nach der Art der sprachlichen Referenz aufgeschlüsselter Vergleich der drei Repräsentationsformen für einen lokal betriebenen Agenten. Der zweite Beitrag ist die Untersuchung, ob sich das Zusammenspiel der Schichten allein über die Gestaltung der Instruktion steuern lässt. Der dritte Beitrag ist ein lauffähiger Demonstrator, der die Erkenntnis in die immersive Zielumgebung überträgt.

1.5 Aufbau der Arbeit

Der Aufbau der Arbeit zeichnet den Weg von der offenen Frage zur belastbaren Antwort nach. Kapitel 2 legt die begrifflichen Grundlagen und ordnet die Arbeit in den Stand der Technik ein, um die Forschungslücke genau zu bestimmen, die sie schließt. Aus dieser Lücke leitet Kapitel 3 ab, was ein

System leisten muss, damit sich die Frage überhaupt beantworten lässt. Kapitel 4 entwickelt daraus das Lösungskonzept, insbesondere den Entwurfsraum der drei Repräsentationsformen und die Entscheidungen, die einen fairen Vergleich ermöglichen. Wie dieses Konzept in ein lauffähiges System übersetzt wird, beschreibt Kapitel 5. Kapitel 6 führt den Vergleich durch und berichtet die Ergebnisse zu beiden Forschungsfragen. Kapitel 7 fasst die Erkenntnisse zusammen, ordnet ihre Grenzen ein und zeigt, welche Fragen offen bleiben.

Kapitel 2

Grundlagen und Stand der Technik

Dieses Kapitel schafft die Grundlage, um die Fragestellung der Arbeit einordnen zu können. Der erste Teil führt die eingesetzten Modelle, das Agenten-Paradigma und die Formen der Szenenrepräsentation ein. Der zweite Teil ordnet die Arbeit in den Stand der Technik ein und leitet daraus die Forschungslücke ab.

2.1 Große Sprach- und Sprach-Bild-Modelle

Die vorliegende Arbeit setzt zwei Arten vortrainierter Modelle als Bausteine ein. Beide werden unverändert genutzt und nicht selbst weiterentwickelt.

Ein großes Sprachmodell, im Folgenden als LLM (Large Language Model) bezeichnet, ist ein auf umfangreichen Textmengen trainiertes neuronales Modell, das zu einer gegebenen Eingabe fortlaufend Text erzeugt. Durch ein zusätzliches Training auf Instruktionen lässt sich ein solches Modell anweisen, eine Aufgabe zu bearbeiten, und gibt seine Antwort wieder als Text aus. In dieser Arbeit übernimmt ein LLM die Rolle des Agenten, der einen Befehl interpretiert und die passende Operation auswählt.

Ein Sprach-Bild-Modell, im Folgenden als VLM (Vision-Language Model) bezeichnet, erweitert dieses Prinzip um eine visuelle Eingabe. Es verarbeitet ein Bild gemeinsam mit einem Text und erzeugt daraus eine textuelle Antwort, etwa eine Beschreibung des Bildinhalts oder die Antwort auf eine Frage zum Bild. In dieser Arbeit übernimmt ein VLM die visuelle Wahrnehmung der Szene.

Der Unterschied zwischen beiden Modellen bestimmt ihre Rollen im System. Das Sprachmodell verarbeitet ausschließlich Text und ist damit auf eine textuelle Beschreibung der Szene angewiesen. Das Sprach-Bild-Modell kann eine gerenderte Ansicht unmittelbar interpretieren. Genau diese unterschiedlichen Zugänge zur Szene bilden den Ausgangspunkt der Frage, wie eine Szene einem solchen Modell am besten bereitgestellt wird.

Beide Modelle werden in dieser Arbeit lokal in einer Größenordnung von etwa sieben Milliarden Parametern betrieben. Die Gründe für den Einsatz lokal betriebener Modelle dieser Größe werden in der Einleitung dargelegt.

2.2 Werkzeugnutzende Agenten

Die Interaktion mit der Szene folgt dem Muster eines werkzeugnutzenden Agenten. Ein solcher Agent ist ein Sprachmodell, das nicht nur Text erzeugt, sondern in einer Schleife aus Wahrnehmung und Handlung Werkzeuge aufruft, um eine Aufgabe zu lösen.

Ein Werkzeug ist dabei eine benannte Funktion mit einer kurzen Beschreibung ihrer Wirkung und ihrer Parameter. Das Sprachmodell entscheidet anhand dieser Beschreibung, welches Werkzeug es

mit welchen Argumenten aufruft. Das Ergebnis des Aufrufs fließt in den Kontext zurück, woraufhin das Modell den nächsten Schritt wählt, bis es die Aufgabe als abgeschlossen meldet. Auf diese Weise verbindet der Agent die sprachliche Interpretation eines Befehls mit konkreten Aktionen in der Umgebung.

In dieser Arbeit wird der Agent mit dem Framework *smolagents* umgesetzt, das einen werkzeugaufzufindenden Agenten bereitstellt [3]. Die Werkzeuge selbst werden über das Model Context Protocol (MCP) angebunden, einen offenen Standard, der Sprachmodellen den Zugriff auf externe Werkzeuge und Datenquellen über eine einheitliche Schnittstelle ermöglicht [4]. Das Protokoll trennt die Bereitstellung der Werkzeuge von ihrer Nutzung durch den Agenten, sodass dieselben Werkzeuge unabhängig vom konkreten Modell aufgerufen werden können.

Genau dieses Muster bildet die Grundlage des in dieser Arbeit umgesetzten Systems. Wie es konkret realisiert ist, beschreibt Kapitel 5.

2.3 Szenenrepräsentation für Sprachmodelle

Damit ein Sprachmodell eine Szene verändern kann, muss es die Szene zunächst erfassen. Da ein Sprachmodell auf Text arbeitet, stellt sich die Frage, in welcher Form eine dreidimensionale Szene ihm zugänglich gemacht wird. Zwei grundlegende Ansätze stehen einander gegenüber.

Der strukturelle Ansatz beschreibt die Szene als Daten. Die Objekte werden mit ihren Eigenschaften wie Typ, Position, Größe und Farbe in einer textuellen Form wie JSON oder als Szenengraph aufgeführt. Diese Darstellung ist exakt und für ein Sprachmodell unmittelbar lesbar, gibt aber nur wieder, was in den Daten kodiert ist.

Der visuelle Ansatz stellt die Szene als gerendertes Bild bereit, das ein Sprach-Bild-Modell interpretiert. Diese Darstellung erfasst das Aussehen der Szene, wie es sich einem Betrachter zeigt, liefert aber keine exakten Koordinaten.

Der visuelle Ansatz bringt eine zusätzliche Anforderung mit sich. Ein Modell muss ein im Bild erkanntes Objekt benennen können, um es anschließend gezielt anzusprechen. Eine verbreitete Technik dafür ist das Set-of-Mark-Prompting, bei dem sichtbare Objekte im Bild mit nummerierten Marken versehen werden [5]. Das Modell kann sich dann auf eine Marke beziehen, und die Nummer lässt sich eindeutig einem Objekt zuordnen.

Unabhängig von der Repräsentationsform hängt die Schwierigkeit einer Aufgabe davon ab, wie im Befehl auf ein Objekt verwiesen wird. Bestehende Arbeiten unterscheiden Referenzen bereits nach verschiedenen Eigenschaften, etwa danach, ob eine Referenz vom Blickwinkel des Betrachters abhängt, oder danach, ob das Zielobjekt in der Szene eindeutig ist [6, 7]. Solche Einteilungen bilden den Ausgangspunkt für die in dieser Arbeit verwendete, feiner nach Referenztypen aufgeschlüsselte Betrachtung, die in Abschnitt 6.2 eingeführt wird.

2.4 Stand der Technik

Die Bausteine der vorliegenden Arbeit sind einzeln gut erforscht. Dieser Abschnitt ordnet die Arbeit entlang von vier Feldern in den Stand der Technik ein und zeigt, an welcher Stelle jedes Feld eine andere Frage verfolgt als die vorliegende Untersuchung.

2.4.1 Strukturelle Szenenmanipulation in immersiven Umgebungen

Ein erstes Feld befasst sich mit der sprachgesteuerten Manipulation von Szenen in virtuellen und gemischten Realitäten. LLMR erzeugt und verändert interaktive Mixed-Reality-Szenen zur Laufzeit, indem es mehrere Sprachmodelle orchestriert und die Szene als strukturierten Graphen führt [8]. VR Mover manipuliert Objekte in der virtuellen Realität über natürliche Sprache und kodiert die Szene

dazu als strukturierte Objektdaten [9]. Beide Arbeiten zeigen, dass sich Szenen in immersiven Umgebungen sprachlich verändern lassen. Sie nutzen dafür jedoch ausschließlich die strukturelle Repräsentation und setzen große, cloudbasierte Modelle ein. Ein Vergleich verschiedener Repräsentationsformen findet nicht statt.

2.4.2 Hybrides Grounding

Ein zweites Feld verbindet strukturelle und visuelle Information, um ein Objekt in einer Szene zu bestimmen. SeeGround stellt eine Szene als Kombination aus einer gerenderten Ansicht und einer räumlich angereicherten textuellen Beschreibung dar und verknüpft beide über visuelle Marken [10]. Dieser Ansatz ist der vorliegenden Arbeit konzeptionell am nächsten, verfolgt aber ein anderes Ziel. Er dient dem Auffinden eines Objekts und nicht seiner Manipulation, setzt ein großes Modell ein und stellt die Repräsentationsformen nicht als gleichwertige Bedingungen einander gegenüber.

Einen verwandten Weg beschreitet SceneGraphGrounder, das das Auffinden eines Objekts als strukturiertes Graph-Matching formuliert [11]. Dabei leitet ein visuelles Modell über eine Marker-Strategie die Beziehungen zwischen Objekten aus zweidimensionalen Ansichten ab, die anschließend in einen persistenten Szenengraphen überführt werden. Die Arbeit berichtet, dass eine explizite strukturelle Repräsentation die Grounding-Genauigkeit verbessert. Damit bestätigt sie, dass die Verbindung von struktureller und visueller Information ein aktiv verfolgter Ansatz ist. Wie SeeGround bleibt sie jedoch beim Auffinden von Objekten und behandelt nicht deren Manipulation. Zudem betrachtet sie die strukturelle und die visuelle Information nicht als getrennte, gegeneinander geprüfte Repräsentationsformen, sondern setzt sie von vornherein gemeinsam ein.

2.4.3 Modalitäts-Ablationen und Modalitäts-Dominanz

Ein drittes Feld untersucht, wie sich verschiedene Eingabemodalitäten auf die Leistung auswirken. Die Arbeit zum Embodied Agent Interface vergleicht unter anderem eine rein strukturelle, eine rein visuelle und eine kombinierte Eingabe und zeigt, dass strukturierter Input reine Bildeingabe deutlich übertrifft [12]. Dieser Vergleich betrifft jedoch die Handlungsplanung und nicht die Szenenmanipulation und schlüsselt die Aufgaben nicht nach Referenztypen auf. In eine ähnliche Richtung weist SIRI-Bench, ein Benchmark für räumliches Schließen [13]. In einer kontrollierten Ablation werden dort baugleiche Modelle einmal mit einer textuellen und einmal mit einer visuellen Eingabe derselben Aufgabe verglichen. Die textbasierten Varianten übertreffen ihre videobasierten Gegenstücke deutlich, und die Untersuchung stellt fest, dass die Modelle sich übermäßig auf textuelle Hinweise stützen und räumliche Information nur schwer aus dem visuellen Eingang gewinnen. Dieser Befund stützt aus einer anderen Domäne die auch in der vorliegenden Arbeit beobachtete Tendenz, dass strukturierte gegenüber rein visueller Information bei räumlichen Aufgaben im Vorteil ist. Er betrifft allerdings abstrakte Reasoning-Aufgaben und nicht die Manipulation einer 3D-Szene und nimmt keine Aufschlüsselung nach Referenztypen vor. Eng verwandt sind darüber hinaus zwei Arbeiten zur Modalitäts-Dominanz. Sie zeigen, dass Sprach-Bild-Modelle textuelle Information gegenüber visueller Information übergewichten und bei widersprüchlichen Eingaben dem Text mehr vertrauen [1, 2]. Eine dieser Arbeiten untersucht dieses Verhalten unter anderem an genau dem visuellen Modell, das auch in der vorliegenden Arbeit eingesetzt wird [2]. Diese Beobachtung liefert die theoretische Grundlage für die Erwartung, dass eine naive Kombination beider Schichten die strukturelle Information überbewerten könnte.

2.4.4 Ansätze mit lokalen, kleinen Modellen

Ein viertes Feld setzt lokal betreibbare Modelle geringer Größe ein, meist aus Gründen des Datenschutzes, der Latenz oder der Offline-Fähigkeit. Ein Ansatz zur Handlungsplanung nutzt ein lokales Modell mit sieben Milliarden Parametern und zeigt, dass sich solche Aufgaben grundsätzlich auch mit kleinen Modellen bearbeiten lassen [14]. Ein weiterer Ansatz löst das Auffinden von Objekten in 3D-Szenen mit einem kleinen visuellen Modell [15]. Beide Arbeiten belegen die Machbarkeit unter Ressourcenbeschränkung, führen aber keinen kontrollierten Vergleich mehrerer Repräsentationsformen für

die Szenenmanipulation durch. Damit bleibt gerade für die ressourcenbeschränkte Umgebung offen, welche Repräsentation eine natürlichsprachliche Manipulation am zuverlässigsten trägt.

2.5 Forschungslücke

Die vier Felder zeigen ein einheitliches Bild. Die strukturelle und die visuelle Repräsentation sind je für sich etabliert. Es gibt Arbeiten zur sprachgesteuerten Manipulation von Szenen, Arbeiten zum hybriden Auffinden von Objekten, Untersuchungen zur Wirkung einzelner Modalitäten und Ansätze mit kleinen, lokal betreibbaren Modellen. Was fehlt, ist eine Untersuchung, die diese Fäden zusammenführt.

Kein bekanntes Werk vereint die folgenden vier Eigenschaften. Es geht erstens um die natürlichsprachliche Manipulation einer Szene und nicht allein um deren Verständnis, das Auffinden von Objekten oder die Erzeugung von Szenen. Es vergleicht zweitens die strukturelle, die visuelle und die hybride Repräsentation als gleichwertige Bedingungen. Es schlüsselt drittens die Aufgaben nach der Art der sprachlichen Referenz auf. Es setzt viertens lokal betreibbare Modelle geringer Größe ein anstelle großer, cloudbasierter Modelle.

Daraus ergibt sich die offene Frage, wie eine Szene einem lokal betriebenen Agenten für die natürlichsprachliche Manipulation am besten bereitgestellt werden sollte und welchen Einfluss die Wahl der Repräsentationsform auf die räumliche Korrektheit und den Ausführungserfolg hat. Offen ist dabei insbesondere, ob eine hybride Kombination beider Repräsentationen ihre jeweiligen Stärken vereint oder ob unter den Bedingungen eines kleinen, lokalen Modells eine Modalität die andere verdrängt. Aus dieser Lücke leitet die Arbeit ihre Zielsetzung ab, die in Kapitel 1 dargelegt wird.

Kapitel 3

Anforderungen

Die Anforderungen an das System ergeben sich nicht aus einem vorgegebenen Lastenheft, sondern aus dem wissenschaftlichen Ziel der Arbeit und den Bedingungen, unter denen sie entsteht. Dieses Kapitel legt zunächst offen, aus welchen Quellen die Anforderungen abgeleitet werden. Darauf aufbauend beschreibt es die funktionalen und die nicht-funktionalen Anforderungen, benennt die Spannungen zwischen ihnen und grenzt am Ende ab, was bewusst nicht gefordert ist.

3.1 Herleitung der Anforderungen

Da die Arbeit kein Auftragsprojekt mit externem Auftraggeber ist, gibt es keinen klassischen Anforderungskatalog. Formale Anforderungen wurden mit der Betreuung nicht im Einzelnen festgelegt. Die Anforderungen leiten sich daher analytisch aus vier Quellen ab, die im Folgenden benannt werden.

Die erste Quelle sind die Forschungsfragen. Das System existiert, um den Einfluss der Repräsentationsform auf die natürlichsprachliche Szenenmanipulation messbar zu machen. Daraus folgt unmittelbar, dass das System mehrere Repräsentationsformen bereitstellen und ihren Einfluss unter fairen Bedingungen sichtbar machen muss.

Die zweite Quelle ist die Zielumgebung. Die Arbeit ist auf eine immersive Anwendung ausgerichtet, in der Datenschutz, geringe Latenz und Unabhängigkeit von einer Netzverbindung eine Rolle spielen. Diese Ausrichtung legt den Betrieb lokaler Modelle nahe und verlangt, dass sich die Verarbeitungskette bis in die Brille übertragen lässt.

Die dritte Quelle ist die wissenschaftliche Methodik. Damit die Ergebnisse belastbar sind, müssen die Messungen reproduzierbar und die Erfolgsbewertung objektiv sein. Dies stellt Anforderungen an die Kontrolle der Szenen und an die Art der Erfolgsmessung.

Die vierte Quelle ist die verfügbare Hardware. Für die Arbeit stand ein vom Institut bereitgestellter Arbeitsplatzrechner mit einer einzelnen Grafikkarte zur Verfügung. Diese Ausstattung ist eine feste Randbedingung und keine freie Entwurfsentscheidung. Sie begrenzt die Größe der einsetzbaren Modelle und prägt damit mehrere der folgenden Anforderungen.

3.2 Funktionale Anforderungen

Die funktionalen Anforderungen beschreiben, was das System leisten muss.

Zunächst muss das System einen natürlichsprachlichen Befehl entgegennehmen und in eine Veränderung der Szene umsetzen. Die dafür nötigen Operationen beschränken sich auf das Erzeugen, Verschieben und Entfernen von Objekten. Diese Beschränkung ist bewusst gewählt, da sich mit diesen

wenigen Operationen bereits alle für die Untersuchung nötigen Arten von Referenzen abdecken lassen, ohne den Funktionsumfang unnötig auszuweiten.

Um die zentrale Frage untersuchen zu können, muss das System die Szene in den drei zu vergleichenden Repräsentationsformen bereitstellen, also strukturell, visuell und hybrid. Dies ist die Kernanforderung, ohne die der Vergleich nicht möglich wäre.

Damit der Vergleich fair bleibt, müssen alle Varianten Objekte über dasselbe Interface ansprechen. Diese Anforderung ist weniger selbstverständlich, als sie zunächst wirkt. Eine rein visuelle Variante hätte ohne ein gemeinsames Kennungssystem kein Handle, über das sie ein erkanntes Objekt für einen Werkzeugaufruf benennen könnte, und wäre damit nicht wegen ihrer Repräsentation im Nachteil, sondern wegen eines fehlenden Zugriffs. Ein gemeinsames Kennungssystem stellt daher sicher, dass gemessene Unterschiede auf die Repräsentation zurückgehen.

Der Erfolg einer Manipulation muss zudem objektiv bestimmbar sein. Das System muss dazu den tatsächlichen Zustand der Szene nach einer Manipulation auslesen, sodass sich der Erfolg unabhängig von der Selbstauskunft des Agenten ermitteln lässt. Diese Anforderung folgt aus der Beobachtung, dass ein kleines Modell einen Erfolg melden kann, den es nicht erreicht hat, was eine Messung anhand seiner eigenen Antwort unzuverlässig machen würde. Schließlich muss sich jedes Testszenario reproduzierbar aufbauen und zurücksetzen lassen, damit Messungen unter identischen Bedingungen wiederholbar sind.

Tabelle 3.1 fasst die funktionalen Anforderungen zusammen. Die Spalte Herkunft verweist darauf, ob eine Anforderung aus den Forschungsfragen oder aus methodischen Gründen folgt.

Tabelle 3.1: Funktionale Anforderungen.

Nr.	Anforderung	Herkunft
FA1	Natürlichsprachliche Befehle in Szenenmanipulationen umsetzen, beschränkt auf Erzeugen, Verschieben und Entfernen von Objekten	RQ1, RQ2
FA2	Die Szene in struktureller, visueller und hybrider Repräsentation bereitstellen	RQ1
FA3	Objekte über ein gemeinsames Kennungssystem ansprechen, unabhängig von der Repräsentationsform	Validität
FA4	Den Erfolg einer Manipulation aus dem tatsächlichen Szenenzustand bestimmen	Validität
FA5	Testszenarien reproduzierbar aufbauen und zurücksetzen	Methodik

3.3 Nicht-funktionale Anforderungen

Die nicht-funktionalen Anforderungen beschreiben keine einzelnen Funktionen, sondern Eigenschaften und Randbedingungen, die das System als Ganzes erfüllen muss.

Aus der Zielumgebung folgt, dass die Modelle lokal betrieben werden. Datenschutz, geringe Latenz und die Unabhängigkeit von einer Netzverbindung sprechen in einer immersiven Anwendung für eine lokale Ausführung ohne Cloud. Damit verbunden ist die Beschränkung auf begrenzte Hardware. Da für die Arbeit eine feste Ausstattung mit einer einzelnen Grafikkarte vorgegeben war, muss das System mit deren Grafikspeicher auskommen. Diese Vorgabe legt die Wahl auf Modelle geringer Größe fest, die neben dem Sprachmodell auch das visuelle Modell gleichzeitig im Speicher halten können.

Für die Aussagekraft der Untersuchung muss die Messung reproduzierbar sein. Unter identischer Konfiguration müssen sich vergleichbare Ergebnisse einstellen, was kontrollierte und wiederholbar aufgebaute Szenen voraussetzt. Da die eigentliche Zielumgebung die immersive Anwendung ist, muss sich dieselbe Verarbeitungskette sowohl am Desktop für die Messung als auch in der Brille betreiben

lassen, ohne dass ihr Kern verändert wird. Schließlich muss der Vergleich so aufgebaut sein, dass die Repräsentationsform die einzige zwischen den Varianten variierende Größe ist. Nur dann lassen sich Unterschiede eindeutig auf die Repräsentation zurückführen.

Tabelle 3.2 fasst die nicht-funktionalen Anforderungen zusammen.

Tabelle 3.2: Nicht-funktionale Anforderungen.

Nr.	Anforderung	Herkunft
NFA1	Modelle lokal ohne Cloud betreiben	Zielumgebung
NFA2	Mit der vorgegebenen Hardware, einer einzelnen Grafikkarte, und Modellen geringer Größe auskommen	Hardware
NFA3	Messungen unter identischer Konfiguration reproduzierbar halten	Methodik
NFA4	Dieselbe Verarbeitungskette am Desktop und in der immersiven Umgebung betreiben	Zielumgebung
NFA5	Die Repräsentationsform als einzige zwischen den Varianten variierende Größe sicherstellen	Validität

3.4 Spannungen zwischen den Anforderungen

Die genannten Anforderungen lassen sich nicht widerspruchsfrei zugleich maximieren. Zwischen ihnen bestehen Spannungen, deren bewusste Auflösung den Charakter der Arbeit prägt.

Eine erste Spannung besteht zwischen der Leistungsfähigkeit und der Ressourcenbeschränkung. Die Anforderung, natürlichsprachliche Befehle zuverlässig umzusetzen, wäre mit großen Modellen leichter zu erfüllen. Die Vorgabe lokaler Modelle geringer Größe begrenzt jedoch die Fähigkeiten des Systems. Diese Spannung wird nicht aufgelöst, sondern angenommen, da gerade das Verhalten unter dieser Beschränkung Gegenstand der Untersuchung ist.

Eine zweite Spannung besteht zwischen der Fairness des Vergleichs und der Praxisnähe. Das gemeinsame Kennungssystem und die kontrolliert aufgebauten Szenen sind für einen sauberen Vergleich notwendig, entfernen die Aufgabe aber ein Stück weit von einer realistischen Anwendung. Hier wird der wissenschaftlichen Kontrolle der Vorrang gegeben, da die Arbeit eine Vergleichsstudie und keine Produktentwicklung ist.

Eine dritte Spannung besteht zwischen der Reproduzierbarkeit und dem Realismus der Szenen. Reproduzierbare Messungen verlangen einfache, kontrolliert aufgebaute Szenen, während die Zielumgebung komplexe, reale Szenen nahelegt. Auch hier wird zugunsten der Reproduzierbarkeit entschieden, und die Übertragung in die reale Umgebung bleibt dem Demonstrator vorbehalten.

Diese Entscheidungen folgen einem einheitlichen Grundsatz. Wo eine wissenschaftliche und eine anwendungsnahe Anforderung in Konflikt geraten, erhält die wissenschaftliche den Vorrang, weil das Ziel der Arbeit eine belastbare Erkenntnis und kein fertiges Produkt ist.

3.5 Abgrenzung des Funktionsumfangs

Ebenso wichtig wie das, was das System leisten muss, ist die Abgrenzung dessen, was bewusst nicht gefordert ist. Diese Abgrenzung entspricht der Nicht-Reichweite der Zielsetzung und hält den Rahmen der Arbeit klar.

Das System muss keine Produktreife erreichen. Es genügt, die untersuchten Repräsentationen und die Kette bis in die immersive Umgebung funktionsfähig zu machen, ohne dass Robustheit unter Dauerlast oder eine ausgereifte Bedienung gefordert ist. Der Umfang der Manipulationen bleibt bewusst auf das

Erzeugen, Verschieben und Entfernen von Objekten beschränkt. Weitere Operationen wie das Drehen oder Skalieren zur Laufzeit sind nicht Teil der Untersuchung. Ebenso wenig muss das System beliebige oder mehrdeutige natürlichsprachliche Formulierungen zuverlässig auflösen. Die Befehle sind für die Untersuchung klar formuliert, und die Robustheit gegenüber umgangssprachlicher Vielfalt ist kein Ziel. Eine Nutzerstudie ist nicht vorgesehen, da die Bewertung rein systembasiert aus dem Szenenzustand erfolgt. Schließlich wird keine Übertragbarkeit auf andere Modelle oder auf reale, komplexe Szenen gefordert, da die Untersuchung auf ein Modellpaar und kontrolliert aufgebaute Szenen begrenzt ist.

Kapitel 4

Konzept

Die Anforderungen aus dem vorigen Kapitel geben vor, was das System leisten muss. Dieses Kapitel entwickelt daraus das Lösungskonzept, also den Entwurf, der diese Anforderungen erfüllt. Es beschreibt zunächst den Lösungsansatz im Überblick und den Entwurfsraum der drei Repräsentationsformen. Anschließend legt es die Entwurfsentscheidungen offen, die einen fairen Vergleich der Formen erst ermöglichen, entwickelt die Idee zur Steuerung ihrer Kombination und begründet, warum der Erfolg nach der Art der sprachlichen Referenz betrachtet werden muss. Die konkrete technische Umsetzung dieses Konzepts beschreibt Kapitel 5.

4.1 Lösungsansatz im Überblick

Der Lösungsansatz beruht auf einem sprachgesteuerten Agenten. Der Agent nimmt einen natürlich-sprachlichen Befehl entgegen, verschafft sich über eine Repräsentation ein Bild der Szene und verändert die Szene über eine feste Menge von Operationen. Der entscheidende Freiheitsgrad des Entwurfs liegt darin, in welcher Form dem Agenten die Szene bereitgestellt wird. Genau diese Form ist der Untersuchungsgegenstand der Arbeit.

Das Konzept folgt einem dreistufigen roten Faden. In der ersten Stufe wird der Einfluss der Repräsentationsform analysiert, indem verschiedene Formen unter gleichen Bedingungen verglichen werden. In der zweiten Stufe wird untersucht, ob sich die Kombination der Repräsentationen gezielt verbessern lässt. In der dritten Stufe wird die beste Variante in die immersive Zielumgebung übertragen und dort als Demonstrator erprobt. Die ersten beiden Stufen entsprechen den beiden Forschungsfragen, die dritte Stufe dient dem Nachweis der Übertragbarkeit.

4.2 Die drei Repräsentationsformen

Der Entwurfsraum umfasst drei Formen, in denen die Szene dem Agenten bereitgestellt werden kann.

Die strukturelle Form beschreibt die Szene als exakte Daten. Sie kennt die Objekte mit ihren Kennungen, Typen, Positionen und Größen und ist damit stark bei allem, was sich aus diesen Daten ableiten lässt, etwa bei geometrischen Beziehungen. Was in den Daten nicht kodiert ist, bleibt für sie jedoch unsichtbar.

Die visuelle Form beschreibt die Szene als gerenderte Ansicht, die von einem visuellen Modell interpretiert wird. Sie erfasst das Aussehen der Szene, wie es sich einem Betrachter zeigt, und ist damit stark bei Eigenschaften, die nur im Bild erkennbar sind. Exakte Zahlenwerte wie Koordinaten liefert sie jedoch nicht.

Die hybride Form stellt beide Schichten zugleich bereit. Sie verbindet die Möglichkeit, exakte Geometrie zu nutzen, mit der Möglichkeit, das Aussehen zu berücksichtigen.

Genau diese drei Formen bilden den Vergleichsraum der Arbeit, weil sie die beiden Einzelmodalitäten und ihre Kombination vollständig abdecken. Der Vergleich der Einzelformen zeigt, wofür jede Schicht zuständig ist, und der Vergleich mit der hybriden Form zeigt, ob eine Kombination die Stärken beider vereint.

Eine bewusste Entscheidung betrifft den Inhalt der strukturellen Schicht. Sie enthält je Objekt die Kennung, den Typ, die Position, die Farbe und die Größe sowie die Pose der Kamera. Vorberechnete räumliche Beziehungen enthält sie jedoch nicht. Eine Relation wie links von muss der Agent aus den Koordinaten selbst ableiten. Andernfalls würde die Auswertung die Güte einer Vorverarbeitung messen und nicht die Eignung der Repräsentation.

4.3 Entwurfsentscheidungen für einen fairen Vergleich

Damit der Vergleich tatsächlich die Repräsentation misst und nicht einen Nebeneffekt des Aufbaus, sind mehrere Entwurfsentscheidungen nötig. Sie stellen sicher, dass keine Variante aus Gründen bevorzugt oder benachteiligt wird, die nichts mit ihrer Repräsentation zu tun haben.

Die erste Entscheidung ist ein gemeinsames Kennungssystem. Alle Varianten sprechen Objekte über dieselben Kennungen an. Eine Kennung ist dabei nur ein Adressierungsmittel und kein Bestandteil des Szenenverständnisses. Die visuelle Variante wird über Marken, die in das gerenderte Bild eingezeichnet werden, an dieselben Kennungen gebunden. Dieses Markieren folgt dem Set-of-Mark-Prinzip [5]. So kann auch die visuelle Variante ein erkanntes Objekt benennen, ohne dass ihr daraus ein struktureller Vorteil erwächst.

Die zweite Entscheidung betrifft die Bewegungsoperationen. Das System stellt eine absolute und eine relative Bewegungsoperation bereit. Die relative Operation ist notwendig, damit sich Objekte auch ohne einen exakten Weltbezug verschieben lassen. Ohne sie wäre die rein visuelle Variante benachteiligt, da sie keine exakten Koordinaten kennt. Dieser Nachteil wäre ein Artefakt des Werkzeugzuschnitts und keine Eigenschaft der Repräsentation.

Die dritte Entscheidung betrifft die bewusste Auslassung von Information. Die unterscheidende Eigenschaft der rein perzeptuellen Aufgaben, etwa ein Oberflächenmuster, wird absichtlich nicht in die strukturelle Schicht aufgenommen. Erst dadurch entsteht ein Fall, in dem die strukturelle Schicht prinzipiell blind ist und sich die exklusive Kompetenz der visuellen Schicht überhaupt zeigen kann.

4.4 Steuerung der Modalitätsfusion

Die hybride Form stellt beide Schichten bereit, legt aber nicht fest, wie der Agent sie gegeneinander gewichtet. Dem Konzept liegt die Annahme zugrunde, dass die bloße Verfügbarkeit beider Schichten nicht genügt, damit ihre Stärken auch tatsächlich zusammenwirken. Diese Annahme stützt sich auf Beobachtungen aus der Literatur, wonach Sprach-Bild-Modelle textuelle Information gegenüber visueller übergewichten [1, 2]. Die Art, wie die beiden Schichten dem Agenten präsentiert werden, wird deshalb selbst zu einem Entwurfsgegenstand.

Das Konzept sieht dafür zwei Strategien vor. Die erste Strategie ist die Priorisierung. Sie erklärt eine der beiden Schichten für einen bestimmten Zweck als maßgeblich und stellt sie in den Vordergrund. Die zweite Strategie ist die Kompetenztrennung. Sie ordnet den beiden Schichten getrennte Zuständigkeiten zu, sodass jede Schicht nur für den Teil der Aufgabe herangezogen wird, für den sie geeignet ist.

Beide Strategien wirken ausschließlich über die Gestaltung der Instruktion. Die Modelle werden nicht nachtrainiert, und ihre Gewichte bleiben unverändert. Diese Beschränkung auf die Instruktionsebene ist eine bewusste Entscheidung. Sie hält den Vergleich sauber, da sich nur der Kontext und nicht

das Modell ändert, und sie entspricht der Fragestellung, die nach der Repräsentation und nicht nach einer Modellanpassung fragt. Die konkrete Ausformulierung der beiden Strategien wird in Kapitel 5 beschrieben.

4.5 Differenzierung nach Referenztyp

Ob eine Repräsentation eine Aufgabe lösen kann, hängt davon ab, wie im Befehl auf ein Objekt verwiesen wird. Ein Verweis über eine exakte Lage stellt andere Anforderungen als ein Verweis über eine sichtbare Eigenschaft. Aus dieser Beobachtung folgt der zentrale konzeptionelle Gedanke der Arbeit. Die beiden Repräsentationen besitzen nicht nur unterschiedlich starke, sondern teils einander ausschließende Zuständigkeiten.

Manche Referenzen lassen sich ausschließlich über die strukturelle Schicht auflösen. Ein Objekt, das im Bild verdeckt ist, bleibt in den strukturellen Daten dennoch verzeichnet. Andere Referenzen lassen sich ausschließlich über die visuelle Schicht auflösen. Eine Eigenschaft wie ein Oberflächenmuster, das in den strukturellen Daten nicht vorkommt, ist nur im Bild erkennbar. Zwischen diesen beiden Polen liegt ein Bereich, in dem beide Schichten dieselbe Referenz auflösen können.

Abbildung 4.1 stellt diese Kompetenzverteilung dar. Gerade die einander ausschließenden Bereiche sind es, die eine Kombination beider Schichten überhaupt sinnvoll machen. Sie begründen zugleich, warum der Erfolg nach der Art der Referenz aufgeschlüsselt betrachtet werden muss und nicht als ein einzelner Gesamtwert. Die konkrete Einteilung der Referenztypen und die zugehörigen Szenarien werden in Kapitel 6 eingeführt.




Abbildung 4.1: Konzeptionelle Kompetenzverteilung der beiden Repräsentationen. Der Überlappungsbereich steht für Referenzen, die beide Schichten auflösen können, die Außenbereiche für die jeweils exklusive Kompetenz einer Schicht. Genau diese exklusiven Bereiche begründen den hybriden Ansatz.

Kapitel 5

Implementierung

Das Konzept aus dem vorigen Kapitel beschreibt, welche Repräsentationen verglichen werden und wie sie sich unterscheiden. Dieses Kapitel zeigt, wie sich dieses Konzept in ein lauffähiges System übersetzt. Es beschreibt zuerst den Aufbau im Überblick und geht anschließend auf die Anbindung der Szene, den Agenten mit seinen Werkzeugen, die konkrete Umsetzung der fünf Repräsentationsvarianten und schließlich auf den VR-Demonstrator ein.

5.1 Systemüberblick

Das System verbindet einen natürlichsprachlichen Befehl mit einer sichtbaren Veränderung der 3D-Szene. Es besteht aus drei lose gekoppelten Schichten, die über festgelegte Schnittstellen kommunizieren. Diese Trennung erlaubt es, die Umgebung auszutauschen, ohne die übrigen Schichten zu verändern, und ist der Grund, warum dieselbe Kette sowohl am Desktop für die Messung als auch in der immersiven Umgebung für den Demonstrator läuft.

Die drei Schichten

Die oberste Schicht übernimmt das Interpretieren und Entscheiden. Hier deutet ein Agent den Befehl und wählt die nötige Manipulation. Der Agent wird von einem lokal betriebenen Sprachmodell angetrieben und greift für die visuelle Wahrnehmung auf ein lokales visuelles Modell zurück.

Die mittlere Schicht verbindet die oberste Schicht mit der Umgebung. Ein Server nach dem Model Context Protocol (MCP) [4] stellt die Manipulationsoperationen als aufrufbare Werkzeuge bereit und übersetzt jeden Aufruf in eine Nachricht an die Umgebung. Eine WebSocket-Verbindung transportiert diese Nachrichten und liefert den Szenenzustand sowie gerenderte Bilder zurück.

Die unterste Schicht ist die Umgebung selbst. Sie hält die Szene, stellt sie dar und führt die Manipulationen aus. In der Evaluation läuft diese Schicht am Desktop, im Demonstrator auf der Meta Quest.

Ablauf einer Manipulation

Ein Durchlauf beginnt mit dem natürlichsprachlichen Befehl an den Agenten. Der Agent verschafft sich zunächst ein Bild der Szene, indem er über die Werkzeuge den strukturellen Zustand oder eine gerenderte Ansicht anfordert. Auf dieser Grundlage entscheidet er, welche Operation auszuführen ist, und ruft das entsprechende Werkzeug auf. Der MCP-Server leitet den Aufruf über die WebSocket-Verbindung an die Umgebung weiter, die die Manipulation ausführt. Anschließend liest die Auswertung den neuen Szenenzustand aus und bestimmt daraus den Erfolg. Abbildung 5.1 stellt diesen Aufbau und den Nachrichtenfluss dar.




Abbildung 5.1: Aufbau des Systems in drei Schichten und Nachrichtenfluss einer Manipulation. Durchgezogene Pfeile zeigen den Vorwärtsfluss, gestrichelte Pfeile den Rückkanal. Die Verbindung zwischen MCP-Server und Umgebung wird über WebSocket übertragen.

5.2 Szenenanbindung

Damit der Agent eine Szene bearbeiten kann, muss die Umgebung sie in einer verarbeitbaren Form bereitstellen. Die Umgebung liefert dazu zwei Sichten auf dieselbe Szene, eine strukturelle und eine visuelle.

Der strukturelle Zustand

Die Umgebung führt intern ein Verzeichnis aller manipulierbaren Objekte. Auf Anfrage serialisiert sie dieses Verzeichnis in eine JSON-Struktur. Sie enthält eine Liste der Objekte mit jeweils einer eindeutigen Kennung, dem Objekttyp, der Farbe, der Größe und der Position sowie zusätzlich die Pose der Kamera. Listing 1 zeigt ein Beispiel dieser Ausgabe. Die Kamerapose ist Teil des Zustands, damit sich auch Aufgaben lösen lassen, die einen Bezug zum Betrachter herstellen. Nicht enthalten sind Eigenschaften, die allein das Aussehen betreffen und über die Grundfarbe hinausgehen, etwa eine Oberflächentextur. Genau diese Lücke ist der Grund, warum rein perzeptuelle Referenzen über den strukturellen Zustand nicht auflösbar sind.

```

1 {
2   "type": "state",
3   "objects": [
4     {"id": "obj_1", "type": "cube", "color": "red", "x": 0.0, "y": 0.0, "z": 0.0,
      ↪ "scale": 1.0},
5     {"id": "obj_2", "type": "sphere", "color": "blue", "x": 2.0, "y": 0.0, "z": 0.0,
      ↪ "scale": 1.0}
6   ],
7   "camera": {
8     "position": [0.0, 1.6, -6.0],
9     "forward": [0.0, 0.0, 1.0],
10    "up":       [0.0, 1.0, 0.0]
11  }
12 }
```

Listing 1: Beispiel des strukturellen Szenenzustands als JSON-Ausgabe der Umgebung.

Die visuelle Sicht und die Objektmarkierung

Für die visuelle Sicht rendert die Umgebung die Szene aus der Kamera und übergibt das Bild. Ein Bild allein erlaubt dem visuellen Modell jedoch nicht, ein erkanntes Objekt für einen Werkzeugaufruf zu benennen. Deshalb wird jedes sichtbare Objekt im Bild mit einer Marke versehen, die seine Kennung trägt. Dieses Vorgehen entspricht dem Set-of-Mark-Prinzip [5]. Das visuelle Modell kann ein Objekt damit über dieselbe Kennung ansprechen, die auch die Werkzeuge verwenden. Abbildung 5.2 zeigt beide Ansichten derselben Szene im Vergleich.

Sichtbarkeit und Verdeckung

Eine Marke wird nur gesetzt, wenn das Objekt tatsächlich sichtbar ist. Ein Sichtstrahl von der Kamera zum Objekt prüft, ob ein anderes Objekt die Sichtlinie unterbricht. Ist das der Fall, gilt das Objekt als verdeckt und erhält keine Marke. Ein verdecktes Objekt fehlt damit in der visuellen Sicht vollständig, bleibt im strukturellen Zustand aber unverändert verzeichnet. Diese Asymmetrie ist die Grundlage der verdeckten Referenzen aus Kategorie E.

Das gemeinsame id-Substrat

Beide Sichten verweisen auf dieselben Kennungen. Die strukturelle Sicht führt sie ohnehin, und die visuelle Sicht verknüpft ihre Marken mit denselben Werten. Dadurch spricht der Agent Objekte un-




Abbildung 5.2: Die visuelle Repräsentation am Beispiel einer einfachen Szene. Links die gerenderte Ansicht, wie sie die Kamera liefert. Rechts dieselbe Ansicht nach dem Set-of-Mark-Verfahren, bei dem jedes sichtbare Objekt eine nummerierte Marke trägt, über die das visuelle Modell es benennen kann. Die Marken sind reine Bezeichner. Die Farbe einer Marke ist bedeutungslos und wird bei der Auswertung ignoriert.

abhängig von der Repräsentationsform über ein einheitliches Interface an. Dieses id-Substrat ist die Voraussetzung dafür, dass der Vergleich der Repräsentationen fair bleibt, wie in Abschnitt 6.1 begründet.

5.3 Agent und Werkzeuge

Der Agent bildet die oberste Schicht des Systems. Er nimmt den Befehl entgegen, verschafft sich ein Bild der Szene und entscheidet, welche Operation auszuführen ist. Dieser Abschnitt beschreibt, wie der Agent aufgebaut ist und über welche Werkzeuge er die Szene verändert.

Der Agent und das Sprachmodell

Als Agent dient ein werkzeugaufzufordernder Agent aus dem Framework `smolagents` [3]. Angetrieben wird er von einem lokal betriebenen Sprachmodell, das über eine OpenAI-kompatible Schnittstelle angesprochen wird, die LM Studio auf dem Rechner bereitstellt. Der Agent arbeitet in einer Schleife. In jedem Schritt entscheidet das Sprachmodell anhand des aktuellen Kontexts, welches Werkzeug mit welchen Argumenten aufgerufen wird, bis es die Aufgabe als abgeschlossen meldet. Abbildung 5.3 stellt diesen Ablauf einer einzelnen Manipulation dar, von der Wahrnehmung bis zur Erfolgsbestimmung aus dem Folgezustand. Die Modelle werden dabei nicht nachtrainiert. Der einzige Hebel zur Steuerung ihres Verhaltens ist die Gestaltung des Kontexts, was den Ansatzpunkt der zweiten Forschungsfrage bildet.

Die Werkzeuge

Die eigentlichen Operationen stellt der MCP-Server als aufrufbare Werkzeuge bereit. Sie lassen sich in zwei Gruppen einteilen. Die manipulierenden Werkzeuge erzeugen, verschieben und entfernen Objekte oder setzen die Szene zurück. Die wahrnehmenden Werkzeuge liefern den strukturellen Zustand oder eine gerenderte Ansicht der Szene. Jedes Werkzeug trägt eine kurze Beschreibung in Form eines Dokumentationskommentars, und genau diese Beschreibung sieht der Agent, wenn er über den nächsten Aufruf entscheidet. Listing 2 zeigt am Beispiel des Verschiebens, wie ein solches Werkzeug aufgebaut ist.




Abbildung 5.3: Ablauf einer einzelnen Manipulation. In der Agentenschleife fragt der Agent die Szene über ein Wahrnehmungswerkzeug ab, das Sprachmodell wählt daraufhin die passende Operation, und das gewählte Werkzeug manipuliert das Objekt. Diese Schritte wiederholen sich, bis der Agent die Aufgabe abschließt. Erst danach liest die Auswertung den tatsächlichen Szenenzustand aus und bewertet den Erfolg daraus, nicht aus der Selbstausskunft des Agenten.

```

1  @mcp.tool()
2  def move_object(object_id: str, x: float, y: float, z: float) -> str:
3      """Move an existing object (id from get_scene_state) to a new position."""
4      global _last_op
5      key = ("move", object_id, x, y, z)
6      if key == _last_op:                               # Schutz gegen doppelte Ausführung
7          return f"Skipped: identical move already applied to {object_id}."
8      _last_op = key
9      send_to_unity({"action": "move", "id": object_id, "x": x, "y": y, "z": z})
10     return f"Done: {object_id} moved to ({x}, {y}, {z})."

```

Listing 2: Beispiel einer Werkzeugdefinition (gekürzt). Der Dokumentationskommentar dient dem Agenten als Beschreibung des Werkzeugs.

Erfolgsmessung und Terminierungsschutz

Der Erfolg einer Manipulation wird nicht aus der Antwort des Agenten abgeleitet, sondern aus dem tatsächlichen Folgezustand der Szene, wie in Abschnitt 6.3 beschrieben. Ein Detail der Werkzeuge hängt unmittelbar damit zusammen. Das lokale Modell bündelte gelegentlich einen Manipulations- und einen Abschlussaufruf so, dass dieselbe Manipulation zweimal ausgeführt wurde. Um dieses Verhalten des Frameworks zu neutralisieren, vergleicht jedes manipulierende Werkzeug den aktuellen Aufruf mit dem unmittelbar vorangegangenen und überspringt eine identische Wiederholung, sichtbar an der Abfrage von `_last_op` in Listing 2. Die Auswirkung dieses Schutzes auf die Ergebnisse wird in Abschnitt 6.6 eingeordnet.

5.4 Die fünf Repräsentationsvarianten

Die fünf Varianten teilen denselben Agenten und dieselbe Grundinstruktion. Diese Grundinstruktion verlangt, vor jeder Manipulation zunächst die Szene wahrzunehmen, niemals eine Kennung zu erfinden, die Aufgabe mit genau einem Manipulationsaufruf zu lösen und danach abzuschließen. Woran sich die Varianten unterscheiden, ist allein das Wahrnehmungswerkzeug, das dem Agenten zur Verfügung steht. Jedes Wahrnehmungswerkzeug trägt einen Dokumentationskommentar, und dieser Kommentar ist die Beschreibung, die der Agent bei der Wahl des nächsten Aufrufs liest. Zusätzlich rahmt der zurückgegebene Text die beiden Schichten, indem er sie benennt und ordnet. Über diese Beschreibung und diese Rahmung wird gesteuert, wie der Agent strukturelle und visuelle Information gegeneinander gewichtet.

Die beiden Einzelrepräsentationen

Die strukturelle Variante erhält ausschließlich Zugriff auf den strukturellen Zustand. Sie sieht die Szene als JSON mit Kennungen, Typen, Farben, Größen und Positionen, jedoch kein Bild. Die visuelle Variante erhält ausschließlich eine Beschreibung der gerenderten und markierten Ansicht. Sie kennt die Objekte nur über ihre Marken und deren sichtbare Eigenschaften, jedoch keine exakten Koordinaten.

Die naive Kombination

Die naive hybride Variante stellt beide Schichten nebeneinander. Sie gibt zuerst den strukturellen Zustand und danach die visuelle Beschreibung aus und benennt nur grob, wofür welche Schicht gedacht ist. Eine verbindliche Zuständigkeitsregel fehlt.

```

1  @tool
2  def get_scene_hybrid() -> str:
3      """Perceive the scene using BOTH exact structural data (ids, positions,
4      colors, sizes, camera) and a visual description. Use exact data for
5      geometry, visual data for semantics."""

```

Listing 3: Wahrnehmungswerkzeug der naiven hybriden Variante.

Priorisierung

Die geführte Variante ändert die Rahmung. Sie stellt die visuelle Beschreibung voran und erklärt sie für das Aussehen als maßgeblich, während die strukturelle Schicht ausdrücklich als rein geometrisch und frei von Aussehens-Information gekennzeichnet wird. Damit verschiebt sie das Gewicht zugunsten des Bildes.

```

1 @tool
2 def get_scene_hybrid_guided() -> str:
3     """Perceive the scene using a visual description AND exact structural
4     data. The visual description is authoritative for how objects LOOK
5     (texture, pattern, whether something stands out). The structural data
6     contains ONLY geometry (positions, sizes, base colors) and does NOT
7     encode any visual surface property."""

```

Listing 4: Wahrnehmungswerkzeug der geführten Variante (Priorisierung des Bildes).

Kompetenztrennung

Die kompetenzgetrennte Variante ordnet die Schichten nicht neu, sondern weist ihnen klar getrennte Aufgaben zu. Wie die naive Variante gibt sie den strukturellen Zustand zuerst aus. Der Unterschied liegt in der ausdrücklichen Arbeitsteilung. Die visuelle Beschreibung dient allein dazu, zu bestimmen, welches Objekt gemeint ist, wenn die Referenz vom Aussehen abhängt. Die strukturelle Schicht liefert alles Numerische, also sämtliche Koordinaten, Größen, Abstände und die Kamerageometrie. Der Unterschied zur Priorisierung ist damit nicht die Reihenfolge, sondern die enge, gegenseitig ausschließende Zuweisung der Zuständigkeiten.

```

1 @tool
2 def get_scene_hybrid_surgical() -> str:
3     """Perceive the scene using a visual description AND exact structural
4     data, with a clear division of labor. Use the VISUAL description ONLY
5     to identify WHICH object is meant when the reference depends on
6     appearance (texture, pattern, 'striped', 'stands out', 'most salient').
7     Use the STRUCTURAL data for EVERYTHING numerical: all coordinates,
8     positions, sizes, distances, camera geometry, and to compute where to
9     move things. Every object id appears in both - match them by id.
10    Never take coordinates from the visual description; never resolve an
11    appearance-based reference from the structural data alone."""

```

Listing 5: Wahrnehmungswerkzeug der kompetenzgetrennten Variante (klare Arbeitsteilung).

Übersicht der Varianten

Tabelle 5.1 fasst zusammen, welche Information die Varianten im Kontext erhalten und nach welcher Regel sie die Schichten gewichten.

Tabelle 5.1: Die fünf Repräsentationsvarianten im Vergleich.

Variante	Im Kontext	Regel zur Gewichtung
strukturell	nur struktureller Zustand	entfällt, keine visuelle Schicht
visuell	nur visuelle Beschreibung	entfällt, keine strukturelle Schicht
naiv hybrid	Struktur, dann Bild	grobe Zuordnung ohne verbindliche Regel
priorisierend	Bild, dann Struktur	Bild maßgeblich fürs Aussehen, Struktur nur Geometrie
kompetenzgetrennt	Struktur, dann Bild	Bild nur zur Objektwahl, Struktur für alles Numerische

5.5 Der VR-Demonstrator

Die Evaluation lief am Desktop unter kontrollierten Bedingungen. Um zu zeigen, dass der Ansatz auch in der eigentlichen Zielumgebung trägt, überführt ein Demonstrator die gesamte Kette in die immersive Umgebung. Er nutzt die kompetenzgetrennte Variante, also die in Kapitel 6 als am zuverlässigsten ermittelte Repräsentation. Dieser Abschnitt beschreibt die Ergänzungen, die für den Betrieb in der Brille nötig waren.

Sprachsteuerung

Der Nutzer spricht einen Befehl. Ein lokal betriebenes Spracherkennungsmodell wandelt die Aufnahme in Text um. Dieser Text wird in dieselbe Kommando-Warteschlange gegeben, die auch in der Evaluation den Agenten antreibt. Ein gesprochener Befehl durchläuft damit genau dieselbe Kette wie ein Befehl im Experiment, ergänzt lediglich um die vorgeschaltete Spracherkennung. Abbildung 5.4 zeigt diesen Ablauf.

Rollentrennung von Renderer und Commander

Über dieselbe Verbindung treten zwei Arten von Clients auf. Die Brille ist der Renderer, der die Manipulationen ausführt und die Szene darstellt. Die Sprachsteuerung ist der Commander, der ausschließlich Befehle einspeist. Eine Anmeldenachricht unterscheidet beide Rollen, damit die Befehlsquelle die Verbindung der Brille nicht verdrängt.

Wahrnehmung in der Brille

Die visuelle Wahrnehmung setzt ein gerendertes Bild der Szene voraus. In der Brille rendert die Hauptkamera jedoch stereoskopisch für beide Augen, was kein brauchbares flaches Bild liefert. Eine dedizierte Aufnahmekamera löst das Problem. Sie folgt der Kopfpose, rendert aber einfach statt stereoskopisch und liefert so das Bild, das das visuelle Modell benötigt.

Netzwerkette

Die Modelle laufen aus Ressourcengründen auf einem entfernten Rechner, den die Brille nicht direkt erreicht. Die Brille verbindet sich deshalb mit einem lokalen Vermittler, der die Nachrichten über ein virtuelles privates Netz an den entfernten Rechner weiterleitet. Ein mobiler Zugangspunkt umgeht dabei die Isolation gemeinsam genutzter Netze, die eine direkte Verbindung sonst unterbindet. Diese Kette ist reine Demonstrationsinfrastruktur und nicht Gegenstand der Untersuchung.

Ablauf und Rückmeldung

Sobald ein Befehl in die Warteschlange gelangt, arbeitet ein Worker den Agentenlauf ab und meldet der Brille den Beginn und den Abschluss der Verarbeitung. Die Brille zeigt diesen Status an, sodass für den Nutzer erkennbar ist, dass ein Befehl gerade bearbeitet wird. Ein früher erprobtes Bedienmenü in der Szene wurde zugunsten der Sprachsteuerung ersetzt, nutzte aber bereits dieselbe Kommando-Warteschlange. Abbildung 5.5 zeigt diese frühe Ausbaustufe im Betrieb, aufgenommen aus der Sicht der Brille. Die Szene enthält drei Objekte, einen roten Würfel, einen gestreiften Würfel und eine blaue Kugel. In der Aufzeichnung werden die vordefinierten Befehle nacheinander ausgelöst, und die zugehörigen Manipulationen sind jeweils unmittelbar in der Szene sichtbar. Der gestreifte Würfel hebt sich an, die blaue Kugel wandert nach links neben den roten Würfel, und der gestreifte Würfel wird schließlich entfernt. Das Video belegt damit anschaulich, dass die vollständige Kette von der Befehlsauswahl bis zur ausgeführten Manipulation in der immersiven Umgebung funktioniert.




Abbildung 5.4: Ablauf eines gesprochenen Befehls im Demonstrator. Der lokale Rechner erkennt die Sprache und leitet den Text als Commander-Nachricht weiter, der entfernte Rechner arbeitet den Agentenlauf ab, und die Brille führt die Manipulation aus und zeigt den Verarbeitungsstatus an.




Abbildung 5.5: Eine frühe Ausbaustufe des Demonstrators in Betrieb. In dieser Fassung werden die Befehle noch nicht gesprochen, sondern über ein Menü in der Szene ausgewählt, das vordefinierte Anweisungen bereitstellt. Das Standbild stammt aus einer Aufzeichnung, in der auf diese Weise unter anderem „move the striped cube up“, „put the blue sphere left of the red cube“ und „delete the striped cube“ ausgelöst werden. Die vollständige Aufzeichnung ist als Begleitmaterial in Anhang A.1 verlinkt.

Kapitel 6

Evaluation

Das vorige Kapitel hat beschrieben, wie das System eine Szene aufnimmt, an den Agenten übergibt und dessen Befehle ausführt. Offen ist damit die eigentliche Frage dieser Arbeit. Welchen Einfluss hat die Form, in der die Szene bereitgestellt wird, auf den Erfolg der Manipulation? Dieses Kapitel beantwortet sie in zwei Schritten. Zunächst vergleicht es die Repräsentationsformen entlang einer nach Referenztypen aufgeschlüsselten Taxonomie und bestimmt, welche Form welche Art von Referenz trägt (RQ1). Anschließend prüft es, ob sich die hybride Repräsentation allein durch die Gestaltung ihrer Instruktion so verbessern lässt, dass sie die Stärken beider Schichten vereint (RQ2). Den Abschluss bildet eine kritische Betrachtung der Validität und der Grenzen dieser Ergebnisse.

6.1 Evaluationsdesign

Die Evaluation prüft, welchen Einfluss die Repräsentationsform auf den Erfolg der Szenenmanipulation hat. Ein solcher Vergleich ist nur aussagekräftig, wenn die Repräsentation der einzige Faktor bleibt, der zwischen den Varianten variiert. Drei Entwurfsentscheidungen stellen das sicher.

Was wird verglichen?

Verglichen werden fünf Varianten, die dieselbe Szene, dieselben Befehle und dieselben Manipulationswerkzeuge nutzen. Sie unterscheiden sich allein darin, in welcher Form die Szene dem Agenten bereitgestellt wird. Die strukturelle Variante übergibt die Szene als exakte Laufzeitdaten der Engine. Die visuelle Variante übergibt eine gerenderte Ansicht, deren Objekte mit Markern versehen sind. Die naive hybride Variante stellt beide Schichten ohne weitere Anweisung nebeneinander. Die geführte und die kompetenzgetrennte Variante ergänzen die hybride Repräsentation um eine Instruktion zur Zuständigkeit der beiden Schichten. Der genaue Aufbau der Varianten ist in [Kapitel X] beschrieben.

Ein gemeinsames Interface für alle Varianten

Die visuelle Variante steht vor einem grundsätzlichen Problem. Ein Modell, das die Szene nur als Bild kennt, hat kein Handle, über das es ein Objekt für einen Werkzeugaufruf benennen könnte. Ohne Gegenmaßnahme wäre die visuelle Variante nicht deshalb im Nachteil, weil ihre Repräsentation schlechter wäre, sondern weil ihr der Zugriff auf die Werkzeuge fehlte. Um diesen Störfaktor auszuschließen, tragen alle Objekte eine eindeutige Kennung, und der Agent spricht Objekte in jeder Variante über dieselbe Kennung an. Die visuelle Variante verbindet dazu die Marker im Bild mit den zugehörigen Kennungen. Auf diesem gemeinsamen Interface beruhen alle Varianten gleichermaßen, sodass gemessene Unterschiede auf die Repräsentation zurückgehen und nicht auf einen ungleichen Werkzeugzugriff.

Woran wird Erfolg gemessen?

Der Erfolg jeder Manipulation wird aus dem tatsächlichen Zustand der Szene nach der Ausführung bestimmt. Nach jedem Befehl liest die Auswertung den Folgezustand aus und vergleicht ihn mit der für das Szenario definierten Soll-Vorgabe. Die Selbstauskunft des Agenten bleibt dabei unberücksichtigt. Diese Entscheidung hat einen konkreten Grund, der in [Abschnitt Y] ausgeführt wird: Das lokale Modell meldet wiederholt einen Erfolg, den der Folgezustand nicht bestätigt. Die Messung aus dem Folgezustand ist gegen dieses Verhalten robust.

Wie oft wird gemessen?

Jede Kombination aus Szenario und Variante wird zehnmal ausgeführt. Der gesamte Durchlauf wird dreimal wiederholt. Berichtet wird der Mittelwert über die drei Durchläufe zusammen mit der Spanne von Minimum und Maximum. Eine einzelne Messung eines stochastisch antwortenden Modells wäre nur eine Momentaufnahme. Erst die Wiederholung mit ausgewiesener Spanne zeigt, welche Unterschiede belastbar sind und welche im Rauschen liegen.

Aufbau der Messumgebung

Die Szenen bestehen aus einfachen geometrischen Grundkörpern und werden kontrolliert aufgebaut, damit jedes Szenario genau eine Repräsentationskompetenz prüft. Als Sprachmodell dient ein lokal betriebenes Qwen2.5-7B, als visuelles Modell ein Qwen2.5-VL-7B. Beide laufen gemeinsam auf einer Nvidia A5000 mit 24 Gigabyte Grafikspeicher. Die Messung selbst erfolgt am Desktop, während die immersive Umgebung die Zielumgebung des Demonstrators bildet. Der Grund für diese Trennung liegt in der Reproduzierbarkeit: Am Desktop lassen sich die Szenen exakt kontrollieren und beliebig oft identisch wiederholen.

6.2 Referenztyp-Taxonomie

Warum die Frage nach der besten Repräsentation zu kurz greift

Ob eine strukturelle oder eine visuelle Repräsentation die bessere ist, lässt sich nicht pauschal beantworten. Die Frage in dieser Form führt sogar in die Irre, weil sie eine einzige Antwort verlangt, wo keine existiert. Welche Repräsentation trägt, hängt davon ab, worauf sich ein Befehl bezieht. Ein Verweis auf die Farbe eines Objekts stellt andere Anforderungen als ein Verweis auf seine Lage oder auf ein Objekt, das im Bild gar nicht zu sehen ist. Statt nach der allgemein besten Repräsentation zu fragen, zerlegt diese Arbeit die natürlichsprachliche Referenz in Typen und prüft für jeden Typ einzeln, welche Repräsentation ihn auflösen kann.

Grundlage ist eine Taxonomie aus fünf Referenztypen. Tabelle 6.1 fasst sie zusammen und zeigt, in welcher Schicht die zur Auflösung nötige Information jeweils verfügbar ist. Kategorie A bildet die Kontrollbedingung. Der Befehl benennt das Zielobjekt direkt über seine Kennung, sodass die Aufgabe unabhängig von der Repräsentationsform lösbar ist. Sie dient damit als Prüfstein für den Messaufbau und nicht als inhaltlicher Vergleich. Kategorie B spricht ein Objekt über ein Attribut an, etwa seine Farbe oder seine Größe. Kategorie C bezieht sich auf eine räumliche Relation zwischen Objekten, etwa die Lage links von einem anderen Objekt. Beide Typen setzen voraus, dass sich das gemeinte Objekt aus Eigenschaften oder Koordinaten bestimmen lässt, die in den strukturellen Daten stehen.

Die beiden letzten Kategorien bilden das eigentliche Gegensatzpaar. Kategorie D bezieht sich auf eine rein perzeptuelle Eigenschaft, etwa ein Oberflächenmuster, das in den strukturellen Daten nicht vorkommt. Ein solches Objekt lässt sich nur über das Bild bestimmen. Kategorie E bezieht sich auf ein Objekt, das im Bild verdeckt und damit unsichtbar ist, in den strukturellen Daten aber vollständig verzeichnet bleibt. Ein solches Objekt lässt sich nur über die Struktur bestimmen. D und E markieren damit die beiden Pole, an denen jeweils nur eine der beiden Schichten Zugang zur Antwort hat.

Genau dieses symmetrische Paar macht sichtbar, ob eine Repräsentation eine Kompetenz besitzt, die der anderen grundsätzlich fehlt.

Die Unterscheidung nach Referenztypen knüpft an bestehende Arbeiten an, die Referenzen etwa nach ihrer Abhängigkeit vom Blickwinkel oder nach der Eindeutigkeit des Zielobjekts einteilen [6, 7]. Über diese Einteilungen hinaus führt die vorliegende Taxonomie die rein perzeptuelle und die verdeckte Referenz als eigene Typen ein. Beide sind notwendig, um die exklusiven Zuständigkeiten der beiden Repräsentationen überhaupt prüfen zu können.

Die konkreten Szenarien, mit denen jeder Referenztyp gemessen wird, führt Tabelle 6.2 auf. Jedes Szenario ist so aufgebaut, dass es genau eine Kompetenz isoliert und andere Einflussfaktoren möglichst ausschließt.

Tabelle 6.1: Verfügbarkeit der zur Auflösung nötigen Information je Referenztyp und Schicht, nach Konstruktion der Szenarien. Die Zeilen D und E bilden das exklusive Gegensatzpaar.

Referenztyp	In der strukturellen Schicht	In der visuellen Schicht
A — direkt	Kennung und Zielkoordinaten vorhanden	markiertes Objekt sichtbar
B — Attribut	Attribute wie Farbe und Größe vorhanden	Aussehen sichtbar
C — relational	exakte Koordinaten vorhanden	Anordnung sichtbar
D — perzeptuell	nicht enthalten	Muster sichtbar
E — verdeckt	vollständig verzeichnet	verdeckt, nicht sichtbar

6.3 Metriken

Ausführungserfolg als primäre Kennzahl

Die verwendeten Erfolgs- und Genauigkeitsmaße orientieren sich an etablierten Metriken aus der Literatur zum sprachlichen Auffinden von Objekten in 3D-Szenen [7, 6]. Als primäre Kennzahl berichtet diese Arbeit den Ausführungserfolg. Er ist je Lauf binär und ergibt sich allein aus dem Folgezustand der Szene, den die Auswertung nach der Manipulation mit der Soll-Vorgabe des Szenarios vergleicht. Ein Lauf gilt genau dann als Erfolg, wenn der Folgezustand die Vorgabe erfüllt. Berichtet wird die Zahl der Erfolge aus zehn Läufen, gemittelt über die drei Durchläufe mit der zugehörigen Spanne. Diese Wahl schließt an die in Abschnitt 6.1 begründete Messung aus dem Folgezustand an und macht die Kennzahl unabhängig von der Selbstauskunft des Agenten.

Szenariospezifische Erfolgskriterien

Was als erfüllte Vorgabe zählt, hängt vom Aufgabentyp ab. Bei jeder Aufgabe muss zunächst das richtige Objekt betroffen sein. Wird ein anderes als das gemeinte Objekt verändert, gilt der Lauf als Misserfolg, auch wenn die Zielkoordinate ansonsten getroffen wäre. Dieses Kriterium erfasst die korrekte Auflösung der Referenz. Bei Aufgaben mit einer Zielposition muss die erreichte Position innerhalb einer festen Toleranz τ um den Sollwert liegen. Der zugehörige Positionsfehler ist der Abstand zwischen erreichter und geforderter Position. In dieser Arbeit ist τ auf 0,1 Einheiten gesetzt. Bei relationalen Aufgaben muss die geforderte Lagebeziehung im Folgezustand gelten, etwa dass ein Objekt einen kleineren x-Wert besitzt als ein anderes. Bei Aufgaben, die ein Objekt entfernen oder erzeugen, muss das Objekt im Folgezustand fehlen oder vorhanden sein. Ein Lauf zählt nur dann als Erfolg, wenn das jeweils maßgebliche Kriterium vollständig erfüllt ist.

Tabelle 6.2: Übersicht aller ausgewerteten Szenarien mit Befehl, Ausgangsszene und Soll-Ergebnis. Die Befehle geben den real gesendeten englischen Stimulus wieder.

ID	Befehl	Ausgangsszene	Soll-Ergebnis
<i>Kategorie A — direkt / id-basiert</i>			
A1	„Spawn a red cube at x=2, y=0, z=1.“	leere Szene	roter Würfel bei (2,0,1) vorhanden
A2	„Move obj_2 to position (0, 1, 0).“	rot (0,0,0), grün (2,0,0), blau (4,0,0)	grüner Würfel (obj_2) bei (0,1,0)
A3	„Delete obj_1.“	wie A2	roter Würfel (obj_1) entfernt
<i>Kategorie B — Attribut-Referenz</i>			
B1	„Raise the red cube by 1 unit.“	rot (1,0,0), blau (3,0,0)	roter Würfel in der Höhe +1
B2	„Delete all red cubes.“	rot (0,0,0), rot (2,0,0), grüne Kugel (4,0,0)	beide roten Würfel entfernt, Kugel bleibt
B3	„Move the largest object to (0, 0, 0).“	roter Würfel Größe 0,5 (-2,0,0); grüner Größe 1,5 (0,0,3); blauer Größe 1,0 (3,0,0)	größtes Objekt (grün) bei (0,0,0)
<i>Kategorie C — räumlich-relational</i>			
C1	„Move the sphere to the left of the cube.“	blaue Kugel (1,0,0), grüner Würfel (-1,0,0)	Kugel links vom Würfel
C2 ^a	„Raise the cube nearest to the camera by 1.“	rot (-2,0,2), grün (0,0,5), blau (2,0,8)	kamera-nächster Würfel in der Höhe +1
C4	„Place the sphere exactly 2 units left of the cube.“	grüner Würfel (1,0,0), blaue Kugel (4,0,0)	Kugel bei x=-1 (genau 2 links)
<i>Kategorie D — rein perzeptuell</i>			
D1	„Raise the striped cube by 1 unit.“	zwei graue Würfel (-1,0,3) und (1,0,3); zweiter gestreift	gestreifter Würfel +1, anderer unverändert
D2	„Move the most salient object to (0, 0, 0).“	vier graue Würfel (-3/-1/3/5, 0, 4); ein gestreifter (1,0,4)	gestreifter (auffälliger) Würfel bei (0,0,0)
<i>Kategorie E — verdeckt</i>			
E1	„Raise the green cube by 1 unit.“	rot (-3,0,5); graue Wand Größe 4,0 (2,0,2); grün (2,0,6) dahinter verdeckt	verdeckter grüner Würfel +1
E2	„Raise every cube by 1 unit.“	wie E1	alle drei Würfel in der Höhe +1

Positionen als (x, y, z), wobei y die Höhe angibt. „Größe“ ist die relative Kantenlänge (Standard 1,0).

^a C2 mit seitlich versetztem Aufbau. Der ursprünglich achsenkollineare Aufbau wurde ersetzt (Abschnitt 6.6). Szenario C3 wurde aus methodischen Gründen ausgeschlossen (ebenda).

6.4 Ergebnisse: Einfluss der Repräsentationsform (RQ1)

Die Ergebnisse berichtet diese Arbeit je Szenario und Kategorie als Mittelwert über drei Durchläufe mit der Spanne [Minimum–Maximum]. In der Szenariotabelle steht jede Zelle für zehn mögliche Erfolge (Tabelle 6.3). Die Kategorietabelle fasst diese Werte je Kategorie zusammen (Tabelle 6.4).

Kategorie A: Misst der Aufbau, was er messen soll?

Bevor sich die Unterschiede zwischen den Repräsentationen deuten lassen, muss eine Frage geklärt sein: Misst der Aufbau überhaupt das, was er messen soll? Kategorie A beantwortet sie. Hier benennt der Befehl das Zielobjekt direkt über seine *id* und die Zielkoordinaten. Die Aufgabe verlangt keine Deutung der Szene, gleich in welcher Form diese repräsentiert ist. Ist der Messaufbau sauber, darf die Repräsentationsform hier keinen Unterschied machen. Genau das zeigt sich: Alle fünf Varianten lösen jedes Szenario in jedem Durchlauf, 30 von 30 bei einer Spanne von [30–30]. Das gemeinsame *id*-Substrat und der Werkzeugzugriff erzeugen also von sich aus keine variantenspezifischen Unterschiede. Jede Abweichung in den folgenden Kategorien geht damit auf die Repräsentationsform zurück und nicht auf ein Artefakt der Messung.

Tabelle 6.3: Erfolg je Szenario und Variante: Mittelwert [Min–Max] über drei Durchläufe (je $N = 10$).

Kat.	Szen.	json	vlm	hybrid	guided	surgical
A	A1	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
A	A2	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
A	A3	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
B	B1	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
B	B2	10,0 [10–10]	9,7 [9–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
B	B3	10,0 [10–10]	0,0 [0–0]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
C	C1	10,0 [10–10]	1,7 [0–3]	8,3 [7–10]	10,0 [10–10]	10,0 [10–10]
C	C2 ⁽¹⁾	0,0 [0–0]	0,0 [0–0]	0,3 [0–1]	2,7 [1–4]	2,0 [1–3]
C	C4	1,7 [0–4]	0,7 [0–2]	3,3 [3–4]	1,3 [1–2]	2,0 [1–3]
D	D1	0,0 [0–0]	10,0 [10–10]	0,7 [0–1]	8,3 [6–10]	9,7 [9–10]
D	D2	0,3 [0–1]	10,0 [10–10]	10,0 [10–10]	7,3 [6–9]	10,0 [10–10]
E	E1	10,0 [10–10]	0,0 [0–0]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
E	E2 ⁽²⁾	10,0 [10–10]	0,0 [0–0]	0,3 [0–1]	0,0 [0–0]	0,0 [0–0]

Tabelle 6.4: Erfolg je Kategorie (Summe über Szenarien), Mittelwert [Min–Max] über drei Durchläufe. Kategorie E getrennt ausgewiesen.

Kat.	max	json	vlm	hybrid	guided	surgical
A	30	30,0	30,0	30,0	30,0	30,0
B	30	30,0	19,7	30,0	30,0	30,0
C	30	11,7	2,4	11,9	14,0	14,0
D	20	0,3	20,0	10,7	15,6	19,7
E1	10	10,0	0,0	10,0	10,0	10,0
E2	10	10,0	0,0	0,3	0,0	0,0

Kategorie B: Genügt der Blick auf die Szene, um Attribute zu beurteilen?

In Kategorie B spricht der Befehl ein Objekt über eine Eigenschaft an, etwa über seine Farbe oder seine Größe. Die strukturelle Variante, die naive hybride Variante und beide instruierten hybriden Varianten lösen jedes Szenario vollständig, 30 von 30. Die visuelle Variante erreicht nur 19,7 von 30. Fast der gesamte Rückstand entsteht in einem einzigen Szenario. Die geringe Abweichung in B2 (9,7 von 10) liegt innerhalb der beobachteten Streuung und trägt keinen eigenen Befund.

Der Einbruch zeigt sich in B3, wo der Agent das größte Objekt bewegen soll. Hier scheitert die visuelle Variante in jedem Durchlauf, 0 von 10, während alle übrigen Varianten das Szenario zuverlässig lösen. Die Ursache dürfte in der Natur des Bildeindrucks liegen. Wie groß ein Objekt im gerenderten Bild erscheint, hängt nicht allein von seiner tatsächlichen Größe ab, sondern auch von seiner Entfernung zur Kamera. Ein weiter hinten stehendes Objekt kann im Bild kleiner wirken, als es tatsächlich ist. Die absolute Größe steht dagegen exakt in den strukturellen Daten. Eine Referenz auf die Größe lässt sich deshalb zuverlässig nur über die strukturelle Schicht auflösen, nicht über den Bildeindruck.

Damit deutet sich bereits an, was die folgenden Kategorien systematisch belegen. Struktur und Bild sind nicht austauschbar, sondern für unterschiedliche Arten von Referenzen zuständig.

Kategorie C: Reicht die richtige Repräsentation, wenn es genau werden muss?

Kategorie C prüft räumlich-relationale Referenzen, bei denen ein Objekt in Bezug auf ein anderes platziert oder ausgewählt wird. Über die Kategorie hinweg zeigt sich zunächst ein vertrautes Bild. Die visuelle Variante bricht fast vollständig ein und erreicht nur 2,4 von 30, während die strukturellen und hybriden Varianten mit rund 12 bis 14 von 30 deutlich davor liegen. Relationale Aufgaben verlangen exakte Koordinaten, und die stehen nur in der strukturellen Schicht.

Das Szenario C1 macht das greifbar. Der Befehl verlangt, die Kugel nach links vom Würfel zu bewegen, also auf einen negativen x-Abstand zum Würfel. Gefordert ist nur die Richtung der Relation, kein exakter Zielwert. Die strukturelle Variante und die hybriden Varianten lösen es zuverlässig oder weitgehend, während die rein visuelle Variante fast durchgehend scheitert.

Ein anderes Bild ergibt sich, sobald die Aufgabe Präzision verlangt. C4 setzt auf derselben Grundstruktur auf wie C1, verschärft sie aber zu einer metrischen Vorgabe: Die Kugel soll exakt zwei Einheiten links vom Würfel liegen. Jetzt scheitern alle Varianten. Keine erreicht mehr als rund drei von zehn, unabhängig davon, ob die Szene strukturell, visuell oder hybrid bereitgestellt wird. Der Sprung von C1 zu C4 ist der eigentliche Befund dieser Kategorie. Solange nur die Richtung einer Relation zählt, entscheidet die Repräsentation über den Erfolg. Sobald ein exakter metrischer Wert gefordert ist, verschiebt sich die Grenze vom Repräsentations- zum Modellproblem.

Auch C2 bestätigt diese Lesart. Hier soll der Agent den zur Kamera nächstgelegenen Würfel um eine Einheit anheben, was eine Distanzberechnung aus der Kameraposition voraussetzt. Alle Varianten bleiben schwach. Der nötige metrische Vergleich gelingt dem lokalen Modell auch dann nicht zuverlässig, wenn ihm die exakten Koordinaten vorliegen. Kategorie C zeigt damit eine Grenze, die keine Repräsentation aufhebt. Die richtige Repräsentation ist notwendig, um die Relation überhaupt auflösbar zu machen, aber sie genügt nicht, wenn das Modell selbst an der geforderten Präzision scheitert.

Kategorie D: Was passiert, wenn nur das Bild die Antwort kennt?

Bisher lag der Vorteil bei der strukturellen Schicht. Kategorie D kehrt dieses Verhältnis um. Hier spricht der Befehl ein Objekt über eine rein visuelle Eigenschaft an, etwa über ein Oberflächenmuster, das in den strukturellen Daten nicht vorkommt. Wer nur Koordinaten und Objekttypen kennt, kann ein gestreiftes Objekt nicht von einem einfarbigen unterscheiden.

Das Ergebnis ist eindeutig. Die visuelle Variante löst jedes Szenario, 20 von 20. Die strukturelle Variante scheitert fast vollständig, 0,3 von 20. Damit steht das Spiegelbild zu den vorigen Kategorien: So wie die visuelle Schicht bei Relationen blind war, ist die strukturelle Schicht bei perzeptuellen Referenzen blind. Beide Repräsentationen haben einen exklusiven Zuständigkeitsbereich, den die jeweils andere nicht abdeckt.

An dieser Stelle lässt sich eine naheliegende Erwartung prüfen. Wenn die hybride Repräsentation beide Schichten bereitstellt, sollte sie mindestens so gut abschneiden wie die jeweils bessere Einzelvariante. Die Daten widerlegen das. Die naive hybride Variante erreicht nur 10,7 von 20, obwohl ihr das Bild vorliegt. Besonders deutlich wird der Bruch in D1. Dort löst die visuelle Variante jedes Szenario, 10

von 10 bei einer Spanne von [10–10], die naive hybride Variante dagegen so gut wie keines, 0,7 von 10 bei einer Spanne von [0–1]. Die Spannen überlappen nicht, der Unterschied ist also belastbar. Die Kombination beider Schichten erbt den visuellen Vorteil somit nicht, sondern verliert ihn. Das deutet darauf hin, dass die strukturelle Information das visuelle Signal verdrängt, statt es zu ergänzen.

Der Effekt tritt allerdings nicht durchgängig auf. In D2 löst dieselbe naive hybride Variante alle Szenarien, 10 von 10. Der Zusammenbruch hängt demnach von Bedingungen ab, die sich aus den Erfolgsraten allein nicht ablesen lassen. Warum die naive Kombination in D1 scheitert und in D2 gelingt, bleibt an dieser Stelle offen und führt unmittelbar zur zweiten Forschungsfrage.

Eines zeigt die Kategorie damit schon jetzt. Nicht die Verfügbarkeit beider Schichten entscheidet über den Erfolg, sondern die Art, wie sie kombiniert werden. Die instruierten hybriden Varianten weisen darauf hin, dass sich der verlorene visuelle Zugriff wiederherstellen lässt. Wie das gelingt und woran die naive Kombination scheitert, ist Gegenstand des folgenden Abschnitts.

Kategorie E: Was ist mit dem, was man nicht sehen kann?

Kategorie D hat gezeigt, dass sich manche Referenzen nur über das Bild auflösen lassen. Kategorie E prüft den umgekehrten Fall. Ein Objekt steht in der Szene, ist im gerenderten Bild aber verdeckt und dadurch unsichtbar. In den strukturellen Daten bleibt es vollständig verzeichnet.

Im Szenario E1 verbirgt eine große Wand ein grünes Objekt, das der Befehl anheben soll. Alle Varianten mit struktureller Schicht lösen die Aufgabe vollständig, 10 von 10. Die rein visuelle Variante scheitert vollständig, 0 von 10. Sie kann ein Objekt nicht ansprechen, das im Bild nicht erscheint.

Damit schließt sich die Kompetenzmatrix. Kategorie D belegt einen bild-exklusiven Bereich, in dem allein die visuelle Schicht trägt. Kategorie E1 belegt das strukturell-exklusive Gegenstück, in dem allein die strukturelle Schicht trägt. Beide Repräsentationen decken jeweils einen Bereich ab, zu dem die andere keinen Zugang hat. Genau diese Symmetrie begründet, warum eine Kombination beider Schichten überhaupt sinnvoll ist.

Ein zweites Szenario dieser Kategorie erlaubt keine ebenso klare Deutung. E2 verlangt, alle Würfel der Szene anzuheben, auch den verdeckten. Damit prüft die Aufgabe nicht allein die Verdeckung, sondern zugleich die Fähigkeit, mehrere Manipulationen nacheinander auszuführen. Die strukturelle Variante löst das Szenario vollständig, 10 von 10. Alle hybriden Varianten scheitern nahezu vollständig, und auch die visuelle Variante erreicht keinen Erfolg. Dieser Einbruch lässt sich nicht sauber der Verdeckung zuschreiben. Die wahrscheinlichere Ursache ist der größere Kontext der hybriden Varianten, der die zuverlässige Ausführung mehrerer aufeinanderfolgender Schritte erschwert. E2 wird deshalb als Mehrschritt-Befund geführt und nicht als reiner Verdeckungstest gewertet.

Zwischenfazit zur ersten Forschungsfrage

Über alle Kategorien hinweg zeigt sich kein Gesamtsieger. Die strukturelle Schicht trägt attributive, qualitativ-relationale und verdeckte Referenzen, die visuelle Schicht trägt perzeptuelle Referenzen. Welche Repräsentation erfolgreich ist, hängt richtungsabhängig vom Referenztyp ab. Die naheliegende Annahme, eine hybride Repräsentation vereine ohne Weiteres die Stärken beider, hält der Prüfung nicht stand. In Kategorie D bleibt die naive Kombination hinter der visuellen Einzelvariante zurück, und die zugehörigen Spannen überlappen nicht. Die Verfügbarkeit beider Schichten genügt also nicht. Entscheidend ist, wie sie kombiniert werden. Damit ist der Ausgangspunkt der zweiten Forschungsfrage erreicht.

6.5 Ergebnisse: Gezielte Verbesserung des hybriden Ansatzes (RQ2)

Die erste Forschungsfrage endete mit einem offenen Punkt. Die naive hybride Repräsentation stellt beide Schichten bereit, nutzt den visuellen Vorteil aber nicht zuverlässig. Die zweite Forschungsfrage prüft, ob sich dieses Verhalten allein durch die Gestaltung der Repräsentation steuern lässt, ohne das Modell zu verändern.

Warum scheitert die naive Kombination?

Der Vergleich der beiden perzeptuellen Szenarien zeigt, dass das Scheitern der naiven Kombination nicht durchgängig auftritt. In D1 stehen zwei graue Würfel, die sich im strukturellen Zustand nicht unterscheiden. Allein die Textur trennt sie, und die steht nur im Bild. Hier erreicht die naive hybride Variante 0,7 von 10, während die rein visuelle Variante jedes Mal löst. In D2 soll unter fünf Würfeln der einzige gestreifte und damit visuell auffälligste Würfel bewegt werden. Dort löst dieselbe naive Variante alle Szenarien, 10 von 10.

Belegt ist damit der Effekt: Die naive Kombination nutzt den visuellen Vorteil in D1 nicht, in D2 hingegen schon. Warum sie im einen Fall scheitert und im anderen gelingt, lässt sich aus den Erfolgsraten allein nicht abschließend bestimmen. Zwei Erklärungen liegen nahe, ohne dass die Daten zwischen ihnen entscheiden. Zum einen benennt der Befehl in D1 mit dem Wort gestreift eine Objekteigenschaft, wie sie sonst in der strukturellen Schicht steht. Das Modell könnte deshalb dort nach einem unterscheidenden Merkmal suchen, wo keines vorhanden ist, während der Befehl in D2 mit dem Wort auffälligstes auf etwas verweist, das nur im Bild existiert. Zum anderen ist die visuelle Eindeutigkeit verschieden, denn ein einzelnes gestreiftes Objekt unter vier gleichen grauen hebt sich stärker ab als eines neben nur einem einfarbigen. Unabhängig von der genauen Ursache lässt sich festhalten, dass die bloße Verfügbarkeit beider Schichten nicht genügt, damit die naive Kombination den visuellen Zugriff zuverlässig nutzt. Diese Beobachtung fügt sich in ein aus der Literatur bekanntes Muster ein, das in der abschließenden Diskussion aufgegriffen wird.

Priorisierung: eine Verschiebung, keine Lösung

Die erste Gegenmaßnahme stellt dem Modell die visuelle Beschreibung voran und erklärt das Bild für das Aussehen als maßgeblich. Diese geführte Variante gewinnt dort, wo die naive Kombination scheitert. In D1 steigt der Erfolg von 0,7 auf 8,3 von 10. Über die Kategorie D hinweg erreicht sie 15,6 von 20 statt der 10,7 der naiven Variante.

Der Gewinn hat jedoch einen Preis. In D2 fällt die geführte Variante auf 7,3 von 10 zurück, bei einer Spanne von [6–9], während die naive Variante dort 10 von 10 hält. Die Spannen überlappen nicht, der Rückgang ist also belastbar. Das Szenario D2 verlangt neben der visuellen Zuordnung eine metrische Verschiebung an eine feste Zielkoordinate. Die Priorisierung verschiebt das Gewicht zugunsten des Bildes und dürfte dadurch jene Aufgaben schwächen, die zugleich eine präzise Nutzung der strukturellen Koordinaten erfordern. Sie tauscht eine Kompetenz gegen eine andere, statt beide zu vereinen.

Kompetenztrennung: beide Schichten zusammenführen

Die zweite Gegenmaßnahme priorisiert nicht, sondern trennt die Zuständigkeiten. Das Bild bestimmt, welches Objekt gemeint ist, die strukturelle Schicht liefert dessen Koordinaten. Diese Variante entstand aus der Analyse des Scheiterns der geführten Variante und wurde nicht an den Testszenarien optimiert.

Das Ergebnis fällt eindeutig aus. In Kategorie D erreicht die kompetenzgetrennte Variante 19,7 von 20 und liegt damit nahe an der Perfektion der rein visuellen Variante. In D1 löst sie 9,7 von 10 bei einer Spanne von [9–10], wo die naive Variante mit 0,7 scheiterte. Zugleich hält sie D2 bei 10 von 10, wo die geführte Variante auf 7,3 zurückfiel. Sie vereint damit, woran die Priorisierung scheiterte: den

visuellen Zugriff aus D1 und die strukturelle Präzision aus D2. Abbildung 6.1 veranschaulicht diese Entwicklung über die fünf Varianten hinweg. In den übrigen Kategorien bleibt sie auf dem besten erreichten Niveau, 30 von 30 in A und B, gleichauf an der Spitze in C und 10 von 10 in E1.




Abbildung 6.1: Erfolg in der rein visuellen Kategorie D über die fünf Varianten. Die rein visuelle Variante bildet die Obergrenze, die rein strukturelle scheitert nahezu vollständig. Die naive Kombination erreicht nur etwa die Hälfte, die Priorisierung verbessert dies, und erst die Kompetenztrennung erreicht nahezu das Niveau der reinen Bildvariante.

Eine Ausnahme ist zu benennen. Im Mehrschritt-Szenario E2 liegt die rein strukturelle Variante mit 10 von 10 vor allen hybriden Varianten, die dort nahezu vollständig scheitern. Dieses Szenario gilt jedoch, wie in der Diskussion der Validität ausgeführt, nicht als reiner Repräsentationstest, da es zugleich die Fähigkeit zu mehreren aufeinanderfolgenden Schritten prüft. Außerhalb dieses Sonderfalls ist die kompetenzgetrennte Variante in jeder gewerteten Zelle die beste oder eine der besten.

Erreichung der zweiten Forschungsfrage

Das gesetzte Kriterium war zweiteilig. Eine Gestaltung sollte dort eine belastbare Verbesserung erzielen, wo die naive Fusion scheitert, und dies ohne Einbußen in den übrigen Kategorien. Die kompetenzgetrennte Variante erfüllt beide Teile. Sie hebt D1 von 0,7 auf 9,7 bei nicht-überlappenden Spannen, und sie bewahrt zugleich das Leistungsniveau in allen anderen gewerteten Kategorien. Anders als die Priorisierung, die nur verschiebt, führt die Kompetenztrennung beide Schichten tatsächlich zusammen. Damit ist gezeigt, dass die Fusion beider Modalitäten kein Automatismus ist, sondern ein steuerbares Gestaltungsproblem, das sich allein auf der Instruktionsebene lösen lässt.

Das übertragbare Gestaltungsprinzip

Aus diesem Ergebnis lässt sich ein Prinzip ableiten, das über den Einzelfall hinausreicht. Die Kompetenztrennung weist jeder Schicht genau den Referenzbereich zu, den die erste Forschungsfrage ihr als exklusiv nachgewiesen hat. Das Bild beantwortet die Frage, welches Objekt gemeint ist, die Struktur die Frage, wo es sich befindet. Der Mehrwert der hybriden Repräsentation entsteht damit nicht aus der bloßen Verfügbarkeit beider Quellen, sondern aus der ausdrücklichen Zuweisung ihrer Zuständigkeiten. Für die Gestaltung eines lokalen Agenten mit gemischter Repräsentation folgt daraus eine konkrete Leitlinie. Die Modalitäten sollten nicht nur nebeneinandergestellt, sondern in ihren Rollen klar getrennt werden, damit die eine die andere nicht verdrängt. Genau diese Variante bildet die Grundlage des in Kapitel [X] vorgestellten Demonstrators und überführt das empirische Ergebnis in eine lauffähige Anwendung.

6.6 Validität und Grenzen

Die vorstehenden Ergebnisse sind nur so belastbar wie die Kontrolle der Bedingungen, unter denen sie entstanden. Dieser Abschnitt legt offen, welche Störfaktoren erkannt und beseitigt wurden, worauf die Messung beruht und wo die Aussagekraft endet.

Kontrolle von Störfaktoren

Mehrere zunächst plausible Befunde erwiesen sich bei genauer Prüfung als Artefakte des Aufbaus und wurden vor der Wertung beseitigt. Ein erster Störfaktor betraf die Marker der visuellen Variante. Ihre Farbe beeinflusste die Farbwahrnehmung des visuellen Modells, das teils die Farbe des Markers statt die des Objekts benannte. Die Marker wurden daraufhin versetzt und die Anweisung angepasst. Ein zweiter Störfaktor lag in Szenarien, in denen ein Referenzobjekt im Koordinatenursprung stand. Dort fielen relative und absolute Zielangabe zusammen, sodass eine relationale Aufgabe auch ohne Verständnis der Relation lösbar war. Die betroffenen Aufbauten wurden entkonfundiert. Ein dritter Störfaktor entstand durch den Sichtbarkeitstest der Marker. Im ursprünglichen, achsenkollinearen Aufbau von C2 erhielten verdeckte Objekte keinen Marker, wodurch das kamera-nächste Objekt im Bild als einziges markiert erschien und die Aufgabe trivial wurde. C2 wurde daraufhin mit seitlich versetztem Aufbau neu gemessen. Ein vierter Fall betraf einen scheinbar deutlichen Nachteil der hybriden Varianten, der sich als Terminierungsartefakt des Frameworks herausstellte. Ein serverseitiger Schutz gegen unmittelbar wiederholte, identische Manipulationen beseitigte ihn.

Als durchgängiger Prüfstein dient die Kontrollkategorie A. Da alle Varianten dort das Maximum erreichen, erzeugt der Messaufbau selbst keine variantenspezifischen Unterschiede. Ein Vollständigkeitsanspruch lässt sich daraus nicht ableiten. Die genannten Störfaktoren sind die markantesten, nicht die einzigen, und unentdeckte Confounds können nicht ausgeschlossen werden. Zusätzlich wurde das Szenario C3 aus der Auswertung genommen, weil die achsenparallele Kameraausrichtung die aus Sicht der Kamera formulierte Referenz mehrdeutig machte.

Erfolg aus dem Folgezustand

Die Entscheidung, den Erfolg ausschließlich aus dem Folgezustand zu bestimmen, hat einen empirischen Hintergrund. Das lokale Modell zeigte ein instabiles Abschlussverhalten. Es meldete wiederholt einen Erfolg, den der Folgezustand nicht bestätigte, benannte teils nicht vorhandene Objektkennungen und führte einzelne Manipulationen doppelt aus. Wie häufig Selbstauskunft und Folgezustand auseinanderfielen, wurde nicht systematisch quantifiziert. Die Beobachtung stützt sich daher auf wiederholte Einzelfälle in den Protokollen und nicht auf eine Rate. Für die Gültigkeit der Ergebnisse genügt diese Grundlage, weil die Messung aus dem Folgezustand von der Selbstauskunft unabhängig ist und ein falsch gemeldeter Erfolg die Erfolgszahl nicht beeinflusst.

Varianz der Messung

Innerhalb einer festen Konfiguration erwies sich die Messung als stabil. Die meisten Zellen zeigen über die drei Durchläufe eine Spanne von null oder eins. Nennenswerte Streuung tritt nur in wenigen Szenarien auf, insbesondere in C1 und C4 sowie in D1 und D2 der geführten Variante. Ein Unterschied in der Größenordnung eines einzelnen Erfolgs wird deshalb nicht als belastbarer Effekt gewertet. Als belastbar gilt ein Unterschied nur dann, wenn sich die Spannen der verglichenen Varianten nicht überlappen. Dieses Kriterium ist eine pragmatische Robustheitsheuristik und kein formaler Signifikanztest. Drei Durchläufe sind eine kleine Basis, sodass die Spannen die tatsächliche Streuung nur annähern und für die Absicherung deutlicher Effekte gedacht sind, nicht für den Nachweis kleiner Unterschiede.

Grenzen des Modells

Einige Befunde sind keine Aussage über die Repräsentation, sondern über das Modell. In den Szenarien C2 und C4 bleiben alle Varianten schwach, unabhängig davon, wie die Szene bereitgestellt wird. Beide

Aufgaben verlangen einen exakten metrischen Bezug, die Platzierung an einer festen Distanz und den Vergleich von Kameraabständen. Das lokale Modell erreicht diese Präzision auch dann nicht zuverlässig, wenn ihm die nötigen Koordinaten vorliegen. An dieser Grenze ändert keine Repräsentation etwas.

Der Mechanismus bleibt eine Hypothese

Die Ergebnisse belegen, dass die strukturelle Schicht das visuelle Signal in bestimmten Fällen verdrängt. Warum das geschieht, konnte nicht abschließend geklärt werden. Der Vergleich von D1 und D2 legt nahe, dass die Formulierung des Befehls und die visuelle Eindeutigkeit des Zielobjekts eine Rolle spielen, ohne dass sich die beiden Einflüsse in diesem Aufbau sauber voneinander trennen lassen. Die Erklärung bleibt daher eine begründete Hypothese und kein nachgewiesener Mechanismus. Sie deckt sich mit Beobachtungen aus der Literatur, die eine Übergewichtung textueller gegenüber visueller Information bei multimodalen Modellen beschreiben [1, 2].

Reichweite der Ergebnisse

Alle Befunde beruhen auf einem einzelnen lokalen Modellpaar und auf synthetischen Szenen aus einfachen Grundkörpern. Sie sind innerhalb dieses Rahmens repliziert und intern konsistent. Eine Übertragung auf größere oder anders gebaute Modelle wurde nicht geprüft. Ebenso wenig lassen sich die Ergebnisse ohne Weiteres auf reale, komplexe Szenen übertragen. Die Aussagekraft der Arbeit liegt damit in der kontrollierten Isolation der Repräsentationskompetenzen und nicht in einer allgemeinen Gültigkeit über Modelle und Szenen hinweg.

Kapitel 7

Zusammenfassung und Ausblick

7.1 Zusammenfassung

Die Arbeit ist von einer einfachen, aber folgenreichen Frage ausgegangen. In welcher Form sollte einem lokal betriebenen KI-Agenten eine 3D-Szene bereitgestellt werden, damit er sie natürlichsprachlich manipulieren kann? Zwei Wege standen einander gegenüber, ein struktureller und ein visueller, mit jeweils eigenen Stärken und einem Bereich, den der andere Weg nicht abdeckt.

Um die Frage zu beantworten, wurde ein prototypisches System entwickelt, das dieselbe Szene in drei Repräsentationsformen bereitstellt, strukturell, visuell und hybrid, und sie über ein gemeinsames Interface manipulierbar macht. Diese Formen wurden unter gleichen Bedingungen an kontrolliert aufgebauten Szenarien gegeneinander gemessen. Der Erfolg wurde dabei aus dem tatsächlichen Zustand der Szene bestimmt und jede Messung mehrfach wiederholt.

Der Vergleich ergab kein pauschales Bild, sondern eine richtungsabhängige Kompetenz. Keine Einzelform ist über alle Aufgaben hinweg überlegen. Die strukturelle Form trägt Referenzen, die sich aus Daten ableiten lassen, und ist als einzige in der Lage, ein im Bild verdecktes Objekt anzusprechen. Die visuelle Form trägt Referenzen, die nur im Bild existieren, etwa ein Oberflächenmuster. Beide Formen besitzen damit einen exklusiven Zuständigkeitsbereich, den die jeweils andere nicht abdecken kann.

Die naheliegende Erwartung, eine hybride Form vereine ohne Weiteres die Stärken beider, hielt der Prüfung nicht stand. Die naive Kombination erbte den strukturellen Vorteil, den visuellen jedoch nicht zuverlässig. Erst als die Zuständigkeiten der beiden Schichten ausdrücklich getrennt wurden, wirkten sie zusammen. Diese kompetenzgetrennte Variante erreichte in der rein visuellen Kategorie nahezu die Leistung der reinen Bildform, mit 19,7 von 20 Punkten gegenüber 10,7 der naiven Kombination, und behielt zugleich die Stärke der strukturellen Form. Eine bloße Priorisierung einer Schicht verschob das Gewicht dagegen nur, statt beide Schichten zu integrieren.

Schließlich wurde die beste Variante in die immersive Zielumgebung übertragen. Ein Demonstrator zeigt, dass die vollständige Kette von einem gesprochenen Befehl bis zur sichtbaren Manipulation lokal auf der Zielhardware funktioniert.

7.2 Beantwortung der Forschungsfragen

Die beiden in Kapitel 1 gestellten Forschungsfragen lassen sich nun direkt beantworten.

Erste Forschungsfrage

Welchen Einfluss hat die Form der Szenenrepräsentation, strukturell, visuell oder hybrid, auf die räumliche Korrektheit und den Ausführungserfolg der natürlichsprachlichen Szenenmanipulation durch einen lokal betriebenen Agenten?

Die Repräsentationsform hat einen erheblichen und richtungsabhängigen Einfluss. Es gibt keine Form, die über alle Aufgaben hinweg überlegen ist. Der Erfolg hängt davon ab, wie im Befehl auf ein Objekt verwiesen wird. Referenzen, deren Merkmal in den Daten kodiert ist, sowie Referenzen auf verdeckte Objekte werden von der strukturellen Form getragen. Referenzen auf rein visuelle Eigenschaften werden ausschließlich von der visuellen Form getragen. Beide Formen besitzen damit einen exklusiven Zuständigkeitsbereich, den die jeweils andere nicht abdecken kann. Die naive hybride Form vereint diese Stärken nicht von selbst. Sie übernimmt den strukturellen Vorteil, erbt den visuellen jedoch nicht zuverlässig, womit die verbreitete Annahme widerlegt ist, eine Kombination sei mindestens so gut wie die jeweils bessere Einzelform.

Zweite Forschungsfrage

Lässt sich das Zusammenspiel der strukturellen und der visuellen Schicht allein durch die Gestaltung der Instruktion so steuern, dass die hybride Repräsentation die Stärken beider Schichten vereint?

Ja, das Zusammenspiel lässt sich allein über die Gestaltung der Instruktion steuern, ohne die Modelle zu verändern. Entscheidend ist jedoch die Art der Steuerung. Eine bloße Priorisierung einer Schicht verschiebt das Gewicht nur und tauscht eine Kompetenz gegen eine andere. Erst die ausdrückliche Trennung der Zuständigkeiten, bei der die visuelle Schicht bestimmt, welches Objekt gemeint ist, und die strukturelle Schicht alle geometrischen Werte liefert, führt beide Schichten tatsächlich zusammen. Diese Variante ist über die Aufgabenbereiche hinweg die beste oder eine der besten und vereint damit die Stärken beider Formen.

Zur Glaubwürdigkeit dieses Befundes gehört die Art seiner Entstehung. Die kompetenzgetrennte Variante wurde nicht an den Testszenarien optimiert. Sie entstand aus der Analyse des Scheiterns der priorisierenden Variante und wurde anschließend einmal über alle Szenarien geprüft, ohne Nachjustierung und ohne Auswahl der Ergebnisse.

7.3 Wissenschaftlicher Beitrag

Über die konkreten Ergebnisse hinaus leistet die Arbeit drei Beiträge, deren Reichweite jeweils bewusst vorsichtig eingeordnet wird.

Der erste Beitrag ist inhaltlicher Art. Die Arbeit zeigt an einem kontrollierten Fall, dass die Verbindung struktureller und visueller Information kein Automatismus ist. Die bloße Verfügbarkeit beider Schichten genügt nicht, damit ihre Stärken zusammenwirken. Ob eine Kombination ihre Bestandteile ergänzt oder ob eine Informationsart die andere verdrängt, hängt von der Gestaltung ihrer Zusammenführung ab. Dieser Befund ist an einem einzelnen Modellpaar gewonnen und wird nicht als allgemein gültig behauptet. Er legt jedoch nahe, dass die Fusion von Modalitäten auch in anderen multimodalen Agenten als Gestaltungsproblem und nicht als selbstverständliches Mehr an Information zu behandeln ist.

Der zweite Beitrag ist methodischer Art. Die Arbeit führt eine nach der Art der sprachlichen Referenz aufgeschlüsselte Betrachtung ein, die den Erfolg nicht als einen Gesamtwert, sondern getrennt nach Referenztypen misst. Erst diese Aufschlüsselung macht die exklusiven Zuständigkeiten der Repräsentationen sichtbar, die ein pauschaler Vergleich verdeckt hätte. Das Schema ist nicht an das konkrete System gebunden und dürfte sich auf ähnliche Vergleiche übertragen lassen.

Der dritte Beitrag ist praktischer Art. Die Arbeit zeigt, dass sich die gesamte Verarbeitungskette

aus 3D-Umgebung, Vermittlungsschicht, Agent und zwei gleichzeitig betriebenen lokalen Modellen umsetzen und bis in die immersive Zielumgebung betreiben lässt. Damit ist belegt, dass ein lokal betriebener Agent für diesen Anwendungsfall grundsätzlich machbar ist. Über die Machbarkeit hinaus wird kein Anspruch auf Produktreife erhoben.

7.4 Grenzen der Arbeit

Die Aussagekraft der Ergebnisse ist an mehrere Grenzen gebunden. Ein Teil dieser Grenzen wurde bereits in Abschnitt 6.6 auf methodischer Ebene behandelt. Hier werden sie auf der Ebene der gesamten Arbeit gebündelt und danach geordnet, ob sie den Untersuchungsgegenstand, die Übertragbarkeit oder die Erklärungs- und Messtiefe betreffen.

Grenzen des Untersuchungsgegenstands

Der Untersuchungsgegenstand wurde bewusst eng gefasst. Befehle, die mehrere Manipulationen zugleich verlangen, wurden nicht systematisch untersucht. Das einzige Szenario mit mehreren aufeinanderfolgenden Schritten ließ sich nicht als reiner Repräsentationstest werten und wurde entsprechend eingeordnet. Die Menge der Operationen blieb auf das Erzeugen, Verschieben und Entfernen beschränkt, andere Operationen wie das Drehen oder Skalieren zur Laufzeit wurden nicht betrachtet. Die Befehle waren durchgehend klar formuliert, sodass offen bleibt, wie die Repräsentationen mit mehrdeutigen oder umgangssprachlichen Formulierungen umgehen. Blickpunktabhängige Referenzen, die sich auf die Sicht des Betrachters beziehen, wurden nicht ausgewertet, obwohl sie gerade für immersive Umgebungen bedeutsam sind. Schließlich wurde der Demonstrator nicht systematisch evaluiert. Er belegt die Machbarkeit der Kette in der Zielumgebung, liefert aber keine eigenen Erfolgsraten.

Grenzen der Übertragbarkeit

Alle Ergebnisse beruhen auf einem einzelnen lokalen Modellpaar. Ob sie sich auf größere oder anders gebaute Modelle übertragen lassen, wurde nicht geprüft. Die Szenen waren synthetisch und bewusst einfach gehalten. Eine Übertragung auf reale, komplexe Szenen ist damit nicht belegt, und auch das Verhalten der Repräsentationen bei wachsender Objektzahl bleibt offen.

Grenzen der Erklärung und Messung

Der Mechanismus hinter der zentralen Beobachtung bleibt eine begründete Hypothese. Warum die strukturelle Schicht das visuelle Signal in bestimmten Fällen verdrängt, ließ sich nicht sauber isolieren, da sich die Zahl der Kandidaten und die Qualität der Bilderkennung nicht voneinander trennen ließen. Eine weitere Grenze liegt im Modell selbst. Aufgaben, die einen exakten metrischen Bezug verlangen, scheitern bei allen Repräsentationen, und keine Repräsentation hebt diese Grenze auf. Wie häufig die Selbstauskunft des Agenten vom tatsächlichen Folgezustand abwich, wurde nur qualitativ beobachtet und nicht quantifiziert. Für die Erfolgsmessung ist dies unerheblich, da sie ohnehin aus dem Folgezustand erfolgt, für eine genaue Charakterisierung des Modellverhaltens fehlt jedoch eine belastbare Zahl. Schließlich beruht die Absicherung der Ergebnisse auf drei Durchläufen. Das verwendete Spannen-Kriterium ist eine pragmatische Heuristik und kein formaler Signifikanztest, sodass nur deutliche Unterschiede als belastbar gelten und kleine Unterschiede bewusst nicht interpretiert werden.

7.5 Ausblick

Aus der Arbeit ergeben sich mehrere Ansatzpunkte für weitere Untersuchungen. Sie folgen demselben roten Faden und lassen sich in unmittelbare Fortführungen, wissenschaftliche Vertiefungen und eine Anwendungsperspektive gliedern.

Eine unmittelbare Fortführung betrifft die Effizienz. Die visuelle Wahrnehmung ist um Größenordnungen langsamer als der strukturelle Abruf, was für eine interaktive immersive Anwendung entscheidend ist. Eine systematische Erhebung von Latenz, Schrittzahl und Rechenaufwand würde den bislang nur qualitativ bekannten Trade-off zwischen den Repräsentationen belastbar machen. Ebenso nahelegend ist die Untersuchung der Szenenkomplexität. Mit wachsender Objektzahl dürfte insbesondere die visuelle Schicht an Grenzen stoßen, da die Markierung vieler Objekte unübersichtlich wird. Weiterhin ließe sich die Menge der Operationen erweitern, etwa um Drehungen und Skalierungen sowie um Befehle, die mehrere Manipulationen zugleich verlangen, deren eigene Schwierigkeit sich in dieser Arbeit bereits angedeutet hat. Schließlich sind blickpunktabhängige Referenzen zu nennen, die sich auf die Sicht des Betrachters beziehen und gerade für immersive Umgebungen charakteristisch sind. Dass solche observer-zentrischen Bezüge ohne einen expliziten Blickpunkt mehrdeutig sind und von einer ausdrücklichen Repräsentation des Blickwinkels profitieren, zeigt sich in jüngeren Arbeiten zur blickpunktabhängigen Segmentierung [16]. Eine saubere Behandlung dieses Referenztyps wäre eine lohnende Erweiterung der hier verwendeten Taxonomie.

Auf wissenschaftlicher Ebene bieten sich zwei Vertiefungen an. Zum einen ließe sich prüfen, ob die gefundenen Kompetenzprofile und die Grenzen der naiven Kombination auch für größere oder anders gebaute Modelle gelten, oder ob eine größere Modellkapazität die beobachtete Verdrängung von selbst auflöst. Zum anderen könnte ein gezieltes Experiment, das die Zahl der Kandidaten und die Qualität der Bilderkennung voneinander trennt, die bislang nur begründete Hypothese über den Verdrängungsmechanismus zu einem belegten Befund weiterentwickeln. Darüber hinaus stellt sich die Frage, ob das Prinzip der Kompetenztrennung über die Szenenmanipulation hinaus auf andere multimodale Aufgaben übertragbar ist.

Aus Anwendungssicht bleibt eine Erprobung mit echten Nutzern offen. Die vorliegende Bewertung ist rein systembasiert. Eine qualitative Nutzerstudie im Demonstrator könnte zeigen, wie Menschen die sprachgesteuerte Manipulation in der immersiven Umgebung tatsächlich erleben, und wäre ein eigenständiger nächster Schritt über diese Arbeit hinaus.

Erklärung: Verwendung von KI-Werkzeugen

Im Rahmen der Erstellung dieser Arbeit wurden generative KI-Werkzeuge eingesetzt. Die Nutzung wird im Folgenden gemäß der KI-Leitlinie der Technischen Hochschule Nürnberg Georg Simon Ohm offengelegt.

- **Claude Opus 4.8 (Anthropic):** Unterstützung bei der Strukturierung und Gliederung der Arbeit, bei der Literaturrecherche mit anschließender Verifikation aller Quellen an den Originalpublikationen, bei der Erstellung und Überarbeitung von Textentwürfen sowie als dialogisches Gegenüber zur Schärfung der Argumentation und zur Reflexion des methodischen Vorgehens.

Sämtliche von KI-Werkzeugen erzeugten Inhalte wurden eigenständig geprüft, überarbeitet und inhaltlich verantwortet. Die Verantwortung für alle Aussagen, Ergebnisse und Schlussfolgerungen dieser Arbeit liegt vollständig beim Verfasser. Die reine Rechtschreib- und Grammatikprüfung ist gemäß Leitlinie nicht dokumentationspflichtig und daher nicht gesondert aufgeführt.

Dokumentationspflichtiger Prompt (inhaltlich prägend). Der folgende Prompt trug maßgeblich zur Fundierung der Forschungslücke (Kapitel 1 und 2) bei:

„Führe eine wissenschaftliche Literaturrecherche zu Szenenrepräsentationen für LLM/VLM-Agenten bei natürlichsprachlicher 3D-Szenenmanipulation durch. Sammle Belege für drei Stränge — strukturelle, visuelle und hybride Repräsentation — sowie für die dazwischen bestehende Forschungslücke, und schätze ab, wie gut die Lückenbehauptung (‘ein systematischer, referenztyp-differenzierter Vergleich struktureller, visueller und hybrider Repräsentation für lokale Agenten fehlt’) gestützt wird.“

Claude Opus 4.8, Anthropic. Die durch die Recherche vorgeschlagenen Quellen wurden ausnahmslos an den Originalpublikationen überprüft; nicht verifizierbare Angaben wurden verworfen.

Abbildungsverzeichnis

4.1	Konzeptionelle Kompetenzverteilung der beiden Repräsentationen. Der Überlappungsbereich steht für Referenzen, die beide Schichten auflösen können, die Außenbereiche für die jeweils exklusive Kompetenz einer Schicht. Genau diese exklusiven Bereiche begründen den hybriden Ansatz.	14
5.1	Aufbau des Systems in drei Schichten und Nachrichtenfluss einer Manipulation. Durchgezogene Pfeile zeigen den Vorwärtsfluss, gestrichelte Pfeile den Rückkanal. Die Verbindung zwischen MCP-Server und Umgebung wird über WebSocket übertragen. . . .	16
5.2	Die visuelle Repräsentation am Beispiel einer einfachen Szene. Links die gerenderte Ansicht, wie sie die Kamera liefert. Rechts dieselbe Ansicht nach dem Set-of-Mark-Verfahren, bei dem jedes sichtbare Objekt eine nummerierte Marke trägt, über die das visuelle Modell es benennen kann. Die Marken sind reine Bezeichner. Die Farbe einer Marke ist bedeutungslos und wird bei der Auswertung ignoriert.	18
5.3	Ablauf einer einzelnen Manipulation. In der Agentenschleife fragt der Agent die Szene über ein Wahrnehmungswerkzeug ab, das Sprachmodell wählt daraufhin die passende Operation, und das gewählte Werkzeug manipuliert das Objekt. Diese Schritte wiederholen sich, bis der Agent die Aufgabe abschließt. Erst danach liest die Auswertung den tatsächlichen Szenenzustand aus und bewertet den Erfolg daraus, nicht aus der Selbstauskunft des Agenten.	19
5.4	Ablauf eines gesprochenen Befehls im Demonstrator. Der lokale Rechner erkennt die Sprache und leitet den Text als Commander-Nachricht weiter, der entfernte Rechner arbeitet den Agentenlauf ab, und die Brille führt die Manipulation aus und zeigt den Verarbeitungsstatus an.	23
5.5	Eine frühe Ausbaustufe des Demonstrators in Betrieb. In dieser Fassung werden die Befehle noch nicht gesprochen, sondern über ein Menü in der Szene ausgewählt, das vordefinierte Anweisungen bereitstellt. Das Standbild stammt aus einer Aufzeichnung, in der auf diese Weise unter anderem „move the striped cube up“, „put the blue sphere left of the red cube“ und „delete the striped cube“ ausgelöst werden. Die vollständige Aufzeichnung ist als Begleitmaterial in Anhang A.1 verlinkt.	24
6.1	Erfolg in der rein visuellen Kategorie D über die fünf Varianten. Die rein visuelle Variante bildet die Obergrenze, die rein strukturelle scheitert nahezu vollständig. Die naive Kombination erreicht nur etwa die Hälfte, die Priorisierung verbessert dies, und erst die Kompetenztrennung erreicht nahezu das Niveau der reinen Bildvariante.	33

Quellcodeverzeichnis

1	Beispiel des strukturellen Szenenzustands als JSON-Ausgabe der Umgebung.	17
2	Beispiel einer Werkzeugdefinition (gekürzt). Der Dokumentationskommentar dient dem Agenten als Beschreibung des Werkzeugs.	19
3	Wahrnehmungswerkzeug der naiven hybriden Variante.	20
4	Wahrnehmungswerkzeug der geführten Variante (Priorisierung des Bildes).	21
5	Wahrnehmungswerkzeug der kompetenzgetrennten Variante (klare Arbeitsteilung). . .	21

Tabellenverzeichnis

3.1	Funktionale Anforderungen.	9
3.2	Nicht-funktionale Anforderungen.	10
5.1	Die fünf Repräsentationsvarianten im Vergleich.	21
6.1	Verfügbarkeit der zur Auflösung nötigen Information je Referenztyp und Schicht, nach Konstruktion der Szenarien. Die Zeilen D und E bilden das exklusive Gegensatzpaar. .	27
6.2	Übersicht aller ausgewerteten Szenarien mit Befehl, Ausgangsszene und Soll-Ergebnis. Die Befehle geben den real gesendeten englischen Stimulus wieder.	28
6.3	Erfolg je Szenario und Variante: Mittelwert [Min–Max] über drei Durchläufe (je $N = 10$). .	29
6.4	Erfolg je Kategorie (Summe über Szenarien), Mittelwert [Min–Max] über drei Durch- läufe. Kategorie E getrennt ausgewiesen.	29

Literaturverzeichnis

- [1] A. Deng, T. Cao, Z. Chen, und B. Hooi, „Words or Vision: Do Vision-Language Models Have Blind Faith in Text?” in *2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, S. 3867–3876. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/11092720> (Zitiert auf Seiten 2, 6, 13 und 35.)
- [2] H. Wu, M. Tang, X. Zheng, und H. Jiang. When Language Overrules: Revealing Text Dominance in Multimodal Large Language Models. [Online]. Available: <http://arxiv.org/abs/2508.10552> (Zitiert auf Seiten 2, 6, 13 und 35.)
- [3] „Smolagents.” [Online]. Available: <https://github.com/huggingface/smolagents> (Zitiert auf Seiten 5 und 18.)
- [4] „MCP.” [Online]. Available: <https://modelcontextprotocol.io> (Zitiert auf Seiten 5 und 15.)
- [5] J. Yang, H. Zhang, F. Li, X. Zou, C. Li, und J. Gao. Set-of-Mark Prompting Unleashes Extraordinary Visual Grounding in GPT-4V. [Online]. Available: <http://arxiv.org/abs/2310.11441> (Zitiert auf Seiten 5, 13 und 17.)
- [6] P. Achlioptas, A. Abdelreheem, F. Xia, M. Elhoseiny, und L. Guibas, „ReferIt3D: Neural Listeners for Fine-Grained 3D Object Identification in Real-World Scenes,” in *Computer Vision – ECCV 2020*, A. Vedaldi, H. Bischof, T. Brox, und J.-M. Frahm, Hrsgg. Springer International Publishing, S. 422–440. (Zitiert auf Seiten 5 und 27.)
- [7] D. Z. Chen, A. X. Chang, und M. Nießner, „ScanRefer: 3D Object Localization in RGB-D Scans Using Natural Language,” in *Computer Vision – ECCV 2020*, A. Vedaldi, H. Bischof, T. Brox, und J.-M. Frahm, Hrsgg. Springer International Publishing, S. 202–221. (Zitiert auf Seiten 5 und 27.)
- [8] F. De La Torre, C. M. Fang, H. Huang, A. Banburski-Fahey, J. Amores Fernandez, und J. Lanier, „LLMR: Real-time Prompting of Interactive Worlds Using Large Language Models,” in *Proceedings of the 2024 CHI Conference on Human Factors in Computing Systems*, Serie CHI ’24. Association for Computing Machinery, S. 1–22. [Online]. Available: <https://dl.acm.org/doi/10.1145/3613904.3642579> (Zitiert auf Seite 5.)
- [9] X. E. Wang, Z. P. T. Sin, Y. Jia, D. Archer, W. H. Y. Fong, Q. Li, und C. Li, „Can You Move These Over There? Exploring an LLM-based VR Mover to Support Natural Multi-object Manipulation,” in *Proceedings of the 38th Annual ACM Symposium on User Interface Software and Technology*, Serie UIST ’25. Association for Computing Machinery, S. 1–18. [Online]. Available: <https://dl.acm.org/doi/10.1145/3746059.3747673> (Zitiert auf Seite 6.)
- [10] R. Li, S. Li, L. Kong, X. Yang, und J. Liang. SeeGround: See and Ground for Zero-Shot Open-Vocabulary 3D Visual Grounding. [Online]. Available: <http://arxiv.org/abs/2412.04383> (Zitiert auf Seite 6.)
- [11] X. Sun, X. Zhang, B. Crowe, D. Albin, und C. Heckman. SceneGraphGrounder: Zero-Shot 3D Visual Grounding via Structured Scene Graph Matching. [Online]. Available: <http://arxiv.org/abs/2605.21788> (Zitiert auf Seite 6.)
- [12] M. Li, S. Zhao, Q. Wang, K. Wang, Y. Zhou, S. Srivastava, C. Gokmen, T. Lee, L. E. Li, R. Zhang, W. Liu, P. Liang, L. Fei-Fei, J. Mao, und J. Wu. Embodied Agent Interface: Benchmarking LLMs for Embodied Decision Making. [Online]. Available: <http://arxiv.org/abs/2410.07166> (Zitiert auf Seite 6.)
- [13] Z. Song, X. Lin, Q. Huang, S. Qin, G. Wang, und L. Lin. SIRI-Bench: Challenging VLMs’ Spatial Intelligence through Complex Reasoning Tasks. [Online]. Available: <http://arxiv.org/abs/2506.14512> (Zitiert auf Seite 6.)

- [14] Z. Wu, Z. Wang, X. Xu, J. Lu, und H. Yan. Embodied Task Planning with Large Language Models. [Online]. Available: <http://arxiv.org/abs/2307.01848> (Zitiert auf Seite 6.)
- [15] D. C. Dinh, K. Le-Duc, F. Draye, C. Ngo, T. J. Zhang, B. Schölkopf, und Z. Jin. PruneGround: Plug-and-play Spatial Pruning for 3D Visual Grounding. [Online]. Available: <http://arxiv.org/abs/2606.31148> (Zitiert auf Seite 6.)
- [16] A. Nanri, K. Reichard, M. Kiray, F. Tombari, B. Busam, und A. Kanezaki. 3D Segmentation Using Viewpoint-Dependent Spatial Relationships. [Online]. Available: <http://arxiv.org/abs/2605.15708> (Zitiert auf Seite 39.)

Anhang A

Begleitmaterial

A.1 Demonstrationsvideo

Als Begleitmaterial zu dieser Arbeit steht eine Videoaufzeichnung des Demonstrators zur Verfügung. Sie zeigt eine frühe Ausbaustufe, in der die Szene über ein Menü in der virtuellen Umgebung manipuliert wird, das vordefinierte Befehle bereitstellt. Das Video ist unter der folgenden Adresse abrufbar.

`https://git.informatik.fh-nuernberg.de/jobboerse/forschung/bachelorarbeiten/
bachelorarbeit-sandro-jaeger/-/blob/fe68f112f06df9da38eff687fd8df8460061186c/BA_VR_
Demo_with_menu.mp4`



Abbildung: QR-Code zur Videoaufzeichnung.