



Bachelorarbeit

Szenenverständnis und -manipulation in immersiven Umgebungen mittels Künstlicher Intelligenz

Sandro Jäger
Matrikelnummer: 3683886

Prüfer: Prof. Dr. Uwe Wienkop
Louis Burk

© Sandro Jäger, 2026

Diese Arbeit, einschließlich ihrer Teile, **ist urheberrechtlich geschützt**. Jede Verwertung außerhalb der engen Grenzen des Urheberrechtsgesetzes ohne Zustimmung des Urhebers ist untersagt und strafbar. Dies gilt insbesondere für Vervielfältigungen, Übersetzungen, Mikroverfilmung und die Speicherung und Verarbeitung in elektronischen Systemen.

Kurzdarstellung

Damit ein KI-Agent eine dreidimensionale Szene natürlichsprachlich verändern kann, muss ihm die Szene zunächst in einer verarbeitbaren Form vorliegen. Dafür stehen zwei grundlegende Wege zur Verfügung, eine strukturelle Beschreibung als exakte Daten und eine visuelle Beschreibung über ein gerendertes Bild. Für selbst gehostete Modelle geringer Größe fehlte bislang ein systematischer Vergleich dieser Formen.

Die vorliegende Arbeit untersucht daher, welchen Einfluss die Repräsentationsform auf den Ausführungserfolg der Szenenmanipulation hat und ob sich eine Kombination beider Formen gezielt gestalten lässt. Dazu wurde ein prototypisches System entwickelt, das dieselbe Szene strukturell, visuell und hybrid bereitstellt und fünf daraus abgeleitete Varianten unter gleichen Bedingungen an dreizehn kontrolliert aufgebauten Szenarien vergleicht. Die Messung selbst fand am Desktop statt; die immersive Umgebung wird ausschließlich in einem Demonstrator gezeigt und nicht eigenständig evaluiert.

Der Vergleich zeigt eine referenztypabhängige Kompetenz ohne Gesamtsieger, wobei beide Formen jeweils einen Bereich abdecken, den die andere nicht erreicht. Eine naive Kombination vereint diese Stärken nicht von selbst. Erst eine ausdrückliche Trennung der Zuständigkeiten führt die beiden Schichten auf diesem Szenarioset zusammen, während eine bloße Priorisierung das Gewicht nur verschiebt. Ob sich dieser Vorteil auf ungesehene Formulierungen überträgt, bleibt offen, da die Variante iterativ am vorliegenden Szenarioset entwickelt wurde. Ein Demonstrator überträgt diese Variante in eine immersive Umgebung und zeigt die Machbarkeit der gesamten Kette.

Schlagwörter

Szenenrepräsentation, Immersive Umgebungen, Multimodale Agenten, Lokale Sprachmodelle, Vision-Language-Modelle

Danksagung

Mein Dank gilt Prof. Dr. Uwe Wienkop und Louis Burk für die Betreuung dieser Arbeit und für die hilfreichen Rückmeldungen im Verlauf. Dem Institut für angewandte Informatik danke ich für die Möglichkeit, diese Arbeit dort anzufertigen, sowie für die bereitgestellte Hardware, ohne die der lokale Betrieb der Modelle nicht möglich gewesen wäre. Ein besonderer Dank gilt schließlich meinem Bruder und meinen Eltern für ihre Unterstützung während des Studiums.

Inhaltsverzeichnis

Abkürzungsverzeichnis	vi
Abbildungsverzeichnis	vii
Tabellenverzeichnis	viii
Quellcodeverzeichnis	ix
1 Einleitung	1
1.1 Motivation und Problemstellung	1
1.2 Relevanz	2
1.3 Zielsetzung und Forschungsfragen	2
1.4 Methodisches Vorgehen	2
1.5 Aufbau der Arbeit	3
2 Grundlagen und Stand der Technik	4
2.1 Große Sprach- und Sprach-Bild-Modelle	4
2.2 Werkzeugnutzende Agenten	5
2.3 Szenenrepräsentation	5
2.4 Stand der Technik	6
2.4.1 Strukturelle Szenenmanipulation in immersiven Umgebungen	6
2.4.2 Hybrides Grounding	6
2.4.3 Modalitäts-Ablationen und Modalitäts-Dominanz	6
2.4.4 Ansätze mit lokalen, kleinen Modellen	7
2.5 Forschungslücke	7
3 Anforderungen	8
3.1 Herleitung der Anforderungen	8
3.2 Funktionale Anforderungen	8
3.3 Nicht-funktionale Anforderungen	9
3.4 Spannungen zwischen den Anforderungen	10
3.5 Abgrenzung des Funktionsumfangs	11
4 Konzept	12
4.1 Lösungsansatz im Überblick	12
4.2 Die drei Repräsentationsformen	12
4.3 Entwurfsentscheidungen	13
4.4 Steuerung der Modalitätsfusion	13
4.5 Differenzierung nach Referenztyp	14
5 Implementierung	16
5.1 Systemüberblick	16

5.2	Szenenanbindung	18
5.3	Agent und Werkzeuge	19
5.4	Die fünf Repräsentationsvarianten	21
5.5	Der VR-Demonstrator	24
6	Evaluation	28
6.1	Evaluationsdesign	28
6.2	Referenztyp-Taxonomie	31
6.3	Metriken	33
6.4	Ergebnisse zu RQ1	34
6.5	Ergebnisse zu RQ2	40
6.6	Validität und Grenzen	42
7	Zusammenfassung und Ausblick	48
7.1	Zusammenfassung	48
7.2	Beantwortung der Forschungsfragen	49
7.3	Beitrag	49
7.4	Grenzen der Arbeit	50
7.5	Ausblick	52
	Glossar	54
	Literaturverzeichnis	55
	Erklärung: Verwendung von KI-Werkzeugen	57
A	Begleitmaterial	58
A.1	Demonstrationsvideo	58

Abkürzungsverzeichnis

API Application Programming Interface, Programmierschnittstelle

ES Execution Success, Ausführungserfolg

FA funktionale Anforderung

GPU Graphics Processing Unit, Grafikprozessor

JSON JavaScript Object Notation

KI Künstliche Intelligenz

LLM Large Language Model, großes Sprachmodell

MCP Model Context Protocol

MR Mixed Reality, gemischte Realität

NFA nicht-funktionale Anforderung

RQ Research Question, Forschungsfrage

SoM Set-of-Mark

STT Speech-to-Text, Spracherkennung

VLM Vision-Language Model, Sprach-Bild-Modell

VPN Virtual Private Network, virtuelles privates Netz

VR Virtual Reality, virtuelle Realität

VRAM Video Random Access Memory, Grafikspeicher

Abbildungsverzeichnis

4.1	Konzeptionelle Kompetenzverteilung der beiden Repräsentationen. Der Überlappungsbereich steht für Referenzen, die beide Schichten auflösen können, die Außenbereiche für die jeweils exklusive Kompetenz einer Schicht. Genau diese exklusiven Bereiche begründen den hybriden Ansatz.	15
5.1	Aufbau des Systems in drei Schichten und Nachrichtenfluss einer Manipulation. Durchgezogene Pfeile zeigen den Vorwärtsfluss, gestrichelte Pfeile den Rückkanal. Die Verbindung zwischen MCP-Server und Umgebung wird über WebSocket übertragen. . . .	17
5.2	Die visuelle Repräsentation am Beispiel einer einfachen Szene. Links die gerenderte Ansicht, wie sie die Kamera liefert. Rechts dieselbe Ansicht nach dem Set-of-Mark-Verfahren, bei dem jedes sichtbare Objekt eine nummerierte Marke trägt, über die das visuelle Modell es benennen kann. Die Marken sind reine Bezeichner. Die Farbe einer Marke ist bedeutungslos und wird bei der Auswertung ignoriert.	19
5.3	Ablauf einer einzelnen Manipulation. In der Agentenschleife fragt der Agent die Szene über ein Wahrnehmungswerkzeug ab, das Sprachmodell wählt daraufhin die passende Operation, und das gewählte Werkzeug manipuliert das Objekt. Diese Schritte wiederholen sich, bis der Agent die Aufgabe abschließt. Erst danach liest die Auswertung den tatsächlichen Szenenzustand aus und bewertet den Erfolg daraus, nicht aus der Selbstauskunft des Agenten.	20
5.4	Ablauf eines gesprochenen Befehls im Demonstrator. Der lokale Rechner erkennt die Sprache und leitet den Text als Commander-Nachricht weiter, der entfernte Rechner arbeitet den Agentenlauf ab, und die Brille führt die Manipulation aus und zeigt den Verarbeitungsstatus an.	26
5.5	Eine frühe Ausbaustufe des Demonstrators in Betrieb. In dieser Fassung werden die Befehle nicht gesprochen, sondern über ein Menü in der Szene ausgewählt, das vordefinierte Anweisungen bereitstellt. Links steht der rote Würfel, rechts die blaue Kugel; der gestreifte Würfel steht in der Mitte und wird von der Menütafel weitgehend verdeckt, sodass nur sein unterer Teil sichtbar bleibt. Das Standbild stammt aus einer Aufzeichnung, in der auf diese Weise unter anderem „move the striped cube up“, „put the blue sphere left of the red cube“ und „delete the striped cube“ ausgelöst werden. Die vollständige Aufzeichnung ist als Begleitmaterial in Anhang A.1 verlinkt. Sie dokumentiert die Menüfassung und nicht die später ergänzte Sprachsteuerung.	27
6.1	Erfolg in der rein visuellen Kategorie D über die fünf Varianten. Die rein visuelle Variante bildet die Obergrenze, die rein strukturelle scheitert nahezu vollständig. Die naive Kombination erreicht nur etwa die Hälfte, die Priorisierung verbessert dies, und erst die Kompetenztrennung erreicht nahezu das Niveau der reinen Bildvariante.	41

Tabellenverzeichnis

3.1	Funktionale Anforderungen.	9
3.2	Nicht-funktionale Anforderungen.	10
5.1	Die fünf Repräsentationsvarianten im Vergleich, mit den in den Ergebnistabellen verwendeten Kurzbezeichnungen.	23
6.1	Konfiguration der Messung, beschränkt auf die Angaben, die den Ausgang der Läufe beeinflussen. Zusammen mit dem verlinkten Code genügen sie, um die Messung zu wiederholen.	30
6.2	Verfügbarkeit der zur Auflösung nötigen Information je Referenztyp und Schicht, nach Konstruktion der Szenarien. Die Zeilen D und E bilden das exklusive Gegensatzpaar. .	31
6.3	Übersicht aller ausgewerteten Szenarien mit Befehl, Ausgangsszene und Soll-Ergebnis. Die Befehle geben den real gesendeten englischen Stimulus wieder.	32
6.4	Erfolg je Szenario und Variante: Mittelwert [Min–Max] über drei Durchläufe (je $N = 10$). .	35
6.5	Erfolg je Kategorie als Summe der zugehörigen Szenario-Mittelwerte über drei Durchläufe. Eine Spanne wird hier nicht ausgewiesen, da sich Minimum und Maximum einer Kategorie nicht aus den Szenario-Spannen zusammensetzen lassen. Kategorie E getrennt ausgewiesen.	35
6.6	Zentrale Zellen als Erfolge aus $n = 30$ Läufen mit Wilson-95 %-Konfidenzintervall der Erfolgsrate.	36
6.7	Exakte Tests nach Fisher für die zentralen Vergleiche, jeweils $n = 30$ je Gruppe. Das Niveau ist nicht für multiples Testen korrigiert.	37

Quellcodeverzeichnis

1	Beispiel des strukturellen Szenenzustands als JSON-Ausgabe der Umgebung.	18
2	Beispiel einer Werkzeugdefinition (gekürzt). Der Dokumentationskommentar dient dem Agenten als Beschreibung des Werkzeugs.	20
3	Prompt, mit dem das visuelle Modell die gerenderte und markierte Ansicht beschreibt. Er wird zusammen mit dem Bild übergeben und ist in allen Varianten mit visueller Schicht identisch.	21
4	Wahrnehmungswerkzeug der naiven hybriden Variante.	22
5	Wahrnehmungswerkzeug der geführten Variante (Priorisierung des Bildes).	22
6	Wahrnehmungswerkzeug der kompetenzgetrennten Variante (klare Arbeitsteilung). . .	23

Kapitel 1

Einleitung

1.1 Motivation und Problemstellung

Ein Nutzer steht in einer virtuellen Szene und sagt einen einfachen Satz: Heb den gestreiften Würfel an. Für einen Menschen ist die Aufgabe trivial. Für einen KI-Agenten beginnt hier das eigentliche Problem. Bevor er den Würfel anheben kann, muss er die Szene verstehen, und dazu muss ihm die Szene in einer Form vorliegen, die er verarbeiten kann.

Für diese Form gibt es zwei grundverschiedene Wege. Der eine Weg beschreibt die Szene strukturell, als exakte Daten über Objekte, ihre Typen, Positionen und Größen. Der andere Weg beschreibt die Szene visuell, als gerendertes Bild, das ein visuelles Modell interpretiert. Beide Wege haben offensichtliche Stärken und ebenso offensichtliche blinde Flecken. Die strukturellen Daten kennen jede Koordinate, aber nicht das Aussehen eines Objekts. Das Bild zeigt das Aussehen, aber keine exakten Zahlen.

Der gestreifte Würfel aus dem Beispiel macht den ersten blinden Fleck sichtbar. Er lässt sich nur über das Bild bestimmen, denn das Streifenmuster steht in keinen strukturellen Daten. Der umgekehrte Fall ist ebenso denkbar. Ein Objekt, das hinter einem anderen verborgen ist, erscheint im Bild überhaupt nicht, bleibt in den strukturellen Daten aber vollständig verzeichnet. Ein Befehl, der sich auf ein solches verdecktes Objekt bezieht, lässt sich nur über die strukturelle Schicht auflösen. Beide Wege haben also nicht nur unterschiedliche Stärken, sondern jeweils einen Bereich, den der andere Weg grundsätzlich nicht abdeckt.

Damit stellt sich eine Frage, die am Anfang jedes solchen Systems steht und bisher ohne empirische Grundlage beantwortet werden musste. In welcher Form sollte einem lokal betriebenen Agenten eine Szene bereitgestellt werden, und lässt sich eine Kombination beider Wege so gestalten, dass sie die Stärken beider vereint? Gerade in immersiven Umgebungen, in denen ein Nutzer über natürliche Sprache mit einer Szene interagiert, ist diese Frage praktisch bedeutsam. Und gerade für lokal betreibbare Modelle, die aus Gründen des Datenschutzes, der Latenz und der Offline-Fähigkeit in solchen Umgebungen naheliegen, fehlt ein systematischer Vergleich dieser Wege.

Der Begriff *lokal* wird in dieser Arbeit durchgängig in einem festgelegten Sinn verwendet und sei hier einmal definiert. Lokal heißt: selbst gehostet auf eigener Hardware, ohne Nutzung eines Cloud-Dienstes, sodass keine Szenen- oder Sprachdaten das eigene Netz verlassen. Lokal heißt ausdrücklich nicht, dass die Modelle auf dem Endgerät selbst rechnen. Sowohl in der Messung als auch im Demonstrator laufen sie auf einem Arbeitsplatzrechner; die Brille erreicht diesen im Demonstrator über eine Netzverbindung innerhalb des Institutsnetzes (Abschnitt 5.5).

1.2 Relevanz

Die Wahl der Repräsentationsform ist keine technische Nebensache. Sie entscheidet mit darüber, welche sprachlichen Anweisungen ein Agent überhaupt zuverlässig umsetzen kann. Eine Repräsentation, die eine ganze Klasse von Referenzen nicht abbildet, lässt die zugehörigen Befehle scheitern, unabhängig davon, wie gut der Agent im Übrigen arbeitet.

Bei großen, cloudbasierten Modellen lässt sich eine schwache Repräsentation teilweise durch schiere Modellgröße ausgleichen. Bei lokal betreibbaren Modellen geringer Größe entfällt dieser Ausgleich. Hier wird die Repräsentation zum eigentlichen Hebel für den Erfolg. Wer ein solches System entwirft, trifft die Entscheidung über die Repräsentationsform früh und mit weitreichenden Folgen, bislang jedoch ohne belastbare Grundlage. Diese Grundlage zu schaffen, ist das praktische Anliegen der Arbeit.

Über den praktischen Nutzen hinaus berührt die Frage ein allgemeineres Problem. Wie sich strukturierte und visuelle Information in einem Agenten verbinden lassen, betrifft jede Anwendung, die beide Arten von Information kombiniert. Ob eine solche Kombination ihre Bestandteile ergänzt oder ob eine Informationsart die andere verdrängt, ist eine offene Frage mit Bedeutung über den hier untersuchten Fall hinaus [1, 2].

1.3 Zielsetzung und Forschungsfragen

Das zentrale Ziel der Arbeit ist eine empirisch fundierte Erkenntnis darüber, welche Repräsentationsform einen lokal betriebenen Agenten bei der natürlichsprachlichen Szenenmanipulation am zuverlässigsten unterstützt. Die Arbeit verfolgt dieses Ziel anhand zweier Forschungsfragen.

Forschungsfrage 1 (RQ1). Welchen Einfluss hat die Form der Szenenrepräsentation, strukturell, visuell oder hybrid, auf den Ausführungserfolg der natürlichsprachlichen Szenenmanipulation durch einen lokal betriebenen Agenten, und zwar aufgeschlüsselt nach der Art der sprachlichen Referenz?

Forschungsfrage 2 (RQ2). Lässt sich das Zusammenspiel der strukturellen und der visuellen Schicht allein durch die Gestaltung der Instruktion so steuern, dass die hybride Repräsentation die Stärken beider Schichten vereint?

Der Ausführungserfolg ist dabei die einzige Zielgröße der Arbeit. Er wird binär je Lauf aus dem tatsächlichen Szenenzustand bestimmt und umfasst zwei Bedingungen, die beide erfüllt sein müssen: Es muss das gemeinte Objekt betroffen sein, und das geforderte Ergebnis muss eintreten, bei Positionsaufgaben innerhalb einer festen Toleranz. Ein separat berichteter, kontinuierlicher Lagefehler ist nicht Teil der Zielgröße; Abschnitt 6.3 legt das Maß im Einzelnen fest.

Über diese beiden Fragen hinaus entsteht ein Demonstrator, der die auf dem untersuchten Szenarioset als am zuverlässigsten ermittelte Variante in die immersive Zielumgebung überträgt. Er beantwortet keine eigene Forschungsfrage und wird nicht eigenständig evaluiert, sondern dient dem Nachweis der praktischen Machbarkeit.

Die Arbeit grenzt ihren Anspruch bewusst ab. Sie beansprucht keine Generalisierung auf andere Modelle oder auf reale, komplexe Szenen, keine global optimale Lösung und keine Produktreife des Demonstrators. Die Ergebnisse gelten für ein lokales Modellpaar in kontrolliert aufgebauten Szenen. Die gesamte Messung fand am Desktop statt; die immersive Umgebung ist Zielumgebung des Demonstrators, nicht Gegenstand der Messung.

1.4 Methodisches Vorgehen

Zur Beantwortung der Forschungsfragen verfolgt die Arbeit einen empirischen Ansatz. Grundlage ist ein prototypisches System, das dieselbe Szene in den drei zu vergleichenden Repräsentationsformen

bereitstellt und über ein gemeinsames Interface manipulierbar macht. Auf dieser Grundlage werden die Formen unter gleichen Bedingungen an einer Reihe kontrolliert aufgebauter Szenarien gegeneinander gemessen. Der Erfolg jeder Manipulation wird dabei aus dem tatsächlichen Zustand der Szene bestimmt und nicht aus der Selbstauskunft des Agenten, und jede Messung wird wiederholt, um belastbare von zufälligen Unterschieden trennen zu können.

Aus diesem Vorgehen ergeben sich drei Beiträge, die in Abschnitt 7.3 wieder aufgegriffen und in ihrer Reichweite eingeordnet werden. Der erste Beitrag ist inhaltlicher Art: der Befund, dass die Verbindung struktureller und visueller Information kein Automatismus ist, sondern ein Gestaltungsproblem, an einem kontrollierten Fall gezeigt. Der zweite Beitrag ist methodischer Art: eine nach der Art der sprachlichen Referenz aufgeschlüsselte Betrachtung, die den Erfolg getrennt nach Referenztypen misst und so exklusive Zuständigkeiten sichtbar macht, die ein pauschaler Vergleich verdeckt. Der dritte Beitrag ist praktischer Art: ein lauffähiger Demonstrator, der die gesamte Kette bis in die immersive Zielumgebung überträgt und deren Machbarkeit belegt.

1.5 Aufbau der Arbeit

Der Aufbau der Arbeit zeichnet den Weg von der offenen Frage zur belastbaren Antwort nach. Kapitel 2 legt die begrifflichen Grundlagen und ordnet die Arbeit in den Stand der Technik ein, um die Forschungslücke genau zu bestimmen, die sie schließt. Aus dieser Lücke leitet Kapitel 3 ab, was ein System leisten muss, damit sich die Frage überhaupt beantworten lässt. Kapitel 4 entwickelt daraus das Lösungskonzept, insbesondere den Entwurfsraum der drei Repräsentationsformen und die Entscheidungen, die einen fairen Vergleich ermöglichen. Wie dieses Konzept in ein lauffähiges System übersetzt wird, beschreibt Kapitel 5. Kapitel 6 führt den Vergleich durch und berichtet die Ergebnisse zu beiden Forschungsfragen. Kapitel 7 fasst die Erkenntnisse zusammen, ordnet ihre Grenzen ein und zeigt, welche Fragen offen bleiben.

Kapitel 2

Grundlagen und Stand der Technik

Dieses Kapitel schafft die Grundlage, um die Fragestellung der Arbeit einordnen zu können. Der erste Teil führt die eingesetzten Modelle, das Agenten-Paradigma und die Formen der Szenenrepräsentation ein. Der zweite Teil ordnet die Arbeit in den Stand der Technik ein und leitet daraus die Forschungslücke ab.

2.1 Große Sprach- und Sprach-Bild-Modelle

Die vorliegende Arbeit setzt zwei Arten vortrainierter Modelle als Bausteine ein. Beide werden unverändert genutzt und nicht selbst weiterentwickelt.

Ein großes Sprachmodell, im Folgenden als LLM (Large Language Model) bezeichnet, ist ein auf umfangreichen Textmengen trainiertes neuronales Modell, das zu einer gegebenen Eingabe fortlaufend Text erzeugt. Durch ein zusätzliches Training auf Instruktionen lässt sich ein solches Modell anweisen, eine Aufgabe zu bearbeiten, und gibt seine Antwort wieder als Text aus. In dieser Arbeit übernimmt ein LLM die Rolle des Agenten, der einen Befehl interpretiert und die passende Operation auswählt.

Ein Sprach-Bild-Modell, im Folgenden als VLM (Vision-Language Model) bezeichnet, erweitert dieses Prinzip um eine visuelle Eingabe. Es verarbeitet ein Bild gemeinsam mit einem Text und erzeugt daraus eine textuelle Antwort, etwa eine Beschreibung des Bildinhalts oder die Antwort auf eine Frage zum Bild. In dieser Arbeit übernimmt ein VLM die visuelle Wahrnehmung der Szene.

Der Unterschied zwischen beiden Modellen bestimmt ihre Rollen im System. Das Sprachmodell verarbeitet ausschließlich Text und ist damit auf eine textuelle Beschreibung der Szene angewiesen. Das Sprach-Bild-Modell kann eine gerenderte Ansicht unmittelbar interpretieren. Diese unterschiedlichen Zugänge zur Szene bilden den Ausgangspunkt der Frage, wie eine Szene einem solchen Modell am besten bereitgestellt wird.

Die zweistufige Pipeline dieser Arbeit

Für das Verständnis aller folgenden Kapitel ist eine architektonische Eigenschaft des hier untersuchten Systems entscheidend, die es von einem einzelnen multimodalen Modell unterscheidet. Die beiden Modelle sind nicht zu einem Modell verschmolzen, sondern in Reihe geschaltet. Das Sprach-Bild-Modell erhält das gerenderte Bild und erzeugt daraus eine natürlichsprachliche Beschreibung. Diese Beschreibung, und nicht das Bild, gelangt anschließend in den Kontext des Sprachmodells, das den Befehl deutet und die Operation wählt. Das Sprachmodell, das die eigentliche Entscheidung trifft, sieht also zu keinem Zeitpunkt ein Bild.

Daraus folgt eine Präzisierung, die für die Einordnung der Ergebnisse wesentlich ist. Was in dieser Arbeit als „visuelle Repräsentation“ bezeichnet wird, ist streng genommen keine Bildeingabe, sondern

eine sprachliche Beschreibung eines Bildes. Wenn im Folgenden von der Gewichtung der strukturellen gegenüber der visuellen Schicht die Rede ist, konkurrieren daher nicht Bild und Text im Inneren eines multimodalen Modells, sondern zwei Textquellen im Kontext eines reinen Sprachmodells: eine exakte, aber unvollständige Datenstruktur und eine reichhaltige, aber unscharfe Beschreibung. Abschnitt 5.4 zeigt die konkrete Umsetzung dieser Pipeline, Abschnitt 6.6 ihre Folgen für die Deutung der Befunde.

Beide Modelle werden in dieser Arbeit lokal im Sinne der in Abschnitt 1.1 gegebenen Definition und in einer Größenordnung von etwa sieben Milliarden Parametern betrieben. Die Gründe dafür, insbesondere Datenschutz, Latenz und Offline-Fähigkeit in der immersiven Zielumgebung, sind in Abschnitt 1.2 dargelegt.

2.2 Werkzeugnutzende Agenten

Die Interaktion mit der Szene folgt dem Muster eines werkzeugnutzenden Agenten. Ein solcher Agent ist ein Sprachmodell, das nicht nur Text erzeugt, sondern in einer Schleife aus Wahrnehmung und Handlung Werkzeuge aufruft, um eine Aufgabe zu lösen.

Ein Werkzeug ist dabei eine benannte Funktion mit einer kurzen Beschreibung ihrer Wirkung und ihrer Parameter. Das Sprachmodell entscheidet anhand dieser Beschreibung, welches Werkzeug es mit welchen Argumenten aufruft. Das Ergebnis des Aufrufs fließt in den Kontext zurück, woraufhin das Modell den nächsten Schritt wählt, bis es die Aufgabe als abgeschlossen meldet. Auf diese Weise verbindet der Agent die sprachliche Interpretation eines Befehls mit konkreten Aktionen in der Umgebung.

In dieser Arbeit wird der Agent mit dem Framework *smolagents* umgesetzt, das einen werkzeugaufzufindenden Agenten bereitstellt [3]. Die Werkzeuge selbst werden über das Model Context Protocol (MCP) angebunden, einen offenen Standard, der Sprachmodellen den Zugriff auf externe Werkzeuge und Datenquellen über eine einheitliche Schnittstelle ermöglicht [4]. Das Protokoll trennt die Bereitstellung der Werkzeuge von ihrer Nutzung durch den Agenten, sodass dieselben Werkzeuge unabhängig vom konkreten Modell aufgerufen werden können.

Dieses Muster bildet die Grundlage des in dieser Arbeit umgesetzten Systems. Wie es konkret realisiert ist, beschreibt Kapitel 5.

2.3 Szenenrepräsentation für Sprachmodelle

Damit ein Sprachmodell eine Szene verändern kann, muss es die Szene zunächst erfassen. Da ein Sprachmodell auf Text arbeitet, stellt sich die Frage, in welcher Form eine dreidimensionale Szene ihm zugänglich gemacht wird. Zwei grundlegende Ansätze stehen einander gegenüber.

Der strukturelle Ansatz beschreibt die Szene als Daten. Die Objekte werden mit ihren Eigenschaften wie Typ, Position, Größe und Farbe in einer textuellen Form wie JSON oder als Szenengraph aufgeführt. Diese Darstellung ist exakt und für ein Sprachmodell unmittelbar lesbar, gibt aber nur wieder, was in den Daten kodiert ist.

Der visuelle Ansatz stellt die Szene als gerendertes Bild bereit, das ein Sprach-Bild-Modell interpretiert. Diese Darstellung erfasst das Aussehen der Szene, wie es sich einem Betrachter zeigt, liefert aber keine exakten Koordinaten.

Der visuelle Ansatz bringt eine zusätzliche Anforderung mit sich. Ein Modell muss ein im Bild erkanntes Objekt benennen können, um es anschließend gezielt anzusprechen. Eine verbreitete Technik dafür ist das Set-of-Mark-Prompting, bei dem sichtbare Objekte im Bild mit nummerierten Marken versehen werden [5]. Das Modell kann sich dann auf eine Marke beziehen, und die Nummer lässt sich eindeutig einem Objekt zuordnen.

Unabhängig von der Repräsentationsform hängt die Schwierigkeit einer Aufgabe davon ab, wie im Befehl auf ein Objekt verwiesen wird. Bestehende Arbeiten unterscheiden Referenzen bereits nach verschiedenen Eigenschaften, etwa danach, ob eine Referenz vom Blickwinkel des Betrachters abhängt, oder danach, ob das Zielobjekt in der Szene eindeutig ist [6, 7]. Solche Einteilungen bilden den Ausgangspunkt für die in dieser Arbeit verwendete, feiner nach Referenztypen aufgeschlüsselte Betrachtung, die in Abschnitt 6.2 eingeführt wird.

2.4 Stand der Technik

Die Bausteine der vorliegenden Arbeit sind einzeln gut erforscht. Dieser Abschnitt ordnet die Arbeit entlang von vier Feldern in den Stand der Technik ein und zeigt, an welcher Stelle jedes Feld eine andere Frage verfolgt als die vorliegende Untersuchung.

2.4.1 Strukturelle Szenenmanipulation in immersiven Umgebungen

Ein erstes Feld befasst sich mit der sprachgesteuerten Manipulation von Szenen in virtuellen und gemischten Realitäten. LLMR erzeugt und verändert interaktive Mixed-Reality-Szenen zur Laufzeit, indem es mehrere Sprachmodelle orchestriert und die Szene als strukturierten Graphen führt [8]. VR Mover manipuliert Objekte in der virtuellen Realität über natürliche Sprache und kodiert die Szene dazu als strukturierte Objektdaten [9]. Beide Arbeiten zeigen, dass sich Szenen in immersiven Umgebungen sprachlich verändern lassen. Sie nutzen dafür jedoch ausschließlich die strukturelle Repräsentation und setzen große, cloudbasierte Modelle ein. Ein Vergleich verschiedener Repräsentationsformen findet nicht statt.

2.4.2 Hybrides Grounding

Ein zweites Feld verbindet strukturelle und visuelle Information, um ein Objekt in einer Szene zu bestimmen. SeeGround stellt eine Szene als Kombination aus einer gerenderten Ansicht und einer räumlich angereicherten textuellen Beschreibung dar und verknüpft beide über visuelle Marken [10]. Dieser Ansatz ist der vorliegenden Arbeit konzeptionell am nächsten, verfolgt aber ein anderes Ziel. Er dient dem Auffinden eines Objekts und nicht seiner Manipulation, setzt ein großes Modell ein und stellt die Repräsentationsformen nicht als gleichwertige Bedingungen einander gegenüber.

Einen verwandten Weg beschreitet SceneGraphGrounder, das das Auffinden eines Objekts als strukturiertes Graph-Matching formuliert [11]. Dabei leitet ein visuelles Modell über eine Marker-Strategie die Beziehungen zwischen Objekten aus zweidimensionalen Ansichten ab, die anschließend in einen persistenten Szenengraphen überführt werden. Die Arbeit berichtet, dass eine explizite strukturelle Repräsentation die Grounding-Genauigkeit verbessert. Damit bestätigt sie, dass die Verbindung von struktureller und visueller Information ein aktiv verfolgter Ansatz ist. Wie SeeGround bleibt sie jedoch beim Auffinden von Objekten und behandelt nicht deren Manipulation. Zudem betrachtet sie die strukturelle und die visuelle Information nicht als getrennte, gegeneinander geprüfte Repräsentationsformen, sondern setzt sie von vornherein gemeinsam ein.

2.4.3 Modalitäts-Ablationen und Modalitäts-Dominanz

Ein drittes Feld untersucht, wie sich verschiedene Eingabemodalitäten auf die Leistung auswirken. Die Arbeit zum Embodied Agent Interface vergleicht unter anderem eine rein strukturelle, eine rein visuelle und eine kombinierte Eingabe und zeigt, dass strukturierter Input reine Bildeingabe deutlich übertrifft [12]. Dieser Vergleich betrifft jedoch die Handlungsplanung und nicht die Szenenmanipulation und schlüsselt die Aufgaben nicht nach Referenztypen auf. In eine ähnliche Richtung weist SIRI-Bench, ein Benchmark für räumliches Schließen [13]. In einer kontrollierten Ablation werden dort baugleiche Modelle einmal mit einer textuellen und einmal mit einer visuellen Eingabe derselben Aufgabe verglichen. Die textbasierten Varianten übertreffen ihre videobasierten Gegenstücke deutlich, und die Untersuchung stellt fest, dass die Modelle sich übermäßig auf textuelle Hinweise

stützen und räumliche Information nur schwer aus dem visuellen Eingang gewinnen. Dieser Befund stützt aus einer anderen Domäne die auch in der vorliegenden Arbeit beobachtete Tendenz, dass strukturierte gegenüber rein visueller Information bei räumlichen Aufgaben im Vorteil ist. Er betrifft allerdings abstrakte Reasoning-Aufgaben und nicht die Manipulation einer 3D-Szene und nimmt keine Aufschlüsselung nach Referenztypen vor. Eng verwandt sind darüber hinaus zwei Arbeiten zur Modalitäts-Dominanz. Sie zeigen, dass Sprach-Bild-Modelle textuelle Information gegenüber visueller Information übergewichten und bei widersprüchlichen Eingaben dem Text mehr vertrauen [1, 2]. Eine der beiden Arbeiten bezieht in ihre Untersuchung auch ein Modell derselben Familie ein, aus der das hier eingesetzte visuelle Modell stammt [2].

Die Übertragbarkeit dieser beiden Arbeiten auf die vorliegende Untersuchung ist allerdings begrenzt und wird hier ausdrücklich nur als Analogie in Anspruch genommen. Beide untersuchen die Gewichtung von Bild gegen Text *innerhalb* eines multimodalen Modells, dem beide Modalitäten zugleich vorliegen. In der hier untersuchten zweistufigen Pipeline liegt der Fall anders: Das entscheidende Sprachmodell sieht überhaupt kein Bild, sondern zwei Textquellen (Abschnitt 2.1). Der eigentliche Konflikt ist deshalb nicht Bild gegen Text, sondern exakte Struktur gegen unscharfe Beschreibung, also der Vorrang einer präzisen, maschinell erzeugten Datenstruktur gegenüber einer sprachlich vagen Schilderung derselben Szene. Die genannten Arbeiten begründen damit keine direkte Erwartung für den hier untersuchten Aufbau, legen aber als strukturell ähnliches Muster nahe, dass eine naive Kombination beider Quellen die präzisere von beiden überbewerten könnte.

2.4.4 Ansätze mit lokalen, kleinen Modellen

Ein viertes Feld setzt lokal betreibbare Modelle geringer Größe ein, meist aus Gründen des Datenschutzes, der Latenz oder der Offline-Fähigkeit. Ein Ansatz zur Handlungsplanung nutzt ein lokales Modell mit sieben Milliarden Parametern und zeigt, dass sich solche Aufgaben grundsätzlich auch mit kleinen Modellen bearbeiten lassen [14]. Ein weiterer Ansatz löst das Auffinden von Objekten in 3D-Szenen mit einem kleinen visuellen Modell [15]. Beide Arbeiten belegen die Machbarkeit unter Ressourcenbeschränkung, führen aber keinen kontrollierten Vergleich mehrerer Repräsentationsformen für die Szenenmanipulation durch. Damit bleibt gerade für die ressourcenbeschränkte Umgebung offen, welche Repräsentation eine natürlichsprachliche Manipulation am zuverlässigsten trägt.

2.5 Forschungslücke

Die vier Felder zeigen ein einheitliches Bild. Die strukturelle und die visuelle Repräsentation sind je für sich etabliert. Es gibt Arbeiten zur sprachgesteuerten Manipulation von Szenen, Arbeiten zum hybriden Auffinden von Objekten, Untersuchungen zur Wirkung einzelner Modalitäten und Ansätze mit kleinen, lokal betreibbaren Modellen. Was fehlt, ist eine Untersuchung, die diese Fäden zusammenführt.

Kein bekanntes Werk vereint die folgenden vier Eigenschaften. Es geht erstens um die natürlichsprachliche Manipulation einer Szene und nicht allein um deren Verständnis, das Auffinden von Objekten oder die Erzeugung von Szenen. Es vergleicht zweitens die strukturelle, die visuelle und die hybride Repräsentation als gleichwertige Bedingungen. Es schlüsselt drittens die Aufgaben nach der Art der sprachlichen Referenz auf. Es setzt viertens lokal betreibbare Modelle geringer Größe ein anstelle großer, cloudbasierter Modelle.

Daraus ergibt sich die offene Frage, wie eine Szene einem lokal betriebenen Agenten für die natürlichsprachliche Manipulation am besten bereitgestellt werden sollte und welchen Einfluss die Wahl der Repräsentationsform auf den Ausführungserfolg hat. Offen ist dabei insbesondere, ob eine hybride Kombination beider Repräsentationen ihre jeweiligen Stärken vereint oder ob unter den Bedingungen eines kleinen, lokalen Modells eine Quelle die andere verdrängt. An dieser Lücke setzen die beiden in Abschnitt 1.3 gestellten Forschungsfragen an. Die folgenden Kapitel entwickeln das System, mit dem sie beantwortet werden.

Kapitel 3

Anforderungen

Die Anforderungen an das System ergeben sich nicht aus einem vorgegebenen Lastenheft, sondern aus dem wissenschaftlichen Ziel der Arbeit und den Bedingungen, unter denen sie entsteht. Dieses Kapitel legt zunächst offen, aus welchen Quellen die Anforderungen abgeleitet werden. Darauf aufbauend beschreibt es die funktionalen und die nicht-funktionalen Anforderungen, benennt die Spannungen zwischen ihnen und grenzt am Ende ab, was bewusst nicht gefordert ist.

3.1 Herleitung der Anforderungen

Da die Arbeit kein Auftragsprojekt mit externem Auftraggeber ist, gibt es keinen klassischen Anforderungskatalog. Formale Anforderungen wurden mit der Betreuung nicht im Einzelnen festgelegt. Die Anforderungen leiten sich daher analytisch aus vier Quellen ab, die im Folgenden benannt werden.

Die erste Quelle sind die Forschungsfragen. Das System existiert, um den Einfluss der Repräsentationsform auf die natürlichsprachliche Szenenmanipulation messbar zu machen. Daraus folgt unmittelbar, dass das System mehrere Repräsentationsformen bereitstellen und ihren Einfluss unter fairen Bedingungen sichtbar machen muss.

Die zweite Quelle ist die Zielumgebung. Die Arbeit ist auf eine immersive Anwendung ausgerichtet, in der Datenschutz, geringe Latenz und Unabhängigkeit von einer Netzverbindung eine Rolle spielen. Diese Ausrichtung legt den Betrieb lokaler Modelle nahe und verlangt, dass sich die Verarbeitungskette bis in die Brille übertragen lässt.

Die dritte Quelle ist die wissenschaftliche Methodik. Damit die Ergebnisse belastbar sind, müssen die Messungen reproduzierbar und die Erfolgsbewertung objektiv sein. Dies stellt Anforderungen an die Kontrolle der Szenen und an die Art der Erfolgsmessung.

Die vierte Quelle ist die verfügbare Hardware. Für die Arbeit stand ein vom Institut bereitgestellter Arbeitsplatzrechner mit einer einzelnen Grafikkarte zur Verfügung. Diese Ausstattung ist eine feste Randbedingung und keine freie Entwurfsentscheidung. Sie begrenzt die Größe der einsetzbaren Modelle und prägt damit mehrere der folgenden Anforderungen.

3.2 Funktionale Anforderungen

Die funktionalen Anforderungen beschreiben, was das System leisten muss.

Zunächst muss das System einen natürlichsprachlichen Befehl entgegennehmen und in eine Veränderung der Szene umsetzen. Die dafür nötigen Operationen beschränken sich auf das Erzeugen, Verschieben und Entfernen von Objekten. Diese Beschränkung ist bewusst gewählt, da sich mit diesen

wenigen Operationen bereits alle für die Untersuchung nötigen Arten von Referenzen abdecken lassen, ohne den Funktionsumfang unnötig auszuweiten.

Um die zentrale Frage untersuchen zu können, muss das System die Szene in den drei zu vergleichenden Repräsentationsformen bereitstellen, also strukturell, visuell und hybrid. Dies ist die Kernanforderung, ohne die der Vergleich nicht möglich wäre.

Damit der Vergleich fair bleibt, müssen alle Varianten Objekte über dasselbe Interface ansprechen, also über ein gemeinsames Kennungssystem. Diese Anforderung ist weniger selbstverständlich, als sie zunächst wirkt; Abschnitt 4.3 begründet sie im Zusammenhang der übrigen Entwurfsentscheidungen für einen fairen Vergleich.

Der Erfolg einer Manipulation muss zudem objektiv bestimmbar sein. Das System muss dazu den tatsächlichen Zustand der Szene nach einer Manipulation auslesen, sodass sich der Erfolg unabhängig von der Selbstauskunft des Agenten ermitteln lässt. Diese Anforderung folgt aus der Beobachtung, dass ein kleines Modell einen Erfolg melden kann, den es nicht erreicht hat, was eine Messung anhand seiner eigenen Antwort unzuverlässig machen würde. Schließlich muss sich jedes Testszenario reproduzierbar aufbauen und zurücksetzen lassen, damit Messungen unter identischen Bedingungen wiederholbar sind.

Tabelle 3.1 fasst die funktionalen Anforderungen zusammen. Die Spalte Herkunft verweist darauf, ob eine Anforderung aus den Forschungsfragen oder aus methodischen Gründen folgt.

Tabelle 3.1: Funktionale Anforderungen.

Nr.	Anforderung	Herkunft
FA1	Natürlichsprachliche Befehle in Szenenmanipulationen umsetzen, beschränkt auf Erzeugen, Verschieben und Entfernen von Objekten	RQ1, RQ2
FA2	Die Szene in struktureller, visueller und hybrider Repräsentation bereitstellen	RQ1
FA3	Objekte über ein gemeinsames Kennungssystem ansprechen, unabhängig von der Repräsentationsform	Validität
FA4	Den Erfolg einer Manipulation aus dem tatsächlichen Szenenzustand bestimmen	Validität
FA5	Testszenarien reproduzierbar aufbauen und zurücksetzen	Methodik

3.3 Nicht-funktionale Anforderungen

Die nicht-funktionalen Anforderungen beschreiben keine einzelnen Funktionen, sondern Eigenschaften und Randbedingungen, die das System als Ganzes erfüllen muss.

Aus der Zielumgebung folgt, dass die Modelle lokal betrieben werden, im Sinne der in Abschnitt 1.1 festgelegten Definition: selbst gehostet auf eigener Hardware und ohne Cloud-Dienst, nicht notwendigerweise auf dem Endgerät. Datenschutz, geringe Latenz und die Unabhängigkeit von einer externen Netzverbindung sprechen in einer immersiven Anwendung für eine solche Ausführung. Damit verbunden ist die Beschränkung auf begrenzte Hardware. Da für die Arbeit eine feste Ausstattung mit einer einzelnen Grafikkarte vorgegeben war, muss das System mit deren Grafikspeicher auskommen. Diese Vorgabe legt die Wahl auf Modelle geringer Größe fest, die neben dem Sprachmodell auch das visuelle Modell gleichzeitig im Speicher halten können.

Für die Aussagekraft der Untersuchung muss die Messung reproduzierbar sein. Unter identischer Konfiguration müssen sich vergleichbare Ergebnisse einstellen, was kontrollierte und wiederholbar aufgebaute Szenen voraussetzt. Da die eigentliche Zielumgebung die immersive Anwendung ist, muss sich dieselbe Verarbeitungskette sowohl am Desktop für die Messung als auch in der Brille betreiben

lassen, ohne dass ihr Kern verändert wird. Schließlich muss der Vergleich so aufgebaut sein, dass die Repräsentationsform die einzige zwischen den Varianten variierende Größe ist. Nur dann lassen sich Unterschiede eindeutig auf die Repräsentation zurückführen.

Tabelle 3.2 fasst die nicht-funktionalen Anforderungen zusammen.

Tabelle 3.2: Nicht-funktionale Anforderungen.

Nr.	Anforderung	Herkunft
NFA1	Modelle lokal, das heißt selbst gehostet und ohne Cloud, betreiben	Zielumgebung
NFA2	Mit der vorgegebenen Hardware, einer einzelnen Grafikkarte, und Modellen geringer Größe auskommen	Hardware
NFA3	Messungen unter identischer Konfiguration reproduzierbar halten und die Konfiguration vollständig dokumentieren	Methodik
NFA4	Dieselbe Verarbeitungskette am Desktop und in der immersiven Umgebung betreiben	Zielumgebung
NFA5	Die Repräsentationsform als einzige zwischen den Varianten variierende Größe sicherstellen	Validität

Zu NFA5 ist eine Einschränkung vorwegzunehmen, die sich erst in der Umsetzung zeigte und in Abschnitt 6.6 ausgeführt wird. Die drei hybriden Varianten unterscheiden sich nicht ausschließlich in ihrer Instruktion, sondern zusätzlich in der Reihenfolge, in der die strukturelle und die visuelle Schicht im Kontext erscheinen. Instruktion und Reihenfolge sind damit konfundiert, sodass NFA5 für den Vergleich der hybriden Varianten untereinander nur eingeschränkt erfüllt ist. Für den Vergleich der drei Repräsentationsformen im engeren Sinne, strukturell gegen visuell gegen hybrid, bleibt die Anforderung unberührt.

3.4 Spannungen zwischen den Anforderungen

Die genannten Anforderungen lassen sich nicht widerspruchsfrei zugleich maximieren. Zwischen ihnen bestehen Spannungen, deren bewusste Auflösung den Charakter der Arbeit prägt.

Eine erste Spannung besteht zwischen der Leistungsfähigkeit und der Ressourcenbeschränkung. Die Anforderung, natürlichsprachliche Befehle zuverlässig umzusetzen, wäre mit großen Modellen leichter zu erfüllen. Die Vorgabe lokaler Modelle geringer Größe begrenzt jedoch die Fähigkeiten des Systems. Diese Spannung wird nicht aufgelöst, sondern angenommen, da gerade das Verhalten unter dieser Beschränkung Gegenstand der Untersuchung ist.

Eine zweite Spannung besteht zwischen der Fairness des Vergleichs und der Praxisnähe. Das gemeinsame Kennungssystem und die kontrolliert aufgebauten Szenen sind für einen sauberen Vergleich notwendig, entfernen die Aufgabe aber ein Stück weit von einer realistischen Anwendung. Hier wird der wissenschaftlichen Kontrolle der Vorrang gegeben, da die Arbeit eine Vergleichsstudie und keine Produktentwicklung ist.

Eine dritte Spannung besteht zwischen der Reproduzierbarkeit und dem Realismus der Szenen. Reproduzierbare Messungen verlangen einfache, kontrolliert aufgebaute Szenen, während die Zielumgebung komplexe, reale Szenen nahelegt. Auch hier wird zugunsten der Reproduzierbarkeit entschieden, und die Übertragung in die reale Umgebung bleibt dem Demonstrator vorbehalten.

Diese Entscheidungen folgen einem einheitlichen Grundsatz. Wo eine wissenschaftliche und eine anwendungsnahe Anforderung in Konflikt geraten, erhält die wissenschaftliche den Vorrang, weil das Ziel der Arbeit eine belastbare Erkenntnis und kein fertiges Produkt ist.

3.5 Abgrenzung des Funktionsumfangs

Ebenso wichtig wie das, was das System leisten muss, ist die Abgrenzung dessen, was bewusst nicht gefordert ist. Diese Abgrenzung entspricht der Nicht-Reichweite der Zielsetzung und hält den Rahmen der Arbeit klar.

Das System muss keine Produktreife erreichen. Es genügt, die untersuchten Repräsentationen und die Kette bis in die immersive Umgebung funktionsfähig zu machen, ohne dass Robustheit unter Dauerlast oder eine ausgereifte Bedienung gefordert ist. Der Umfang der Manipulationen bleibt bewusst auf das Erzeugen, Verschieben und Entfernen von Objekten beschränkt. Weitere Operationen wie das Drehen oder Skalieren zur Laufzeit sind nicht Teil der Untersuchung. Ebenso wenig muss das System beliebige oder mehrdeutige natürlichsprachliche Formulierungen zuverlässig auflösen. Die Befehle sind für die Untersuchung klar formuliert, und die Robustheit gegenüber umgangssprachlicher Vielfalt ist kein Ziel. Eine Nutzerstudie ist nicht vorgesehen, da die Bewertung rein systembasiert aus dem Szenenzustand erfolgt. Schließlich wird keine Übertragbarkeit auf andere Modelle oder auf reale, komplexe Szenen gefordert, da die Untersuchung auf ein Modellpaar und kontrolliert aufgebaute Szenen begrenzt ist.

Kapitel 4

Konzept

Die Anforderungen aus dem vorigen Kapitel geben vor, was das System leisten muss. Dieses Kapitel entwickelt daraus das Lösungskonzept, also den Entwurf, der diese Anforderungen erfüllt. Es beschreibt zunächst den Lösungsansatz im Überblick und den Entwurfsraum der drei Repräsentationsformen. Anschließend legt es die Entwurfsentscheidungen offen, die einen fairen Vergleich der Formen erst ermöglichen, entwickelt die Idee zur Steuerung ihrer Kombination und begründet, warum der Erfolg nach der Art der sprachlichen Referenz betrachtet werden muss. Die konkrete technische Umsetzung dieses Konzepts beschreibt Kapitel 5.

4.1 Lösungsansatz im Überblick

Der Lösungsansatz beruht auf einem sprachgesteuerten Agenten. Der Agent nimmt einen natürlich-sprachlichen Befehl entgegen, verschafft sich über eine Repräsentation ein Bild der Szene und verändert die Szene über eine feste Menge von Operationen. Der entscheidende Freiheitsgrad des Entwurfs liegt darin, in welcher Form dem Agenten die Szene bereitgestellt wird. Diese Form ist der Untersuchungsgegenstand der Arbeit.

Das Konzept folgt einem dreistufigen roten Faden. In der ersten Stufe wird der Einfluss der Repräsentationsform analysiert, indem verschiedene Formen unter gleichen Bedingungen verglichen werden. In der zweiten Stufe wird untersucht, ob sich die Kombination der Repräsentationen gezielt verbessern lässt. In der dritten Stufe wird die beste Variante in die immersive Zielumgebung übertragen und dort als Demonstrator erprobt. Die ersten beiden Stufen entsprechen den beiden Forschungsfragen, die dritte Stufe dient dem Nachweis der Übertragbarkeit.

4.2 Die drei Repräsentationsformen

Der Entwurfsraum umfasst drei Formen, in denen die Szene dem Agenten bereitgestellt werden kann.

Die strukturelle Form beschreibt die Szene als exakte Daten. Sie kennt die Objekte mit ihren Kennungen, Typen, Positionen und Größen und ist damit stark bei allem, was sich aus diesen Daten ableiten lässt, etwa bei geometrischen Beziehungen. Was in den Daten nicht kodiert ist, bleibt für sie jedoch unsichtbar.

Die visuelle Form beschreibt die Szene als gerenderte Ansicht, die von einem visuellen Modell interpretiert wird. Sie erfasst das Aussehen der Szene, wie es sich einem Betrachter zeigt, und ist damit stark bei Eigenschaften, die nur im Bild erkennbar sind. Exakte Zahlenwerte wie Koordinaten liefert sie jedoch nicht.

Hier ist eine Präzisierung nötig, die den Entwurfsraum wesentlich prägt. Die visuelle Form wird nicht als Bild an das entscheidende Modell übergeben, denn dieses Modell ist ein reines Sprachmodell. Der Entwurf schaltet die beiden Modelle in Reihe: Das Sprach-Bild-Modell erhält das gerenderte Bild und erzeugt daraus eine natürlichsprachliche Beschreibung, und erst diese Beschreibung gelangt in den Kontext des Sprachmodells, das den Befehl deutet (vgl. Abschnitt 2.1). Die visuelle Form ist im Entwurfsraum dieser Arbeit also die *sprachliche Beschreibung* eines Bildes und nicht das Bild selbst.

Die hybride Form stellt beide Schichten zugleich bereit. Sie verbindet die Möglichkeit, exakte Geometrie zu nutzen, mit der Möglichkeit, das Aussehen zu berücksichtigen. Was in ihr aufeinandertrifft, sind damit zwei Textquellen im Kontext desselben Sprachmodells: eine exakte, aber unvollständige Datenstruktur und eine reichhaltige, aber unscharfe Beschreibung.

Diese drei Formen bilden den Vergleichsraum der Arbeit, weil sie die beiden Einzelquellen und ihre Kombination vollständig abdecken. Der Vergleich der Einzelformen zeigt, wofür jede Schicht zuständig ist, und der Vergleich mit der hybriden Form zeigt, ob eine Kombination die Stärken beider vereint.

Eine bewusste Entscheidung betrifft den Inhalt der strukturellen Schicht. Sie enthält je Objekt die Kennung, den Typ, die Position, die Farbe und die Größe sowie die Pose der Kamera. Vorberechnete räumliche Beziehungen enthält sie jedoch nicht. Eine Relation wie links von muss der Agent aus den Koordinaten selbst ableiten. Andernfalls würde die Auswertung die Güte einer Vorverarbeitung messen und nicht die Eignung der Repräsentation.

4.3 Entwurfsentscheidungen für einen fairen Vergleich

Damit der Vergleich tatsächlich die Repräsentation misst und nicht einen Nebeneffekt des Aufbaus, sind mehrere Entwurfsentscheidungen nötig. Sie stellen sicher, dass keine Variante aus Gründen bevorzugt oder benachteiligt wird, die nichts mit ihrer Repräsentation zu tun haben.

Die erste Entscheidung ist ein gemeinsames Kennungssystem. Alle Varianten sprechen Objekte über dieselben Kennungen an. Eine Kennung ist dabei nur ein Adressierungsmittel und kein Bestandteil des Szenenverständnisses. Die visuelle Variante wird über Marken, die in das gerenderte Bild eingezeichnet werden, an dieselben Kennungen gebunden. Dieses Markieren folgt dem Set-of-Mark-Prinzip [5]. So kann auch die visuelle Variante ein erkanntes Objekt benennen, ohne dass ihr daraus ein struktureller Vorteil erwächst.

Die zweite Entscheidung betrifft die Bewegungsoperationen. Das System stellt eine absolute und eine relative Bewegungsoperation bereit. Die relative Operation ist notwendig, damit sich Objekte auch ohne einen exakten Weltbezug verschieben lassen. Ohne sie wäre die rein visuelle Variante benachteiligt, da sie keine exakten Koordinaten kennt. Dieser Nachteil wäre ein Artefakt des Werkzeugzuschnitts und keine Eigenschaft der Repräsentation.

Die dritte Entscheidung betrifft die bewusste Auslassung von Information. Die unterscheidende Eigenschaft der rein perzeptuellen Aufgaben, etwa ein Oberflächenmuster, wird absichtlich nicht in die strukturelle Schicht aufgenommen. Erst dadurch entsteht ein Fall, in dem die strukturelle Schicht prinzipiell blind ist und sich die exklusive Kompetenz der visuellen Schicht überhaupt zeigen kann.

4.4 Steuerung der Modalitätsfusion

Die hybride Form stellt beide Schichten bereit, legt aber nicht fest, wie der Agent sie gegeneinander gewichtet. Dem Konzept liegt die Annahme zugrunde, dass die bloße Verfügbarkeit beider Schichten nicht genügt, damit ihre Stärken auch tatsächlich zusammenwirken. Diese Annahme stützt sich auf eine Analogie zu Beobachtungen aus der Literatur, wonach multimodale Modelle bei widersprüchlichen Eingaben der textuellen Information den Vorrang geben [1, 2]. Die Analogie ist dabei nicht mehr als das: Die genannten Arbeiten betrachten die Konkurrenz von Bild und Text innerhalb eines Modells, während hier zwei Textquellen im Kontext eines Sprachmodells konkurrieren, eine exakte Struktur und

eine unscharfe Beschreibung (Abschnitt 2.4). Die Erwartung lautet daher präziser, dass die exaktere der beiden Quellen die unschärfere überschreibt, auch wo nur die unschärfere die Antwort enthält. Die Art, wie die beiden Schichten dem Agenten präsentiert werden, wird deshalb selbst zu einem Entwurfsgegenstand.

Das Konzept sieht dafür zwei Strategien vor. Die erste Strategie ist die Priorisierung. Sie erklärt eine der beiden Schichten für einen bestimmten Zweck als maßgeblich und stellt sie in den Vordergrund. Die zweite Strategie ist die Kompetenztrennung. Sie ordnet den beiden Schichten getrennte Zuständigkeiten zu, sodass jede Schicht nur für den Teil der Aufgabe herangezogen wird, für den sie geeignet ist.

Beide Strategien wirken ausschließlich über die Gestaltung der Instruktion. Die Modelle werden nicht nachtrainiert, und ihre Gewichte bleiben unverändert. Diese Beschränkung auf die Instruktionsebene ist eine bewusste Entscheidung. Sie hält den Vergleich sauber, da sich nur der Kontext und nicht das Modell ändert, und sie entspricht der Fragestellung, die nach der Repräsentation und nicht nach einer Modellanpassung fragt. Die konkrete Ausformulierung der beiden Strategien wird in Kapitel 5 beschrieben.

4.5 Differenzierung nach Referenztyp

Ob eine Repräsentation eine Aufgabe lösen kann, hängt davon ab, wie im Befehl auf ein Objekt verwiesen wird. Ein Verweis über eine exakte Lage stellt andere Anforderungen als ein Verweis über eine sichtbare Eigenschaft. Aus dieser Beobachtung folgt der zentrale konzeptionelle Gedanke der Arbeit. Die beiden Repräsentationen besitzen nicht nur unterschiedlich starke, sondern teils einander ausschließende Zuständigkeiten.

Manche Referenzen lassen sich ausschließlich über die strukturelle Schicht auflösen. Ein Objekt, das im Bild verdeckt ist, bleibt in den strukturellen Daten dennoch verzeichnet. Andere Referenzen lassen sich ausschließlich über die visuelle Schicht auflösen. Eine Eigenschaft wie ein Oberflächenmuster, das in den strukturellen Daten nicht vorkommt, ist nur im Bild erkennbar. Zwischen diesen beiden Polen liegt ein Bereich, in dem beide Schichten dieselbe Referenz auflösen können.

Abbildung 4.1 stellt diese Kompetenzverteilung dar. Gerade die einander ausschließenden Bereiche sind es, die eine Kombination beider Schichten überhaupt sinnvoll machen. Sie begründen zugleich, warum der Erfolg nach der Art der Referenz aufgeschlüsselt betrachtet werden muss und nicht als ein einzelner Gesamtwert. Die konkrete Einteilung der Referenztypen und die zugehörigen Szenarien werden in Kapitel 6 eingeführt.




Abbildung 4.1: Konzeptionelle Kompetenzverteilung der beiden Repräsentationen. Der Überlappungsbereich steht für Referenzen, die beide Schichten auflösen können, die Außenbereiche für die jeweils exklusive Kompetenz einer Schicht. Genau diese exklusiven Bereiche begründen den hybriden Ansatz.

Kapitel 5

Implementierung

Das Konzept aus dem vorigen Kapitel beschreibt, welche Repräsentationen verglichen werden und wie sie sich unterscheiden. Dieses Kapitel zeigt, wie sich dieses Konzept in ein lauffähiges System übersetzt. Es beschreibt zuerst den Aufbau im Überblick und geht anschließend auf die Anbindung der Szene, den Agenten mit seinen Werkzeugen, die konkrete Umsetzung der fünf Repräsentationsvarianten und schließlich auf den VR-Demonstrator ein.

5.1 Systemüberblick

Das System verbindet einen natürlichsprachlichen Befehl mit einer sichtbaren Veränderung der 3D-Szene. Es besteht aus drei lose gekoppelten Schichten, die über festgelegte Schnittstellen kommunizieren. Diese Trennung erlaubt es, die Umgebung auszutauschen, ohne die übrigen Schichten zu verändern, und ist der Grund, warum dieselbe Kette sowohl am Desktop für die Messung als auch in der immersiven Umgebung für den Demonstrator läuft.

Die drei Schichten

Die oberste Schicht übernimmt das Interpretieren und Entscheiden. Hier deutet ein Agent den Befehl und wählt die nötige Manipulation. Der Agent wird von einem lokal betriebenen Sprachmodell angetrieben und greift für die visuelle Wahrnehmung auf ein lokales visuelles Modell zurück.

Die mittlere Schicht verbindet die oberste Schicht mit der Umgebung. Ein Server nach dem Model Context Protocol (MCP) [4] stellt die Manipulationsoperationen als aufrufbare Werkzeuge bereit und übersetzt jeden Aufruf in eine Nachricht an die Umgebung. Eine WebSocket-Verbindung transportiert diese Nachrichten und liefert den Szenenzustand sowie gerenderte Bilder zurück.

Die unterste Schicht ist die Umgebung selbst. Sie hält die Szene, stellt sie dar und führt die Manipulationen aus. In der Evaluation läuft diese Schicht am Desktop, im Demonstrator auf der Meta Quest.

Ablauf einer Manipulation

Ein Durchlauf beginnt mit dem natürlichsprachlichen Befehl an den Agenten. Der Agent verschafft sich zunächst ein Bild der Szene, indem er über die Werkzeuge den strukturellen Zustand oder eine gerenderte Ansicht anfordert. Auf dieser Grundlage entscheidet er, welche Operation auszuführen ist, und ruft das entsprechende Werkzeug auf. Der MCP-Server leitet den Aufruf über die WebSocket-Verbindung an die Umgebung weiter, die die Manipulation ausführt. Anschließend liest die Auswertung den neuen Szenenzustand aus und bestimmt daraus den Erfolg. Abbildung 5.1 stellt diesen Aufbau und den Nachrichtenfluss dar.




Abbildung 5.1: Aufbau des Systems in drei Schichten und Nachrichtenfluss einer Manipulation. Durchgezogene Pfeile zeigen den Vorwärtsfluss, gestrichelte Pfeile den Rückkanal. Die Verbindung zwischen MCP-Server und Umgebung wird über WebSocket übertragen.

5.2 Szenenanbindung

Damit der Agent eine Szene bearbeiten kann, muss die Umgebung sie in einer verarbeitbaren Form bereitstellen. Die Umgebung liefert dazu zwei Sichten auf dieselbe Szene, eine strukturelle und eine visuelle.

Der strukturelle Zustand

Die Umgebung führt intern ein Verzeichnis aller manipulierbaren Objekte. Auf Anfrage serialisiert sie dieses Verzeichnis in eine JSON-Struktur. Sie enthält eine Liste der Objekte mit jeweils einer eindeutigen Kennung, dem Objekttyp, der Farbe, der Größe und der Position sowie zusätzlich die Pose der Kamera. Listing 1 zeigt ein Beispiel dieser Ausgabe. Die Kamerapose ist Teil des Zustands, damit sich auch Aufgaben lösen lassen, die einen Bezug zum Betrachter herstellen. Nicht enthalten sind Eigenschaften, die allein das Aussehen betreffen und über die Grundfarbe hinausgehen, etwa eine Oberflächentextur. Diese Lücke ist der Grund, warum rein perzeptuelle Referenzen über den strukturellen Zustand nicht auflösbar sind.

```

1 {
2   "type": "state",
3   "objects": [
4     {"id": "obj_1", "type": "cube", "color": "red", "x": 0.0, "y": 0.0, "z": 0.0,
5      ↪ "scale": 1.0},
6     {"id": "obj_2", "type": "sphere", "color": "blue", "x": 2.0, "y": 0.0, "z": 0.0,
7      ↪ "scale": 1.0}
8   ],
9   "camera": {
10    "position": [0.0, 1.6, -6.0],
11    "forward": [0.0, 0.0, 1.0],
12    "up": [0.0, 1.0, 0.0]
13  }
14 }
```

Listing 1: Beispiel des strukturellen Szenenzustands als JSON-Ausgabe der Umgebung.

Die visuelle Sicht und die Objektmarkierung

Für die visuelle Sicht rendert die Umgebung die Szene aus der Kamera und übergibt das Bild. Ein Bild allein erlaubt dem visuellen Modell jedoch nicht, ein erkanntes Objekt für einen Werkzeugaufruf zu benennen. Deshalb wird jedes sichtbare Objekt im Bild mit einer Marke versehen, die seine Kennung trägt. Dieses Vorgehen entspricht dem Set-of-Mark-Prinzip [5]. Das visuelle Modell kann ein Objekt damit über dieselbe Kennung ansprechen, die auch die Werkzeuge verwenden. Abbildung 5.2 zeigt beide Ansichten derselben Szene im Vergleich.

Sichtbarkeit und Verdeckung

Eine Marke wird nur gesetzt, wenn das Objekt tatsächlich sichtbar ist. Ein einzelner Sichtstrahl von der Kamera zum Objektmittelpunkt prüft, ob ein anderes Objekt die Sichtlinie unterbricht. Ist das der Fall, gilt das Objekt als verdeckt und erhält keine Marke. Ein verdecktes Objekt fehlt damit in der visuellen Sicht vollständig, bleibt im strukturellen Zustand aber unverändert verzeichnet. Diese Asymmetrie ist die Grundlage derjenigen Testfälle, in denen ein Befehl auf ein im Bild unsichtbares Objekt verweist; Abschnitt 6.2 führt sie als eigenen Referenztyp ein.

Der Test ist bewusst einfach gehalten und arbeitet binär. Ein Objekt gilt als sichtbar oder als verdeckt, eine Teilverdeckung kennt er nicht. Für die hier verwendeten Szenen, in denen ein Objekt entweder




Abbildung 5.2: Die visuelle Repräsentation am Beispiel einer einfachen Szene. Links die gerenderte Ansicht, wie sie die Kamera liefert. Rechts dieselbe Ansicht nach dem Set-of-Mark-Verfahren, bei dem jedes sichtbare Objekt eine nummerierte Marke trägt, über die das visuelle Modell es benennen kann. Die Marken sind reine Bezeichner. Die Farbe einer Marke ist bedeutungslos und wird bei der Auswertung ignoriert.

frei steht oder vollständig hinter einer großen Wand liegt, genügt diese Unterscheidung. In dichterem Szenen wäre sie unzureichend, was Abschnitt 6.6 als Grenze aufgreift.

Das gemeinsame id-Substrat

Beide Sichten verweisen auf dieselben Kennungen. Die strukturelle Sicht führt sie ohnehin, und die visuelle Sicht verknüpft ihre Marken mit denselben Werten. Dadurch spricht der Agent Objekte unabhängig von der Repräsentationsform über ein einheitliches Interface an. Warum dieses id-Substrat für die Fairness des Vergleichs unverzichtbar ist, begründet Abschnitt 4.3.

5.3 Agent und Werkzeuge

Der Agent bildet die oberste Schicht des Systems. Er nimmt den Befehl entgegen, verschafft sich ein Bild der Szene und entscheidet, welche Operation auszuführen ist. Dieser Abschnitt beschreibt, wie der Agent aufgebaut ist und über welche Werkzeuge er die Szene verändert.

Der Agent und das Sprachmodell

Als Agent dient ein werkzeugaufrufender Agent aus dem Framework `smolagents` [3]. Angetrieben wird er von einem lokal betriebenen Sprachmodell, das über eine OpenAI-kompatible Schnittstelle angesprochen wird, die LM Studio auf dem Rechner bereitstellt. Der Agent arbeitet in einer Schleife. In jedem Schritt entscheidet das Sprachmodell anhand des aktuellen Kontexts, welches Werkzeug mit welchen Argumenten aufgerufen wird, bis es die Aufgabe als abgeschlossen meldet. Abbildung 5.3 stellt diesen Ablauf einer einzelnen Manipulation dar, von der Wahrnehmung bis zur Erfolgsbestimmung aus dem Folgezustand. Die Modelle werden dabei nicht nachtrainiert. Der einzige Hebel zur Steuerung ihres Verhaltens ist die Gestaltung des Kontexts, was den Ansatzpunkt der zweiten Forschungsfrage bildet.

Die Werkzeuge

Die eigentlichen Operationen stellt der MCP-Server als aufrufbare Werkzeuge bereit. Sie lassen sich in zwei Gruppen einteilen. Die manipulierenden Werkzeuge erzeugen, verschieben und entfernen Objekte oder setzen die Szene zurück. Die wahrnehmenden Werkzeuge liefern den strukturellen Zustand oder




Abbildung 5.3: Ablauf einer einzelnen Manipulation. In der Agentenschleife fragt der Agent die Szene über ein Wahrnehmungswerkzeug ab, das Sprachmodell wählt daraufhin die passende Operation, und das gewählte Werkzeug manipuliert das Objekt. Diese Schritte wiederholen sich, bis der Agent die Aufgabe abschließt. Erst danach liest die Auswertung den tatsächlichen Szenenzustand aus und bewertet den Erfolg daraus, nicht aus der Selbstauskunft des Agenten.

eine gerenderte Ansicht der Szene. Jedes Werkzeug trägt eine kurze Beschreibung in Form eines Dokumentationskommentars, und genau diese Beschreibung sieht der Agent, wenn er über den nächsten Aufruf entscheidet. Listing 2 zeigt am Beispiel des Verschiebens, wie ein solches Werkzeug aufgebaut ist.

```

1 @mcp.tool()
2 def move_object(object_id: str, x: float, y: float, z: float) -> str:
3     """Move an existing object (id from get_scene_state) to a new position."""
4     global _last_op
5     key = ("move", object_id, x, y, z)
6     if key == _last_op:                               # Schutz gegen doppelte Ausführung
7         return f"Skipped: identical move already applied to {object_id}."
8     _last_op = key
9     send_to_unity({"action": "move", "id": object_id, "x": x, "y": y, "z": z})
10    return f"Done: {object_id} moved to ({x}, {y}, {z})."

```

Listing 2: Beispiel einer Werkzeugdefinition (gekürzt). Der Dokumentationskommentar dient dem Agenten als Beschreibung des Werkzeugs.

Erfolgsmessung und Terminierungsschutz

Der Erfolg einer Manipulation wird nicht aus der Antwort des Agenten abgeleitet, sondern aus dem tatsächlichen Folgezustand der Szene, wie in Abschnitt 6.3 beschrieben. Ein Detail der Werkzeuge hängt unmittelbar damit zusammen. Das lokale Modell bündelte gelegentlich einen Manipulations- und einen Abschlusssaufruf so, dass dieselbe Manipulation zweimal ausgeführt wurde. Um dieses Verhalten des Frameworks zu neutralisieren, vergleicht jedes manipulierende Werkzeug den aktuellen Aufruf mit dem unmittelbar vorangegangenen und überspringt eine identische Wiederholung, sichtbar an der Abfrage von `_last_op` in Listing 2.

Dieser Schutz ist eine grobe Maßnahme mit einer Nebenwirkung, die offen zu benennen ist. Er kann nicht unterscheiden, ob eine identische Wiederholung ein Artefakt des Frameworks oder eine vom Befehl geforderte Handlung ist. Ein Befehl, der dieselbe Operation absichtlich zweimal verlangt, würde dadurch ebenso blockiert. Für die hier ausgewerteten Szenarien tritt dieser Fall nicht auf, da kein Soll-Ergebnis zwei identische Aufrufe erfordert. Bei Mehrschritt-Befehlen ist er jedoch nicht mehr auszuschließen; Abschnitt 6.6 greift das als Grenze auf.

5.4 Die fünf Repräsentationsvarianten

Die fünf Varianten teilen denselben Agenten und dieselbe Grundinstruktion. Diese Grundinstruktion verlangt, vor jeder Manipulation zunächst die Szene wahrzunehmen, niemals eine Kennung zu erfinden, die Aufgabe mit genau einem Manipulationsaufruf zu lösen und danach abzuschließen. Woran sich die Varianten unterscheiden, ist allein das Wahrnehmungswerkzeug, das dem Agenten zur Verfügung steht. Jedes Wahrnehmungswerkzeug trägt einen Dokumentationskommentar, und dieser Kommentar ist die Beschreibung, die der Agent bei der Wahl des nächsten Aufrufs liest. Zusätzlich rahmt der zurückgegebene Text die beiden Schichten, indem er sie benennt und ordnet. Über diese Beschreibung und diese Rahmung wird gesteuert, wie der Agent strukturelle und visuelle Information gegeneinander gewichtet.

Die Vorgabe genau eines Manipulationsaufrufs ist eine Vereinfachung, die zu einem Teil der Szenarien in Spannung steht. Zwei der ausgewerteten Szenarien verlangen ihrem Soll-Ergebnis nach mehr als eine Manipulation, weil mehrere Objekte betroffen sind. Abschnitt 6.6 legt diesen Widerspruch offen und diskutiert seine Folgen für die Deutung der betroffenen Zellen.

Die beiden Einzelrepräsentationen

Die strukturelle Variante erhält ausschließlich Zugriff auf den strukturellen Zustand. Sie sieht die Szene als JSON mit Kennungen, Typen, Farben, Größen und Positionen, jedoch kein Bild. Die visuelle Variante erhält ausschließlich eine Beschreibung der gerenderten und markierten Ansicht. Sie kennt die Objekte nur über ihre Marken und deren sichtbare Eigenschaften, jedoch keine exakten Koordinaten.

Der zweite Punkt ist wörtlich zu nehmen und für die Einordnung aller Ergebnisse wesentlich. Nicht das Bild selbst gelangt in den Kontext des Agenten, sondern eine natürlichsprachliche Beschreibung, die das visuelle Modell aus dem Bild erzeugt. Das Sprachmodell, das die Operation wählt, sieht zu keinem Zeitpunkt ein Bild (Abschnitt 2.1). Auch die hybriden Varianten kombinieren daher nicht Bild und Daten, sondern zwei Textquellen: den JSON-Zustand und die vom visuellen Modell erzeugte Beschreibung. Welche Eigenschaften diese Beschreibung enthält, hängt vollständig davon ab, worauf der an das visuelle Modell gerichtete Prompt sie ausrichtet. Dieser Prompt ist damit ein eigener, nicht variiertes Bestandteil des Aufbaus und in allen Varianten mit visueller Schicht identisch. Listing 3 gibt ihn im Wortlaut wieder.

```

1 "Each object has a yellow numbered badge floating above it. Badges are
2 labels ONLY - ignore badge color; report the actual object color. For
3 each numbered object give number, shape (cube/sphere/cylinder), color,
4 qualitative position, and a surface texture descriptor (e.g. 'striped'
5 or 'solid'). Answer ONLY as a JSON list with keys: number, shape,
6 color, position, texture."
```

Listing 3: Prompt, mit dem das visuelle Modell die gerenderte und markierte Ansicht beschreibt. Er wird zusammen mit dem Bild übergeben und ist in allen Varianten mit visueller Schicht identisch.

Zwei Eigenschaften dieses Prompts prägen die Ergebnisse und werden deshalb hier festgehalten.

Erstens verlangt er genau fünf Angaben je Objekt: Nummer, Form, Farbe, qualitative Lage und einen Texturdeskriptor. Eine Größenangabe fordert er nicht an. Was die visuelle Schicht über die Größe eines Objekts berichtet, ist damit bestenfalls zufällig in der Lagebeschreibung enthalten. Abschnitt 6.4 greift das bei der Deutung des Szenarios B3 auf.

Zweitens nennt der Prompt als Beispiel für einen Texturdeskriptor ausdrücklich „striped“. Damit enthält bereits die gemeinsame Wahrnehmungsstufe ein Wort, das in den Befehlen der perzeptuellen Szenarien vorkommt. Das betrifft alle Varianten mit visueller Schicht gleichermaßen und ist daher

kein Vorteil einer einzelnen Variante, engt aber die Aussagekraft der Kategorie D insgesamt ein; Abschnitt 6.6 führt den Punkt aus.

Die Anbindung der Marken an die Kennungen erfolgt über eine Nummerierung. Jedes sichtbare Objekt erhält eine gelbe, nummerierte Marke oberhalb seiner Bildposition, und eine Zuordnungstabelle übersetzt die vom visuellen Modell genannten Nummern zurück in die Objektkennungen. Der Prompt weist das Modell ausdrücklich an, die Farbe der Marke zu ignorieren und die tatsächliche Objektfarbe zu berichten. Diese Anweisung geht auf einen in Abschnitt 6.6 beschriebenen Störfaktor zurück.

Die naive Kombination

Die naive hybride Variante stellt beide Schichten nebeneinander. Sie gibt zuerst den strukturellen Zustand und danach die visuelle Beschreibung aus und benennt nur grob, wofür welche Schicht gedacht ist. Eine verbindliche Zuständigkeitsregel fehlt.

```

1 @tool
2 def get_scene_hybrid() -> str:
3     """Perceive the scene using BOTH exact structural data (ids, positions,
4     colors, sizes, camera) and a visual description. Use exact data for
5     geometry, visual data for semantics."""

```

Listing 4: Wahrnehmungswerkzeug der naiven hybriden Variante.

Priorisierung

Die geführte Variante ändert die Rahmung. Sie stellt die visuelle Beschreibung voran und erklärt sie für das Aussehen als maßgeblich, während die strukturelle Schicht ausdrücklich als rein geometrisch und frei von Aussehens-Information gekennzeichnet wird. Damit verschiebt sie das Gewicht zugunsten des Bildes.

```

1 @tool
2 def get_scene_hybrid_guided() -> str:
3     """Perceive the scene using a visual description AND exact structural
4     data. The visual description is authoritative for how objects LOOK
5     (texture, pattern, whether something stands out). The structural data
6     contains ONLY geometry (positions, sizes, base colors) and does NOT
7     encode any visual surface property."""

```

Listing 5: Wahrnehmungswerkzeug der geführten Variante (Priorisierung des Bildes).

Kompetenztrennung

Die kompetenzgetrennte Variante ordnet die Schichten nicht neu, sondern weist ihnen klar getrennte Aufgaben zu. Wie die naive Variante gibt sie den strukturellen Zustand zuerst aus. Der Unterschied liegt in der ausdrücklichen Arbeitsteilung. Die visuelle Beschreibung dient allein dazu, zu bestimmen, welches Objekt gemeint ist, wenn die Referenz vom Aussehen abhängt. Die strukturelle Schicht liefert alles Numerische, also sämtliche Koordinaten, Größen, Abstände und die Kamerageometrie. Der Unterschied zur Priorisierung ist damit nicht allein die Reihenfolge, sondern vor allem die enge, gegenseitig ausschließende Zuweisung der Zuständigkeiten.

Zur Entstehung der kompetenzgetrennten Variante

Diese Variante ist nicht vorab entworfen, sondern iterativ entwickelt worden, und zwar an demselben Szenarioset, an dem sie anschließend berichtet wird. Weil dieser Umstand die Reichweite des Befundes unmittelbar begrenzt, wird er hier offengelegt.

Der Ausgangspunkt war die Beobachtung, dass die naive Kombination den visuellen Zugriff in einem Teil der perzeptuellen Szenarien verliert und die Priorisierung diesen Verlust behebt, dafür aber metrische Aufgaben schwächt. Aus der Analyse dieses Tauschs entstand die Instruktion, die beiden Schichten getrennte Rollen zuzuweisen statt eine von ihnen zu bevorzugen. Die Formulierung der Instruktion wurde dabei in mehreren Schritten geschärft, wobei die Ergebnisse der jeweils vorangegangenen Läufe bekannt waren.

Ein Blick auf Listing 6 macht die Folge sichtbar. Der Prompt nennt mit „striped“ und „most salient“ zwei Wörter, die wörtlich in den Befehlen der perzeptuellen Szenarien D1 und D2 vorkommen. Die Instruktion ist damit sprachlich auf genau jene Testfälle abgestimmt, an denen ihr Vorteil gemessen wird. Der Befund, dass die Kompetenztrennung die beiden Schichten zusammenführt, gilt deshalb für dieses Szenarioset, und seine Übertragung auf ungesehene Formulierungen ist nicht gezeigt. Abschnitt 6.6 führt diesen Punkt als zentrale Grenze, Abschnitt 7.5 nennt die Prüfung, die dafür nötig wäre.

```

1 @tool
2 def get_scene_hybrid_surgical() -> str:
3     """Perceive the scene using a visual description AND exact structural
4     data, with a clear division of labor. Use the VISUAL description ONLY
5     to identify WHICH object is meant when the reference depends on
6     appearance (texture, pattern, 'striped', 'stands out', 'most salient').
7     Use the STRUCTURAL data for EVERYTHING numerical: all coordinates,
8     positions, sizes, distances, camera geometry, and to compute where to
9     move things. Every object id appears in both - match them by id.
10    Never take coordinates from the visual description; never resolve an
11    appearance-based reference from the structural data alone."""

```

Listing 6: Wahrnehmungswerkzeug der kompetenzgetrennten Variante (klare Arbeitsteilung).

Übersicht der Varianten

Tabelle 5.1 fasst zusammen, welche Information die Varianten im Kontext erhalten und nach welcher Regel sie die Schichten gewichten. Die Tabelle nennt zugleich die Kurzbezeichnungen aus dem Code, die in den Ergebnistabellen des Evaluationskapitels als Spaltenköpfe erscheinen. Deutsche Bezeichnung und Kurzbezeichnung meinen durchgängig dasselbe; im Fließtext wird die deutsche verwendet.

Tabelle 5.1: Die fünf Repräsentationsvarianten im Vergleich, mit den in den Ergebnistabellen verwendeten Kurzbezeichnungen.

Variante	Kurzform	Im Kontext	Regel zur Gewichtung
strukturell	json	nur struktureller Zustand	entfällt, keine visuelle Schicht
visuell	vlm	nur visuelle Beschreibung	entfällt, keine strukturelle Schicht
naiv hybrid	hybrid	Struktur, dann Beschreibung	grobe Zuordnung ohne verbindliche Regel
priorisierend	guided	Beschreibung, dann Struktur	Beschreibung maßgeblich fürs Aussehen, Struktur nur Geometrie
kompetenzgetrennt	surgical	Struktur, dann Beschreibung	Beschreibung nur zur Objektwahl, Struktur für alles Numerische

Die Spalte „Im Kontext“ macht eine Nebenwirkung des Entwurfs sichtbar. Die priorisierende Variante unterscheidet sich von den beiden anderen hybriden Varianten nicht nur in ihrer Zuständigkeitsregel, sondern zusätzlich in der Reihenfolge, in der die beiden Schichten im Kontext erscheinen. Instruktion und Reihenfolge sind damit nicht getrennt variiert, sondern konfundiert. Abschnitt 6.6 behandelt diesen Punkt und die daraus folgende Einschränkung von NFA5.

5.5 Der VR-Demonstrator

Die Evaluation lief am Desktop unter kontrollierten Bedingungen. Um zu zeigen, dass der Ansatz auch in der eigentlichen Zielumgebung trägt, überführt ein Demonstrator die gesamte Kette in die immersive Umgebung. Er nutzt die kompetenzgetrennte Variante, also die in Kapitel 6 auf dem untersuchten Szenarioset als am zuverlässigsten ermittelte Repräsentation. Dieser Abschnitt beschreibt die Ergänzungen, die für den Betrieb in der Brille nötig waren.

Vorab ist der Betriebsbegriff zu präzisieren, um ein Missverständnis zu vermeiden. Der Demonstrator ist lokal im Sinne der Definition aus Abschnitt 1.1: alle Modelle sind selbst gehostet, kein Cloud-Dienst ist beteiligt, und keine Szenen- oder Sprachdaten verlassen das Institutsnetz. Er ist ausdrücklich nicht „lokal auf dem Endgerät“. Die Modelle rechnen auf dem Arbeitsplatzrechner, und die Brille erreicht ihn über die unten beschriebene Netzwerkkette.

Sprachsteuerung

Der Nutzer spricht einen Befehl. Ein selbst gehostetes Whisper-Modell in der Größe `small` wandelt die Aufnahme in Text um. Es läuft auf dem lokalen Rechner auf der CPU, nimmt mit 16 kHz auf und ist auf englische Eingaben festgelegt, passend zur Sprache der Befehle. Dieser Text wird in dieselbe Kommando-Warteschlange gegeben, die auch in der Evaluation den Agenten antreibt. Ein gesprochener Befehl durchläuft damit dieselbe Kette wie ein Befehl im Experiment, ergänzt lediglich um die vorgeschaltete Spracherkennung. Abbildung 5.4 zeigt diesen Ablauf.

Zum Nachweisstand dieser Kette ist eine Klarstellung nötig. Die Sprachsteuerung ist umgesetzt und lauffähig, ihr Ablauf ist in Abbildung 5.4 dargestellt. Die als Begleitmaterial beigelegte Videoaufzeichnung dokumentiert jedoch die frühere Ausbaustufe mit Bedienmenü und damit nicht die Spracheingabe. Was das Video belegt, ist die Kette von der Befehlsauswahl über Agent und MCP-Server bis zur sichtbaren Manipulation in der Brille. Die vorgeschaltete Spracherkennung ist dagegen konzeptionell umgesetzt, aber nicht per Aufzeichnung belegt.

Rollentrennung von Renderer und Commander

Über dieselbe Verbindung treten zwei Arten von Clients auf. Die Brille ist der Renderer, der die Manipulationen ausführt und die Szene darstellt. Die Sprachsteuerung ist der Commander, der ausschließlich Befehle einspeist. Eine Anmeldenachricht unterscheidet beide Rollen, damit die Befehlsquelle die Verbindung der Brille nicht verdrängt.

Wahrnehmung in der Brille

Die visuelle Wahrnehmung setzt ein gerendertes Bild der Szene voraus. In der Brille rendert die Hauptkamera jedoch stereoskopisch für beide Augen, was kein brauchbares flaches Bild liefert. Eine dedizierte Aufnahmekamera löst das Problem. Sie folgt der Kopfpose, rendert aber einfach statt stereoskopisch und liefert so das Bild, das das visuelle Modell benötigt.

Netzwerkkette

Die Modelle laufen aus Ressourcengründen auf dem Arbeitsplatzrechner im Institutsnetz, den die Brille nicht direkt erreicht. Die Brille verbindet sich deshalb mit einem Vermittler auf einem Rechner

im selben Funknetz, der die Nachrichten über ein virtuelles privates Netz an den Arbeitsplatzrechner weiterleitet. Ein mobiler Zugangspunkt umgeht dabei die Isolation gemeinsam genutzter Netze, die eine direkte Verbindung sonst unterbindet. Diese Kette ist reine Demonstrationsinfrastruktur und nicht Gegenstand der Untersuchung. Sie erklärt zugleich, weshalb „lokal“ hier selbst gehostet und nicht gerätenah bedeutet: Die Rechenlast liegt bewusst nicht auf der Brille, wohl aber vollständig innerhalb eigener Infrastruktur.

Ablauf und Rückmeldung

Sobald ein Befehl in die Warteschlange gelangt, arbeitet ein Worker den Agentenlauf ab und meldet der Brille den Beginn und den Abschluss der Verarbeitung. Die Brille zeigt diesen Status an, sodass für den Nutzer erkennbar ist, dass ein Befehl gerade bearbeitet wird. Ein früher erprobtes Bedienmenü in der Szene wurde später um die Sprachsteuerung ergänzt, nutzte aber bereits dieselbe Kommando-Warteschlange. Abbildung 5.5 zeigt diese frühe Ausbaustufe im Betrieb, aufgenommen aus der Sicht der Brille. Die Szene enthält drei Objekte, einen roten Würfel links, einen gestreiften Würfel in der Mitte und eine blaue Kugel rechts. Der gestreifte Würfel wird in diesem Standbild von der Menütafel weitgehend verdeckt; sichtbar bleibt nur sein unterer Teil unterhalb der Schaltflächen. In der Aufzeichnung werden die vordefinierten Befehle nacheinander ausgelöst, und die zugehörigen Manipulationen sind jeweils unmittelbar in der Szene sichtbar. Der gestreifte Würfel hebt sich an, die blaue Kugel wandert nach links neben den roten Würfel, und der gestreifte Würfel wird schließlich entfernt. Das Video belegt damit die Kette von der Befehlsauswahl bis zur ausgeführten Manipulation in der immersiven Umgebung. Es belegt nicht die Spracheingabe, die erst in der späteren Ausbaustufe hinzukam und nicht aufgezeichnet wurde.




Abbildung 5.4: Ablauf eines gesprochenen Befehls im Demonstrator. Der lokale Rechner erkennt die Sprache und leitet den Text als Commander-Nachricht weiter, der entfernte Rechner arbeitet den Agentenlauf ab, und die Brille führt die Manipulation aus und zeigt den Verarbeitungsstatus an.




Abbildung 5.5: Eine frühe Ausbaustufe des Demonstrators in Betrieb. In dieser Fassung werden die Befehle nicht gesprochen, sondern über ein Menü in der Szene ausgewählt, das vordefinierte Anweisungen bereitstellt. Links steht der rote Würfel, rechts die blaue Kugel; der gestreifte Würfel steht in der Mitte und wird von der Menütafel weitgehend verdeckt, sodass nur sein unterer Teil sichtbar bleibt. Das Standbild stammt aus einer Aufzeichnung, in der auf diese Weise unter anderem „move the striped cube up“, „put the blue sphere left of the red cube“ und „delete the striped cube“ ausgelöst werden. Die vollständige Aufzeichnung ist als Begleitmaterial in Anhang A.1 verlinkt. Sie dokumentiert die Menüfassung und nicht die später ergänzte Sprachsteuerung.

Kapitel 6

Evaluation

Das vorige Kapitel hat beschrieben, wie das System eine Szene aufnimmt, an den Agenten übergibt und dessen Befehle ausführt. Offen ist damit die eigentliche Frage dieser Arbeit. Welchen Einfluss hat die Form, in der die Szene bereitgestellt wird, auf den Erfolg der Manipulation? Dieses Kapitel beantwortet sie in zwei Schritten. Zunächst vergleicht es die Repräsentationsformen entlang einer nach Referenztypen aufgeschlüsselten Taxonomie und bestimmt, welche Form welche Art von Referenz trägt (RQ1). Anschließend prüft es, ob sich die hybride Repräsentation allein durch die Gestaltung ihrer Instruktion so verbessern lässt, dass sie die Stärken beider Schichten vereint (RQ2). Den Abschluss bildet eine kritische Betrachtung der Validität und der Grenzen dieser Ergebnisse.

6.1 Evaluationsdesign

Die Evaluation prüft, welchen Einfluss die Repräsentationsform auf den Erfolg der Szenenmanipulation hat. Ein solcher Vergleich ist nur aussagekräftig, wenn die Repräsentation der einzige Faktor bleibt, der zwischen den Varianten variiert. Drei Entwurfsentscheidungen stellen das sicher.

Gegenstand des Vergleichs

Verglichen werden fünf Varianten, die dieselbe Szene, dieselben Befehle und dieselben Manipulationswerkzeuge nutzen. Sie unterscheiden sich allein darin, in welcher Form die Szene dem Agenten bereitgestellt wird. Die strukturelle Variante übergibt die Szene als exakte Laufzeitdaten der Engine. Die visuelle Variante übergibt eine gerenderte Ansicht, deren Objekte mit Markern versehen sind. Die naive hybride Variante stellt beide Schichten ohne weitere Anweisung nebeneinander. Die geführte und die kompetenzgetrennte Variante ergänzen die hybride Repräsentation um eine Instruktion zur Zuständigkeit der beiden Schichten. Der genaue Aufbau der Varianten, einschließlich der Zuordnung ihrer deutschen Bezeichnungen zu den in den Ergebnistabellen verwendeten Kurzformen, ist in Abschnitt 5.4 beschrieben.

Für die Deutung aller folgenden Ergebnisse ist dabei eine Eigenschaft des Aufbaus im Blick zu behalten. Das Sprachmodell, das die Operation wählt, erhält in keiner Variante ein Bild, sondern im visuellen Fall eine vom Sprach-Bild-Modell erzeugte Beschreibung des Bildes (Abschnitt 2.1). Verglichen werden damit streng genommen nicht Bild und Daten, sondern eine exakte Datenstruktur und eine unscharfe sprachliche Beschreibung derselben Szene.

Ein gemeinsames Interface für alle Varianten

Alle Varianten sprechen Objekte über dasselbe Kennungssystem an, und die visuelle Variante bindet ihre Bildmarken an dieselben Kennungen. Ohne diese Maßnahme wäre die visuelle Variante nicht wegen

ihrer Repräsentation im Nachteil, sondern wegen eines fehlenden Werkzeugzugriffs; Abschnitt 4.3 führt diese Entwurfsentscheidung und ihre Begründung aus. Gemessene Unterschiede gehen damit auf die Repräsentation zurück und nicht auf einen ungleichen Zugriff.

Grundlage der Erfolgsmessung

Der Erfolg jeder Manipulation wird aus dem tatsächlichen Zustand der Szene nach der Ausführung bestimmt. Nach jedem Befehl liest die Auswertung den Folgezustand aus und vergleicht ihn mit der für das Szenario definierten Soll-Vorgabe. Die Selbstauskunft des Agenten bleibt dabei unberücksichtigt. Diese Entscheidung hat einen konkreten Grund, der in Abschnitt 6.6 ausgeführt wird: Das lokale Modell meldet wiederholt einen Erfolg, den der Folgezustand nicht bestätigt. Die Messung aus dem Folgezustand ist gegen dieses Verhalten robust.

Zahl der Wiederholungen

Jede Kombination aus Szenario und Variante wird zehnmal ausgeführt. Der gesamte Durchlauf wird dreimal wiederholt, sodass jede Zelle auf 30 Läufen beruht. Berichtet wird der Mittelwert über die drei Durchläufe zusammen mit der Spanne von Minimum und Maximum. Eine einzelne Messung eines stochastisch antwortenden Modells wäre nur eine Momentaufnahme. Die Wiederholung mit ausgewiesener Spanne zeigt, wie stark eine Zelle zwischen den Durchläufen schwankt. Für die Absicherung der zentralen Vergleiche werden die 30 Läufe einer Zelle zusätzlich zusammengefasst und inferenzstatistisch ausgewertet, wie Abschnitt 6.3 beschreibt.

Ausgewertet werden dreizehn Szenarien in fünf Kategorien. Die Kategorien sind dabei unterschiedlich stark besetzt: drei Szenarien in den Kategorien A, B und C, aber nur je zwei in den Kategorien D und E. Gerade die beiden zuletzt genannten tragen die inhaltlich zentralen Befunde, sodass diese auf einer schmalen Basis von je zwei Aufgaben beruhen. Abschnitt 6.6 greift das als Grenze auf.

Aufbau der Messumgebung

Die Szenen bestehen aus einfachen geometrischen Grundkörpern und werden kontrolliert aufgebaut, damit jedes Szenario genau eine Repräsentationskompetenz prüft. Als Sprachmodell dient ein selbst gehostetes Qwen2.5-7B, als visuelles Modell ein Qwen2.5-VL-7B. Beide laufen gemeinsam auf einer NVIDIA RTX A5000 mit 24 Gigabyte Grafkspeicher. Die Messung selbst erfolgt am Desktop, während die immersive Umgebung die Zielumgebung des Demonstrators bildet. Der Grund für diese Trennung liegt in der Reproduzierbarkeit: Am Desktop lassen sich die Szenen exakt kontrollieren und beliebig oft identisch wiederholen.

Konfiguration und Reproduzierbarkeit

Anforderung NFA3 verlangt, dass sich die Messung unter identischer Konfiguration wiederholen lässt. Dazu gehört, diese Konfiguration vollständig anzugeben. Tabelle 6.1 führt die dafür nötigen Angaben auf.

Die Tabelle beschränkt sich auf Angaben, die den Ausgang der Läufe beeinflussen. Die Erfolgstoleranz ist in Abschnitt 6.3 festgelegt, die Spracherkennung des Demonstrators in Abschnitt 5.5 beschrieben; beide gehören nicht zur Messkonfiguration.

Zwei Angaben verdienen einen Kommentar.

Beide Modelle liegen in derselben Quantisierungsstufe vor. Das ist für den Vergleich nicht unerheblich: Eine unterschiedlich starke Quantisierung hätte die beiden Schichten ungleich beeinträchtigt und damit eine weitere Störgröße neben der Repräsentationsform eingeführt. Mit 4,68 GB und 6,04 GB belegen die Gewichte zusammen rund 10,7 GB und lassen auf der verwendeten Karte Raum für den Schlüssel-Wert-Zwischenspeicher beider Modelle, was den gleichzeitigen Betrieb erst ermöglicht und Anforderung NFA2 erfüllt.

Tabelle 6.1: Konfiguration der Messung, beschränkt auf die Angaben, die den Ausgang der Läufe beeinflussen. Zusammen mit dem verlinkten Code genügen sie, um die Messung zu wiederholen.

Größe	Wert
Sprachmodell	<code>qwen2.5-7b-instruct</code> , GGUF Q4_K_M, 4096 Token Kontext
Visuelles Modell	<code>qwen/qwen2.5-vl-7b</code> , GGUF Q4_K_M, 4096 Token Kontext
Hardware, Laufzeit	NVIDIA RTX A5000 mit 24 GB, LM Studio (CLI-Commit <code>efce996</code>), beide Modelle gleichzeitig geladen
Agent	<code>smolagents 1.26.0 (ToolCallingAgent)</code> unter Python 3.13, <code>max_steps = 6</code>
Dekodierung	Sprachmodell: Temperatur 0,8 (Voreinstellung der Laufzeitumgebung, im Client nicht überschrieben). Visuelles Modell: Temperatur 0,1 (im Client ausdrücklich gesetzt). Kein fester Seed
Messumfang	13 Szenarien $\times$ 5 Varianten, je 10 Läufe in 3 Durchläufen, also 30 Läufe pro Zelle
Code und Rohdaten	https://git.informatik.fh-nuernberg.de/jobboerse/forschung/bachelorarbeiten/bachelorarbeit-sandro-jaeger

Die Kontextlänge von 4096 Token ist demgegenüber knapp bemessen, und sie trifft die Varianten ungleich. Die strukturelle Variante trägt nur den JSON-Zustand im Kontext, die visuelle nur die erzeugte Beschreibung, die drei hybriden Varianten dagegen beides zugleich, jeweils zusätzlich zu Grundinstruktion, Werkzeugbeschreibungen und dem bisherigen Verlauf der Agentenschleife. Der verfügbare Rest für mehrere aufeinanderfolgende Schritte fällt bei den hybriden Varianten damit systematisch kleiner aus. Ob dieser Unterschied in den Messungen wirksam wurde, etwa durch Abschneiden des Kontexts in längeren Läufen, wurde nicht überwacht und lässt sich nachträglich nicht mehr feststellen. Abschnitt 6.6 führt diesen Punkt als Grenze.

Die beiden Modelle wurden dabei unterschiedlich dekodiert, was für die Deutung der Streuung wesentlich ist.

Das Sprachmodell, das die eigentliche Entscheidung trifft, lief mit einer Temperatur von 0,8. Das ist keine nahezu deterministische Einstellung, sondern eine, die den Antwortraum spürbar öffnet. Die zehn Läufe einer Zelle sind damit weitgehend unabhängige Ziehungen aus einer breiten Verteilung und nicht wiederholte Ziehungen derselben Antwort.

Dieser Umstand verstärkt die Aussagekraft der Ergebnisse, statt sie zu schwächen. Eine Zelle, die bei 0 von 30 oder bei 30 von 30 liegt, erreicht diesen Wert nicht, weil das Modell ohnehin immer dasselbe antwortet, sondern trotz erheblichen Spielraums in der Dekodierung. Die vielen Zellen ohne jede Streuung sind unter dieser Bedingung ein Befund und kein Artefakt einer zu eng gewählten Temperatur. Sie zeigen, dass der jeweilige Effekt stärker wirkt als das Rauschen, das eine Temperatur von 0,8 erzeugt.

Das visuelle Modell wurde demgegenüber mit einer Temperatur von 0,1 betrieben und arbeitet damit nahezu deterministisch. Die aus einer gegebenen Szene erzeugte Beschreibung fällt über die Läufe hinweg weitgehend gleich aus. Für die Wahrnehmungsstufe ist das erwünscht, da sie als Eingabe und nicht als Untersuchungsgegenstand dient: Eine stark schwankende Szenenbeschreibung hätte eine zusätzliche Störgröße zwischen die Repräsentationsform und das Ergebnis geschoben. Die verbleibende Streuung einer Zelle geht damit fast vollständig auf das Sprachmodell zurück, also auf die Stufe, die verglichen wird.

Für die in Abschnitt 6.3 berichteten Konfidenzintervalle folgt daraus, dass ihre Annahme von 30 unabhängigen Beobachtungen im Wesentlichen zutrifft. Eine Restabhängigkeit bleibt, da alle Läufe einer Zelle dieselbe, nahezu unveränderliche Szenenbeschreibung verwenden; sie betrifft jedoch die

Eingabe und nicht die gemessene Entscheidung.

6.2 Referenztyp-Taxonomie

Warum die Frage nach der besten Repräsentation zu kurz greift

Ob eine strukturelle oder eine visuelle Repräsentation die bessere ist, lässt sich nicht pauschal beantworten. Die Frage in dieser Form führt sogar in die Irre, weil sie eine einzige Antwort verlangt, wo keine existiert. Welche Repräsentation trägt, hängt davon ab, worauf sich ein Befehl bezieht. Ein Verweis auf die Farbe eines Objekts stellt andere Anforderungen als ein Verweis auf seine Lage oder auf ein Objekt, das im Bild gar nicht zu sehen ist. Statt nach der allgemein besten Repräsentation zu fragen, zerlegt diese Arbeit die natürlichsprachliche Referenz in Typen und prüft für jeden Typ einzeln, welche Repräsentation ihn auflösen kann.

Grundlage ist eine Taxonomie aus fünf Referenztypen. Tabelle 6.2 fasst sie zusammen und zeigt, in welcher Schicht die zur Auflösung nötige Information jeweils verfügbar ist. Kategorie A bildet die Kontrollbedingung. Der Befehl benennt das Zielobjekt direkt über seine Kennung, sodass die Aufgabe unabhängig von der Repräsentationsform lösbar ist. Sie dient damit als Prüfstein für den Messaufbau und nicht als inhaltlicher Vergleich. Kategorie B spricht ein Objekt über ein Attribut an, etwa seine Farbe oder seine Größe. Kategorie C bezieht sich auf eine räumliche Relation zwischen Objekten, etwa die Lage links von einem anderen Objekt. Beide Typen setzen voraus, dass sich das gemeinte Objekt aus Eigenschaften oder Koordinaten bestimmen lässt, die in den strukturellen Daten stehen.

Die beiden letzten Kategorien bilden das eigentliche Gegensatzpaar. Kategorie D bezieht sich auf eine rein perzeptuelle Eigenschaft, etwa ein Oberflächenmuster, das in den strukturellen Daten nicht vorkommt. Ein solches Objekt lässt sich nur über das Bild bestimmen. Kategorie E bezieht sich auf ein Objekt, das im Bild verdeckt und damit unsichtbar ist, in den strukturellen Daten aber vollständig verzeichnet bleibt. Ein solches Objekt lässt sich nur über die Struktur bestimmen. D und E markieren damit die beiden Pole, an denen jeweils nur eine der beiden Schichten Zugang zur Antwort hat. Dieses symmetrische Paar macht sichtbar, ob eine Repräsentation eine Kompetenz besitzt, die der anderen grundsätzlich fehlt.

Die Unterscheidung nach Referenztypen knüpft an bestehende Arbeiten an, die Referenzen etwa nach ihrer Abhängigkeit vom Blickwinkel oder nach der Eindeutigkeit des Zielobjekts einteilen [6, 7]. Über diese Einteilungen hinaus führt die vorliegende Taxonomie die rein perzeptuelle und die verdeckte Referenz als eigene Typen ein. Beide sind notwendig, um die exklusiven Zuständigkeiten der beiden Repräsentationen überhaupt prüfen zu können.

Die konkreten Szenarien, mit denen jeder Referenztyp gemessen wird, führt Tabelle 6.3 auf. Jedes Szenario ist so aufgebaut, dass es genau eine Kompetenz isoliert und andere Einflussfaktoren möglichst ausschließt.

Tabelle 6.2: Verfügbarkeit der zur Auflösung nötigen Information je Referenztyp und Schicht, nach Konstruktion der Szenarien. Die Zeilen D und E bilden das exklusive Gegensatzpaar.

Referenztyp	In der strukturellen Schicht	In der visuellen Schicht
A — direkt	Kennung und Zielkoordinaten vorhanden	markiertes Objekt sichtbar
B — Attribut	Attribute wie Farbe und Größe vorhanden	Aussehen sichtbar
C — relational	exakte Koordinaten vorhanden	Anordnung sichtbar
D — perzeptuell	nicht enthalten	Muster sichtbar
E — verdeckt	vollständig verzeichnet	verdeckt, nicht sichtbar

Tabelle 6.3: Übersicht aller ausgewerteten Szenarien mit Befehl, Ausgangsszene und Soll-Ergebnis. Die Befehle geben den real gesendeten englischen Stimulus wieder.

ID	Befehl	Ausgangsszene	Soll-Ergebnis
<i>Kategorie A — direkt / id-basiert</i>			
A1	„Spawn a red cube at x=2, y=0, z=1.“	leere Szene	roter Würfel bei (2,0,1) vorhanden
A2	„Move obj_2 to position (0, 1, 0).“	rot (0,0,0), grün (2,0,0), blau (4,0,0)	grüner Würfel (obj_2) bei (0,1,0)
A3	„Delete obj_1.“	wie A2	roter Würfel (obj_1) entfernt
<i>Kategorie B — Attribut-Referenz</i>			
B1	„Raise the red cube by 1 unit.“	rot (1,0,0), blau (3,0,0)	roter Würfel in der Höhe +1
B2	„Delete all red cubes.“	rot (0,0,0), rot (2,0,0), grüne Kugel (4,0,0)	beide roten Würfel entfernt, Kugel bleibt
B3	„Move the largest object to (0, 0, 0).“	roter Würfel Größe 0,5 (-2,0,0); grüner Größe 1,5 (0,0,3); blauer Größe 1,0 (3,0,0)	größtes Objekt (grün) bei (0,0,0)
<i>Kategorie C — räumlich-relational</i>			
C1	„Move the sphere to the left of the cube.“	blaue Kugel (1,0,0), grüner Würfel (-1,0,0)	Kugel links vom Würfel
C2 ^a	„Raise the cube nearest to the camera by 1.“	rot (-2,0,2), grün (0,0,5), blau (2,0,8)	kamera-nächster Würfel in der Höhe +1
C4	„Place the sphere exactly 2 units left of the cube.“	grüner Würfel (1,0,0), blaue Kugel (4,0,0)	Kugel bei x=-1 (genau 2 links)
<i>Kategorie D — rein perzeptuell</i>			
D1	„Raise the striped cube by 1 unit.“	zwei graue Würfel (-1,0,3) und (1,0,3); zweiter gestreift	gestreifter Würfel +1, anderer unverändert
D2	„Move the most salient object to (0, 0, 0).“	vier graue Würfel (-3/-1/3/5, 0, 4); ein gestreifter (1,0,4)	gestreifter (auffälliger) Würfel bei (0,0,0)
<i>Kategorie E — verdeckt</i>			
E1	„Raise the green cube by 1 unit.“	rot (-3,0,5); graue Wand Größe 4,0 (2,0,2); grün (2,0,6) dahinter verdeckt	verdeckter grüner Würfel +1
E2	„Raise every cube by 1 unit.“	wie E1	alle drei Würfel in der Höhe +1

Positionen als (x, y, z), wobei y die Höhe angibt. „Größe“ ist die relative Kantenlänge (Standard 1,0).

^a C2 mit seitlich versetztem Aufbau. Der ursprünglich achsenkollineare Aufbau wurde ersetzt (Abschnitt 6.6). Szenario C3 wurde aus methodischen Gründen ausgeschlossen (ebenda).

6.3 Metriken

Ausführungserfolg als primäre Kennzahl

Die verwendeten Erfolgs- und Genauigkeitsmaße orientieren sich an etablierten Metriken aus der Literatur zum sprachlichen Auffinden von Objekten in 3D-Szenen [7, 6]. Als primäre Kennzahl berichtet diese Arbeit den Ausführungserfolg. Er ist je Lauf binär und ergibt sich allein aus dem Folgezustand der Szene, den die Auswertung nach der Manipulation mit der Soll-Vorgabe des Szenarios vergleicht. Ein Lauf gilt genau dann als Erfolg, wenn der Folgezustand die Vorgabe erfüllt. Berichtet wird die Zahl der Erfolge aus zehn Läufen, gemittelt über die drei Durchläufe mit der zugehörigen Spanne. Diese Wahl schließt an die in Abschnitt 6.1 begründete Messung aus dem Folgezustand an und macht die Kennzahl unabhängig von der Selbstauskunft des Agenten.

Szenariospezifische Erfolgskriterien

Was als erfüllte Vorgabe zählt, hängt vom Aufgabentyp ab. Bei jeder Aufgabe muss zunächst das richtige Objekt betroffen sein. Wird ein anderes als das gemeinte Objekt verändert, gilt der Lauf als Misserfolg, auch wenn die Zielkoordinate ansonsten getroffen wäre. Dieses Kriterium erfasst die korrekte Auflösung der Referenz. Bei Aufgaben mit einer Zielposition muss die erreichte Position innerhalb einer festen Toleranz τ um den Sollwert liegen. Bei relationalen Aufgaben muss die geforderte Lagebeziehung im Folgezustand gelten, etwa dass ein Objekt einen kleineren x-Wert besitzt als ein anderes. Bei Aufgaben, die ein Objekt entfernen oder erzeugen, muss das Objekt im Folgezustand fehlen oder vorhanden sein. Ein Lauf zählt nur dann als Erfolg, wenn das jeweils maßgebliche Kriterium vollständig erfüllt ist.

Die Toleranz ist auf $\tau = 0,1$ Einheiten gesetzt. Der Wert ist nicht aus einer externen Vorgabe übernommen, sondern für diesen Aufbau festgelegt worden, und zwar an zwei Größen orientiert. Er liegt deutlich unter der kleinsten in den Szenarien geforderten Verschiebung von einer Einheit, sodass eine Zielposition nicht schon durch eine grob danebenliegende Bewegung als getroffen gilt. Zugleich liegt er über der Genauigkeit, mit der die Engine Positionen zurückmeldet, sodass numerisches Rauschen keinen korrekten Lauf verwirft. Ein Zehntel der kleinsten geforderten Distanz erfüllt beide Bedingungen. Eine Untersuchung, wie empfindlich die Ergebnisse auf diese Wahl reagieren, wurde nicht durchgeführt; Abschnitt 6.6 führt das als Grenze.

Was nicht gemessen wird

Ein kontinuierlicher Lagefehler, also der Abstand zwischen erreichter und geforderter Position als eigene Kennzahl, wird in dieser Arbeit nicht berichtet. Die Toleranz τ geht ausschließlich als Schwelle in das binäre Erfolgskriterium ein. Die Zielgröße der Arbeit ist damit allein der Ausführungserfolg, der die Korrektheit der Referenzauflösung und das Eintreten des geforderten Ergebnisses zusammenfasst; Abschnitt 1.3 formuliert RQ1 entsprechend.

Eine nachträgliche Berechnung dieses Lagefehlers ist nicht möglich. Für die beiden metrischen Szenarien C2 und C4, in denen er am aufschlussreichsten wäre, liegen die erreichten Endpositionen nicht mehr vor. Das ist insofern bedauerlich, als gerade dort alle Varianten am binären Kriterium scheitern: Ein kleiner mittlerer Lagefehler hieße, dass die Varianten knapp danebenliegen, ein großer, dass sie die Aufgabe grundsätzlich verfehlen. Zwischen diesen beiden Deutungen kann diese Arbeit nicht entscheiden. Abschnitt 6.6 führt den Punkt als Grenze, Abschnitt 7.5 als naheliegende Ergänzung einer künftigen Messung.

Statistische Auswertung der zentralen Vergleiche

Der Mittelwert über drei Durchläufe mit Spanne beschreibt, wie stabil eine Zelle zwischen den Durchläufen ist, trägt aber als Entscheidungsgrundlage nur begrenzt. Drei Durchläufe sind eine schmale Basis, und ein Kriterium, das nicht-überlappende Spannen als belastbar wertet, ist eine Heuristik

ohne Fehlerkontrolle. Für die inhaltlich zentralen Vergleiche werden deshalb zusätzlich die je 30 Einzelläufe einer Zelle zusammengefasst und regulär inferenzstatistisch ausgewertet.

Da jeder Lauf binär ausgeht, ist eine Zelle durch die Zahl k der Erfolge aus $n = 30$ Läufen vollständig beschrieben. Für jede Zelle wird die Erfolgsrate als Anteil k/n mit einem Wilson-Konfidenzintervall zum Niveau 95 % angegeben. Das Wilson-Intervall ist dem gewöhnlichen Normalapproximationsintervall hier vorzuziehen, weil viele Zellen an den Rändern liegen, also bei null oder bei allen Erfolgen, wo die Normalapproximation ein Intervall der Breite null liefern würde. Für den Vergleich zweier Zellen wird der exakte Test nach Fisher auf der zugehörigen Vierfeldertafel gerechnet, der keine Annahmen über erwartete Zellhäufigkeiten voraussetzt und auch bei extremen Anteilen gültig bleibt.

Die Annahme unabhängiger Läufe ist dabei vertretbar, da das Sprachmodell mit einer Temperatur von 0,8 dekodiert wurde und seine Antworten entsprechend streuen können. Eine Restabhängigkeit besteht darin, dass alle Läufe einer Zelle dieselbe, nahezu deterministisch erzeugte Szenenbeschreibung verwenden; sie betrifft die Eingabe und nicht die gemessene Entscheidung. Mitzudenken ist ferner, dass mehrere Vergleiche gerechnet werden, ohne das Niveau für multiples Testen zu korrigieren. Die berichteten zentralen Unterschiede sind allerdings so groß, dass keiner von ihnen an einer Entscheidungsgrenze hängt.

6.4 Ergebnisse: Einfluss der Repräsentationsform (RQ1)

Die Ergebnisse berichtet diese Arbeit je Szenario und Kategorie als Mittelwert über drei Durchläufe mit der Spanne [Minimum–Maximum]. In der Szenariotabelle steht jede Zelle für zehn mögliche Erfolge (Tabelle 6.4). Die Kategorietabelle fasst diese Werte je Kategorie zusammen (Tabelle 6.5).

Kategorie A: Prüfung des Messaufbaus

Bevor sich die Unterschiede zwischen den Repräsentationen deuten lassen, muss geklärt sein, ob der Aufbau überhaupt das misst, was er messen soll. Kategorie A dient dieser Prüfung. Hier benennt der Befehl das Zielobjekt direkt über seine *id* und die Zielkoordinaten. Die Aufgabe verlangt keine Deutung der Szene, gleich in welcher Form diese repräsentiert ist. Ist der Messaufbau sauber, darf die Repräsentationsform hier keinen Unterschied machen. Das bestätigt sich: Alle fünf Varianten lösen jedes der drei Szenarien in jedem der 30 Läufe. Das gemeinsame *id*-Substrat und der Werkzeugzugriff erzeugen also von sich aus keine variantenspezifischen Unterschiede. Abweichungen in den folgenden Kategorien gehen damit auf die Repräsentationsform zurück, soweit nicht die in Abschnitt 6.6 benannten Restkonfundierungen greifen.

Tabelle 6.6 fasst die inhaltlich tragenden Zellen als absolute Erfolgszahlen aus je 30 Läufen zusammen und gibt die zugehörigen Wilson-Konfidenzintervalle an. Tabelle 6.7 berichtet die exakten Tests nach Fisher für die Vergleiche, auf denen die Argumentation dieses und des folgenden Abschnitts beruht. Beide Tabellen enthalten keine neuen Messungen, sondern fassen die bereits berichteten Läufe anders zusammen.

Kategorie B: Attribut-Referenzen

In Kategorie B spricht der Befehl ein Objekt über eine Eigenschaft an, etwa über seine Farbe oder seine Größe. Die strukturelle Variante, die naive hybride Variante und beide instruierten hybriden Varianten lösen jedes Szenario vollständig, 30 von 30. Die visuelle Variante erreicht nur 19,7 von 30. Fast der gesamte Rückstand entsteht in einem einzigen Szenario. Die geringe Abweichung in B2 (9,7 von 10) liegt innerhalb der beobachteten Streuung und trägt keinen eigenen Befund.

Der Einbruch zeigt sich in B3, wo der Agent das größte Objekt bewegen soll. Hier scheitert die visuelle Variante in jedem Durchlauf, 0 von 30 Läufen gegenüber 30 von 30 aller übrigen Varianten ($p = 1,7 \cdot 10^{-17}$, Tabelle 6.7). Das Ergebnis ist damit eindeutig; seine Ursache ist es nicht.

Tabelle 6.4: Erfolg je Szenario und Variante: Mittelwert [Min–Max] über drei Durchläufe (je $N = 10$).

Kat.	Szen.	json	vlm	hybrid	guided	surgical
A	A1	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
A	A2	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
A	A3	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
B	B1	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
B	B2	10,0 [10–10]	9,7 [9–10]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
B	B3	10,0 [10–10]	0,0 [0–0]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
C	C1	10,0 [10–10]	1,7 [0–3]	8,3 [7–10]	10,0 [10–10]	10,0 [10–10]
C	C2 ⁽¹⁾	0,0 [0–0]	0,0 [0–0]	0,3 [0–1]	2,7 [1–4]	2,0 [1–3]
C	C4	1,7 [0–4]	0,7 [0–2]	3,3 [3–4]	1,3 [1–2]	2,0 [1–3]
D	D1	0,0 [0–0]	10,0 [10–10]	0,7 [0–1]	8,3 [6–10]	9,7 [9–10]
D	D2	0,3 [0–1]	10,0 [10–10]	10,0 [10–10]	7,3 [6–9]	10,0 [10–10]
E	E1	10,0 [10–10]	0,0 [0–0]	10,0 [10–10]	10,0 [10–10]	10,0 [10–10]
E	E2 ⁽²⁾	10,0 [10–10]	0,0 [0–0]	0,3 [0–1]	0,0 [0–0]	0,0 [0–0]

Spaltenköpfe sind die Kurzformen der Varianten nach Tabelle 5.1: **json** strukturell, **vlm** visuell, **hybrid** naiv hybrid, **guided** priorisierend, **surgical** kompetenzgetrennt.

⁽¹⁾ C2 wurde nach Entdeckung eines Störfaktors mit seitlich versetztem Aufbau neu gemessen; die Werte stammen aus dieser zweiten Messung und sind nicht mit den übrigen Zeilen im selben Durchlauf erhoben (Abschnitt 6.6).

⁽²⁾ E2 ist kein reiner Verdeckungstest. Das Soll-Ergebnis verlangt die Manipulation mehrerer Objekte und damit mehr als einen Manipulationsaufruf, was der Grundinstruktion widerspricht (Abschnitt 6.6). Die Zeile wird deshalb nicht als Repräsentationsbefund gewertet.

Tabelle 6.5: Erfolg je Kategorie als Summe der zugehörigen Szenario-Mittelwerte über drei Durchläufe. Eine Spanne wird hier nicht ausgewiesen, da sich Minimum und Maximum einer Kategorie nicht aus den Szenario-Spannen zusammensetzen lassen. Kategorie E getrennt ausgewiesen.

Kat.	max	json	vlm	hybrid	guided	surgical
A	30	30,0	30,0	30,0	30,0	30,0
B	30	30,0	19,7	30,0	30,0	30,0
C	30	11,7	2,4	11,9	14,0	14,0
D	20	0,3	20,0	10,7	15,6	19,7
E1	10	10,0	0,0	10,0	10,0	10,0
E2	10	10,0	0,0	0,3	0,0	0,0

Naheliegender wäre eine perspektivische Erklärung: Wie groß ein Objekt im gerenderten Bild erscheint, hängt nicht allein von seiner Größe ab, sondern auch von seiner Entfernung zur Kamera, sodass ein weiter hinten stehendes Objekt kleiner wirken kann, als es ist. Diese Erklärung ist hier jedoch nicht nötig, und sie träge auch nicht den Kern.

Die Ursache liegt in der Architektur der Pipeline und lässt sich am Aufbau selbst ablesen. Das entscheidende Sprachmodell sieht kein Bild, sondern die vom visuellen Modell erzeugte Beschreibung (Abschnitt 2.1). Welche Eigenschaften diese Beschreibung enthält, legt der Wahrnehmungs-Prompt fest, und dieser fordert genau fünf Angaben je Objekt an: Nummer, Form, Farbe, qualitative Lage und einen Texturdeskriptor (Listing 3). Eine Größenangabe ist darunter nicht.

Der visuellen Variante fehlt in B3 also nicht die Wahrnehmungsfähigkeit, sondern schlicht die Information. Sie soll das größte Objekt bestimmen, erhält aber eine Beschreibung, die über Größen nichts aussagt. Ein vollständiges Scheitern ist unter dieser Bedingung kein überraschender Befund, sondern der zu erwartende. Das Ergebnis ist damit erklärt, aber es ist eine Aussage über den Zuschnitt des Wahrnehmungs-Prompts und nicht über eine grundsätzliche Grenze visueller Repräsentationen. Ein Prompt, der auch die Objektgröße abfragt, hätte hier vermutlich anders abgeschnitten; geprüft wurde das nicht. Abschnitt 6.6 führt diesen Punkt als Grenze.

Festhalten lässt sich unabhängig von der Ursache, dass eine Referenz auf die absolute Größe über

Tabelle 6.6: Zentrale Zellen als Erfolge aus $n = 30$ Läufen mit Wilson-95 %-Konfidenzintervall der Erfolgsrate.

Szen.	Variante	Erfolge	Wilson-95 %-KI
D1	strukturell	0/30	[0,0 %; 11,4 %]
D1	visuell	30/30	[88,6 %; 100,0 %]
D1	naiv hybrid	2/30	[1,8 %; 21,3 %]
D1	priorisierend	25/30	[66,4 %; 92,7 %]
D1	kompetenzgetrennt	29/30	[83,3 %; 99,4 %]
D2	strukturell	1/30	[0,6 %; 16,7 %]
D2	visuell	30/30	[88,6 %; 100,0 %]
D2	naiv hybrid	30/30	[88,6 %; 100,0 %]
D2	priorisierend	22/30	[55,6 %; 85,8 %]
D2	kompetenzgetrennt	30/30	[88,6 %; 100,0 %]
E1	strukturell	30/30	[88,6 %; 100,0 %]
E1	visuell	0/30	[0,0 %; 11,4 %]
B3	visuell	0/30	[0,0 %; 11,4 %]
C1	visuell	5/30	[7,3 %; 33,6 %]
C2	strukturell	0/30	[0,0 %; 11,4 %]
C2	priorisierend	8/30	[14,2 %; 44,4 %]
C4	strukturell	5/30	[7,3 %; 33,6 %]
C4	naiv hybrid	10/30	[19,2 %; 51,2 %]

die strukturelle Schicht zuverlässig aufgelöst wird und über die visuelle Schicht in diesem Aufbau gar nicht. Struktur und visuelle Beschreibung sind damit nicht austauschbar, sondern für unterschiedliche Arten von Referenzen zuständig.

Kategorie C: Räumlich-relationale Referenzen

Kategorie C prüft räumlich-relationale Referenzen, bei denen ein Objekt in Bezug auf ein anderes platziert oder ausgewählt wird. Über die Kategorie hinweg zeigt sich zunächst ein vertrautes Bild. Die visuelle Variante bricht fast vollständig ein und erreicht nur 2,4 von 30, während die strukturellen und hybriden Varianten mit rund 12 bis 14 von 30 deutlich davor liegen. Relationale Aufgaben verlangen exakte Koordinaten, und die stehen nur in der strukturellen Schicht.

Das Szenario C1 macht das greifbar. Der Befehl verlangt, die Kugel nach links vom Würfel zu bewegen, also auf einen negativen x-Abstand zum Würfel. Gefordert ist nur die Richtung der Relation, kein exakter Zielwert. Die strukturelle Variante und die hybriden Varianten lösen es zuverlässig oder weitgehend, während die rein visuelle Variante fast durchgehend scheitert.

Ein anderes Bild ergibt sich, sobald die Aufgabe Präzision verlangt. C4 setzt auf derselben Grundstruktur auf wie C1, verschärft sie aber zu einer metrischen Vorgabe: Die Kugel soll exakt zwei Einheiten links vom Würfel liegen. Jetzt scheitern alle Varianten. Keine erreicht mehr als rund drei von zehn, unabhängig davon, ob die Szene strukturell, visuell oder hybrid bereitgestellt wird. Der Sprung von C1 zu C4 ist der eigentliche Befund dieser Kategorie. Solange nur die Richtung einer Relation zählt, entscheidet die Repräsentation über den Erfolg. Sobald ein exakter metrischer Wert gefordert ist, verschiebt sich die Grenze vom Repräsentations- zum Modellproblem.

Bei C2 ist diese Lesart dagegen nicht ohne Weiteres haltbar, weshalb dieses Szenario eine eigene Betrachtung verlangt. Der Befehl verlangt, den zur Kamera nächstgelegenen Würfel um eine Einheit

Tabelle 6.7: Exakte Tests nach Fisher für die zentralen Vergleiche, jeweils $n = 30$ je Gruppe. Das Niveau ist nicht für multiples Testen korrigiert.

Vergleich	Erfolge	p
D1: naiv hybrid vs. visuell	2/30 vs. 30/30	$8,4 \cdot 10^{-15}$
D1: naiv hybrid vs. kompetenzgetrennt	2/30 vs. 29/30	$2,3 \cdot 10^{-13}$
D1: naiv hybrid vs. priorisierend	2/30 vs. 25/30	$1,4 \cdot 10^{-9}$
D2: priorisierend vs. naiv hybrid	22/30 vs. 30/30	0,0046
D2: priorisierend vs. kompetenzgetrennt	22/30 vs. 30/30	0,0046
D1: strukturell vs. visuell	0/30 vs. 30/30	$1,7 \cdot 10^{-17}$
E1: visuell vs. strukturell	0/30 vs. 30/30	$1,7 \cdot 10^{-17}$
B3: visuell vs. strukturell	0/30 vs. 30/30	$1,7 \cdot 10^{-17}$
C1: visuell vs. strukturell	5/30 vs. 30/30	$5,5 \cdot 10^{-12}$

anzuheben. Alle Varianten bleiben schwach, die strukturelle Variante erreicht 0 von 30 Läufen.

Ein Wert von exakt null ist hier erklärungsbedürftig, denn die Aufgabe ist aus den strukturellen Daten heraus nicht schwer. Die drei Würfel liegen bei $(-2, 0, 2)$, $(0, 0, 5)$ und $(2, 0, 8)$, also gestaffelt entlang der z-Achse. Steht die Kamera wie in Listing 1 bei negativem z und blickt entlang der positiven z-Achse, so ist der kameranächste Würfel derjenige mit dem kleinsten z-Wert, und diese Ordnung stimmt mit der euklidischen Distanzordnung überein. Das Zielobjekt ließe sich dann bereits durch einen Vergleich dreier Zahlen bestimmen, ohne jede Wurzelrechnung. Dass dieselbe Variante B1, eine strukturell gleich einfache Anhebe-Aufgabe, in 30 von 30 Läufen löst, passt schlecht zu der Annahme, das Modell scheitere hier an der Rechnung. Ein deterministisches Null bei gleichzeitig deterministischer Perfektion in einer verwandten Aufgabe deutet eher auf eine systematische Ursache als auf ein Präzisionsproblem hin.

Drei Erklärungen kommen in Betracht, zwischen denen die berichteten Erfolgsraten nicht entscheiden. Erstens könnte das Modell die Referenz tatsächlich falsch auflösen, etwa indem es Kameranähe mit einer anderen Ordnung verwechselt oder die Blickrichtung ignoriert. Zweitens könnte die Soll-Vorgabe der Auswertung ein anderes Objekt als korrekt führen, als die Szenengeometrie nahelegt; ein solcher Fehler würde jeden Lauf gleichmäßig verwerfen und erzeugte genau das beobachtete Muster. Drittens könnte ein Werkzeug- oder Aufbaufehler vorliegen, etwa eine nicht übernommene Anhebung. Erst die zweite und dritte Erklärung sind Fehler des Aufbaus, nur die erste wäre ein Befund über das Modell.

Welche der drei Erklärungen zutrifft, lässt sich nachträglich nicht mehr entscheiden. Für C2 liegen keine verwertbaren Aufzeichnungen der einzelnen Läufe mehr vor, sodass sich nicht nachvollziehen lässt, welches Objekt der Agent manipuliert hat und mit welchen Argumenten. Eine Fehleranalyse, die zwischen einer falschen Referenzauflösung und einem Fehler in Szenario, Soll-Vorgabe oder Werkzeug unterscheidet, hätte genau diese Angaben gebraucht.

C2 wird deshalb nicht als Beleg für eine Modellgrenze geführt, sondern als ungeklärter Fall. Für C4, das eine metrische Zielvorgabe von exakt zwei Einheiten verlangt und in dem alle Varianten zwischen 2 und 10 Erfolgen aus 30 liegen, bleibt die Deutung als Präzisionsgrenze des Modells dagegen tragfähig, weil dort kein Wert deterministisch null ist und die Streuung zu einem graduellen Scheitern passt.

Kategorie C zeigt damit zweierlei. Solange nur die Richtung einer Relation zählt, entscheidet die Repräsentation über den Erfolg. Sobald ein exakter metrischer Wert gefordert ist, verschiebt sich die Grenze vom Repräsentations- zum Modellproblem, wobei im Fall von C2 ein Aufbaufehler als Alternative nicht ausgeschlossen ist.

Kategorie D: Rein perzeptuelle Referenzen

Bisher lag der Vorteil bei der strukturellen Schicht. Kategorie D kehrt dieses Verhältnis um. Hier spricht der Befehl ein Objekt über eine rein visuelle Eigenschaft an, etwa über ein Oberflächenmuster, das in den strukturellen Daten nicht vorkommt. Wer nur Koordinaten und Objekttypen kennt, kann ein gestreiftes Objekt nicht von einem einfarbigen unterscheiden.

Das Ergebnis ist eindeutig. Die visuelle Variante löst jedes Szenario, 20 von 20. Die strukturelle Variante scheitert fast vollständig, 0,3 von 20. Es zeigt sich das Spiegelbild zu den vorigen Kategorien: So wie die visuelle Schicht bei Relationen blind war, ist die strukturelle Schicht bei perzeptuellen Referenzen blind. Beide Repräsentationen haben einen exklusiven Zuständigkeitsbereich, den die jeweils andere nicht abdeckt.

An dieser Stelle lässt sich eine naheliegende Erwartung prüfen. Wenn die hybride Repräsentation beide Schichten bereitstellt, sollte sie mindestens so gut abschneiden wie die jeweils bessere Einzelvariante. Die Daten sprechen dagegen. Die naive hybride Variante erreicht nur 10,7 von 20, obwohl ihr die visuelle Beschreibung vorliegt. Besonders deutlich wird der Bruch in D1. Dort löst die visuelle Variante jeden Lauf, 30 von 30, die naive hybride Variante dagegen 2 von 30 ($p = 8,4 \cdot 10^{-15}$, Tabelle 6.7). Die Kombination beider Schichten erbt den Vorteil der visuellen Beschreibung somit nicht, sondern verliert ihn.

Die Deutung dieses Verlusts ist damit allerdings noch nicht festgelegt. Naheliegend ist die Annahme, die strukturelle Information verdränge die visuelle, statt sie zu ergänzen. Ebenso gut mit den Daten vereinbar ist jedoch eine schlichtere Erklärung, die der Aufbau nicht ausschließt. In der D1-Szene stehen zwei graue Würfel bei $(-1, 0, 3)$ und $(1, 0, 3)$, wobei der *zweite* der gestreifte ist. Wählt ein Agent systematisch das erste in der Liste aufgeführte Objekt, ohne die Referenz überhaupt aufzulösen, so ergibt sich genau das beobachtete Muster. Für diese Lesart spricht, dass auch die rein strukturelle Variante 0 von 30 erreicht, obwohl blindes Raten zwischen zwei Kandidaten etwa 15 von 30 ergäbe. Das Gewicht dieses Arguments hängt an der Dekodierung: Bei einer Temperatur von 0,8 hätte ein auch nur teilweise zufälliges Wahlverhalten über 30 Läufe hinweg mit hoher Wahrscheinlichkeit mindestens einen Treffer erzeugt. Ein Wert von exakt null ist unter dieser Bedingung kein Zeichen von Zufall, sondern von Systematik, und eine Positionspräferenz ist die einfachste Systematik, die zu null führt. Die 2 von 30 der naiven hybriden Variante fügen sich in dasselbe Bild.

Damit stehen zwei gleichrangige Hypothesen nebeneinander, zwischen denen dieser Aufbau nicht entscheidet. Nach der ersten verdrängt die exakte Struktur die unscharfe Beschreibung. Nach der zweiten liegt ein Reihenfolgeeffekt vor, bei dem die Position eines Objekts in der Aufzählung die Wahl bestimmt. Beide erklären D1 vollständig. Eine Entscheidung zwischen ihnen verlangte eine Messung mit vertauschter Objektreihenfolge, in der der gestreifte Würfel an erster Stelle steht; eine solche Messung wurde nicht durchgeführt. Abschnitt 6.6 führt diese Konfundierung als Grenze.

Der Effekt tritt zudem nicht durchgängig auf. In D2 löst dieselbe naive hybride Variante alle Läufe, 30 von 30. In D2 steht der gestreifte Würfel bei $(1, 0, 4)$ räumlich zwischen den vier grauen Würfeln und damit weder am Rand noch an erster Stelle einer nach der x-Koordinate geordneten Aufzählung. Eine reine Präferenz für das erste Objekt erklärt den dortigen Erfolg folglich nicht, was die Reihenfolgehypothese schwächt, ohne sie für D1 auszuräumen. Ob die Reihenfolge im übergebenen JSON dieser räumlichen Ordnung entspricht, geht aus der Szenariodefinition nicht hervor und wäre den Protokollen zu entnehmen. Warum die naive Kombination in D1 scheitert und in D2 gelingt, bleibt an dieser Stelle offen und führt unmittelbar zur zweiten Forschungsfrage.

Eines zeigt die Kategorie unabhängig davon. Nicht die Verfügbarkeit beider Schichten entscheidet über den Erfolg, sondern die Art, wie sie kombiniert werden. Die instruierten hybriden Varianten weisen darauf hin, dass sich der verlorene Zugriff auf die visuelle Beschreibung wiederherstellen lässt. Wie das gelingt und woran die naive Kombination scheitert, ist Gegenstand des folgenden Abschnitts.

Kategorie E: Verdeckte Referenzen

Kategorie D hat gezeigt, dass sich manche Referenzen nur über das Bild auflösen lassen. Kategorie E prüft den umgekehrten Fall. Ein Objekt steht in der Szene, ist im gerenderten Bild aber verdeckt und dadurch unsichtbar. In den strukturellen Daten bleibt es vollständig verzeichnet.

Im Szenario E1 verbirgt eine große Wand ein grünes Objekt, das der Befehl anheben soll. Alle Varianten mit struktureller Schicht lösen die Aufgabe vollständig, 10 von 10. Die rein visuelle Variante scheitert vollständig, 0 von 10. Sie kann ein Objekt nicht ansprechen, das im Bild nicht erscheint.

Die Kompetenzmatrix schließt sich damit. Kategorie D belegt einen bild-exklusiven Bereich, in dem allein die visuelle Schicht trägt. Kategorie E1 belegt das strukturell-exklusive Gegenstück, in dem allein die strukturelle Schicht trägt. Beide Repräsentationen decken jeweils einen Bereich ab, zu dem die andere keinen Zugang hat. Diese Symmetrie begründet, warum eine Kombination beider Schichten überhaupt sinnvoll ist.

Ein zweites Szenario dieser Kategorie erlaubt keine ebenso klare Deutung. E2 verlangt, alle Würfel der Szene anzuheben, auch den verdeckten. Damit prüft die Aufgabe nicht allein die Verdeckung, sondern zugleich die Fähigkeit, mehrere Manipulationen nacheinander auszuführen. Die strukturelle Variante löst das Szenario vollständig, 30 von 30. Alle hybriden Varianten scheitern nahezu vollständig, und auch die visuelle Variante erreicht keinen Erfolg.

Vor jeder inhaltlichen Deutung ist hier ein Widerspruch im Aufbau selbst zu benennen. Die allen Varianten gemeinsame Grundinstruktion verlangt ausdrücklich, die Aufgabe mit *genau einem* Manipulationsaufruf zu lösen und danach abzuschließen (Abschnitt 5.4). E2 lässt sich unter dieser Vorgabe nicht lösen, denn drei Würfel anzuheben erfordert drei Aufrufe. Der Agent muss also gegen seine Grundinstruktion verstoßen, um erfolgreich zu sein. Gemessen wird in dieser Zelle folglich nicht in erster Linie die Repräsentation, sondern die Neigung einer Variante, eine explizite Instruktion zu übergehen. Dass ausgerechnet die strukturelle Variante das zuverlässig tut, ist ein Befund über ihr Instruktionsverhalten und nicht über ihre Repräsentationskompetenz.

Auch B2 ist von dieser Spannung berührt, denn „delete all red cubes“ betrifft zwei Objekte. Dort gelingt das Szenario allen hybriden Varianten in 30 von 30 Läufen. Das ist mit der zunächst plausiblen Erklärung, der größere Kontext der hybriden Varianten erschwere mehrere aufeinanderfolgende Schritte, nur schwer vereinbar: Wäre sie zutreffend, müsste B2 den hybriden Varianten ähnliche Schwierigkeiten bereiten wie E2.

Die Ursache des Einbruchs in E2 bleibt damit ungeklärt. Die zuvor naheliegende Erklärung über den größeren Kontext der hybriden Varianten wird durch B2 nicht gestützt und wird deshalb nicht länger behauptet. E2 wird als nicht auswertbare Zelle geführt: weder als reiner Verdeckungstest noch als belastbarer Mehrschritt-Befund. Die Aussagen der Kategorie E stützen sich folglich allein auf E1.

Zwischenfazit zur ersten Forschungsfrage

Über alle gewerteten Zellen hinweg zeigt sich kein Gesamtsieger. Die strukturelle Schicht trägt attributive, qualitativ-relationale und verdeckte Referenzen, die visuelle Schicht trägt perzeptuelle Referenzen. Welche Repräsentation erfolgreich ist, hängt vom Referenztyp ab. Die naheliegende Annahme, eine hybride Repräsentation vereine ohne Weiteres die Stärken beider, hält der Prüfung nicht stand. In D1 bleibt die naive Kombination mit 2 von 30 deutlich hinter der visuellen Einzelvariante mit 30 von 30 zurück ($p = 8,4 \cdot 10^{-15}$). Die Verfügbarkeit beider Schichten genügt also nicht. Entscheidend ist, wie sie kombiniert werden, wobei für D1 neben der Verdrängungshypothese ein Reihenfolgeeffekt als gleichrangige Erklärung offen bleibt. Damit ist der Ausgangspunkt der zweiten Forschungsfrage erreicht.

6.5 Ergebnisse: Gezielte Verbesserung des hybriden Ansatzes (RQ2)

Die erste Forschungsfrage endete mit einem offenen Punkt. Die naive hybride Repräsentation stellt beide Schichten bereit, nutzt den visuellen Vorteil aber nicht zuverlässig. Die zweite Forschungsfrage prüft, ob sich dieses Verhalten allein durch die Gestaltung der Repräsentation steuern lässt, ohne das Modell zu verändern.

Das Scheitern der naiven Kombination

Der Vergleich der beiden perzeptuellen Szenarien zeigt, dass das Scheitern der naiven Kombination nicht durchgängig auftritt. In D1 stehen zwei graue Würfel, die sich im strukturellen Zustand nicht unterscheiden; allein die Textur trennt sie, und die steht nur in der visuellen Beschreibung. Hier erreicht die naive hybride Variante 2 von 30 Läufen, während die rein visuelle Variante alle 30 löst. In D2 soll unter fünf Würfeln der einzige gestreifte und damit visuell auffälligste Würfel bewegt werden. Dort löst dieselbe naive Variante alle 30 Läufe.

Belegt ist damit der Effekt: Die naive Kombination nutzt den visuellen Vorteil in D1 nicht, in D2 hingegen schon. Warum sie in einen Fall scheitert und im anderen gelingt, lässt sich aus den Erfolgsraten allein nicht bestimmen. Drei Erklärungen liegen nahe, ohne dass die Daten zwischen ihnen entscheiden. Diese drei Hypothesen werden im Folgenden und in Kapitel 7 durchgängig verwendet.

Die erste betrifft die Formulierung des Befehls. In D1 benennt das Wort „striped“ eine Objekteigenschaft, wie sie sonst in der strukturellen Schicht steht. Das Modell könnte deshalb dort nach einem unterscheidenden Merkmal suchen, wo keines vorhanden ist, während „most salient“ in D2 auf etwas verweist, das ausschließlich in der visuellen Beschreibung existiert.

Die zweite betrifft die visuelle Eindeutigkeit des Zielobjekts. Ein einzelnes gestreiftes Objekt unter vier gleichen grauen hebt sich in der Beschreibung stärker ab als eines neben nur einem einfarbigen.

Die dritte betrifft die Reihenfolge der Objekte. Wie im vorigen Abschnitt ausgeführt, ist in D1 der gestreifte Würfel das zweite von zwei Objekten, und eine systematische Wahl des erstgenannten Objekts erzeugt dasselbe Ergebnismuster.

Unabhängig davon, welche dieser Erklärungen zutrifft, lässt sich festhalten, dass die bloße Verfügbarkeit beider Schichten nicht genügt, damit die naive Kombination den visuellen Zugriff zuverlässig nutzt. Diese Beobachtung ähnelt einem aus der Literatur bekannten Muster der Modalitäts-Dominanz, wobei die Analogie nur mit den in Abschnitt 2.4 genannten Einschränkungen trägt.

Priorisierung: eine Verschiebung, keine Lösung

Die erste Gegenmaßnahme stellt dem Modell die visuelle Beschreibung voran und erklärt sie für das Aussehen als maßgeblich. Diese geführte Variante gewinnt dort, wo die naive Kombination scheitert. In D1 steigt der Erfolg von 2 auf 25 von 30 Läufen ($p = 1,4 \cdot 10^{-9}$). Über die Kategorie D hinweg erreicht sie 15,6 von 20 statt der 10,7 der naiven Variante.

Dabei ist eine Einschränkung mitzudenken, die für alle Vergleiche zwischen den hybriden Varianten gilt. Die geführte Variante unterscheidet sich von der naiven nicht allein durch ihre Zuständigkeitsregel, sondern zusätzlich durch die Reihenfolge der beiden Schichten im Kontext (Tabelle 5.1). Ob der Gewinn auf die Instruktion oder auf die Voranstellung der visuellen Beschreibung zurückgeht, lässt dieser Aufbau offen.

Der Gewinn hat zudem einen Preis. In D2 fällt die geführte Variante auf 22 von 30 zurück, während die naive Variante dort 30 von 30 hält ($p = 0,0046$). Das Szenario D2 verlangt neben der visuellen Zuordnung eine metrische Verschiebung an eine feste Zielkoordinate. Die Priorisierung verschiebt das Gewicht zugunsten der visuellen Beschreibung und dürfte dadurch jene Aufgaben schwächen,

die zugleich eine präzise Nutzung der strukturellen Koordinaten erfordern. Sie tauscht damit eine Kompetenz gegen eine andere, statt beide zu vereinen.

Kompetenztrennung: beide Schichten zusammenführen

Die zweite Gegenmaßnahme priorisiert nicht, sondern trennt die Zuständigkeiten. Die visuelle Beschreibung bestimmt, welches Objekt gemeint ist, die strukturelle Schicht liefert dessen Koordinaten.

Über die Entstehung dieser Variante ist vorab Rechenschaft abzulegen, weil sie die Reichweite des folgenden Befundes begrenzt. Sie wurde nicht vorab entworfen, sondern iterativ aus der Analyse der beiden vorangegangenen Varianten entwickelt, und zwar in Kenntnis der Ergebnisse auf genau dem Szenarioset, auf dem sie anschließend berichtet wird. Ihre Instruktion nennt mit „striped“ und „most salient“ zwei Wörter, die wörtlich in den Befehlen von D1 und D2 vorkommen (Listing 6). Der im Folgenden berichtete Vorteil ist damit auf diesem Szenarioset gezeigt; seine Übertragung auf ungesehene Formulierungen ist offen. Abschnitt 5.4 beschreibt den Entwicklungsweg im Einzelnen.

Auf diesem Szenarioset fällt das Ergebnis eindeutig aus. In Kategorie D erreicht die kompetenzgetrennte Variante 19,7 von 20 und liegt damit nahe an der Perfektion der rein visuellen Variante. In D1 löst sie 29 von 30 Läufen, wo die naive Variante mit 2 von 30 scheiterte ($p = 2,3 \cdot 10^{-13}$). Zugleich hält sie D2 bei 30 von 30, wo die geführte Variante auf 22 von 30 zurückfiel ($p = 0,0046$). Sie vereint damit, woran die Priorisierung scheiterte: den Zugriff auf die visuelle Beschreibung aus D1 und die strukturelle Präzision aus D2. Abbildung 6.1 veranschaulicht diese Entwicklung über die fünf Varianten hinweg. In den übrigen Kategorien bleibt sie auf dem besten erreichten Niveau, 30 von 30 in A und B, gleichauf an der Spitze in C und 30 von 30 in E1.




Abbildung 6.1: Erfolg in der rein visuellen Kategorie D über die fünf Varianten. Die rein visuelle Variante bildet die Obergrenze, die rein strukturelle scheitert nahezu vollständig. Die naive Kombination erreicht nur etwa die Hälfte, die Priorisierung verbessert dies, und erst die Kompetenztrennung erreicht nahezu das Niveau der reinen Bildvariante.

Eine Ausnahme ist zu benennen. In E2 liegt die rein strukturelle Variante mit 30 von 30 vor allen hybriden Varianten, die dort nahezu vollständig scheitern. Diese Zelle wird jedoch, wie in Abschnitt 6.6 ausgeführt, nicht gewertet, weil ihr Soll-Ergebnis der Grundinstruktion widerspricht. Außerhalb dieses Sonderfalls ist die kompetenzgetrennte Variante in jeder gewerteten Zelle die beste oder eine der besten.

Erreichung der zweiten Forschungsfrage

Das gesetzte Kriterium war zweiteilig. Eine Gestaltung sollte dort eine belastbare Verbesserung erzielen, wo die naive Fusion scheitert, und dies ohne Einbußen in den übrigen Kategorien. Die kompe-

tenzgetrennte Variante erfüllt beide Teile. Sie hebt D1 von 2 auf 29 von 30 Läufen, und sie bewahrt zugleich das Leistungsniveau in allen anderen gewerteten Kategorien. Anders als die Priorisierung, die nur verschiebt, führt die Kompetenztrennung beide Schichten zusammen. Die zweite Forschungsfrage ist damit für dieses Szenarioset positiv beantwortet: Die Fusion beider Quellen ist kein Automatismus, sondern ein steuerbares Gestaltungsproblem, das sich allein auf der Instruktionsebene angehen lässt.

Zwei Einschränkungen begrenzen diese Antwort. Erstens ist die Variante am selben Szenarioset entwickelt worden, an dem sie gemessen wird, sodass ihre Generalisierung auf ungesehene Formulierungen offen bleibt. Zweitens variieren die hybriden Varianten neben der Instruktion auch die Reihenfolge der Schichten, sodass der Beitrag beider Faktoren nicht getrennt ist. Beide Punkte werden in Abschnitt 6.6 als Grenzen geführt.

Das übertragbare Gestaltungsprinzip

Aus diesem Ergebnis lässt sich ein Prinzip formulieren, das über den Einzelfall hinausweist, ohne über ihn hinaus belegt zu sein. Die Kompetenztrennung weist jeder Schicht genau den Referenzbereich zu, den die erste Forschungsfrage ihr als exklusiv zugeordnet hat. Die visuelle Beschreibung beantwortet die Frage, welches Objekt gemeint ist, die Struktur die Frage, wo es sich befindet. Der Mehrwert der hybriden Repräsentation entstände damit nicht aus der bloßen Verfügbarkeit beider Quellen, sondern aus der ausdrücklichen Zuweisung ihrer Zuständigkeiten. Für die Gestaltung eines lokalen Agenten mit gemischter Repräsentation ergibt sich daraus die Leitlinie, die Quellen nicht nur nebeneinanderzustellen, sondern ihnen klar getrennte Rollen zu geben.

Als Leitlinie ist dies eine Empfehlung und kein nachgewiesenes Prinzip. Sie beruht auf zwei Szenarien einer Kategorie, gemessen mit einer Instruktion, die an eben diesen Szenarien entwickelt wurde. Diese Variante bildet die Grundlage des in Abschnitt 5.5 beschriebenen Demonstrators und überführt das empirische Ergebnis in eine lauffähige Anwendung.

6.6 Validität und Grenzen

Die vorstehenden Ergebnisse sind nur so belastbar wie die Kontrolle der Bedingungen, unter denen sie entstanden. Dieser Abschnitt legt offen, welche Störfaktoren erkannt und beseitigt wurden, worauf die Messung beruht und wo die Aussagekraft endet.

Kontrolle von Störfaktoren

Mehrere zunächst plausible Befunde erwiesen sich bei genauer Prüfung als Artefakte des Aufbaus und wurden vor der Wertung beseitigt. Ein erster Störfaktor betraf die Marker der visuellen Variante. Ihre Farbe beeinflusste die Farbwahrnehmung des visuellen Modells, das teils die Farbe des Markers statt die des Objekts benannte. Die Marker wurden daraufhin versetzt und die Anweisung angepasst. Ein zweiter Störfaktor lag in Szenarien, in denen ein Referenzobjekt im Koordinatenursprung stand. Dort fielen relative und absolute Zielangabe zusammen, sodass eine relationale Aufgabe auch ohne Verständnis der Relation lösbar war. Die betroffenen Aufbauten wurden entkonfundiert. Ein dritter Störfaktor entstand durch den Sichtbarkeitstest der Marker. Im ursprünglichen, achsenkollinearen Aufbau von C2 erhielten verdeckte Objekte keinen Marker, wodurch das kamera-nächste Objekt im Bild als einziges markiert erschien und die Aufgabe trivial wurde. C2 wurde daraufhin mit seitlich versetztem Aufbau neu gemessen. Ein vierter Fall betraf einen scheinbar deutlichen Nachteil der hybriden Varianten, der sich als Terminierungsartefakt des Frameworks herausstellte. Ein serverseitiger Schutz gegen unmittelbar wiederholte, identische Manipulationen beseitigte ihn.

Als durchgängiger Prüfstein dient die Kontrollkategorie A. Da alle Varianten dort das Maximum erreichen, erzeugt der Messaufbau selbst keine variantenspezifischen Unterschiede. Ein Vollständigkeitsanspruch lässt sich daraus nicht ableiten. Die genannten Störfaktoren sind die markantesten, nicht die einzigen, und unentdeckte Confounds können nicht ausgeschlossen werden.

Entscheidungen nach Sichtung der Ergebnisse

Mehrere der vorstehenden Eingriffe wurden getroffen, nachdem die zugehörigen Ergebnisse bereits vorlagen. Diese Abfolge ist methodisch nicht neutral und wird deshalb ausdrücklich benannt.

Das Szenario C3 wurde aus der Auswertung genommen, weil die achsenparallele Kameraausrichtung die aus Sicht der Kamera formulierte Referenz mehrdeutig machte. Das Szenario C2 wurde nach demselben Muster nicht ausgeschlossen, sondern mit verändertem Aufbau neu gemessen und in dieser zweiten Fassung berichtet. Beide Entscheidungen erfolgten nach Sichtung der ersten Ergebnisse. Sie sind inhaltlich begründet, da in beiden Fällen ein benennbarer Störfaktor vorlag und nicht ein unerwünschtes Ergebnis den Ausschlag gab. Vorab festgelegt waren sie jedoch nicht. Ein Vorgehen, bei dem Szenarien erst nach Kenntnis ihrer Ergebnisse ein- oder ausgeschlossen werden, erhöht grundsätzlich das Risiko, dass die berichtete Auswahl zugunsten der erzählten Deutung ausfällt.

Ebenso wurde E2 erst nach Sichtung der Ergebnisse als nicht wertbar eingestuft. Dass das Soll-Ergebnis dieses Szenarios der Grundinstruktion widerspricht, war beim Entwurf nicht bedacht worden.

Die kompetenzgetrennte Variante schließlich wurde iterativ und in Kenntnis der Ergebnisse der übrigen Varianten entwickelt; der folgende Abschnitt behandelt diesen Punkt eigens.

Der Wahrnehmungs-Prompt bestimmt mit, was die visuelle Schicht leisten kann

Die visuelle Schicht wird in dieser Arbeit nicht durch das Bild begrenzt, sondern durch den Prompt, der aus dem Bild eine Beschreibung macht (Listing 3). Er fordert Nummer, Form, Farbe, qualitative Lage und einen Texturdeskriptor an, und nur diese Angaben stehen dem Sprachmodell anschließend zur Verfügung.

Daraus folgen zwei Einschränkungen.

Erstens sind Befunde über die Schwäche der visuellen Variante nur so weit tragfähig, wie der Prompt reicht. Das vollständige Scheitern in B3 geht darauf zurück, dass der Prompt keine Größenangabe anfordert, und ist damit keine Aussage über visuelle Repräsentationen im Allgemeinen, sondern über diese eine Ausgestaltung. Ein Prompt, der auch Größen abfragte, hätte dort vermutlich besser abgeschnitten. Die Kategorie B belegt folglich nicht, dass Attributreferenzen grundsätzlich strukturelle Daten erfordern, sondern dass sie es unter dem hier gewählten Prompt tun.

Zweitens nennt der Prompt als Beispiel für einen Texturdeskriptor ausdrücklich „striped“, also genau das Merkmal, über das die perzeptuellen Szenarien D1 und D2 ihr Zielobjekt ansprechen. Die gemeinsame Wahrnehmungsstufe ist damit auf die Testfälle hin formuliert. Da alle Varianten mit visueller Schicht denselben Prompt verwenden, verzerrt das den Vergleich *zwischen* ihnen nicht. Es begrenzt aber die Aussagekraft der Kategorie D insgesamt: Gezeigt ist, dass die visuelle Schicht eine Eigenschaft erkennt, auf die ihr Wahrnehmungs-Prompt sie ausdrücklich hinweist. Ob sie ein unerwartetes Oberflächenmerkmal ebenso zuverlässig berichtet hätte, ist offen. Zusammen mit der am Szenarioset entwickelten Instruktion der besten Variante bedeutet das, dass die Testfälle an zwei Stellen in den Aufbau eingeflossen sind.

Die kompetenzgetrennte Variante ist am Szenarioset entwickelt

Dies ist die gewichtigste Einschränkung der Ergebnisse zur zweiten Forschungsfrage. Die kompetenzgetrennte Variante entstand nicht aus einer vorab formulierten Theorie, sondern aus der Analyse des Verhaltens der naiven und der priorisierenden Variante auf demselben Szenarioset, auf dem sie anschließend gemessen wird. Ihre Instruktion enthält mit „striped“ und „most salient“ zwei Formulierungen, die wörtlich in den Befehlen von D1 und D2 auftreten (Listing 6).

Damit ist der Befund wie folgt einzuordnen. Gezeigt ist, dass sich die Kombination beider Schichten durch die Gestaltung der Instruktion auf diesem Szenarioset erheblich verbessern lässt. Nicht gezeigt

ist, dass die kompetenzgetrennte Variante auf ungesesehenen Formulierungen ebenso überlegen wäre. Ein Teil ihres Vorteils könnte darauf beruhen, dass ihre Instruktion die im Testbefehl verwendeten Wörter bereits enthält und dem Modell damit die Zuordnung abnimmt, statt eine allgemeine Kompetenz zu vermitteln. Zwischen beiden Möglichkeiten kann diese Arbeit nicht entscheiden. Abschnitt 7.5 nennt die beiden Prüfungen, die dafür nötig wären.

Instruktion und Reihenfolge sind konfundiert

Die drei hybriden Varianten unterscheiden sich nicht nur in ihrer Zuständigkeitsregel. Die priorisierende Variante stellt zusätzlich die visuelle Beschreibung voran, während die naive und die kompetenzgetrennte Variante mit dem strukturellen Zustand beginnen (Tabelle 5.1). Instruktion und Reihenfolge variieren damit gemeinsam, und ihr jeweiliger Beitrag lässt sich aus diesen Messungen nicht trennen. Insoweit ist Anforderung NFA5, die Repräsentationsform als einzige variierende Größe zu halten, für den Vergleich der hybriden Varianten untereinander nicht erfüllt. Für den Vergleich der drei Repräsentationsformen im engeren Sinne bleibt sie unberührt, da sich dort strukturelle, visuelle und hybride Bedingung in der Repräsentation selbst unterscheiden.

Reihenfolge der Objekte als alternative Erklärung in D1

Der zentrale Befund der Kategorie D beruht auf D1, und für dieses Szenario besteht eine zweite, gleichrangige Erklärung. Der gestreifte Würfel ist dort das zweite der beiden Objekte. Eine systematische Wahl des erstgenannten Objekts, ohne Auflösung der Referenz, erzeugt dasselbe Muster wie eine Verdrängung der visuellen durch die strukturelle Information. Das vollständige Scheitern der strukturellen Variante mit 0 von 30 stützt diese Lesart, denn ein Raten zwischen zwei Kandidaten ergäbe etwa 15 von 30. Die 2 von 30 der naiven hybriden Variante fügen sich ein.

Eine Entscheidung zwischen beiden Erklärungen verlangte eine Wiederholung von D1 mit vertauschter Objektreihenfolge. Eine solche Messung liegt nicht vor. Die Verdrängungshypothese ist daher nicht als belegt zu behandeln, sondern als eine von zwei mit den Daten verträglichen Erklärungen.

Widerspruch zwischen Grundinstruktion und Mehrobjekt-Szenarien

Die Grundinstruktion verlangt genau einen Manipulationsaufruf, während die Soll-Ergebnisse von B2 und E2 mehrere Objekte betreffen. Für E2 führt das dazu, dass die Zelle nicht wertbar ist, weil ein Erfolg nur durch Missachtung der Instruktion zustande kommen kann. Warum B2 den hybriden Varianten dennoch durchgängig gelingt, ist ungeklärt und hängt davon ab, ob das Löschwerkzeug mehrere Objekte in einem Aufruf annimmt. Die zunächst naheliegende Erklärung des E2-Einbruchs über den größeren Kontext der hybriden Varianten wird durch B2 nicht gestützt und in dieser Arbeit nicht mehr vertreten.

Weitere Einschränkungen des Aufbaus

Drei kleinere Punkte sind der Vollständigkeit halber zu nennen.

Die Sichtbarkeitsprüfung arbeitet mit einem einzelnen Sichtstrahl auf den Objektmittelpunkt und kennt daher nur die Zustände sichtbar und verdeckt (Abschnitt 5.2). Teilweise verdeckte Objekte lassen sich damit nicht abbilden. Für die hier verwendeten Szenen genügt das, weil ein Objekt entweder frei steht oder vollständig hinter einer Wand liegt; in dichteren Szenen wäre der Test unzureichend.

Der Schutz gegen unmittelbar wiederholte, identische Werkzeugaufrufe kann nicht unterscheiden, ob eine Wiederholung ein Artefakt des Frameworks oder eine vom Befehl geforderte Handlung ist (Abschnitt 5.3). In den ausgewerteten Szenarien tritt der Konfliktfall nicht auf, bei Mehrschritt-Befehlen wäre er jedoch möglich.

Die Erfolgstoleranz $\tau = 0,1$ ist für diesen Aufbau festgelegt und nicht aus einer externen Vorgabe übernommen (Abschnitt 6.3). Wie empfindlich insbesondere die metrischen Szenarien C2 und C4

auf diese Wahl reagieren, wurde nicht untersucht. Eine großzügigere Toleranz könnte die dortigen Erfolgsraten anheben, ohne dass sich an der Rangfolge der Varianten etwas ändern muss.

Schließlich war das Kontextfenster mit 4096 Token knapp bemessen, und es belastet die Varianten ungleich, da die hybriden Varianten beide Schichten zugleich tragen (Abschnitt 6.1). Damit ist eine Asymmetrie dokumentiert, die nicht auf die Repräsentationsform als solche zurückgeht, sondern auf ihren Platzbedarf. Es liegt nahe, darin eine Erklärung für das Scheitern der hybriden Varianten in E2 zu vermuten, da dieses Szenario mehrere aufeinanderfolgende Schritte und damit einen längeren Verlauf erfordert. Diese Vermutung trägt jedoch nicht ohne Weiteres, denn B2 verlangt ebenfalls die Manipulation mehrerer Objekte und gelingt allen hybriden Varianten in 30 von 30 Läufen. Ob und wo der knappe Kontext tatsächlich wirksam wurde, hätte eine Protokollierung der Kontextauslastung je Lauf zeigen müssen; eine solche wurde nicht vorgenommen. Die Frage bleibt damit offen und ist bei einer Wiederholung der Messung vorab zu berücksichtigen.

Die Aufzeichnung beschränkt die nachträgliche Analyse

Die Erfolgsmessung selbst ist von der Art der Aufzeichnung unberührt, da sie unmittelbar aus dem Folgezustand erfolgt. Für die nachträgliche Deutung einzelner Befunde fehlen jedoch Angaben, die ohne zusätzlichen Messaufwand hätten mitgeschrieben werden können.

Für die beiden metrischen Szenarien C2 und C4 liegen keine verwertbaren Aufzeichnungen der Läufe mehr vor. Damit lässt sich weder der erreichte Lagefehler bestimmen, also die Frage, ob die Varianten dort knapp oder grundsätzlich scheitern, noch nachvollziehen, welches Objekt der Agent in C2 tatsächlich manipuliert hat. Gerade die zweite Frage wäre aufschlussreich, da sie zwischen einer falschen Referenzauflösung und einem Fehler in Szenario, Soll-Vorgabe oder Werkzeug unterscheiden würde. Beide Punkte bleiben deshalb offen, und C2 wird als ungeklärter Fall und nicht als Beleg für eine Modellgrenze geführt.

Eine Protokollierung der abgesetzten Werkzeugaufrufe mit ihren Argumenten sowie der erreichten Endpositionen ist bei einer Wiederholung der Messung vorzusehen. Sie kostet nichts, beantwortet aber genau die Fragen, an denen die Deutung dieser Arbeit an mehreren Stellen endet.

Schmale Basis der zentralen Kategorien

Die inhaltlich tragenden Befunde beruhen auf schmäler Grundlage. Den bild-exklusiven Bereich belegen zwei Szenarien, den strukturell-exklusiven Bereich nach dem Ausschluss von E2 nur noch eines. Eine Kategorie mit zwei Aufgaben erlaubt keine Aussage darüber, wie sich der Effekt über die Breite möglicher perzeptueller Referenzen verhält, und ein einzelnes Szenario erst recht nicht. Die Konfidenzintervalle in Tabelle 6.6 quantifizieren die Unsicherheit innerhalb einer Zelle, nicht die Unsicherheit darüber, ob diese Zelle für ihren Referenztyp repräsentativ ist. Letztere ist die größere und in dieser Arbeit nicht quantifizierbar.

Erfolg aus dem Folgezustand

Die Entscheidung, den Erfolg ausschließlich aus dem Folgezustand zu bestimmen, hat einen empirischen Hintergrund. Das lokale Modell zeigte ein instabiles Abschlussverhalten. Es meldete wiederholt einen Erfolg, den der Folgezustand nicht bestätigte, benannte teils nicht vorhandene Objektkennungen und führte einzelne Manipulationen doppelt aus. Wie häufig Selbstauskunft und Folgezustand auseinanderfielen, wurde nicht systematisch quantifiziert. Die Beobachtung stützt sich daher auf wiederholte Einzelfälle in den Protokollen und nicht auf eine Rate. Für die Gültigkeit der Ergebnisse genügt diese Grundlage, weil die Messung aus dem Folgezustand von der Selbstauskunft unabhängig ist und ein falsch gemeldeter Erfolg die Erfolgszahl nicht beeinflusst.

Varianz der Messung

Innerhalb einer festen Konfiguration erwies sich die Messung als stabil. Die meisten Zellen zeigen über die drei Durchläufe eine Spanne von null oder eins. Nennenswerte Streuung tritt nur in wenigen Szenarien auf, insbesondere in C1 und C4 sowie in D1 und D2 der geführten Variante.

Diese Stabilität ist bemerkenswert, weil das Sprachmodell mit einer Temperatur von 0,8 dekodiert wurde. Die Konstanz vieler Zellen geht also nicht auf eine nahezu deterministische Dekodierung zurück, sondern tritt trotz erheblichen Spielraums in der Antwortwahl auf. Wo eine Zelle über 30 Läufe hinweg keinen einzigen abweichenden Ausgang zeigt, wirkt der zugrunde liegende Effekt demnach stärker als das Rauschen der Dekodierung.

Die in einer früheren Fassung dieser Arbeit verwendete Heuristik, einen Unterschied genau dann als belastbar zu werten, wenn sich die Spannen zweier Varianten nicht überlappen, ist für die zentralen Vergleiche durch die in Abschnitt 6.3 beschriebene inferenzstatistische Auswertung ersetzt worden. Die Spannen werden weiterhin berichtet, dienen aber der Beschreibung der Durchlaufstabilität und nicht als Entscheidungskriterium. Für alle Vergleiche, auf denen eine inhaltliche Aussage beruht, sind Konfidenzintervalle und exakte Tests in den Tabellen 6.6 und 6.7 ausgewiesen.

Ein Vorbehalt bleibt: Es wird ohne Korrektur für multiples Testen gerechnet. Die berichteten zentralen Unterschiede sind allerdings so deutlich, dass keiner von ihnen an einer Entscheidungsgrenze liegt; die Vergleiche in D2 mit $p = 0,0046$ sind die schwächsten und bleiben auch bei einer konservativen Korrektur bestehen.

Grenzen des Modells

Ein Teil der Befunde betrifft eher das Modell als die Repräsentation, allerdings nicht in gleichem Maß für beide metrischen Szenarien.

Für C4 trägt diese Deutung. Die Aufgabe verlangt eine Platzierung in exakt zwei Einheiten Abstand, und alle Varianten liegen zwischen 2 und 10 Erfolgen aus 30. Das Scheitern ist graduell und streut, was zu einer Präzisionsgrenze des Modells passt: Die Koordinaten liegen vor, die geforderte Rechengenauigkeit wird nur manchmal erreicht. An dieser Grenze ändert keine Repräsentation etwas.

Für C2 ist die Deutung als Modellgrenze dagegen nicht belegt. Dort erreicht die strukturelle Variante 0 von 30, obwohl die Aufgabe sich auf einen Vergleich dreier Koordinaten reduzieren lässt und dieselbe Variante die strukturell vergleichbare Aufgabe B1 in 30 von 30 Läufen löst. Ein deterministisches Null bei gleichzeitiger deterministischer Perfektion in einer verwandten Aufgabe ist eher ein Hinweis auf einen systematischen Fehler in Szenario, Soll-Vorgabe oder Werkzeug als auf eine Präzisionsgrenze. Abschnitt 6.4 führt die drei in Betracht kommenden Erklärungen auf. Solange die Protokolle nicht ausgewertet sind, wird C2 nicht als Beleg für eine Modellgrenze geführt.

Anzumerken ist ferner, dass C2 eine blickpunktbezogene Referenz enthält, da „nearest to the camera“ auf die Position des Betrachters Bezug nimmt. Die Aussage, blickpunktabhängige Referenzen seien in dieser Arbeit nicht ausgewertet worden, trifft daher nicht uneingeschränkt zu; sie gilt für das eigens dafür vorgesehene und ausgeschlossene Szenario C3, nicht für C2.

Der Mechanismus bleibt eine Hypothese

Die Ergebnisse zeigen, dass die naive Kombination beider Schichten den Zugriff auf die visuelle Beschreibung in bestimmten Fällen verliert. Warum das geschieht, konnte nicht geklärt werden. Drei Erklärungen sind mit den Daten verträglich und werden in dieser Arbeit durchgängig gemeinsam geführt: die Formulierung des Befehls, die visuelle Eindeutigkeit des Zielobjekts und ein Reihenfolgeeffekt bei der Objektwahl. Sie lassen sich in diesem Aufbau nicht voneinander trennen. Die zunächst formulierte Deutung, die exakte strukturelle Information verdränge die unschärfere Beschreibung, ist eine von mehreren Möglichkeiten und kein nachgewiesener Mechanismus.

Sie ähnelt Beobachtungen aus der Literatur zur Übergewichtung textueller gegenüber visueller Information in multimodalen Modellen [1, 2]. Diese Ähnlichkeit ist jedoch nur eine Analogie. Die zitierten Arbeiten betrachten die Konkurrenz von Bild und Text innerhalb eines Modells, während hier zwei Textquellen im Kontext eines Sprachmodells konkurrieren (Abschnitt 2.4). Sie stützen die Hypothese daher nicht, sondern zeigen nur, dass ein strukturell verwandtes Phänomen anderswo beschrieben ist.

Reichweite der Ergebnisse

Alle Befunde beruhen auf einem einzelnen lokalen Modellpaar und auf synthetischen Szenen aus einfachen Grundkörpern. Sie sind innerhalb dieses Rahmens repliziert und intern konsistent. Eine Übertragung auf größere oder anders gebaute Modelle wurde nicht geprüft. Ebenso wenig lassen sich die Ergebnisse ohne Weiteres auf reale, komplexe Szenen übertragen. Für die Ergebnisse zur zweiten Forschungsfrage kommt hinzu, dass die beste Variante am Szenarioset selbst entwickelt wurde, sodass ihre Überlegenheit für dieses Set gezeigt, für ungesehene Formulierungen aber offen ist. Die Aussagekraft der Arbeit liegt damit in der kontrollierten Isolation der Repräsentationskompetenzen und nicht in einer allgemeinen Gültigkeit über Modelle und Szenen hinweg.

Kapitel 7

Zusammenfassung und Ausblick

7.1 Zusammenfassung

Die Arbeit ist von einer einfachen, aber folgenreichen Frage ausgegangen. In welcher Form sollte einem lokal betriebenen KI-Agenten eine 3D-Szene bereitgestellt werden, damit er sie natürlichsprachlich manipulieren kann? Zwei Wege standen einander gegenüber, ein struktureller und ein visueller, mit jeweils eigenen Stärken und einem Bereich, den der andere Weg nicht abdeckt.

Um die Frage zu beantworten, wurde ein prototypisches System entwickelt, das dieselbe Szene in drei Repräsentationsformen bereitstellt, strukturell, visuell und hybrid, und sie über ein gemeinsames Interface manipulierbar macht. Diese Formen wurden unter gleichen Bedingungen an kontrolliert aufgebauten Szenarien gegeneinander gemessen. Der Erfolg wurde dabei aus dem tatsächlichen Zustand der Szene bestimmt und jede Messung mehrfach wiederholt.

Der Vergleich ergab kein pauschales Bild, sondern eine referenztypabhängige Kompetenz. Keine Einzelform ist über alle Aufgaben hinweg überlegen. Die strukturelle Form trägt Referenzen, die sich aus Daten ableiten lassen, und ist als einzige in der Lage, ein im Bild verdecktes Objekt anzusprechen. Die visuelle Form trägt Referenzen, die nur über das Aussehen bestimmbar sind, etwa ein Oberflächenmuster. Beide Formen besitzen damit einen exklusiven Zuständigkeitsbereich, den die jeweils andere nicht abdecken kann.

Die naheliegende Erwartung, eine hybride Form vereine ohne Weiteres die Stärken beider, hielt der Prüfung nicht stand. Die naive Kombination erbte den strukturellen Vorteil, den visuellen jedoch nicht zuverlässig. Erst als die Zuständigkeiten der beiden Schichten ausdrücklich getrennt wurden, wirkten sie zusammen. Diese kompetenzgetrennte Variante erreichte in der rein perzeptuellen Kategorie nahezu die Leistung der reinen Bildvariante, mit 19,7 von 20 Punkten gegenüber 10,7 der naiven Kombination, und behielt zugleich die Stärke der strukturellen Form. Eine bloße Priorisierung einer Schicht verschob das Gewicht dagegen nur, statt beide Schichten zu integrieren. Dieser Befund gilt für das untersuchte Szenarioset, an dem die kompetenzgetrennte Variante zugleich entwickelt wurde; Abschnitt 7.4 ordnet das ein.

Schließlich wurde diese Variante in die immersive Zielumgebung übertragen. Ein Demonstrator zeigt, dass die Kette von einem Befehl bis zur sichtbaren Manipulation in der Brille funktioniert, wobei die Modelle selbst gehostet auf einem Arbeitsplatzrechner laufen und nicht auf dem Endgerät. Dokumentiert ist per Aufzeichnung die Menüfassung; die ergänzte Spracheingabe ist umgesetzt, aber nicht per Video belegt.

7.2 Beantwortung der Forschungsfragen

Die beiden in Kapitel 1 gestellten Forschungsfragen lassen sich nun direkt beantworten.

Erste Forschungsfrage

Welchen Einfluss hat die Form der Szenenrepräsentation, strukturell, visuell oder hybrid, auf den Ausführungserfolg der natürlichsprachlichen Szenenmanipulation durch einen lokal betriebenen Agenten, und zwar aufgeschlüsselt nach der Art der sprachlichen Referenz?

Die Repräsentationsform hat einen erheblichen und referenztypabhängigen Einfluss. Es gibt keine Form, die über alle Aufgaben hinweg überlegen ist. Der Erfolg hängt davon ab, wie im Befehl auf ein Objekt verwiesen wird. Referenzen, deren Merkmal in den Daten kodiert ist, sowie Referenzen auf verdeckte Objekte werden von der strukturellen Form getragen. Referenzen auf rein visuelle Eigenschaften werden ausschließlich von der visuellen Form getragen. Beide Formen besitzen damit einen exklusiven Zuständigkeitsbereich, den die jeweils andere nicht abdecken kann. Die naive hybride Form vereint diese Stärken nicht von selbst. Sie übernimmt den strukturellen Vorteil, erbt den visuellen jedoch nicht zuverlässig. Das spricht gegen die Erwartung, eine Kombination sei stets mindestens so gut wie die jeweils bessere Einzelform. Für D1, wo dieser Bruch am deutlichsten auftritt, bleibt allerdings ein Reihenfolgeeffekt bei der Objektwahl als gleichrangige Erklärung offen, sodass der Befund die Erwartung in Frage stellt, aber nicht widerlegt.

Zweite Forschungsfrage

Lässt sich das Zusammenspiel der strukturellen und der visuellen Schicht allein durch die Gestaltung der Instruktion so steuern, dass die hybride Repräsentation die Stärken beider Schichten vereint?

Auf dem untersuchten Szenarioset lautet die Antwort ja: Das Zusammenspiel lässt sich allein über die Gestaltung der Instruktion steuern, ohne die Modelle zu verändern. Entscheidend ist dabei die Art der Steuerung. Eine bloße Priorisierung einer Schicht verschiebt das Gewicht nur und tauscht eine Kompetenz gegen eine andere. Erst die ausdrückliche Trennung der Zuständigkeiten, bei der die visuelle Beschreibung bestimmt, welches Objekt gemeint ist, und die strukturelle Schicht alle geometrischen Werte liefert, führt beide Schichten zusammen. Diese Variante ist über die gewerteten Aufgabenbereiche hinweg die beste oder eine der besten.

Zur Einordnung dieses Befundes gehört die Art seiner Entstehung, und sie begrenzt seine Reichweite deutlich. Die kompetenzgetrennte Variante wurde nicht vorab entworfen, sondern iterativ aus der Analyse der naiven und der priorisierenden Variante entwickelt, und zwar in Kenntnis der Ergebnisse auf genau dem Szenarioset, an dem sie anschließend gemessen wurde. Ihre Instruktion enthält mit „striped“ und „most salient“ zwei Formulierungen, die wörtlich in den Testbefehlen vorkommen. Gezeigt ist damit, dass sich die Kombination beider Schichten auf diesem Szenarioset durch die Instruktion erheblich verbessern lässt. Nicht gezeigt ist, dass dieser Vorteil auf ungesehene Formulierungen übergeht. Hinzu kommt, dass sich die hybriden Varianten neben der Instruktion auch in der Reihenfolge der beiden Schichten unterscheiden, sodass der Beitrag beider Faktoren nicht getrennt ist. Die Antwort auf die zweite Forschungsfrage ist deshalb ein belastbarer Befund für diesen Aufbau und eine offene Frage darüber hinaus.

7.3 Wissenschaftlicher Beitrag

Über die konkreten Ergebnisse hinaus leistet die Arbeit drei Beiträge, deren Reichweite jeweils bewusst vorsichtig eingeordnet wird.

Der erste Beitrag ist inhaltlicher Art. Die Arbeit zeigt an einem kontrollierten Fall, dass die Verbindung struktureller und visueller Information kein Automatismus ist. Die bloße Verfügbarkeit beider

Schichten genügt nicht, damit ihre Stärken zusammenwirken. Ob eine Kombination ihre Bestandteile ergänzt oder ob eine Informationsart die andere verdrängt, hängt von der Gestaltung ihrer Zusammenführung ab. Dieser Befund ist an einem einzelnen Modellpaar, an dreizehn Szenarien und in einer zweistufigen Pipeline gewonnen und wird nicht als allgemein gültig behauptet. Er legt jedoch nahe, dass die Fusion mehrerer Informationsquellen auch in anderen Agenten als Gestaltungsproblem und nicht als selbstverständliches Mehr an Information zu behandeln ist.

Der zweite Beitrag ist methodischer Art. Die Arbeit führt eine nach der Art der sprachlichen Referenz aufgeschlüsselte Betrachtung ein, die den Erfolg nicht als einen Gesamtwert, sondern getrennt nach Referenztypen misst. Erst diese Aufschlüsselung macht die exklusiven Zuständigkeiten der Repräsentationen sichtbar, die ein pauschaler Vergleich verdeckt hätte. Das Schema ist nicht an das konkrete System gebunden und dürfte sich auf ähnliche Vergleiche übertragen lassen.

Der dritte Beitrag ist praktischer Art. Die Arbeit zeigt, dass sich die gesamte Verarbeitungskette aus 3D-Umgebung, Vermittlungsschicht, Agent und zwei gleichzeitig betriebenen, selbst gehosteten Modellen umsetzen und bis in die immersive Zielumgebung betreiben lässt. Damit ist belegt, dass ein solcher Agent für diesen Anwendungsfall grundsätzlich machbar ist, wobei die Modelle auf einem Arbeitsplatzrechner und nicht auf dem Endgerät rechnen. Über die Machbarkeit hinaus wird kein Anspruch auf Produktreife erhoben, und der Demonstrator wurde nicht eigenständig evaluiert.

7.4 Grenzen der Arbeit

Die Aussagekraft der Ergebnisse ist an mehrere Grenzen gebunden. Ein Teil dieser Grenzen wurde bereits in Abschnitt 6.6 auf methodischer Ebene behandelt. Hier werden sie auf der Ebene der gesamten Arbeit gebündelt und danach geordnet, ob sie den Untersuchungsgegenstand, die Übertragbarkeit oder die Erklärungs- und Messtiefe betreffen.

Grenzen des Untersuchungsgegenstands

Der Untersuchungsgegenstand wurde bewusst eng gefasst. Befehle, die mehrere Manipulationen zugleich verlangen, wurden nicht systematisch untersucht. Erschwerend kommt hinzu, dass die allen Varianten gemeinsame Grundinstruktion genau einen Manipulationsaufruf verlangt, während zwei Szenarien ihrem Soll-Ergebnis nach mehrere Objekte betreffen. Für das Szenario E2 führt dieser Widerspruch dazu, dass ein Erfolg nur durch Missachtung der Instruktion zustande kommen kann; die Zelle wurde deshalb nicht gewertet, sodass sich der strukturell-exklusive Befund am Ende auf ein einziges Szenario stützt. Warum das zweite betroffene Szenario allen hybriden Varianten dennoch gelingt, blieb ungeklärt.

Die Menge der Operationen blieb auf das Erzeugen, Verschieben und Entfernen beschränkt, andere Operationen wie das Drehen oder Skalieren zur Laufzeit wurden nicht betrachtet. Die Befehle waren durchgehend klar formuliert, sodass offen bleibt, wie die Repräsentationen mit mehrdeutigen oder umgangssprachlichen Formulierungen umgehen. Blickpunktabhängige Referenzen wurden nicht systematisch untersucht: Das eigens dafür vorgesehene Szenario C3 musste ausgeschlossen werden, weil die achsenparallele Kameraausrichtung die Referenz mehrdeutig machte. Ganz ohne solche Bezüge blieb die Auswertung allerdings nicht, denn das Szenario C2 nimmt mit „nearest to the camera“ auf die Position des Betrachters Bezug. Gerade dieses Szenario gehört zu den ungeklärten Fällen.

Schließlich wurde der Demonstrator nicht systematisch evaluiert. Er belegt die Machbarkeit der Kette in der Zielumgebung, liefert aber keine eigenen Erfolgsraten. Belegt ist per Aufzeichnung zudem nur die Menüfassung, nicht die später ergänzte Spracheingabe.

Grenzen der Übertragbarkeit

Alle Ergebnisse beruhen auf einem einzelnen lokalen Modellpaar. Ob sie sich auf größere oder anders gebaute Modelle übertragen lassen, wurde nicht geprüft. Die Szenen waren synthetisch und bewusst

einfach gehalten. Eine Übertragung auf reale, komplexe Szenen ist damit nicht belegt, und auch das Verhalten der Repräsentationen bei wachsender Objektzahl bleibt offen.

Eine besondere Grenze betrifft die beste gefundene Variante. Sie wurde an demselben Szenarioset entwickelt, an dem sie anschließend gemessen wurde, und ihre Instruktion nennt wörtlich zwei Wörter aus den Testbefehlen. Ihre Überlegenheit ist damit für dieses Szenarioset gezeigt, ihre Generalisierung auf ungesehene Formulierungen ist offen. Das betrifft nicht nur diese eine Variante, sondern die Reichweite der Antwort auf die zweite Forschungsfrage insgesamt.

Hinzu kommt, dass die Ergebnisse architektonisch an eine zweistufige Pipeline gebunden sind. Das entscheidende Sprachmodell erhält kein Bild, sondern eine vom Sprach-Bild-Modell erzeugte Beschreibung. Was hier als Konkurrenz von Struktur und Bild erscheint, ist genauer die Konkurrenz einer exakten Datenstruktur mit einer unscharfen sprachlichen Beschreibung. Für ein einzelnes multimodales Modell, dem Bild und Daten unmittelbar vorliegen, sind diese Befunde nicht ohne Weiteres gültig.

Grenzen der Erklärung und Messung

Der Mechanismus hinter der zentralen Beobachtung bleibt eine Hypothese, genauer: eine von dreien. Warum die naive Kombination den Zugriff auf die visuelle Beschreibung in bestimmten Fällen verliert, ließ sich nicht isolieren. Mit den Daten verträglich sind die Formulierung des Befehls, die visuelle Eindeutigkeit des Zielobjekts und ein Reihenfolgeeffekt bei der Objektwahl, bei dem das erstgenannte Objekt unabhängig von der Referenz gewählt wird. Der letzte Punkt wiegt besonders schwer, weil er nicht nur den Mechanismus, sondern den Befund selbst betrifft: Im tragenden Szenario ist das Zielobjekt das zweite von zwei Objekten, und das vollständige Scheitern der strukturellen Variante passt ebenso gut zu einer Positionspräferenz wie zu einer Verdrängung. Eine Messung mit vertauschter Objektreihenfolge, die zwischen beiden entscheiden würde, liegt nicht vor.

Ebenso wenig getrennt sind Instruktion und Reihenfolge der Schichten im Kontext, da die hybriden Varianten beides zugleich variieren.

Eine weitere Grenze liegt im Modell selbst, jedoch nicht überall dort, wo das zunächst so schien. Für die Aufgabe mit exakter metrischer Zielvorgabe ist die Deutung als Präzisionsgrenze tragfähig, da alle Varianten dort graduell und streuend scheitern. Für das Szenario mit dem kameranächsten Objekt ist sie es nicht: Ein Wert von exakt null bei gleichzeitig perfekter Lösung einer strukturell vergleichbaren Aufgabe deutet eher auf einen Fehler in Szenario, Soll-Vorgabe oder Werkzeug hin. Dieser Fall bleibt ungeklärt und wird nicht als Modellgrenze geführt.

Mehrere Entscheidungen über den Zuschnitt der Auswertung fielen nach Sichtung der Ergebnisse, namentlich der Ausschluss eines Szenarios, die Neumessung eines zweiten und die Einstufung eines dritten als nicht wertbar. Alle drei sind inhaltlich begründet, waren aber nicht vorab festgelegt.

Wie häufig die Selbstauskunft des Agenten vom tatsächlichen Folgezustand abwich, wurde nur qualitativ beobachtet und nicht quantifiziert. Für die Erfolgsmessung ist dies unerheblich, da sie ohnehin aus dem Folgezustand erfolgt, für eine genaue Charakterisierung des Modellverhaltens fehlt jedoch eine belastbare Zahl.

Zur Absicherung der Ergebnisse wurden die je 30 Läufe einer Zelle zusammengefasst und mit Wilson-Konfidenzintervallen und exakten Tests nach Fisher ausgewertet. Diese Zahlen sichern die Unterschiede innerhalb einer Zelle ab, nicht jedoch die Frage, ob eine Zelle für ihren Referenztyp repräsentativ ist. Dort liegt die größere Unsicherheit, denn die zentralen Kategorien umfassen nur zwei Szenarien, nach dem Ausschluss von E2 im strukturell-exklusiven Fall sogar nur eines. Innerhalb einer Zelle sind die Zahlen dagegen belastbar: Das Sprachmodell wurde mit einer Temperatur von 0,8 dekodiert, sodass die 30 Läufe weitgehend unabhängig sind und die durchweg konstanten Zellen trotz und nicht wegen der Dekodierung zustande kamen.

Drei kleinere Einschränkungen des Aufbaus seien abschließend genannt. Die Sichtbarkeitsprüfung arbeitet mit einem einzelnen Sichtstrahl und kennt daher keine Teilverdeckung. Der Schutz gegen unmit-

telbar wiederholte, identische Werkzeugaufrufe würde auch eine vom Befehl geforderte Wiederholung blockieren. Und die Erfolgstoleranz wurde für diesen Aufbau festgelegt, ohne dass geprüft wurde, wie empfindlich die metrischen Szenarien auf diese Wahl reagieren.

7.5 Ausblick

Aus der Arbeit ergeben sich mehrere Ansatzpunkte für weitere Untersuchungen. Sie folgen demselben roten Faden und lassen sich in unmittelbare Fortführungen, wissenschaftliche Vertiefungen und eine Anwendungsperspektive gliedern.

Die dringlichste Fortführung betrifft die Frage, ob die beste gefundene Variante ihren Vorteil auch außerhalb des Szenariosets behält, an dem sie entwickelt wurde. Zwei Prüfungen bieten sich dafür an, und sie ergänzen einander. Die erste ist eine Messung an neuen, zuvor ungesesehenen Szenarien, insbesondere mit anderen perzeptuellen Eigenschaften als einem Streifenmuster und mit anderer sprachlicher Formulierung derselben Referenz. Die zweite ist eine Variante der Instruktion, die keine szenariospezifischen Wörter mehr enthält, also ohne „striped“ und „most salient“ auskommt und die Zuständigkeitstrennung rein abstrakt formuliert. Erst wenn eine so formulierte Instruktion auf ungesesehenen Szenarien denselben Vorteil zeigt, ließe sich von einem übertragbaren Gestaltungsprinzip sprechen statt von einer für diesen Testsatz wirksamen Formulierung.

Unabhängig von der inhaltlichen Ausrichtung sollte eine Wiederholung mehr mitschreiben als diese Arbeit. Die abgesetzten Werkzeugaufrufe mit ihren Argumenten und die erreichten Endpositionen kosten keinen zusätzlichen Messaufwand, hätten hier aber mehrere offene Deutungen entschieden, etwa ob die metrischen Szenarien knapp oder grundsätzlich scheitern und welches Objekt der Agent in den ungeklärten Fällen tatsächlich gewählt hat.

Ebenso vorrangig ist eine Messung, die den in der Kategorie D verbliebenen Reihenfolgeeffekt ausschließt. Es genügte, die tragenden Szenarien mit vertauschter Objektreihenfolge zu wiederholen und zusätzlich die Reihenfolge der beiden Schichten im Kontext unabhängig von der Instruktion zu variieren. Beides ist ohne neuen Aufbau möglich und würde die zentrale Deutung der Arbeit entweder absichern oder korrigieren.

Eine weitere Fortführung betrifft die Effizienz. Der Abruf der visuellen Schicht ist erkennbar langsamer als der des strukturellen Zustands, da er einen zusätzlichen Inferenzschritt des Sprach-Bild-Modells erfordert. Wie groß dieser Unterschied ausfällt, wurde in dieser Arbeit nicht gemessen, sodass über seine Größenordnung nichts ausgesagt werden kann. Eine systematische Erhebung von Latenz, Schrittzahl und Rechenaufwand würde den bislang nur qualitativ bekannten Trade-off zwischen den Repräsentationen belastbar machen und ist gerade für eine interaktive immersive Anwendung von Bedeutung. Ebenso naheliegend ist die Untersuchung der Szenenkomplexität. Mit wachsender Objektzahl dürfte insbesondere die visuelle Schicht an Grenzen stoßen, da die Markierung vieler Objekte unübersichtlich wird. Weiterhin ließe sich die Menge der Operationen erweitern, etwa um Drehungen und Skalierungen sowie um Befehle, die mehrere Manipulationen zugleich verlangen, deren eigene Schwierigkeit sich in dieser Arbeit bereits angedeutet hat. Schließlich sind blickpunktabhängige Referenzen zu nennen, die sich auf die Sicht des Betrachters beziehen und gerade für immersive Umgebungen charakteristisch sind. Dass solche observer-zentrischen Bezüge ohne einen expliziten Blickpunkt mehrdeutig sind und von einer ausdrücklichen Repräsentation des Blickwinkels profitieren, zeigt sich in jüngeren Arbeiten zur blickpunktabhängigen Segmentierung [16]. Eine saubere Behandlung dieses Referenztyps wäre eine lohnende Erweiterung der hier verwendeten Taxonomie.

Auf wissenschaftlicher Ebene bieten sich zwei Vertiefungen an. Zum einen ließe sich prüfen, ob die gefundenen Kompetenzprofile und die Grenzen der naiven Kombination auch für größere oder anders gebaute Modelle gelten, oder ob eine größere Modellkapazität den beobachteten Bruch von selbst auflöst. Zum anderen könnte ein gezieltes Experiment die drei offenen Erklärungen voneinander trennen, indem es die Formulierung des Befehls, die visuelle Eindeutigkeit des Zielobjekts und die Reihenfolge der Objekte unabhängig voneinander variiert. Erst ein solcher Aufbau könnte aus der bislang offe-

nen Deutung einen belegten Mechanismus machen. Aufschlussreich wäre schließlich ein Vergleich der zweistufigen Pipeline mit einem einzelnen multimodalen Modell, dem Bild und strukturelle Daten unmittelbar vorliegen; er würde zeigen, ob der hier beobachtete Effekt an der Architektur der Pipeline hängt oder unabhängig von ihr auftritt. Darüber hinaus stellt sich die Frage, ob das Prinzip der Kompetenztrennung über die Szenenmanipulation hinaus auf andere multimodale Aufgaben übertragbar ist.

Aus Anwendungssicht bleibt eine Erprobung mit echten Nutzern offen. Die vorliegende Bewertung ist rein systembasiert. Eine qualitative Nutzerstudie im Demonstrator könnte zeigen, wie Menschen die sprachgesteuerte Manipulation in der immersiven Umgebung tatsächlich erleben, und wäre ein eigenständiger nächster Schritt über diese Arbeit hinaus.

Glossar

Folgezustand Tatsächlicher Zustand der Szene nach einer Manipulation, aus dem der Ausführungserfolg unabhängig von der Selbstauskunft des Agenten bestimmt wird

Grounding Auflösung einer sprachlichen Referenz auf ein konkretes Szenenobjekt

id-Substrat Geteiltes Interface, über das alle Repräsentationsvarianten Objekte anhand derselben ids ansprechen

kompetenzgetrennte hybride Repräsentation Hybride Repräsentation mit expliziter Aufgabenteilung: die visuelle Beschreibung bestimmt, welches Objekt gemeint ist, die strukturelle Schicht liefert alle numerischen Werte

lokaler Betrieb In dieser Arbeit: selbst gehosteter Betrieb der Modelle auf eigener Hardware ohne Nutzung eines Cloud-Dienstes. Der Begriff besagt nicht, dass die Modelle auf dem Endgerät selbst rechnen; im Demonstrator laufen sie auf einem Arbeitsplatzrechner im Institutsnetz, den die Brille über ein virtuelles privates Netz erreicht

naive hybride Repräsentation Kombination aus struktureller und visueller Schicht ohne verbindliche Instruktion zur Zuständigkeit der beiden Quellen

priorisierende hybride Repräsentation Hybride Repräsentation mit vorangestellter visueller Beschreibung, die als maßgeblich für das Aussehen deklariert wird

Referenztyp Art, in der ein natürlichsprachlicher Befehl auf ein Objekt verweist, etwa über eine Kennung, ein Attribut, eine räumliche Relation, eine rein sichtbare Eigenschaft oder ein verdecktes Objekt

strukturelle Repräsentation Bereitstellung der Szene als exakte Laufzeitdaten der Engine (Objekt-ids, Typen, Positionen, Größen, Farben, Kamerapose) in textueller Form, hier als JSON

visuelle Repräsentation Bereitstellung der Szene über eine von einem Sprach-Bild-Modell erzeugte natürlichsprachliche Beschreibung der gerenderten, mit Set-of-Mark-Markern versehenen Ansicht. Das Sprachmodell erhält die Beschreibung, nicht das Bild

Literaturverzeichnis

- [1] A. Deng, T. Cao, Z. Chen, und B. Hooi, „Words or Vision: Do Vision-Language Models Have Blind Faith in Text?” in *2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2025, S. 3867–3876, Abgerufen am 03.09.2026. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/11092720> (Zitiert auf Seiten 2, 7, 13 und 47.)
- [2] H. Wu, M. Tang, X. Zheng, und H. Jiang. (2025) When Language Overrides: Revealing Text Dominance in Multimodal Large Language Models. Abgerufen am 27.08.2026. [Online]. Available: <http://arxiv.org/abs/2508.10552> (Zitiert auf Seiten 2, 7, 13 und 47.)
- [3] Hugging Face. (2024) Smolagents. [Online]. Available: <https://github.com/huggingface/smolagents> (Zitiert auf Seiten 5 und 19.)
- [4] Anthropic. Model Context Protocol. [Online]. Available: <https://modelcontextprotocol.io> (Zitiert auf Seiten 5 und 16.)
- [5] J. Yang, H. Zhang, F. Li, X. Zou, C. Li, und J. Gao. (2023) Set-of-Mark Prompting Unleashes Extraordinary Visual Grounding in GPT-4V. Abgerufen am 10.09.2026. [Online]. Available: <http://arxiv.org/abs/2310.11441> (Zitiert auf Seiten 5, 13 und 18.)
- [6] P. Achlioptas, A. Abdelreheem, F. Xia, M. Elhoseiny, und L. Guibas, „ReferIt3D: Neural Listeners for Fine-Grained 3D Object Identification in Real-World Scenes,” in *Computer Vision – ECCV 2020*, A. Vedaldi, H. Bischof, T. Brox, und J.-M. Frahm, Hrsgg. Springer International Publishing, 2020, S. 422–440. (Zitiert auf Seiten 6, 31 und 33.)
- [7] D. Z. Chen, A. X. Chang, und M. Nießner, „ScanRefer: 3D Object Localization in RGB-D Scans Using Natural Language,” in *Computer Vision – ECCV 2020*, A. Vedaldi, H. Bischof, T. Brox, und J.-M. Frahm, Hrsgg. Springer International Publishing, 2020, S. 202–221. (Zitiert auf Seiten 6, 31 und 33.)
- [8] F. De La Torre, C. M. Fang, H. Huang, A. Banburski-Fahey, J. Amores Fernandez, und J. Lanier, „LLMR: Real-time Prompting of Interactive Worlds Using Large Language Models,” in *Proceedings of the 2024 CHI Conference on Human Factors in Computing Systems*, Serie CHI ’24. Association for Computing Machinery, 2024, S. 1–22, Abgerufen am 10.09.2026. [Online]. Available: <https://dl.acm.org/doi/10.1145/3613904.3642579> (Zitiert auf Seite 6.)
- [9] X. E. Wang, Z. P. T. Sin, Y. Jia, D. Archer, W. H. Y. Fong, Q. Li, und C. Li, „Can You Move These Over There? Exploring an LLM-based VR Mover to Support Natural Multi-object Manipulation,” in *Proceedings of the 38th Annual ACM Symposium on User Interface Software and Technology*, Serie UIST ’25. Association for Computing Machinery, 2025, S. 1–18, Abgerufen am 10.09.2026. [Online]. Available: <https://dl.acm.org/doi/10.1145/3746059.3747673> (Zitiert auf Seite 6.)
- [10] R. Li, S. Li, L. Kong, X. Yang, und J. Liang. (2025) SeeGround: See and Ground for Zero-Shot Open-Vocabulary 3D Visual Grounding. Abgerufen am 10.09.2026. [Online]. Available: <http://arxiv.org/abs/2412.04383> (Zitiert auf Seite 6.)
- [11] X. Sun, X. Zhang, B. Crowe, D. Albin, und C. Heckman. (2026) SceneGraphGrounder: Zero-Shot 3D Visual Grounding via Structured Scene Graph Matching. Abgerufen am 27.08.2026. [Online]. Available: <http://arxiv.org/abs/2605.21788> (Zitiert auf Seite 6.)
- [12] M. Li, S. Zhao, Q. Wang, K. Wang, Y. Zhou, S. Srivastava, C. Gokmen, T. Lee, L. E. Li, R. Zhang, W. Liu, P. Liang, L. Fei-Fei, J. Mao, und J. Wu. (2025) Embodied Agent Interface: Benchmarking LLMs for Embodied Decision Making. Abgerufen am 10.09.2026. [Online]. Available: <http://arxiv.org/abs/2410.07166> (Zitiert auf Seite 6.)

- [13] Z. Song, X. Lin, Q. Huang, S. Qin, G. Wang, und L. Lin. (2026) SRI-Bench: Challenging VLMs' Spatial Intelligence through Complex Reasoning Tasks. Abgerufen am 27.08.2026. [Online]. Available: <http://arxiv.org/abs/2506.14512> (Zitiert auf Seite 6.)
- [14] Z. Wu, Z. Wang, X. Xu, J. Lu, und H. Yan. (2023) Embodied Task Planning with Large Language Models. Abgerufen am 11.09.2026. [Online]. Available: <http://arxiv.org/abs/2307.01848> (Zitiert auf Seite 7.)
- [15] D. C. Dinh, K. Le-Duc, F. Draye, C. Ngo, T. J. Zhang, B. Schölkopf, und Z. Jin. (2026) PruneGround: Plug-and-play Spatial Pruning for 3D Visual Grounding. Abgerufen am 27.08.2026. [Online]. Available: <http://arxiv.org/abs/2606.31148> (Zitiert auf Seite 7.)
- [16] A. Nanri, K. Reichard, M. Kiray, F. Tombari, B. Busam, und A. Kanezaki. (2026) 3D Segmentation Using Viewpoint-Dependent Spatial Relationships. Abgerufen am 27.08.2026. [Online]. Available: <http://arxiv.org/abs/2605.15708> (Zitiert auf Seite 52.)

Erklärung: Verwendung von KI-Werkzeugen

Im Rahmen der Erstellung dieser Arbeit wurde das KI-Werkzeug Claude (Anthropic) eingesetzt. Die Nutzung wird im Folgenden gemäß der KI-Leitlinie der Technischen Hochschule Nürnberg Georg Simon Ohm offengelegt.

- Grobe Literaturrecherche mit anschließender manueller Überarbeitung und Verifikation der Quellen.
- Umformulierung von selbst verfasstem Text.
- Unterstützung bei der Codeerstellung im Implementierungsteil.

Sämtliche von dem Werkzeug erzeugten Inhalte wurden eigenständig geprüft, überarbeitet und inhaltlich verantwortet. Die Verantwortung für alle Aussagen, Ergebnisse und Schlussfolgerungen dieser Arbeit liegt vollständig beim Verfasser. Die reine Rechtschreib- und Grammatikprüfung ist gemäß Leitlinie nicht dokumentationspflichtig und daher nicht aufgeführt.

Anhang A

Begleitmaterial

A.1 Demonstrationsvideo

Als Begleitmaterial zu dieser Arbeit steht eine Videoaufzeichnung des Demonstrators zur Verfügung. Sie zeigt eine frühe Ausbaustufe, in der die Szene über ein Menü in der virtuellen Umgebung manipuliert wird, das vordefinierte Befehle bereitstellt. Das Video ist unter der folgenden Adresse abrufbar.

`https://git.informatik.fh-nuernberg.de/jobboerse/forschung/bachelorarbeiten/
bachelorarbeit-sandro-jaeger/-/blob/fe68f112f06df9da38eff687fd8df8460061186c/BA_VR_
Demo_with_menu.mp4`



Abbildung: QR-Code zur Videoaufzeichnung.